





ΟΙΚΟΝΟΜΕΤΡΙΑ

Αρχές και Εφαρμογές



5^η Έκδοση

Damodar N. Gujarati
Dawn C. Porter

Επιστημονική Επιμέλεια
Περσεφόνη Τσαλίκη
Αναπλ. Καθηγήτρια Α.Π.Θ.



ΕΚΔΟΣΕΙΣ ΤΖΙΟΛΑ

Κεφάλαιο 1

Η Φύση της Ανάλυσης Παλινδρόμησης

Όπως αναφέρεται στην Εισαγωγή, η παλινδρόμηση αποτελεί ένα βασικό εργαλείο της οικονομετρίας και σε αυτό το κεφάλαιο εξετάζουμε πολύ σύντομα τη φύση αυτού του εργαλείου.

1.1 Ιστορική Προέλευση του Όρου Παλινδρόμηση

Ο όρος παλινδρόμηση εισήχθη από τον Francis Galton. Σε ένα πολύ γνωστό άρθρο του, ο Galton διαπίστωσε ότι, αν και υπήρχε μία τάση οι ψηλοί γονείς να έχουν ψηλά παιδιά και οι κοντοί γονείς να έχουν κοντά παιδιά, το μέσο ύψος των παιδιών που γεννιόνταν από γονείς ενός ορισμένου ύψους έτεινε να μετακινείται ή να «παλινδρομεί» προς το μέσο ύψος του συνολικού πληθυσμού.¹ Με άλλα λόγια, το ύψος των παιδιών των ασυνήθιστα ψηλών ή ασυνήθιστα κοντών γονέων τείνει να κινείται προς το μέσο ύψος του πληθυσμού. Ο νόμος της καθολικής παλινδρόμησης του Galton επιβεβαιώθηκε από τον φίλο του Karl Pearson, ο οποίος συνέλεξε περισσότερες από χίλιες εγγραφές αναφορικά με τα ύψη μελών διαφόρων οικογενειών.² Βρήκε ότι το μέσο ύψος των γιων μίας ομάδας ψηλών πατέρων ήταν χαμηλότερο από το ύψος των πατέρων και το μέσο ύψος των γιων μίας ομάδας κοντών πατέρων ήταν υψηλότερο από το ύψος των πατέρων τους, με αποτέλεσμα οι ψηλοί και οι κοντοί γιοι να «παλινδρομούν» προς το μέσο ύψος όλων των ανδρών. Σύμφωνα με τα λόγια του Galton, αυτό ήταν «παλινδρόμηση προς τη μετριότητα.»

1.2 Η Σύγχρονη Ερμηνεία της Παλινδρόμησης

Ωστόσο, η σύγχρονη ερμηνεία της παλινδρόμησης είναι αρκετά διαφορετική. Σε γενικές γραμμές, μπορούμε να πούμε

Η ανάλυση παλινδρόμησης ασχολείται με τη μελέτη της εξάρτησης μίας μεταβλητής, της εξαρτημένης μεταβλητής, από μία ή από περισσότερες άλλες μεταβλητές, τις ερμηνευτικές μεταβλητές, με σκοπό την εκτίμηση ή/και την πρόβλεψη της τιμής του (πληθυσμιακού) μέσου όρου σε όρους των γνωστών ή σταθερών τιμών (σε επαναλαμβανόμενη δειγματοληψία) των τελευταίων.

Η πλήρης σημασία αυτής της άποψης αναφορικά με την ανάλυση παλινδρόμησης θα καταστεί σαφέστερη καθώς προχωρούμε στο παρόν βιβλίο, όμως μερικά απλά παραδείγματα θα καταστήσουν τη βασική ιδέα αρκετά σαφή.


Παραδείγματα

1. Ας επανεξετάσουμε το νόμο της καθολικής παλινδρόμησης του Galton. Ο Galton ενδιαφερόταν να μάθει γιατί υπήρχε μία σταθερότητα στην κατανομή των υψών ενός πληθυσμού. Όμως το ενδιαφέρον μας δεν εστιάζεται σε αυτή την εξήγηση αλλά κυρίως στο να μάθουμε πώς μεταβάλλεται το μέσο ύψος των γιων, δοθέντος του ύψους των πατέρων. Με άλλα λόγια, το ενδιαφέρον μας είναι η πρόβλε-

¹Francis Galton, "Family Likeness in Stature," *Proceedings of Royal Society, London*, vol. 40, 1886, σσ. 42–72.

²K. Pearson and A. Lee, "On the Laws of Inheritance," *Biometrika*, vol. 2, Nov. 1903, σσ. 357–462.

ψη του μέσου ύψους των γιων γνωρίζοντας το ύψος των πατέρων τους. Για να δείτε πώς μπορεί να γίνει αυτό, μελετήστε το Διάγραμμα 1.1, το οποίο είναι ένα **διάγραμμα διασποράς** (scatter diagram – scattergram).




ΔΙΑΓΡΑΜΜΑ 1.1 Υποθετική κατανομή υψών γιων που αντιστοιχούν σε συγκεκριμένα ύψη πατέρων.

Το διάγραμμα αυτό δείχνει την κατανομή των υψών των γιων σε έναν υποθετικό πληθυσμό που αντιστοιχούν σε συγκεκριμένες ή σταθερές τιμές ύψους του πατέρα. Παρατηρήστε ότι σε κάθε δεδομένο ύψος του πατέρα αντιστοιχεί μία *σειρά* ή κατανομή υψών των γιων. Ωστόσο, παρατηρούμε ότι παρά τη μεταβλητότητα του ύψους των γιων για μία δεδομένη τιμή του ύψους του πατέρα, ο μέσος όρος του ύψους των γιων αυξάνει γενικά καθώς αυξάνει το ύψος του πατέρα. Για να διευκρινιστεί αυτό οι σταυροί που περιέχονται σε κύκλο στο Διάγραμμα δείχνουν το *μέσο* ύψος των γιων που αντιστοιχεί σε ένα συγκεκριμένο ύψος του πατέρα. Ενώνοντας αυτούς τους μέσους όρους, παίρνουμε τη γραμμή που φαίνεται στο διάγραμμα. Αυτή η γραμμή, όπως θα δούμε, είναι γνωστή ως η **γραμμή παλινδρόμησης** (regression line). Δείχνει πώς το *μέσο* ύψος των γιων αυξάνεται καθώς αυξάνεται το ύψος του πατέρα.³


- Εξετάστε το διάγραμμα διασποράς στο Διάγραμμα 1.2, το οποίο παρουσιάζει την κατανομή του ύψους των αγοριών, που μετράται σε *σταθερές* ηλικίες, ενός υποθετικού πληθυσμού. Σε κάθε ηλικία, έχουμε μία σειρά, ή κατανομή, υψών. Προφανώς, δεν είναι πιθανό να έχουν όλα τα αγόρια μίας συγκεκριμένης ηλικίας τα ίδια ύψη. Όμως το ύψος, *κατά μέσο όρο*, αυξάνει με την ηλικία (φυσικά, μέχρι μία ορισμένη ηλικία), κάτι που γίνεται προφανές, αν σχεδιάσουμε μία γραμμή (τη γραμμή παλινδρόμησης), η οποία διατρέχει τα σημεία που περιέχονται στους κύκλους και τα οποία αντιπροσωπεύουν το μέσο ύψος στις συγκεκριμένες ηλικίες. Συνεπώς, γνωρίζοντας την ηλικία, ίσως μπορούμε να προβλέψουμε μέσω της γραμμής παλινδρόμησης το μέσο ύψος που αντιστοιχεί στην εκάστοτε ηλικία.
- Όσον αφορά τα οικονομικά παραδείγματα, ένας οικονομολόγος μπορεί να ενδιαφέρεται για τη μελέτη της εξάρτησης των προσωπικών καταναλωτικών δαπανών από το μετά φόρων ή διαθέσιμο πραγματικό προσωπικό εισόδημα. Μία τέτοια ανάλυση μπορεί να είναι χρήσιμη για την εκτίμηση της οριακής ροπής προς κατανάλωση (MPC), δηλαδή της μέσης μεταβολής της καταναλωτικής δαπάνης για μία, π.χ., μεταβολή του πραγματικού εισοδήματος κατά ένα δολάριο.
- Ένας μονοπωλητής που μπορεί να καθορίσει την τιμή ή την εκροή (αλλά όχι και τα δύο) μπορεί να θέλει να μάθει την ανταπόκριση της ζήτησης για ένα προϊόν στις μεταβολές των τιμών. Ένα τέτοιο πείραμα μπορεί να επιτρέψει την εκτίμηση της **ελαστικότητας ζήτησης ως προς την τιμή** (price elasticity) (δηλαδή, την ανταπόκριση ως προς την τιμή) για το προϊόν και μπορεί να βοηθήσει να προσδιοριστούν οι τιμές που θα οδηγήσουν σε υψηλότερα κέρδη.

³ Σε αυτό το στάδιο της ανάπτυξης του συγκεκριμένου θέματος, θα ονομάσουμε αυτή τη γραμμή παλινδρόμησης απλά ως τη γραμμή που συνδέει το μέσο, ή τη μέση τιμή της εξαρτημένης μεταβλητής (ύψος γιου), που αντιστοιχεί στη δοθείσα τιμή της ερμηνευτικής μεταβλητής (ύψος πατέρα). Σημειώστε ότι αυτή η γραμμή έχει θετική κλίση, αλλά η κλίση της είναι μικρότερη από 1, γεγονός που είναι σύμφωνο με την παλινδρόμηση προς τη μετρίότητα του Galton. (Γιατί;)



ΔΙΑΓΡΑΜΜΑ 1.2 Υποθετική κατανομή υψών που αντιστοιχούν σε συγκεκριμένες ηλικίες.


5. Ένας οικονομολόγος που ειδικεύεται στα οικονομικά της εργασίας μπορεί να θέλει να μελετήσει το ρυθμό μεταβολής των μισθών σε σχέση με το ποσοστό ανεργίας. Τα ιστορικά στοιχεία παρουσιάζονται στο διάγραμμα διασποράς (Διάγραμμα 1.3).



ΔΙΑΓΡΑΜΜΑ 1.3 Υποθετική καμπύλη Phillips.

Η καμπύλη στο Διάγραμμα 1.3 είναι ένα παράδειγμα της *καμπύλης Phillips* η οποία συσχετίζει τις μεταβολές των μισθών με το ποσοστό ανεργίας. Ένα τέτοιο διάγραμμα διασποράς μπορεί να επιτρέψει σε έναν οικονομολόγο που ασχολείται με τα οικονομικά της εργασίας να προβλέψει τη μέση μεταβολή των μισθών δοθέντος ενός ποσοστού ανεργίας. Η γνώση αυτή μπορεί να είναι χρήσιμη για την εξαγωγή συμπερασμάτων και τη διατύπωση προτάσεων πολιτικής σχετικά με τον πληθωρισμό σε μία οικονομία, καθώς οι αυξήσεις των μισθών είναι πιθανό να αντανakλώνται στις αυξημένες τιμές.

6. Είναι γνωστό από τη νομισματική θεωρία ότι, με όλους τους άλλους παράγοντες σταθερούς, όσο υψηλότερο είναι το ποσοστό πληθωρισμού π , τόσο χαμηλότερο είναι το ποσοστό k του εισοδήματος που οι άνθρωποι θα θέλουν να διατηρήσουν με τη μορφή χρήματος, όπως απεικονίζεται στο Διάγραμμα 1.4. Η κλίση αυτής της γραμμής αντιπροσωπεύει τη μεταβολή στο k δοθείσης μίας μεταβολής του ποσοστού πληθωρισμού. Μία ποσοτική ανάλυση αυτής της σχέσης θα επιτρέψει στον οικονομολόγο να προβλέψει το ποσό των χρημάτων, ως ποσοστό του εισοδήματός τους, που οι άνθρωποι θα θέλουν να διακρατήσουν σε διάφορα επίπεδα πληθωρισμού.



ΔΙΑΓΡΑΜΜΑ 1.4 Διακράτηση χρήματος σε σχέση με το ποσοστό πληθωρισμού π .

7. Ο διευθυντής μάρκετινγκ μίας εταιρείας μπορεί να θέλει να γνωρίζει πως σχετίζεται η ζήτηση για το προϊόν της εταιρείας με π.χ. τις διαφημιστικές δαπάνες. Μία τέτοια μελέτη θα συνέβαλλε καθοριστικά στο να ανακαλύψει την *ελαστικότητα της ζήτησης σε σχέση με τις διαφημιστικές δαπάνες*, δηλαδή, την ποσοστιαία μεταβολή της ζήτησης σε μία μεταβολή του διαφημιστικού προϋπολογισμού κατά 1 τοις εκατό. Αυτή η γνώση μπορεί να είναι χρήσιμη για τον προσδιορισμό του «άριστου» διαφημιστικού προϋπολογισμού.
8. Τέλος, ένας γεωπόνος μπορεί να ενδιαφέρεται για τη μελέτη της εξάρτησης της απόδοσης μίας καλλιέργειας π.χ. του σίτου, από τη θερμοκρασία, τις βροχοπτώσεις, την ηλιοφάνεια και τα λιπάσματα. Μία τέτοια ανάλυση εξάρτησης μπορεί να καταστήσει δυνατή την πρόβλεψη της μέσης απόδοσης των καλλιεργειών, δοθέντων των πληροφοριών που αφορούν τις ερμηνευτικές μεταβλητές.

Οι τεχνικές της ανάλυσης παλινδρόμησης που παρουσιάζονται στο παρόν βιβλίο είναι ειδικά σχεδιασμένες για τη μελέτη αντίστοιχων εξαρτήσεων μεταξύ μεταβλητών.

1.3 Στατιστικές Σχέσεις έναντι Προσδιοριστικών Σχέσεων

Από τα παραδείγματα που παρατίθενται στην Ενότητα 1.2, ο αναγνώστης θα παρατηρήσει ότι στην ανάλυση παλινδρόμησης μας απασχολεί αυτό που είναι γνωστό ως η *στατιστική*, και όχι η *συναρτησιακή* ή *προσδιοριστική* εξάρτηση μεταξύ των μεταβλητών, όπως αυτές της κλασικής φυσικής. Στις στατιστικές σχέσεις μεταξύ των μεταβλητών ουσιαστικά ασχολούμαστε με **τυχαίες** ή **στοχαστικές**⁴ μεταβλητές, δηλαδή, μεταβλητές που έχουν κατανομές πιθανότητας. Στις συναρτησιακές ή προσδιοριστικές εξαρτήσεις, από την άλλη, ασχολούμαστε επίσης με μεταβλητές, όμως αυτές οι μεταβλητές δεν είναι τυχαίες ή στοχαστικές.

Η εξάρτηση της απόδοσης των καλλιεργειών από τη θερμοκρασία, τις βροχοπτώσεις, την ηλιοφάνεια και το λίπασμα, για παράδειγμα, είναι στατιστικής φύσης υπό την έννοια ότι οι ερμηνευτικές μεταβλητές, αν και είναι σίγουρα σημαντικές, δε θα επιτρέψουν στο γεωπόνο να προβλέψει την απόδοση των καλλιεργειών ακριβώς λόγω σφαλμάτων που εμπλέκονται στη μέτρηση αυτών των μεταβλητών, καθώς και λόγω μίας σειράς άλλων παραγόντων (μεταβλητών) που επηρεάζουν συλλογικά την απόδοση, αλλά μπορεί να είναι δύσκολο να προσδιοριστούν ξεχωριστά. Επομένως, είναι βέβαιο ότι θα υπάρχει κάποια «εγγενής» ή τυχαία μεταβλητότητα στην εξαρτημένη μεταβλητή της απόδοσης των καλλιεργειών, η οποία δε μπορεί να εξηγηθεί πλήρως ανεξάρτητα από τον αριθμό των ερμηνευτικών μεταβλητών που θα χρησιμοποιήσουμε.

Αντιθέτως, σε προσδιοριστικά φαινόμενα, ασχολούμαστε με σχέσεις του τύπου π.χ. του νόμου της βαρύτητας του Newton, σύμφωνα με τον οποίο: Κάθε σωματίδιο στο σύμπαν έλκει κάθε άλλο σωματίδιο με δύναμη ευθέως ανάλογη του γινομένου των μαζών τους και αντιστρόφως ανάλογη του τετραγώνου της απόστασης μεταξύ τους. Χρησιμοποιώντας μαθηματικούς συμβολισμούς, $F = k(m_1 m_2 / r^2)$, όπου F = δύναμη, m_1

⁴ Η λέξη στοχαστική προέρχεται από την ελληνική λέξη *στόχος*. Το αποτέλεσμα της ρίψης βελών σε ένα στόχο είναι μία στοχαστική διαδικασία, δηλαδή, μία διαδικασία γεμάτη με αστοχίες.

και m_2 οι μάζες των δύο σωματιδίων, r = απόσταση και k = σταθερά της αναλογίας. Ένα άλλο παράδειγμα είναι ο νόμος του Ohm, ο οποίος αναφέρει: Για μεταλλικούς αγωγούς για ένα περιορισμένο εύρος θερμοκρασίας το ρεύμα C είναι ευθέως ανάλογο της τάσης V δηλαδή $C = (1/k)V$ όπου $1/k$ είναι η σταθερά της αναλογίας. Άλλα παραδείγματα τέτοιων προσδιοριστικών σχέσεων είναι ο νόμος των αερίων του Boyle, ο νόμος της ηλεκτρικής ενέργειας του Kirchhoff και ο νόμος της κίνησης των σωμάτων του Newton.

Στο παρόν βιβλίο δε μας απασχολούν αντίστοιχες προσδιοριστικές σχέσεις. Ασφαλώς, εάν υπάρχουν σφάλματα μέτρησης π.χ. στο k του νόμου της βαρύτητας του Newton, η, κατά τα άλλα, προσδιοριστική σχέση μετατρέπεται σε μία στατιστική σχέση. Σε αυτήν την περίπτωση, η δύναμη μπορεί να προβλεφθεί μόνο κατά προσέγγιση από την τιμή του k (και των m_1, m_2 και r), η οποία περιέχει σφάλματα. Σε αυτήν την περίπτωση η μεταβλητή F μετατρέπεται σε μία τυχαία μεταβλητή.

1.4 Παλινδρόμηση έναντι Αιτιότητας

Παρόλο που η ανάλυση παλινδρόμησης ασχολείται με την εξάρτηση μίας μεταβλητής από άλλες μεταβλητές, αυτό δε συνεπάγεται κατ' ανάγκη αιτιότητα. Σύμφωνα με τις δηλώσεις των Kendall και Stuart, «Μια στατιστική σχέση, όσο ισχυρή και αν είναι, δε μπορεί ποτέ να αποδείξει αιτιώδη συνάφεια: οι ιδέες μας για την αιτιότητα πρέπει να προέρχονται εκτός της στατιστικής, και εν τέλει από κάποια θεωρία.»⁵

Στο παράδειγμα της απόδοσης των καλλιεργειών που παρατέθηκε παραπάνω, δεν υπάρχει κανένας στατιστικός λόγος να υποθέσουμε ότι οι βροχοπτώσεις δεν εξαρτώνται από την απόδοση των καλλιεργειών. Το γεγονός ότι αντιμετωπίζουμε την απόδοση των καλλιεργειών ως ένα παράγοντα που εξαρτάται από τη βροχόπτωση (μεταξύ άλλων) οφείλεται σε μη-στατιστικές εκτιμήσεις: Σύμφωνα με την κοινή λογική, η σχέση δε μπορεί να αντιστραφεί, διότι δε μπορούμε να ελέγξουμε τις βροχοπτώσεις μεταβάλλοντας την απόδοση των καλλιεργειών.

Σε όλα τα παραδείγματα που αναφέρονται στην Ενότητα 1.2, αυτό που πρέπει να επισημανθεί είναι ότι **μία στατιστική σχέση καθεαυτή δε συνεπάγεται λογικά αιτιότητα**. Για να καταλογίσει κάποιος αιτιότητα, πρέπει να επικαλεστεί *a priori* θεωρητικές απόψεις. Συνεπώς, στο τρίτο παράδειγμα που αναφέρθηκε, κάποιος μπορεί να επικαλεστεί την οικονομική θεωρία λέγοντας ότι οι καταναλωτικές δαπάνες εξαρτώνται από το πραγματικό εισόδημα.⁶

1.5 Παλινδρόμηση έναντι Συσχέτισης

Η **ανάλυση συσχέτισης** (correlation analysis) είναι στενά συνδεδεμένη, αλλά εννοιολογικά πολύ διαφορετική, από την ανάλυση παλινδρόμησης, όπου ο πρωταρχικός στόχος είναι η μέτρηση της *δύναμης* ή του *βαθμού γραμμικής συσχέτισης* μεταξύ δύο μεταβλητών. Ο **συντελεστής συσχέτισης** (correlation coefficient), τον οποίο θα μελετήσουμε λεπτομερώς στο Κεφάλαιο 3, μετρά τη δύναμη αυτής της (γραμμικής) σχέσης. Για παράδειγμα, μπορεί να ενδιαφερόμαστε να βρούμε τη συσχέτιση (το συντελεστή συσχέτισης) μεταξύ του καπνίσματος και του καρκίνου του πνεύμονα, μεταξύ των βαθμών των μαθητών στη στατιστική και στα μαθηματικά, μεταξύ των βαθμών στο λύκειο και των βαθμών στο πανεπιστήμιο και ούτω καθεξής. Όπως έχουμε ήδη επισημάνει, στην ανάλυση παλινδρόμησης δεν ενδιαφερόμαστε πρωτίστως για ένα τέτοιο μέτρο. Αντ' αυτού, προσπαθούμε να εκτιμήσουμε ή να προβλέψουμε τη μέση τιμή μίας μεταβλητής βάσει των σταθερών τιμών άλλων μεταβλητών. Επομένως, μπορεί να θέλουμε να γνωρίζουμε αν μπορούμε να προβλέψουμε τη μέση βαθμολογία σε μία εξέταση ενός μαθήματος στατιστικής, γνωρίζοντας τη βαθμολογία του φοιτητή σε μία εξέταση μαθηματικών.

Η παλινδρόμηση και η συσχέτιση έχουν ορισμένες θεμελιώδεις διαφορές στις οποίες αξίζει να αναφερθούμε. Στην ανάλυση παλινδρόμησης υπάρχει μία ασυμμετρία στον τρόπο με τον οποίο αντιμετωπίζονται η εξαρτημένη και οι ερμηνευτικές μεταβλητές. Η εξαρτημένη μεταβλητή θεωρείται ότι είναι στατιστική, τυχαία ή στοχαστική, δηλαδή ότι έχει μία κατανομή πιθανότητας. Οι ερμηνευτικές μεταβλητές, από


⁵ M. G. Kendall and A. Stuart, *The Advanced Theory of Statistics*, Charles Griffin Publishers, New York, vol. 2, 1961, κεφ. 26, σελ. 279.

⁶ Όπως θα δούμε στο Κεφάλαιο 3, η κλασική ανάλυση παλινδρόμησης βασίζεται στην υπόθεση ότι το υπόδειγμα που χρησιμοποιείται στην ανάλυση είναι το σωστό υπόδειγμα. Ως εκ τούτου, η κατεύθυνση της αιτιότητας μπορεί να είναι εγγενής στο υπόδειγμα.

την άλλη, θεωρούνται ότι έχουν σταθερές τιμές (σε επαναλαμβανόμενη δειγματοληψία),⁷ γεγονός που έγινε προφανές από τον ορισμό της παλινδρόμησης που παραθέσαμε στην Ενότητα 1.2. Συνεπώς, στο Διάγραμμα 1.2 υποθέσαμε ότι η μεταβλητή ηλικία ήταν σταθερή σε συγκεκριμένα επίπεδα και οι μετρήσεις του ύψους ελήφθησαν σε αυτά τα επίπεδα. Αντιθέτως, στην ανάλυση συσχέτισης αντιμετωπίζουμε οποιεσδήποτε (δύο) μεταβλητές συμμετρικά· δεν υπάρχει καμία διάκριση μεταξύ των εξαρτημένων και των ερμηνευτικών μεταβλητών. Άλλωστε, η συσχέτιση μεταξύ των βαθμών στα μαθηματικά και στη στατιστική είναι η ίδια με εκείνη μεταξύ των βαθμών στη στατιστική και στα μαθηματικά. Επιπλέον, και οι δύο μεταβλητές υποτίθεται ότι είναι τυχαίες. Όπως θα δούμε, το μεγαλύτερο μέρος της θεωρίας συσχέτισης βασίζεται στην υπόθεση της τυχαιότητας των μεταβλητών, ενώ το μεγαλύτερο μέρος της θεωρίας παλινδρόμησης που θα παρουσιαστεί σε αυτό το βιβλίο βασίζεται στην υπόθεση ότι η εξαρτημένη μεταβλητή είναι στοχαστική ενώ οι ερμηνευτικές μεταβλητές είναι σταθερές ή μη-στοχαστικές.⁸

1.6 Ορολογία και Συμβολισμοί

Πριν προχωρήσουμε στην ανάλυση της θεωρίας παλινδρόμησης, ας σταθούμε εν συντομία στο ζήτημα της ορολογίας και των συμβολισμών. Στη βιβλιογραφία οι όροι *εξαρτημένη μεταβλητή* και *ερμηνευτική μεταβλητή* περιγράφονται ποικιλοτρόπως. Μία αντιπροσωπευτική λίστα είναι:



Παρά το γεγονός ότι αποτελεί ζήτημα προσωπικής προτίμησης και παράδοσης, σε αυτό το βιβλίο θα χρησιμοποιήσουμε τους όρους *εξαρτημένη μεταβλητή/ερμηνευτική μεταβλητή* ή τους πιο ουδέτερους, *παλινδρομούμενη μεταβλητή* και *παλινδρομητής*.

Αν μελετούμε την εξάρτηση μίας μεταβλητής από μία μόνο ερμηνευτική μεταβλητή, όπως αυτή της καταναλωτικής δαπάνης από το πραγματικό εισόδημα, μία τέτοια μελέτη είναι γνωστή ως απλή, ή **διμεταβλητή ανάλυση παλινδρόμησης** (two-variable regression analysis). Ωστόσο, αν μελετούμε την εξάρτηση μίας μεταβλητής από περισσότερες από μία ερμηνευτικές μεταβλητές, όπως στο παράδειγμα της απόδοσης των καλλιεργειών και της βροχόπτωσης, της θερμοκρασίας, της ηλιοφάνειας και των λιπασμάτων, τότε είναι γνωστή ως **ανάλυση πολλαπλής παλινδρόμησης** (multiple regression analysis). Με άλλα λόγια, στη διμεταβλητή παλινδρόμηση υπάρχει μόνο μία ερμηνευτική μεταβλητή, ενώ στην πολλαπλή παλινδρόμηση υπάρχουν περισσότερες από μία ερμηνευτικές μεταβλητές.

Ο όρος **τυχαίο** (random) είναι συνώνυμος του όρου **στοχαστικό** (stochastic). Όπως προαναφέρθηκε, μία τυχαία ή στοχαστική μεταβλητή είναι μία μεταβλητή που μπορεί να πάρει οποιοδήποτε σύνολο τιμών, θετικών ή αρνητικών, με μία δεδομένη πιθανότητα.⁹

⁷ Είναι σημαντικό να σημειωθεί ότι οι ερμηνευτικές μεταβλητές μπορεί να είναι εγγενώς στοχαστικές, όμως για το σκοπό της ανάλυσης παλινδρόμησης υποθέτουμε ότι οι τιμές τους είναι σταθερές σε επαναλαμβανόμενη δειγματοληψία (δηλαδή, η μεταβλητή X παίρνει τις ίδιες τιμές σε διάφορα δείγματα), καθιστώντας τις με τον τρόπο αυτό πρακτικά μη-τυχαίες ή μη-στοχαστικές. Περισσότερα όμως για το συγκεκριμένο ζήτημα θα δούμε στο Κεφάλαιο 3, Εν. 3.2.

⁸ Σε προχωρημένα επίπεδα οικονομετρίας, μπορούμε να χαλαρώσουμε την υπόθεση ότι οι ερμηνευτικές μεταβλητές είναι μη-στοχαστικές (βλ. εισαγωγή του Δευτέρου Μέρους).

⁹ Βλ. **Παράρτημα Α** για τον ακριβή ορισμό και για περαιτέρω λεπτομέρειες.

Εκτός αν ορίζεται διαφορετικά, το γράμμα Y θα δηλώνει την εξαρτημένη μεταβλητή και το X ($X_1, X_2, \dots, X_k$) θα δηλώνει τις ερμηνευτικές μεταβλητές, X_k είναι η $k^{\text{η}}$ ερμηνευτική μεταβλητή. Ο δείκτης i ή t θα δηλώνει την $i^{\text{η}}$ ή $t^{\text{η}}$ παρατήρηση ή τιμή. X_{ki} (ή X_{kt}) θα δηλώνει την $i^{\text{η}}$ (ή $t^{\text{η}}$) παρατήρηση της μεταβλητής X_k . N (ή T) θα δηλώνει το συνολικό αριθμό των παρατηρήσεων ή των τιμών στον πληθυσμό, και n (ή t) το συνολικό αριθμό των παρατηρήσεων στο δείγμα. Ο δείκτης i θα χρησιμοποιείται για **διαστρωματικά στοιχεία** (cross-sectional data) (δηλαδή, στοιχεία που έχουν συλλεχθεί σε μία χρονική στιγμή) και ο δείκτης t θα χρησιμοποιείται για **χρονοσειρές στοιχείων** (time series data) (δηλαδή, στοιχεία που έχουν συλλεχθεί κατά τη διάρκεια μίας χρονικής περιόδου). Η φύση των διαστρωματικών στοιχείων και των χρονοσειρών στοιχείων, καθώς και το σημαντικό θέμα της φύσης και των πηγών των στοιχείων για την εμπειρική ανάλυση, συζητείται στην επόμενη ενότητα.

1.7 Η Φύση και οι Πηγές των Στοιχείων για την Οικονομική Ανάλυση

Η επιτυχία κάθε οικονομετρικής ανάλυσης εξαρτάται εν τέλει από τη διαθεσιμότητα των κατάλληλων στοιχείων. Συνεπώς, είναι απαραίτητο να συζητήσουμε τη φύση, τις πηγές και τους περιορισμούς που μπορεί να αντιμετωπίσει κάποιος στην εμπειρική ανάλυση.

Τύποι Στοιχείων

Υπάρχουν τρεις τύποι στοιχείων που μπορεί να είναι διαθέσιμοι για εμπειρική ανάλυση: οι **χρονοσειρές στοιχείων**, τα **διαστρωματικά στοιχεία** και τα **ομαδοποιημένα στοιχεία** (δηλαδή, ο συνδυασμός των χρονοσειρών και των διαστρωματικών στοιχείων).

Χρονοσειρές Στοιχείων

Τα στοιχεία που παρουσιάζονται στον Πίνακα 1 της Εισαγωγής είναι ένα παράδειγμα χρονοσειρών στοιχείων. Μία χρονοσειρά (time series data) είναι μία σειρά από παρατηρήσεις αναφορικά με τις τιμές που παίρνει μία μεταβλητή σε διαφορετικές χρονικές στιγμές. Τα στοιχεία αυτά μπορούν να συλλεχθούν σε τακτά χρονικά διαστήματα, όπως **καθημερινά** (π.χ. οι τιμές των μετοχών, δελτία καιρού), **εβδομαδιαία** (π.χ. στοιχεία προσφοράς χρήματος), **μηνιαία** [π.χ. το ποσοστό ανεργίας, ο Δείκτης Τιμών Καταναλωτή (ΔΤΚ)], **τριμηνιαία** (π.χ. το ΑΕΠ), **ετήσια** (π.χ. κρατικοί προϋπολογισμοί), **ανά πενταετία**, δηλαδή, κάθε 5 χρόνια (π.χ. η απογραφή των κατασκευών), ή **ανά δεκαετία** (π.χ. η απογραφή του πληθυσμού). Ορισμένες φορές υπάρχουν διαθέσιμα στοιχεία τόσο σε τριμηνιαία όσο και σε ετήσια βάση, όπως στην περίπτωση των στοιχείων για το ΑΕΠ και για τις καταναλωτικές δαπάνες. Με την έλευση των Η/Υ υψηλής ταχύτητας, τα στοιχεία μπορούν πλέον να συλλέγονται ανά τακτά χρονικά διαστήματα, όπως τα στοιχεία για τις τιμές των μετοχών, τα οποία μπορούν να συλλέγονται κυριολεκτικά συνεχώς (στο λεγόμενο: *πραγματικό χρόνο*).

Παρόλο που οι χρονοσειρές στοιχείων χρησιμοποιούνται σε μεγάλο βαθμό στις οικονομετρικές μελέτες, παρουσιάζουν ιδιαίτερα προβλήματα για τους οικονομετρες. Όπως θα δείξουμε στα κεφάλαια που αφορούν την οικονομετρία χρονοσειρών, οι περισσότερες εμπειρικές εργασίες που βασίζονται σε χρονοσειρές στοιχείων προϋποθέτουν ότι οι υποκείμενες χρονοσειρές είναι **στάσιμες** (stationary). Αν και είναι πολύ νωρίς για να εισαγάγουμε την ακριβή τεχνική έννοια της στασιμότητας στο συγκεκριμένο σημείο, θα μπορούσαμε να πούμε ότι μία χρονοσειρά είναι στάσιμη, αν η μέση τιμή της και η διακύμανσή της δε διαφέρουν συστηματικά διαχρονικά. Για να γίνει αυτό περισσότερο κατανοητό, ας εξετάσουμε το Διάγραμμα 1.5, το οποίο απεικονίζει τη συμπεριφορά της προσφοράς χρήματος $M1$ στην Ηνωμένες Πολιτείες από την 1^η Ιανουαρίου 1959, έως τον Σεπτέμβριο του 1999. (Τα πραγματικά στοιχεία δίνονται στην Άσκηση 1.4.) Όπως μπορείτε να δείτε από αυτό το διάγραμμα, η προσφορά χρήματος $M1$ παρουσιάζει μία σταθερή ανοδική **τάση** (trend), όπως επίσης και μεταβλητότητα κατά τη διάρκεια των ετών, γεγονός που υποδηλώνει ότι η χρονολογική σειρά $M1$ δεν είναι στάσιμη.¹⁰ Το θέμα αυτό θα διερευνηθεί πλήρως στο Κεφάλαιο 21.

¹⁰Για να γίνει ευκολότερα κατανοητό χωρίσαμε τα στοιχεία σε τέσσερις χρονικές περιόδους: 1951:01 μέχρι 1962:12, 1963:01 μέχρι 1974:12, 1975:01 μέχρι 1986:12, 1987:01 μέχρι 1999:09. Γι' αυτές τις υποπεριόδους οι μέσες τιμές της προσφοράς χρήματος (με τις αντίστοιχες τυπικές αποκλίσεις σε παρένθεση) ήταν, αντίστοιχα, 165,88 (23,27), 323,20 (72,66), 788,12 (195,43) και 1099 (27,84), όλα τα ποσά είναι σε δισεκατομμύρια δολάρια. Αυτή είναι μία γενική ένδειξη του γεγονότος ότι η προσφορά χρήματος δεν ήταν στάσιμη σε όλη την περίοδο.

Κεφάλαιο 2

Διμεταβλητή Ανάλυση Παλινδρόμησης: Ορισμένες Βασικές Ιδέες

Στο Κεφάλαιο 1 χρησιμοποιήσαμε γενικούς όρους για να συζητήσουμε την έννοια της παλινδρόμησης. Σε αυτό το κεφάλαιο θα προσεγγίσουμε το θέμα περισσότερο ολοκληρωμένα. Συγκεκριμένα, το παρόν και τα επόμενα τρία κεφάλαια εισάγουν τον αναγνώστη στη θεωρία της απλούστερης δυνατής ανάλυσης παλινδρόμησης, δηλαδή, της **διμεταβλητής παλινδρόμησης**, ή της **παλινδρόμησης δύο μεταβλητών** στην οποία η εξαρτημένη μεταβλητή (παλινδρομούμενη μεταβλητή - regressand) σχετίζεται σε μία ερμηνευτική μεταβλητή (παλινδρομητής - regressor). Αρχικά εξετάζεται αυτή η υπόθεση, όχι λόγω της πρακτικής της επάρκειάς, αλλά επειδή παρουσιάζει τις θεμελιώδεις ιδέες της ανάλυσης παλινδρόμησης με τον απλούστερο δυνατό τρόπο και μερικές από αυτές τις ιδέες μπορούν να απεικονιστούν με τη βοήθεια γραφημάτων δύο διαστάσεων. Επιπλέον, όπως θα δούμε, η γενικότερη ανάλυση πολλαπλής παλινδρόμησης στην οποία η παλινδρομούμενη μεταβλητή σχετίζεται με έναν ή περισσότερους παλινδρομητές είναι από πολλές απόψεις μία λογική επέκταση της περίπτωσης των δύο μεταβλητών.

2.1 Ένα Υποθετικό Παράδειγμα

Όπως σημειώνεται στην Ενότητα 1.2, η ανάλυση παλινδρόμησης¹ επικεντρώνεται σε μεγάλο βαθμό στην εκτίμηση και/ή την πρόβλεψη της μέσης τιμής (του πληθυσμού) της εξαρτημένης μεταβλητής βάσει των γνωστών ή σταθερών τιμών της ερμηνευτικής μεταβλητής.² Για να το κατανοήσετε, εξετάστε τα στοιχεία που παρουσιάζονται στον Πίνακα 2.1. Τα στοιχεία στον πίνακα αναφέρονται σε ένα συνολικό πληθυσμό 60 οικογενειών σε μία υποθετική κοινότητα των οποίων το εβδομαδιαίο εισόδημά τους (X) και η εβδομαδιαία κατανάλωσή τους (Y) είναι σε δολάρια. Οι 60 οικογένειες χωρίζονται σε 10 εισοδηματικές ομάδες (από \$80 έως \$260) και οι εβδομαδιαίες δαπάνες της κάθε οικογένειας στις διάφορες ομάδες παρουσιάζονται στον πίνακα. Ως εκ τούτου, έχουμε 10 σταθερές τιμές της X και τις αντίστοιχες τιμές της Y έναντι κάθε μίας από τις τιμές X . επομένως, υπάρχουν 10 υποπληθυσμοί της Y .


Υπάρχουν σημαντικές διαφορές στις εβδομαδιαίες καταναλωτικές δαπάνες σε κάθε ομάδα εισοδήματος, η οποία μπορεί να φανεί καθαρά από το Διάγραμμα 2.1. Όμως η γενική εικόνα είναι ότι, παρά τη μεταβλητότητα των εβδομαδιαίων καταναλωτικών δαπανών κάθε κατηγορίας εισοδήματος, *κατά μέσο όρο*, οι εβδομαδιαίες καταναλωτικές δαπάνες αυξάνουν όσο αυξάνει το εισόδημα. Για να γίνει αυτό καλύτερα κατανοητό, στον Πίνακα 2.1 έχουμε συμπεριλάβει τη μέση τιμή ή το μέσο όρο των εβδομαδιαίων καταναλωτικών δαπανών που αντιστοιχούν σε κάθε ένα από τα 10 εισοδηματικά επίπεδα.

¹ Ο αναγνώστης, οι γνώσεις στατιστικής του οποίου έχουν 'σκουριάσει' κάπως, ίσως θέλει να τις 'φρεσκάρει' λίγο διαβάζοντας το στατιστικό παράρτημα, **Παράρτημα Α**, πριν διαβάσει αυτό το κεφάλαιο.

² Η προσδοκώμενη τιμή, ή προσδοκία, ή μέση τιμή του πληθυσμού μίας τυχαίας μεταβλητής Y συμβολίζεται με το σύμβολο $E(Y)$. Από την άλλη, η μέση τιμή ενός δείγματος τιμών από τον πληθυσμό Y συμβολίζεται με $\bar{Y}$, και διαβάζεται ως Y παύλα (ή Y μέσος)

ΠΙΝΑΚΑΣ 2.1 Εβδομαδιαίο Εισόδημα X Νοικοκυριών (σε \$)

$X \rightarrow$	80	100	120	140	160	180	200	220	240	260
$Y \downarrow$	55	65	79	80	102	110	120	135	137	150
Εβδομαδιαίες καταναλωτικές δαπάνες νοικοκυριών Y, \$	60	70	84	93	107	115	136	137	145	152
	65	74	90	95	110	120	140	140	155	175
	70	80	94	103	116	130	144	152	165	178
	75	85	98	108	118	135	145	157	175	180
	—	88	—	113	125	140	—	160	189	185
	—	—	—	115	—	—	—	162	—	191
Σύνολο	325	462	445	707	678	750	685	1043	966	1211
Υπό Συνθήκη Μέσες Τιμές της Y, $E(Y X)$	65	77	89	101	113	125	137	149	161	173



ΔΙΑΓΡΑΜΜΑ 2.1 Υπό συνθήκη κατανομή δαπανών για διάφορα εισοδηματικά επίπεδα (στοιχεία του Πίνακα 2.1).

Συνεπώς, το εβδομαδιαίο εισοδηματικό επίπεδο των \$80 αντιστοιχεί σε μέση καταναλωτική δαπάνη \$65, ενώ το εβδομαδιαίο εισοδηματικό επίπεδο των \$200, αντιστοιχεί σε μέση καταναλωτική δαπάνη \$137. Συνολικά έχουμε 10 μέσες τιμές για 10 υποπληθυσμούς της Y. Αυτές οι μέσες τιμές ονομάζονται **υπό συνθήκη προσδοκώμενες τιμές** (conditional expected values), διότι εξαρτώνται από τις τιμές που δίνονται στην (υπό συνθήκη) μεταβλητή X. Συμβολικά, τις παρουσιάζουμε ως $E(Y|X)$, η οποία διαβάζεται ως η προσδοκώμενη τιμή της Y δοθείσης της τιμής της X (βλ. επίσης τον Πίνακα 2.2).

ΠΙΝΑΚΑΣ 2.2 Υπό Συνθήκη Πιθανότητες $p(Y|X_i)$ για τα Στοιχεία του Πίνακα 2.1

$X \rightarrow$	80	100	120	140	160	180	200	220	240	260
$Y \downarrow$	1/5	1/6	1/5	1/7	1/6	1/6	1/5	1/7	1/6	1/7
Υπό Συνθήκη Πιθανότητες $p(Y X_i)$	1/5	1/6	1/5	1/7	1/6	1/6	1/5	1/7	1/6	1/7
	1/5	1/6	1/5	1/7	1/6	1/6	1/5	1/7	1/6	1/7
	1/5	1/6	1/5	1/7	1/6	1/6	1/5	1/7	1/6	1/7
	—	1/6	—	1/7	1/6	1/6	—	1/7	1/6	1/7
	—	—	—	1/7	—	—	—	1/7	—	1/7
Υπό Συνθήκη Μέσες Τιμές της Y	65	77	89	101	113	125	137	149	161	173


Είναι σημαντικό να διακρίνουμε αυτές τις υπό συνθήκη προσδοκώμενες τιμές από την **άνευ συνθηκών προσδοκώμενη τιμή** (unconditional expected value) των εβδομαδιαίων καταναλωτικών δαπανών, $E(Y)$. Αν προσθέσουμε τις εβδομαδιαίες καταναλωτικές δαπάνες για το σύνολο των 60 οικογενειών του πληθυσμού και διαιρέσουμε αυτό τον αριθμό με 60, θα έχουμε τον αριθμό \$121,20 ($\$7272/60$), ο οποίος είναι η άνευ συνθηκών μέση τιμή ή προσδοκώμενη αξία των εβδομαδιαίων καταναλωτικών δαπανών,

$E(Y)$ είναι άνευ συνθηκών με την έννοια ότι για να καταλήξουμε σε αυτόν τον αριθμό δεν έχουμε λάβει υπόψη μας τα επίπεδα εισοδήματος των διαφόρων οικογενειών.³ Προφανώς, οι διάφορες υπό συνθήκη προσδοκώμενες τιμές της Y που δίνονται στον Πίνακα 2.1 είναι διαφορετικές από την άνευ συνθηκών προσδοκώμενη τιμή της Y των \$121,20. Όταν κάνουμε την ερώτηση: «Ποια είναι η προσδοκώμενη τιμή της εβδομαδιαίας καταναλωτικής δαπάνης μίας οικογένειας;» θα λάβουμε την απάντηση \$121,20 (η άνευ συνθηκών μέση τιμή). Όμως εάν κάνουμε την ερώτηση, «Ποια είναι η προσδοκώμενη τιμή της εβδομαδιαίας καταναλωτικής δαπάνης μίας οικογένειας με μηνιαίο εισόδημα, \$140;» θα λάβουμε την απάντηση \$101 (η υπό συνθήκη μέση τιμή). Για να το θέσουμε διαφορετικά, αν κάνουμε την ερώτηση, «Ποια είναι η καλύτερη (μέση) πρόβλεψη των εβδομαδιαίων δαπανών των οικογενειών με εβδομαδιαίο εισόδημα \$140;» η απάντηση θα ήταν \$101. Επομένως, η γνώση του επιπέδου του εισοδήματος μπορεί να μας δώσει τη δυνατότητα να προβλέψουμε με μεγαλύτερη ακρίβεια τη μέση τιμή της καταναλωτικής δαπάνης από ό, τι εάν δεν έχουμε αυτή τη γνώση.⁴ Αυτή είναι πιθανώς η ουσία της ανάλυσης παλινδρόμησης, όπως θα δείτε στο σύνολο του παρόντος βιβλίου.

Τα σκούρα κυκλωμένα σημεία στο Διάγραμμα 2.1 δείχνουν τις υπό συνθήκη μέσες τιμές της Y έναντι των διαφόρων τιμών της X . Αν ενώσουμε αυτές τις υπό συνθήκη μέσες τιμές, καταλήγουμε σε αυτό που είναι γνωστό ως η **γραμμή παλινδρόμησης του πληθυσμού (ΓΠΠ)** (population regression line - PRL), ή γενικότερα, η **καμπύλη παλινδρόμησης του πληθυσμού (population regression curve)**.⁵ Πιο απλά, είναι η **παλινδρόμηση της Y έναντι της X** . Το επίθετο «πληθυσμός» προέρχεται από το γεγονός ότι στο συγκεκριμένο παράδειγμα ασχολούμαστε με το συνολικό πληθυσμό των 60 οικογενειών. Φυσικά, στην πραγματικότητα, ένας πληθυσμός μπορεί να αποτελείται από πολλές οικογένειες.

Γεωμετρικά, επομένως, μία καμπύλη παλινδρόμησης του πληθυσμού είναι απλώς ο γεωμετρικός τόπος των υπό συνθήκη μέσων της εξαρτημένης μεταβλητής για τις σταθερές αξίες της ερμηνευτικής μεταβλητής. Πιο απλά, είναι η καμπύλη που συνδέει τους μέσους των υποπληθυσμών της Y που αντιστοιχούν στις δοθείσες τιμές του παλινδρομητή X . Το Διάγραμμα 2.2 δείχνει ότι για κάθε X (δηλαδή, επίπεδο εισοδήματος) υπάρχει ένας πληθυσμός τιμών της Y (εβδομαδιαία καταναλωτική δαπάνη) που βρίσκεται διεσπαρμένος γύρω από τον (υπό συνθήκη) μέσο των τιμών αυτών της Y . Για λόγους απλότητας, υποθέτουμε πως αυτές οι τιμές της Y κατανέμονται συμμετρικά γύρω από τις αντίστοιχες (υπό συνθήκη) μέσες τιμές τους. Και η γραμμή παλινδρόμησης (ή καμπύλη) διαπερνά αυτές τις (υπό συνθήκη) μέσες τιμές.

Έχοντας αποκτήσει αυτό το υπόβαθρο, ο αναγνώστης μπορεί να ξαναδιαβάσει τον ορισμό της παλινδρόμησης που παραθέσαμε στην Ενότητα 1.2.



ΔΙΑΓΡΑΜΜΑ 2.2 Γραμμή παλινδρόμησης του πληθυσμού (στοιχεία Πίνακα 2.1).

³ Όπως φαίνεται στο Παράρτημα Α, σε γενικές γραμμές οι υπό συνθήκη και οι άνευ συνθηκών μέσες τιμές είναι διαφορετικές.

⁴ Είμαι ευγνώμων στον James Davidson όσον αφορά αυτό το ζήτημα. Βλ. James Davidson, *Econometric Theory*, Blackwell Publishers, Oxford, H.B., 2000, σελ. 11.

⁵ Στο συγκεκριμένο παράδειγμα η PRL είναι ευθεία γραμμή, όμως θα μπορούσε να είναι καμπύλη (βλ. Διάγραμμα 2.3).

2.2 Η Έννοια της Συνάρτησης Παλινδρόμησης του Πληθυσμού (PRF)

Από την προηγούμενη συζήτηση και τα Διαγράμματα 2.1 και 2.2, είναι σαφές ότι κάθε υπό συνθήκη μέσος $E(Y | X_i)$ είναι μία συνάρτηση της X_i , όπου X_i είναι μία δεδομένη τιμή της X . Συμβολικά,

$$E(Y | X_i) = f(X_i) \quad (2.2.1)$$

όπου $f(X_i)$ υποδηλώνει κάποια συνάρτηση της ερμηνευτικής μεταβλητής X . Στο παράδειγμά μας, $E(Y | X_i)$ είναι μία γραμμική συνάρτηση της X_i . Η εξίσωση (2.2.1) είναι γνωστή ως **υπό συνθήκη συνάρτηση προσδοκίας – ΣΣΠ** (conditional expectation function - CEF) ή **συνάρτηση παλινδρόμησης του πληθυσμού** (population regression function - PRF) ή **παλινδρόμηση πληθυσμού** (population regression - PR) για συντομία. Αναφέρει απλώς ότι η *προσδοκώμενη τιμή* της κατανομής της Y δοθείσης της X_i συνδέεται συναρτησιακά με τη X_i . Με απλά λόγια, δηλώνει πως ο μέσος ή η μέση απόκριση της Y ποικίλλει ανάλογα με τη X .

Τι μορφή παίρνει η συνάρτηση $f(X_i)$; Αυτό είναι ένα σημαντικό ερώτημα γιατί σε πραγματικές συνθήκες δεν έχουμε στη διάθεσή μας το σύνολο του πληθυσμού προκειμένου να το εξετάσουμε. Η συναρτησιακή μορφή της PRF είναι επομένως ένα εμπειρικό ζήτημα, παρόλο που σε ορισμένες ειδικές περιπτώσεις, η θεωρία μπορεί να διαδραματίζει επίσης σημαντικό ρόλο. Για παράδειγμα, ένας οικονομολόγος θα μπορούσε να θεωρήσει ως δεδομένο ότι η καταναλωτική δαπάνη σχετίζεται γραμμικά με το εισόδημα. Ως εκ τούτου, ως μία πρώτη προσέγγιση ή υπόθεση εργασίας, μπορούμε να υποθέσουμε ότι η PRF $E(Y | X_i)$ είναι μία γραμμική συνάρτηση της X_i ,

$$E(Y | X_i) = \beta_1 + \beta_2 X_i \quad (2.2.2)$$

όπου β_1 και β_2 είναι άγνωστες, αλλά σταθερές παράμετροι που είναι γνωστές ως **συντελεστές παλινδρόμησης** (regression coefficients). Οι β_1 και β_2 , επίσης, είναι γνωστές και ως **συντελεστής σταθεράς** (intercept coefficient) και **συντελεστής κλίσης** (slope coefficient), αντίστοιχα. Η εξίσωση (2.2.2), είναι γνωστή ως **γραμμική συνάρτηση παλινδρόμησης του πληθυσμού** (linear population regression function). Ορισμένες εναλλακτικές εκφράσεις που χρησιμοποιούνται στη βιβλιογραφία είναι **γραμμικό υπόδειγμα παλινδρόμησης του πληθυσμού** ή απλώς **γραμμική παλινδρόμηση του πληθυσμού**. Στη συνέχεια, οι όροι **παλινδρόμηση**, **εξίσωση παλινδρόμησης**, και **υπόδειγμα παλινδρόμησης** θα χρησιμοποιούνται ως συνώνυμα.

Στην ανάλυση παλινδρόμησης το ενδιαφέρον μας επικεντρώνεται στην εκτίμηση των PRF όπως αυτών της Εξίσωσης 2.2.2, δηλαδή, στην εκτίμηση των τιμών των αγνώστων β_1 και β_2 , με βάση τις παρατηρήσεις των Y και X . Το θέμα αυτό θα μελετηθεί αναλυτικά στο Κεφάλαιο 3.

2.3 Η Έννοια του Όρου Γραμμικό

Δεδομένου ότι το παρόν βιβλίο ασχολείται κατά κύριο λόγο με γραμμικά υποδείγματα όπως το (2.2.2), είναι απαραίτητο να γνωρίζουμε τι σημαίνει πραγματικά ο όρος **γραμμικό**, λόγω του ότι μπορεί να ερμηνευθεί με δύο διαφορετικούς τρόπους.

Γραμμικότητα ως προς τις Μεταβλητές

Η πρώτη και ίσως πιο «φυσική» έννοια της γραμμικότητας είναι ότι η υπό συνθήκη προσδοκία της Y είναι μία γραμμική συνάρτηση της X_i , όπως, για παράδειγμα, η Εξίσωση (2.2.2).⁶ Γεωμετρικά, η καμπύλη παλινδρόμησης στην περίπτωση αυτή είναι μία ευθεία γραμμή. Με βάση αυτή την ερμηνεία, μία συνάρτηση παλινδρόμησης, όπως η $E(Y | X_i) = \beta_1 + \beta_2 X_i^2$ δεν είναι μία γραμμική συνάρτηση επειδή η μεταβλητή X εμφανίζεται υψωμένη στο τετράγωνο.


⁶ Μία συνάρτηση $Y = f(X)$ θεωρείται γραμμική ως προς τη X , αν η X εμφανίζεται με μία δύναμη ή δείκτη ίση με 1 (δηλαδή, εξαιρούνται όροι όπως X^2 , $\sqrt{X}$, και ούτω καθεξής) και δεν πολλαπλασιάζεται ή διαιρείται με οποιοδήποτε άλλη μεταβλητή (για παράδειγμα, $X \cdot Z$ ή X/Z , όπου Z είναι μία άλλη μεταβλητή). Αν η Y εξαρτάται μόνο από τη X , ένας άλλος τρόπος να δηλώσουμε ότι η Y σχετίζεται γραμμικά με τη X είναι ότι ο ρυθμός μεταβολής της Y ως προς τη X (δηλαδή, η κλίση ή παράγωγος της Y ως προς τη X , dY/dX) είναι ανεξάρτητη από την τιμή της X . Επομένως, εάν $Y = 4X$, $dY/dX = 4$, το οποίο είναι ανεξάρτητο από την τιμή της X . Όμως εάν $Y = 4X^2$, $dY/dX = 8X$, το οποίο δεν είναι ανεξάρτητο από την τιμή που παίρνει η X . Ως εκ τούτου αυτή η συνάρτηση δεν είναι γραμμική ως προς το X .

Γραμμικότητα ως προς τις Παραμέτρους

Η δεύτερη ερμηνεία της γραμμικότητας είναι ότι η υπό συνθήκη προσδοκία της Y , $E(Y | X_i)$, είναι μία γραμμική συνάρτηση των παραμέτρων, δηλαδή των β ενώ μπορεί να είναι ή μπορεί να μην είναι γραμμική ως προς τη μεταβλητή X .⁷ Σε αυτή την ερμηνεία το $E(Y | X_i) = \beta_1 + \beta_2 X_i^2$ είναι ένα γραμμικό (ως προς τις παραμέτρους) υπόδειγμα παλινδρόμησης. Για να το δείτε αυτό, ας υποθέσουμε ότι η X παίρνει την τιμή 3. Ως εκ τούτου, $E(Y | X=3) = \beta_1 + 9\beta_2$, η οποία είναι προφανώς γραμμική ως προς τις β_1 και β_2 . Όλα τα υποδείγματα που φαίνονται στο Διάγραμμα 2.3 είναι επομένως γραμμικά υποδείγματα παλινδρόμησης, δηλαδή, υποδείγματα γραμμικά ως προς τις παραμέτρους τους.

Ας εξετάσουμε τώρα το υπόδειγμα $E(Y | X_i) = \beta_1 + \beta_2^2 X_i$. Αν $X=3$ τότε παίρνουμε $E(Y | X_i) = \beta_1 + 3\beta_2^2$, το οποίο είναι μη γραμμικό ως προς την παράμετρο β_2 . Το υπόδειγμα αυτό είναι ένα παράδειγμα ενός μη γραμμικού (ως προς την παράμετρο) υποδείγματος παλινδρόμησης. Θα συζητήσουμε τέτοια υποδείγματα στο Κεφάλαιο 14.

Από τις δύο ερμηνείες της γραμμικότητας, η γραμμικότητα ως προς τις παραμέτρους αφορά την ανάπτυξη της θεωρίας παλινδρόμησης που θα παρουσιαστεί σύντομα. Ως εκ τούτου, από τώρα και στο εξής ο όρος «γραμμική» παλινδρόμηση θα σημαίνει πάντα μία παλινδρόμηση που είναι γραμμική ως προς τις παραμέτρους. Δηλαδή, οι παράμετροι β υψώνονται μόνο στην πρώτη δύναμη. Μπορεί να είναι ή μπορεί να μην είναι γραμμική ως προς τις ερμηνευτικές μεταβλητές, X . Σχηματικά, αυτό παρουσιάζεται στον Πίνακα 2.3. Συνεπώς, η $E(Y | X_i) = \beta_1 + \beta_2 X_i$, η οποία είναι γραμμική τόσο ως προς τις παραμέτρους όσο και ως προς τη μεταβλητή, είναι ένα γραμμικό υπόδειγμα παλινδρόμησης, και το ίδιο ισχύει για το $E(Y | X_i) = \beta_1 + \beta_2 X_i^2$, το οποίο είναι γραμμικό ως προς τις παραμέτρους, αλλά μη γραμμικό ως προς τη μεταβλητή X .



ΔΙΑΓΡΑΜΜΑ 2.3 Γραμμικές συναρτήσεις ως προς τις παραμέτρους.

ΠΙΝΑΚΑΣ 2.3 Υποδείγματα γραμμικής παλινδρόμησης

Γραμμικό Υπόδειγμα ως προς τις Παραμέτρους;	Γραμμικό Υπόδειγμα ως προς τις μεταβλητές;	
	Ναι	Όχι
Ναι	LRM	LRM
Όχι	NLRM	NLRM

Σημείωση: LRM = γραμμικό υπόδειγμα παλινδρόμησης και NLRM = μη γραμμικό υπόδειγμα παλινδρόμησης

⁷ Μία συνάρτηση λέγεται ότι είναι γραμμική ως προς την παράμετρο β_1 , αν η β_1 υψώνεται μόνο στην 1^η και δεν πολλαπλασιάζεται ή διαιρείται με οποιαδήποτε άλλη παράμετρο (για παράδειγμα, $\beta_1\beta_2$, β_2/β_1 , και ούτω καθεξής).

2.4 Στοχαστικός Προσδιορισμός της PRF

Είναι σαφές από το Διάγραμμα 2.1 ότι, όσο αυξάνεται το οικογενειακό εισόδημα, οι οικογενειακές καταναλωτικές δαπάνες αυξάνουν επίσης κατά μέσο όρο. Τι συμβαίνει όμως με τις καταναλωτικές δαπάνες μίας μεμονωμένης οικογένειας σε σχέση με το (σταθερό) επίπεδο εισοδήματός της; Είναι προφανές από τον Πίνακα 2.1 και το Διάγραμμα 2.1 ότι η καταναλωτική δαπάνη μίας μεμονωμένης οικογένειας δεν αυξάνεται απαραίτητα καθώς αυξάνεται το επίπεδο του εισοδήματος. Για παράδειγμα, από τον Πίνακα 2.1 παρατηρούμε ότι για το επίπεδο εισοδήματος των \$100 υπάρχει μία οικογένεια οι καταναλωτικές δαπάνες της οποίας είναι \$65, που είναι ένα ποσό μικρότερο από τις καταναλωτικές δαπάνες δύο οικογενειών, το εβδομαδιαίο εισόδημα των οποίων είναι μόνο \$80. Όμως, παρατηρούμε ότι η μέση καταναλωτική δαπάνη οικογενειών με εβδομαδιαίο εισόδημα ύψους \$100 είναι μεγαλύτερη από τη μέση καταναλωτική δαπάνη οικογενειών με εβδομαδιαίο εισόδημα ύψους \$80 (\$77 έναντι \$65).

Τι μπορούμε να πούμε λοιπόν για τη σχέση μεταξύ των καταναλωτικών δαπανών μίας μεμονωμένης οικογένειας και ενός δεδομένου επιπέδου εισοδήματος; Βλέπουμε από το Διάγραμμα 2.1 ότι, δεδομένου του επιπέδου εισοδήματος X_i , οι καταναλωτικές δαπάνες μίας μεμονωμένης οικογένειας είναι συγκεκριμένες γύρω από τη μέση κατανάλωση του συνόλου των οικογενειών σε εκείνη τη X_i , δηλαδή, γύρω από την υπό συνθήκη προσδοκία της. Ως εκ τούτου, μπορούμε να εκφράσουμε την απόκλιση μίας μεμονωμένης Y_i γύρω από την προσδοκώμενη τιμή της ως εξής:

$$\begin{aligned} u_i &= Y_i - E(Y | X_i) \quad \text{ή} \\ Y_i &= E(Y | X_i) + u_i \end{aligned} \quad (2.4.1)$$

όπου η απόκλιση u_i είναι μία μη παρατηρήσιμη τυχαία μεταβλητή που παίρνει θετικές ή αρνητικές τιμές. Τεχνικά, η u_i είναι γνωστή ως **στοχαστικός διαταρακτικός όρος** (stochastic disturbance term) ή **στοχαστικός όρος σφάλματος** (stochastic error term).

Πώς ερμηνεύουμε την Εξίσωση (2.4.1); Μπορούμε να πούμε ότι οι δαπάνες μίας μεμονωμένης οικογένειας, δοθέντος του επιπέδου του εισοδήματος της, μπορεί να εκφραστεί ως το άθροισμα των δύο συνιστωσών:

- ✦ $E(Y | X_i)$, το οποίο είναι απλά η μέση καταναλωτική δαπάνη του συνόλου των οικογενειών με το ίδιο επίπεδο εισοδήματος. Αυτή η συνιστώσα είναι γνωστή ως η **συστηματική ή προσδιοριστική** συνιστώσα και
- ✦ u_i , το οποίο είναι η **τυχαία ή μη συστηματική** συνιστώσα. Θα εξετάσουμε τη φύση του στοχαστικού διαταρακτικού όρου, όμως προς το παρόν υποθέτουμε ότι πρόκειται για ένα *υποκατάστατο ή προσέγγιση* για όλες τις μεταβλητές που έχουν παραλειφθεί ή αγνοούνται και οι οποίες μπορεί να επηρεάσουν τη Y , αλλά δεν περιλαμβάνονται (ή δεν μπορούν να περιληφθούν) στο υπόδειγμα παλινδρόμησης.

Εάν η $E(Y | X_i)$ θεωρείται ότι είναι γραμμική ως προς τη X_i , όπως στην Εξίσωση (2.2.2), η Εξίσωση (2.4.1) μπορεί να γραφεί ως

$$Y_i = E(Y | X_i) + u_i = \beta_1 + \beta_2 X_i + u_i \quad (2.4.2)$$

Η εξίσωση (2.4.2) προϋποθέτει ότι η καταναλωτική δαπάνη μίας οικογένειας σχετίζεται γραμμικά με το εισόδημα της συν το διαταρακτικό όρο. Συνεπώς, οι μεμονωμένες καταναλωτικές δαπάνες, με δεδομένη τη $X = \$80$ (βλ. Πίνακα 2.1), μπορούν να εκφραστούν ως

$$\begin{aligned} Y_1 &= 55 = \beta_1 + \beta_2(80) + u_1 \\ Y_2 &= 60 = \beta_1 + \beta_2(80) + u_2 \\ Y_3 &= 65 = \beta_1 + \beta_2(80) + u_3 \\ Y_4 &= 70 = \beta_1 + \beta_2(80) + u_4 \\ Y_5 &= 75 = \beta_1 + \beta_2(80) + u_5 \end{aligned} \quad (2.4.3)$$

Αν πάρουμε την προσδοκώμενη τιμή της Εξίσωσης (2.4.1) και στις δύο πλευρές, παίρνουμε

$$E(Y_i | X_i) = E[E(Y | X_i)] + E(u_i | X_i) = E(Y | X_i) + E(u_i | X_i) \quad (2.4.4)$$

όπου γίνεται χρήση της ιδιότητας ότι η προσδοκώμενη τιμή μίας σταθεράς είναι η ίδια η σταθερά.⁸ Πρέπει να παρατηρήσετε ότι στην Εξίσωση (2.4.4) έχουμε χρησιμοποιήσει την υπό συνθήκη προσδοκία, η οποία είναι υπό συνθήκη των δοθεισών X .

⁸ Βλ. **Παράρτημα Α** για μία σύντομη συζήτηση σχετικά με τις ιδιότητες του όρου προσδοκίας E . Σημειώστε ότι η $E(Y | X_i)$, όταν η τιμή της X_i είναι σταθερή, είναι μία σταθερά.

Εφόσον η $E(Y_i | X_i)$ είναι ακριβώς το ίδιο με την $E(Y | X_i)$, από την Εξίσωση (2.4.4) συνεπάγεται ότι

$$E(u_i | X_i) = 0 \quad (2.4.5)$$

Συνεπώς, η υπόθεση ότι η γραμμή παλινδρόμησης διατρέχει τους υπό συνθήκη μέσους της Y (βλ. Διάγραμμα 2.2) σημαίνει ότι η υπό συνθήκη μέσες τιμές του u_i (υπό συνθήκη των δοθεισών X) είναι μηδέν.

Από την προηγούμενη συζήτηση, είναι σαφές ότι η Εξ. (2.2.2) και η Εξ. (2.4.2) είναι ισοδύναμες μορφές, εφόσον $E(u_i | X_i) = 0$.⁹ Όμως, η στοχαστική μορφή της Εξ. (2.4.2) έχει το πλεονέκτημα ότι δείχνει με σαφήνεια ότι υπάρχουν και άλλες μεταβλητές, εκτός από το εισόδημα, που επηρεάζουν την καταναλωτική δαπάνη και ότι η καταναλωτική δαπάνη μίας μεμονωμένης οικογένειας δε μπορεί να εξηγηθεί πλήρως μόνο από τις μεταβλητές που συμπεριλαμβάνονται στο υπόδειγμα παλινδρόμησης.

2.5 Η Σημασία του Στοχαστικού Διαταρακτικού Όρου

Όπως σημειώνεται στην Ενότητα 2.4, ο διαταρακτικός όρος u_i είναι ένα υποκατάστατο για όλες εκείνες τις μεταβλητές που παραλείπονται από το υπόδειγμα, αλλά που επηρεάζουν συλλογικά τη Y . Το προφανές ερώτημα που προκύπτει είναι: Γιατί δεν εισάγουμε όλες αυτές τις μεταβλητές στο υπόδειγμα; Διαφορετικά, γιατί να μην αναπτύξουμε ένα υπόδειγμα πολλαπλής παλινδρόμησης με όσο το δυνατόν περισσότερες μεταβλητές; Οι λόγοι είναι πολλοί.

- ✦ *Ασάφεια της θεωρίας:* Η θεωρία, αν αυτή υπάρχει, που καθορίζει τη συμπεριφορά της Y μπορεί να είναι, και συχνά είναι, ελλιπής. Μπορεί να γνωρίζουμε με βεβαιότητα ότι το εβδομαδιαίο εισόδημα X επηρεάζει την εβδομαδιαία καταναλωτική δαπάνη Y , αλλά μπορεί να αγνοούμε ή να είμαστε αβέβαιοι αναφορικά με τις άλλες μεταβλητές που επηρεάζουν τη Y . Ως εκ τούτου, ο u_i μπορεί να χρησιμοποιηθεί ως υποκατάστατο για όλες τις μεταβλητές που δεν έχουν συμπεριληφθεί στο υπόδειγμα.
- ✦ *Μη διαθεσιμότητα στοιχείων:* Ακόμη και αν γνωρίζουμε ποιες είναι ορισμένες από τις μεταβλητές που δεν έχουν συμπεριληφθεί, μπορεί να μην έχουμε ποσοτικές πληροφορίες σχετικά με αυτές τις μεταβλητές. Είναι αρκετά συνηθισμένο στην εμπειρική ανάλυση τα στοιχεία που θα ήταν ιδανικό να έχουμε να μην είναι διαθέσιμα. Για παράδειγμα, για να εξηγήσουμε την οικογενειακή καταναλωτική δαπάνη κατ' αρχήν θα μπορούσαμε να εισαγάγουμε ως μία ερμηνευτική μεταβλητή τον πλούτο της οικογένειας εκτός από τη μεταβλητή του εισοδήματος. Δυστυχώς όμως, οι πληροφορίες σχετικά με τον πλούτο των οικογενειών δεν είναι γενικά διαθέσιμες. Ως εκ τούτου, μπορεί να είμαστε αναγκασμένοι να παραλείψουμε τη μεταβλητή πλούτο από το υπόδειγμα μας παρά τη μεγάλη θεωρητική σημασία της για την εξήγηση των καταναλωτικών δαπανών.
- ✦ *Βασικές μεταβλητές έναντι βοηθητικών μεταβλητών:* Ας υποθέσουμε ότι στο παράδειγμά μας σχετικά με τη σχέση κατανάλωσης - εισοδήματος, εκτός από το εισόδημα X_1 , ο αριθμός των παιδιών ανά οικογένεια X_2 , το φύλο X_3 , η θρησκεία X_4 , η εκπαίδευση X_5 και η γεωγραφική περιοχή X_6 , επηρεάζουν επίσης τις καταναλωτικές δαπάνες. Είναι όμως πολύ πιθανό ότι η κοινή επίδραση όλων ή ορισμένων εξ αυτών των μεταβλητών μπορεί να είναι τόσο μικρή και, στην καλύτερη περίπτωση μη συστηματική ή τυχαία οπότε πρακτικά, και για λόγους κόστους, η ρητή εισαγωγή τους στο υπόδειγμα δε θα έχει σημαντικό αποτέλεσμα. Ο ερευνητής ελπίζει ότι το συνδυασμένο τους αποτέλεσμα μπορεί να αντιμετωπίζεται ως μία τυχαία μεταβλητή u_i .¹⁰
- ✦ *Εγγενής τυχαιότητα της ανθρώπινης συμπεριφοράς:* Ακόμη και αν καταφέρουμε να εισάγουμε όλες τις σχετικές μεταβλητές στο υπόδειγμα, είναι φυσικό να υπάρχει μία «εγγενής» τυχαιότητα στις επιμέρους Y που δε μπορεί να εξηγηθεί, ασχέτως από το πόσο έντονα προσπαθούμε να το επιτύχουμε. Οι διαταρακτικοί όροι, u , μπορούν κάλλιστα να αντικατοπτρίζουν αυτήν την εγγενή τυχαιότητα.
- ✦ *Χαμηλής ποιότητας προσεγγιστικές μεταβλητές:* Αν και το κλασικό υπόδειγμα παλινδρόμησης (που θα παρουσιαστεί στο Κεφάλαιο 3) υποθέτει ότι οι μεταβλητές Y και X μετρώνται με ακρίβεια, στην πράξη, τα στοιχεία μπορεί να 'μαστίζονται' από σφάλματα μέτρησης. Για παράδειγμα, η γνωστή θεωρία του Milton Friedman όσον αφορά τη συνάρτηση κατανάλωσης.¹¹ Θεωρεί τη

⁹ Στην πραγματικότητα, στη μέθοδο των ελαχίστων τετραγώνων που θα παρουσιαστεί στο Κεφάλαιο 3, υποθέτουμε ρητά ότι η $E(u_i | X_i) = 0$. Βλ. Εν. 3.2.

¹⁰ Μία επιπλέον δυσκολία είναι ότι οι μεταβλητές όπως το φύλο, η εκπαίδευση και η θρησκεία είναι δύσκολο να ποσοτικοποιηθούν.

¹¹ Milton Friedman, *A Theory of the Consumption Function*, Princeton University Press, Princeton, N.J., 1957.

μόνιμη κατανάλωση (Y^p) ως συνάρτηση του μονίμου εισοδήματος (X^p). Καθότι όμως τα στοιχεία για τις μεταβλητές αυτές δεν είναι άμεσα παρατηρήσιμα, στην πράξη χρησιμοποιούμε προσεγγιστικές μεταβλητές, όπως η τρέχουσα κατανάλωση (Y) και το τρέχον εισόδημα (X), τα οποία είναι παρατηρήσιμα. Δεδομένου ότι οι παρατηρηθείσες τιμές των Y και X μπορεί να μην ισούνται με Y^p και X^p , υπάρχει το πρόβλημα των σφαλμάτων μέτρησης. Στη συγκεκριμένη περίπτωση, ο διαταρακτικός όρος u μπορεί να αντιπροσωπεύει επίσης σφάλματα μέτρησης. Όπως θα δούμε σε επόμενο κεφάλαιο, αν υπάρχουν τέτοια σφάλματα μέτρησης, ενδέχεται να έχουν σοβαρές επιπτώσεις στην εκτίμηση των συντελεστών παλινδρόμησης, β .

- ♦ *Αρχή της φειδούς:* Ακολουθώντας τον κανόνα του Occam (Occam's razor),¹² θα θέλαμε να διατηρήσουμε το υπόδειγμα παλινδρόμησης όσο το δυνατόν απλούστερο. Αν μπορούμε να εξηγήσουμε τη συμπεριφορά της Y «ουσιαστικά» με δύο ή τρεις ερμηνευτικές μεταβλητές και αν η θεωρία μας δεν είναι αρκετά ισχυρή ώστε να προτείνει ποιες μπορεί να είναι οι υπόλοιπες μεταβλητές που μπορούν να συμπεριληφθούν, ποιος ο λόγος να εισάγουμε περισσότερες μεταβλητές; Ας αντιπροσωπεύονται όλες οι υπόλοιπες μεταβλητές από το u_i . Ασφαλώς, δεν πρέπει να αποκλείουμε τις σχετικές και σημαντικές μεταβλητές απλώς και μόνο για να διατηρήσουμε το υπόδειγμα παλινδρόμησης απλό.
- ♦ *Λανθασμένη συναρτησιακή μορφή:* Ακόμη και αν έχουμε θεωρητικά σωστές μεταβλητές οι οποίες εξηγούν ένα φαινόμενο και ακόμη και αν μπορούμε να αποκτήσουμε στοιχεία σχετικά με αυτές τις μεταβλητές, πολύ συχνά δε γνωρίζουμε τη μορφή της συναρτησιακής σχέσης μεταξύ των παλινδρομούμενων μεταβλητών και των παλινδρομητών. Είναι η καταναλωτική δαπάνη μία γραμμική (αμετάβλητη) συνάρτηση του εισοδήματος ή μία μη γραμμική (αμετάβλητη) συνάρτηση αυτού; Αν είναι το πρώτο, τότε η σωστή συναρτησιακή σχέση μεταξύ των Y και X είναι η $Y_i = \beta_1 + \beta_2 X_i + u_i$, εάν όμως είναι το δεύτερο τότε η σωστή συναρτησιακή σχέση είναι $Y_i = \beta_1 + \beta_2 X_i + \beta_3 X_i^2 + u_i$. Στα διμεταβλητά υποδείγματα η συναρτησιακή μορφή της σχέσης μπορεί συχνά να επιλεγεί από τα διαγράμματα διασποράς. Όμως σε ένα υπόδειγμα πολλαπλής παλινδρόμησης, δεν είναι εύκολο να προσδιοριστεί η κατάλληλη συναρτησιακή μορφή, καθώς δε μπορούμε να απεικονίσουμε γραφικά τα διαγράμματα διασποράς σε πολλαπλές διαστάσεις.

Για όλους αυτούς τους λόγους, οι στοχαστικοί διαταρακτικοί όροι u_i διαδραματίζουν έναν εξαιρετικά κρίσιμο ρόλο στην ανάλυση παλινδρόμησης, τον οποίο θα δούμε όσο προχωρούμε στο παρόν βιβλίο.

2.6 Η Συνάρτηση Παλινδρόμησης του Δείγματος (SRF)

Περιορίζοντας τη συζήτησή μας μέχρι τώρα στον πληθυσμό των τιμών της Y που αντιστοιχούν στις σταθερές X , αποφύγαμε συνειδητά ζητήματα δειγματοληψίας (Σημειώστε ότι τα στοιχεία του Πίνακα 2.1 αντιπροσωπεύουν τον πληθυσμό, όχι ένα δείγμα). Στο σημείο αυτό όμως πρέπει να αντιμετωπίσουμε τα προβλήματα δειγματοληψίας, καθότι στις περισσότερες περιπτώσεις αυτό που έχουμε δεν είναι παρά ένα δείγμα των τιμών της Y που αντιστοιχούν σε κάποιες σταθερές X . Ως εκ τούτου, τώρα πρέπει να εκτιμήσουμε την PRF βάσει των πληροφοριών που έχουμε για το δείγμα.

Ως παράδειγμα, ας υποθέσουμε ότι ο πληθυσμός του Πίνακα 2.1 δεν ήταν γνωστός σε μας και οι μόνες πληροφορίες που είχαμε ήταν ένα τυχαία επιλεγμένο δείγμα των τιμών της Y για τις σταθερές X , όπως αυτά δίνονται στον Πίνακα 2.4. Σε αντίθεση με τον Πίνακα 2.1, τώρα έχουμε μόνο μία τιμή Y που αντιστοιχεί στα στοιχεία για τη X κάθε Y (δοθεισών των X_i) στον Πίνακα 2.4 επιλέγεται τυχαία από τις παρόμοιες Y που αντιστοιχούν στις ίδιες X_i από τον πληθυσμό του Πίνακα 2.1.

Το ερώτημα είναι: Μπορούμε να προβλέψουμε, από το δείγμα του Πίνακα 2.4, τη μέση εβδομαδιαία καταναλωτική δαπάνη Y του συνόλου του πληθυσμού η οποία αντιστοιχεί στις επιλεγμένες X ; Με άλλα λόγια, μπορούμε να εκτιμήσουμε την PRF από το δείγμα; Όπως μπορεί να υποπτευθεί ο αναγνώστης, ενδεχομένως να μην είμαστε σε θέση να εκτιμήσουμε την PRF με «ακρίβεια» λόγω διακυμάνσεων στη δειγματοληψία. Για να το διαπιστώσουμε, ας υποθέσουμε ότι εξάγουμε ένα επιπλέον τυχαίο δείγμα από τον πληθυσμό του Πίνακα 2.1, όπως παρουσιάζεται στον Πίνακα 2.5.

¹² "That descriptions be kept as simple as possible until proved inadequate," *The World of Mathematics*, vol. 2, J. R. Newman (ed.), Simon & Schuster, New York, 1956, σελ. 1247, ή, "Entities should not be multiplied beyond necessity," Donald F. Morrison, *Applied Linear Statistical Methods*, Prentice Hall, Englewood Cliffs, N.J., 1983, σελ. 58.


Παρουσιάζοντας διαγραμματικά τα στοιχεία των Πινάκων 2.4 και 2.5, παίρνουμε το Διάγραμμα 2.4. Σε αυτό το διάγραμμα διασποράς σχεδιάζονται δύο γραμμές παλινδρόμησης δείγματος (sample regression lines, SRF) ούτως ώστε να «προσαρμόζονται» αρκετά καλά στα σημεία: Η SRF_1 προέρχεται από το πρώτο δείγμα, και η SRF_2 προέρχεται από το δεύτερο δείγμα. Ποια από τις δύο γραμμές παλινδρόμησης αντιπροσωπεύει την «πραγματική» γραμμή παλινδρόμησης του πληθυσμού; Αν δεν κοιτάξουμε το Διάγραμμα 2.1, το οποίο υποτίθεται ότι αντιπροσωπεύει την παλινδρόμηση του πληθυσμού, δεν υπάρχει τρόπος ώστε να είμαστε απολύτως βέβαιοι ότι κάποια από τις δύο γραμμές παλινδρόμησης που παρουσιάζονται στο Διάγραμμα 2.4 αντιπροσωπεύει την πραγματική γραμμή (ή καμπύλη) παλινδρόμησης του πληθυσμού. Οι γραμμές παλινδρόμησης στο Διάγραμμα 2.4 υποθετικά, αντιπροσωπεύουν τη γραμμή παλινδρόμησης του πληθυσμού, όμως λόγω διακυμάνσεων στη δειγματοληψία είναι στην καλύτερη περίπτωση μία προσέγγιση της πραγματικής παλινδρόμησης του πληθυσμού. Σε γενικές γραμμές, θα παίρναμε N διαφορετικές SRF για N διαφορετικά δείγματα, και αυτές οι SRF δεν είναι πιθανό να είναι οι ίδιες.

ΠΙΝΑΚΑΣ 2.4 Πρώτο Τυχαιο Δείγμα
από τον Πληθυσμό του Πίνακα 2.1

Y	X
70	80
65	100
90	120
95	140
110	160
115	180
120	200
140	220
155	240
150	260

ΠΙΝΑΚΑΣ 2.5 Δεύτερο Τυχαιο Δείγμα
από τον Πληθυσμό του Πίνακα 2.1

Y	X
55	80
88	100
90	120
80	140
118	160
120	180
145	200
135	220
145	240
175	260



ΔΙΑΓΡΑΜΜΑ 2.4 Γραμμές παλινδρόμησης που βασίζονται σε δύο διαφορετικά δείγματα.

Τώρα, κατ' αναλογία με την PRF στην οποία βασίζεται η γραμμή παλινδρόμησης του πληθυσμού, μπορούμε να αναπτύξουμε την έννοια της **συνάρτησης παλινδρόμησης του δείγματος** (SRF) η οποία θα εκπροσωπεί τη γραμμή παλινδρόμησης του δείγματος. Το αντίστοιχο της Εξίσωσης (2.2.2) σε όρους δείγματος μπορεί να γραφεί ως:

$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i \quad (2.6.1)$$

όπου $\hat{Y}$ διαβάζεται ως «Y-καπέλο»

$\hat{Y}_i$ = εκτιμητής της $E(Y | X_i)$

$\hat{\beta}_1$ = εκτιμητής του β_1

$\hat{\beta}_2$ = εκτιμητής του β_2

Σημειώστε ότι ένας **εκτιμητής** (estimator), γνωστός και ως **στατιστική** (του δείγματος), είναι απλά ένας κανόνας ή ένας τύπος ή μία μέθοδος που δηλώνει πως να εκτιμήσουμε την παράμετρο του πληθυσμού από τις πληροφορίες που παρέχονται από το δείγμα που έχουμε στη διάθεσή μας. Μία συγκεκριμένη αριθμητική τιμή που λαμβάνεται από τον εκτιμητή σε μία εφαρμογή είναι γνωστή ως **εκτίμηση** (estimate).¹³ Πρέπει να τονίσουμε ότι ένας εκτιμητής είναι τυχαίος, ενώ μία εκτίμηση μη τυχαία. (Γιατί;)

Τώρα, όπως ακριβώς εκφράσαμε την PRF σε δύο ισοδύναμες μορφές, Εξ. (2.2.2) και Εξ. (2.4.2), μπορούμε να εκφράσουμε την SRF στην Εξίσωση (2.6.1) στη στοχαστική της μορφή, ως εξής:

$$Y_i = \beta_1 + \beta_2 X_i + \hat{u}_i \quad (2.6.2)$$

όπου, εκτός από τα σύμβολα που έχουν ήδη οριστεί, ο $\hat{u}_i$ δηλώνει τον όρο των **καταλοίπων** (residual) (του δείγματος). Εννοιολογικά, ο $\hat{u}_i$ είναι ανάλογος του u_i και μπορεί να θεωρηθεί ως μία **εκτίμηση** του u_i . Έχει εισαχθεί στην SRF για τους ίδιους λόγους που εισήχθη ο u_i στην PRF.


Για να συνοψίσουμε, ο πρωταρχικός στόχος μας στην ανάλυση παλινδρόμησης είναι να εκτιμήσουμε την PRF:

$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

βάσει της SRF:

$$Y_i = \hat{\beta}_1 + \hat{\beta}_2 X_i + \hat{u}_i$$

καθώς τις περισσότερες φορές η ανάλυση μας βασίζεται σε ένα δείγμα που προέρχεται από κάποιο πληθυσμό. Όμως λόγω των διακυμάνσεων στη δειγματοληψία, η εκτίμησή μας της PRF βάσει της SRF είναι στην καλύτερη περίπτωση μία προσέγγιση. Αυτή η προσέγγιση απεικονίζεται διαγραμματικά στο Διάγραμμα 2.5.



ΔΙΑΓΡΑΜΜΑ 2.5 Γραμμές παλινδρόμησης δείγματος και πληθυσμού.

¹³ Όπως σημειώνεται στην Εισαγωγή, ένα καπέλο πάνω από μία μεταβλητή θα σημαίνει έναν εκτιμητή της σχετικής τιμής του πληθυσμού.

Για $X = X_i$, έχουμε μία παρατήρηση (του δείγματος) $Y = Y_i$. Σε όρους της SRF, η παρατηρούμενη Y_i μπορεί να εκφραστεί ως:

$$Y_i = \hat{Y}_i + \hat{u}_i \quad (2.6.3)$$

και σε όρους της PRF, μπορεί να εκφραστεί ως

$$Y_i = E(Y | X_i) + u_i \quad (2.6.4)$$

Τώρα προφανώς στο Διάγραμμα 2.5, ο $\hat{Y}_i$ *υπερεκτιμά* την πραγματική $E(Y | X_i)$ για τις X_i . Με την ίδια λογική, για κάθε X_i προς τα αριστερά του σημείου A , η SRF θα *υποεκτιμά* την πραγματική PRF. Όμως ο αναγνώστης μπορεί να δει με ευκολία ότι αυτή η υπερεκτίμηση και η υποεκτίμηση είναι αναπόφευκτες, λόγω των διακυμάνσεων στη δειγματοληψία.

Το κρίσιμο ερώτημα τώρα είναι: Με δεδομένο ότι η SRF, δεν είναι παρά μία προσέγγιση της PRF, μπορούμε να επινοήσουμε έναν κανόνα ή μία μέθοδο που θα κάνει αυτή την προσέγγιση όσο το δυνατόν «καλύτερη»; Με άλλα λόγια, πώς θα πρέπει να κατασκευάζεται η SRF έτσι ώστε η $\hat{\beta}_1$ να είναι όσο το δυνατόν «πλησιέστερα» στον πραγματικό β_1 και η $\hat{\beta}_2$ να είναι όσο το δυνατόν «πλησιέστερα» στον πραγματικό β_2 , παρόλο που δε θα γνωρίζουμε ποτέ τους πραγματικούς β_1 και β_2 ;

Η απάντηση στο ερώτημα αυτό θα μας απασχολήσει σε μεγάλο βαθμό στο Κεφάλαιο 3. Αξίζει να σημειωθεί ότι μπορούμε να αναπτύξουμε διαδικασίες οι οποίες μας καθοδηγούν στον τρόπο κατασκευής της SRF ώστε να αντικατοπτρίζει την PRF όσο το δυνατόν πιστότερα. Είναι συναρπαστικό ότι αυτό μπορεί να γίνει ακόμα κι αν ποτέ δεν έχουμε προσδιορίσει την ίδια την PRF.

2.7 Χαρακτηριστικά Παραδείγματα

Ολοκληρώνουμε το παρόν κεφάλαιο με δύο παραδείγματα.

ΠΑΡΑΔΕΙΓΜΑ 2.1 Μέσο Ωρομίσθιο βάσει Εκπαίδευσης

Ο Πίνακας 2.6 παρουσιάζει στοιχεία για το επίπεδο εκπαίδευσης (με βάση τον αριθμό των ετών φοίτησης), το μέσο ωρομίσθιο που κερδίζουν οι άνθρωποι σε κάθε επίπεδο εκπαίδευσης, καθώς και τον αριθμό των ανθρώπων στο εκάστοτε επίπεδο εκπαίδευσης. Ο Ernst Berndt αρχικά συγκέντρωσε τα στοιχεία που παρουσιάζονται στον πίνακα, και αυτά προέρχονται από την έρευνα για τον πληθυσμό που διεξήχθη το Μάιο του 1985.¹⁴

ΠΙΝΑΚΑΣ 2.6 Μέσο Ωρομίσθιο βάσει Εκπαίδευσης

Έτη Φοίτησης	Μέσος Μισθός, \$	Αριθμός Ατόμων
6	4,4567	3
7	5,7700	5
8	5,9787	15
9	7,3317	12
10	7,3182	17
11	6,5844	27
12	7,8182	218
13	7,8351	37
14	11,0223	56
15	10,6738	13
16	10,8361	70
17	13,6150	24
18	13,5310	31
Σύνολο		528

Πηγή: Arthur S. Goldberger, *Introductory Econometrics*, Harvard University Press, Cambridge, Mass., 1998, Πίνακας 1.1, σελ. 5 (προσαρμοσμένος Πίνακας).

¹⁴ Ernst R. Berndt, *The Practice of Econometrics: Classic and Contemporary*, Addison Wesley, Reading, Mass., 1991. Παρεμπιπτόντως, αυτό είναι ένα εξαιρετικό βιβλίο στο οποίο ο αναγνώστης μπορεί να μάθει πώς πραγματοποιούν έρευνα οι οικονομήτρες.

Κεφάλαιο 3

Διμεταβλητό Υπόδειγμα Παλινδρόμησης: Το Πρόβλημα της Εκτίμησης

Όπως επισημάναμε στο Κεφάλαιο 2, αρχικά εκτιμούμε τη συνάρτηση παλινδρόμησης του πληθυσμού (PRF) βάσει της συνάρτησης παλινδρόμησης του δείγματος (SRF) όσο το δυνατόν ακριβέστερα. Στο **Παράρτημα Α**, στο τέλος του βιβλίου, παρουσιάζουμε τις πλέον διαδεδομένες μεθόδους εκτίμησης: **των ελαχίστων τετραγώνων (OLS)** και της **μέγιστης πιθανοφάνειας** (maximum likelihood - ML). Σε γενικές γραμμές, η μέθοδος των ελαχίστων τετραγώνων (OLS) είναι αυτή που χρησιμοποιείται εκτενώς στην ανάλυση παλινδρόμησης κυρίως επειδή είναι διαισθητικά ελκυστικότερη και μαθηματικά πολύ απλούστερη από τη μέθοδο της μέγιστης πιθανοφάνειας. Εκτός αυτού, όπως θα δείξουμε αργότερα, στο πλαίσιο της γραμμικής παλινδρόμησης, οι δύο μέθοδοι οδηγούν σε παρόμοια αποτελέσματα.

3.1 Η Μέθοδος των Ελαχίστων Τετραγώνων

Η μέθοδος των ελαχίστων τετραγώνων αποδίδεται στον Carl Friedrich Gauss, ένα Γερμανό μαθηματικό. Υπό ορισμένες προϋποθέσεις (που αναλύονται στην Ενότητα 3.2), η μέθοδος των ελαχίστων τετραγώνων έχει ορισμένες πολύ ελκυστικές στατιστικές ιδιότητες που την έχουν καταστήσει μία από τις πιο ισχυρές και δημοφιλείς μεθόδους ανάλυσης παλινδρόμησης. Για να κατανοήσουμε αυτή τη μέθοδο, θα εξηγήσουμε πρώτα την αρχή των ελαχίστων τετραγώνων.

Υπενθυμίζεται ότι η διμεταβλητή PRF:

$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

δεν είναι άμεσα παρατηρήσιμη και την εκτιμούμε από την SRF:

$$\begin{aligned} Y_i &= \hat{\beta}_1 + \hat{\beta}_2 X_i + \hat{u}_i \\ &= \hat{Y}_i + \hat{u}_i \end{aligned}$$

όπου $\hat{Y}_i$ είναι η εκτιμηθείσα (υπό συνθήκη μέσης) τιμή της Y_i .

Πώς καθορίζεται όμως η ίδια η SRF; Για να το κατανοήσουμε αυτό, ας προχωρήσουμε ως εξής. Κατ' αρχάς, παρουσιάζουμε την Εξίσωση 2.6.3 ως

$$\begin{aligned} \hat{u}_i &= Y_i - \hat{Y}_i \\ &= Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i \end{aligned} \tag{3.1.1}$$


που δείχνει ότι τα $\hat{u}_i$ (τα κατάλοιπα) είναι απλώς οι διαφορές μεταξύ των πραγματικών και των εκτιμημένων τιμών της Y .

Τώρα δοθέντων n ζευγών παρατηρήσεων των Y και X , θα θέλαμε να καθορίσουμε την SRF με τέτοιο τρόπο ώστε να είναι όσο το δυνατόν πλησιέστερα στην πραγματική Y . Για το σκοπό αυτό, μπορεί να υιοθετήσουμε το ακόλουθο κριτήριο: Επιλέγουμε την SRF με τέτοιο τρόπο ώστε το άθροισμα των καταλοίπων $\sum \hat{u}_i = \sum (Y_i - \hat{Y}_i)$ να είναι όσο το δυνατόν μικρότερο. Αν και διαισθητικά ελκυστικό, αυτό δεν είναι ένα πολύ καλό κριτήριο, όπως φαίνεται και στο υποθετικό διάγραμμα διασποράς που παρουσιάζεται στο Διάγραμμα 3.1.

Αν υιοθετήσουμε το κριτήριο της ελαχιστοποίησης του $\sum \hat{u}_i$, το Διάγραμμα 3.1 δείχνει ότι τα κατάλοιπα $\hat{u}_2$ και $\hat{u}_3$, καθώς και τα κατάλοιπα $\hat{u}_1$ και $\hat{u}_4$ έχουν την ίδια βαρύτητα στο άθροισμα $\hat{u}_1 + \hat{u}_2 + \hat{u}_3 + \hat{u}_4$, αν και τα δύο πρώτα κατάλοιπα βρίσκονται πολύ πιο κοντά στην SRF σε σχέση με τα δύο τελευταία. Με άλλα λόγια, όλα τα κατάλοιπα έχουν την ίδια σημασία ανεξάρτητα από το πόσο κοντά ή πόσο μακριά είναι διάσπαρτες οι επιμέρους παρατηρήσεις από την SRF. Μία συνέπεια αυτού είναι ότι είναι αρκετά πιθανό το αλγεβρικό άθροισμα των $\hat{u}_i$ να είναι μικρό (ακόμα και μηδέν) παρόλο που τα $\hat{u}_i$ είναι διασκορπισμένα μακριά από την SRF. Για να γίνει αυτό πιο κατανοητό, ας υποθέσουμε ότι τα $\hat{u}_1$, $\hat{u}_2$, $\hat{u}_3$, και $\hat{u}_4$ στο Διάγραμμα 3.1 παίρνουν τις τιμές 10, -2, +2, και -10, αντίστοιχα. Το αλγεβρικό άθροισμα αυτών των καταλοίπων είναι μηδέν παρόλο που τα $\hat{u}_1$ και $\hat{u}_4$ είναι διάσπαρτα ευρύτερα γύρω από την SRF από ότι τα $\hat{u}_2$ και $\hat{u}_3$. Μπορούμε να αποφύγουμε αυτό το πρόβλημα αν υιοθετήσουμε το κριτήριο των ελαχίστων τετραγώνων, το οποίο ορίζει ότι η SRF μπορεί να καθοριστεί με τέτοιο τρόπο ώστε το

$$\begin{aligned}\sum \hat{u}_i^2 &= \sum (Y_i - \hat{Y}_i)^2 \\ &= \sum (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i)^2\end{aligned}\quad (3.1.2)$$

-να είναι όσο το δυνατόν μικρότερο, όπου $\hat{u}_i^2$ είναι το τετράγωνο των καταλοίπων. Τετραγωνίζοντας τα $\hat{u}_i$, αυτή η μέθοδος δίνει περισσότερη βαρύτητα σε κατάλοιπα όπως τα $\hat{u}_1$ και $\hat{u}_4$ στο Διάγραμμα 3.1 από ότι στα κατάλοιπα $\hat{u}_2$ και $\hat{u}_3$. Όπως αναφέρθηκε προηγουμένως, με βάση το κριτήριο του ελαχίστου $\sum \hat{u}_i$, το άθροισμα μπορεί να είναι μικρό, ακόμη κι αν τα $\hat{u}_i$ είναι διάσπαρτα μακριά γύρω από την SRF. Όμως αυτό δεν είναι δυνατόν στο πλαίσιο της μεθόδου των ελαχίστων τετραγώνων, καθώς όσο μεγαλύτερα είναι τα $\hat{u}_i$ (σε απόλυτη τιμή), τόσο μεγαλύτερο θα είναι το $\sum \hat{u}_i^2$. Μία περαιτέρω αιτιολόγηση για τη χρήση της μεθόδου των ελαχίστων τετραγώνων έγκειται στο γεγονός ότι οι εκτιμητές που προκύπτουν από αυτήν, έχουν ορισμένες πολύ επιθυμητές στατιστικές ιδιότητες, όπως θα δούμε σύντομα.



ΔΙΑΓΡΑΜΜΑ 3.1 Κριτήριο των ελαχίστων τετραγώνων

ΠΙΝΑΚΑΣ 3.1 Πειραματικός Προσδιορισμός της SRF

Y_i	X_i	$\hat{Y}_{1i}$	$\hat{u}_{1i}$	$\hat{u}_{1i}^2$	$\hat{Y}_{2i}$	$\hat{u}_{2i}$	$\hat{u}_{2i}^2$
(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
4	1	2,929	1,071	1,147	4	0	0
5	4	7,000	-2,000	4,000	7	-2	4
7	5	8,357	-1,357	1,841	8	-1	1
12	6	9,714	2,286	5,226	9	3	9
Σύνολο: 28	16		0,0	12,214		0	14

Σημειώσεις: $\hat{Y}_{1i} = 1,572 + 1,357X_i$ (δηλ. $\hat{\beta}_1 = 1,572$ και $\hat{\beta}_2 = 1,357$), $\hat{Y}_{2i} = 3 + 1X_i$ (δηλ. $\hat{\beta}_1 = 3$ και $\hat{\beta}_2 = 1$), $\hat{u}_{1i} = (Y_i - \hat{Y}_{1i})$, $\hat{u}_{2i} = (Y_i - \hat{Y}_{2i})$.

Είναι προφανές από την Εξίσωση 3.1.2 ότι

$$\sum \hat{u}_i^2 = f(\hat{\beta}_1, \hat{\beta}_2) \quad (3.1.3)$$

δηλαδή, το άθροισμα των τετραγώνων των καταλοίπων είναι κάποια συνάρτηση των εκτιμητών $\hat{\beta}_1$ και $\hat{\beta}_2$. Για κάθε σύνολο στοιχείων, η επιλογή διαφορετικών τιμών για τους $\hat{\beta}_1$ και $\hat{\beta}_2$ δίνει διαφορετικά $\hat{u}$ και ως εκ τούτου διαφορετικές τιμές για το $\sum \hat{u}_i^2$. Για να καταστεί αυτό σαφές, ας εξετάσουμε τα υποθετικά στοιχεία για τις Y και X που παρουσιάζονται στις δύο πρώτες στήλες του Πίνακα 3.1. Ας πραγματοποιήσουμε τώρα δύο πειράματα. Στο πείραμα 1, έστω ότι $\hat{\beta}_1 = 1,572$ και $\hat{\beta}_2 = 1,357$ (προς το παρόν μη σας απασχολεί πώς καταλήξαμε σε αυτές τις τιμές).¹ Χρησιμοποιώντας αυτές τις τιμές για τους $\hat{\beta}$ και τις τιμές της X που παρουσιάζονται στη στήλη (2) του Πίνακα 3.1, μπορούμε με ευκολία να υπολογίσουμε την εκτιμημένη $\hat{Y}_i$ η οποία δίνεται στη στήλη (3) του πίνακα ως $\hat{Y}_{1i}$ (ο δείκτης 1 υποδηλώνει το πρώτο πείραμα). Τώρα ας πραγματοποιήσουμε ένα ακόμη πείραμα, χρησιμοποιώντας όμως αυτή τη φορά τις τιμές $\hat{\beta}_1 = 3$ και $\hat{\beta}_2 = 1$. Οι εκτιμημένες τιμές της Y_i από αυτό πείραμα δίνονται ως $\hat{Y}_{2i}$ στη στήλη (6) του Πίνακα 3.1. Δεδομένου ότι οι τιμές των $\hat{\beta}$ στα δύο πειράματα είναι διαφορετικές, θα έχουμε διαφορετικές τιμές για τα εκτιμημένα κατάλοιπα, όπως φαίνεται στον πίνακα. Τα κατάλοιπα από το πρώτο πείραμα είναι $\hat{u}_{1i}$ και από το δεύτερο πείραμα είναι $\hat{u}_{2i}$. Τα τετράγωνα των καταλοίπων αυτών δίνονται στις στήλες (5) και (8). Προφανώς, όπως αναμένεται από την Εξίσωση 3.1.3, αυτά τα αθροίσματα των τετραγώνων των καταλοίπων είναι διαφορετικά καθώς βασίζονται σε διαφορετικά σύνολα τιμών των $\hat{\beta}$.

Ποια σύνολα τιμών $\hat{\beta}$ θα πρέπει να επιλέξουμε; Εφόσον οι τιμές των $\hat{\beta}$ του πρώτου πειράματος μας δίνουν ένα χαμηλότερο $\sum \hat{u}_i^2$ ($= 12.214$) από αυτό που προκύπτει από τις τιμές των $\hat{\beta}$ του δεύτερου πειράματος ($= 14$), θα μπορούσαμε να πούμε ότι οι $\hat{\beta}$ του πρώτου πειράματος είναι οι «καλύτερες» τιμές. Πώς το γνωρίζουμε όμως; Εάν είχαμε άπειρο χρόνο και άπειρη υπομονή, θα μπορούσαμε να διεξάγουμε πολλά περισσότερα πειράματα, επιλέγοντας διαφορετικά σύνολα $\hat{\beta}$ κάθε φορά και συγκρίνοντάς το $\sum \hat{u}_i^2$ και επιλέγοντας, στη συνέχεια, το σύνολο των τιμών $\hat{\beta}$ που μας δίνει την ελάχιστη δυνατή τιμή του $\sum \hat{u}_i^2$ υποθέτοντας, φυσικά, ότι έχουμε εξετάσει όλες τις πιθανές τιμές των β_1 και β_2 . Επειδή όμως ο χρόνος, και σίγουρα η υπομονή, είναι περιορισμένα, πρέπει να εξετάσουμε κάποιες συντομεύσεις σε αυτή τη διαδικασία δοκιμής και λάθους. Ευτυχώς, η μέθοδος των ελαχίστων τετραγώνων μας προσφέρει μία τέτοια συντόμηση. Η αρχή ή η μέθοδος των ελαχίστων τετραγώνων επιλέγει τους $\hat{\beta}_1$ και $\hat{\beta}_2$ με τέτοιο τρόπο ώστε, για ένα δεδομένο δείγμα ή ένα σύνολο στοιχείων, το $\sum \hat{u}_i^2$ είναι όσο το δυνατόν μικρότερο. Με άλλα λόγια, για ένα δεδομένο δείγμα, η μέθοδος των ελαχίστων τετραγώνων μας παρέχει μοναδικούς εκτιμητές των β_1 και β_2 που δίνουν τη μικρότερη δυνατή τιμή του $\sum \hat{u}_i^2$. Πώς επιτυγχάνεται αυτό; Αυτό είναι μία απλή άσκηση διαφορικού λογισμού. Όπως παρουσιάζεται στο Παράρτημα 3Α, Ενότητα 3Α.1, η διαδικασία της παραγώγισης δίνει τις παρακάτω εξισώσεις για την εκτίμηση των β_1 και β_2 :

$$\sum Y_i = n\hat{\beta}_1 + \hat{\beta}_2 \sum X_i \quad (3.1.4)$$

¹ Οι τιμές αυτές προκύπτουν από τη μέθοδο των ελαχίστων τετραγώνων. Δείτε τις Εξισώσεις (3.1.6) και (3.1.7).

$$\sum Y_i X_i = \hat{\beta}_1 \sum X_i + \hat{\beta}_2 \sum X_i^2 \quad (3.1.5)$$

όπου n είναι το μέγεθος του δείγματος. Αυτές οι ταυτόχρονες εξισώσεις είναι γνωστές ως **κανονικές εξισώσεις** (normal equations).

Λύνοντας τις κανονικές εξισώσεις ταυτόχρονα, έχουμε

$$\begin{aligned} \hat{\beta}_2 &= \frac{n \sum X_i Y_i - \sum X_i \sum Y_i}{n \sum X_i^2 - (\sum X_i)^2} \\ &= \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} \\ &= \frac{\sum x_i y_i}{\sum x_i^2} \end{aligned} \quad (3.1.6)$$

όπου $\bar{X}$ και $\bar{Y}$ είναι οι μέσοι του δείγματος των X και Y και ορίζουμε $x_i = (X_i - \bar{X})$ και $y_i = (Y_i - \bar{Y})$. Στο εξής, θεωρούμε ότι τα πεζά γράμματα υποδηλώνουν αποκλίσεις από τις μέσες τιμές.

$$\begin{aligned} \hat{\beta}_1 &= \frac{\sum X_i^2 \sum Y_i - \sum X_i \sum X_i Y_i}{n \sum X_i^2 - (\sum X_i)^2} \\ &= \bar{Y} - \hat{\beta}_2 \bar{X} \end{aligned} \quad (3.1.7)$$

Το τελευταίο βήμα για την Εξίσωση 3.1.7 προκύπτει απευθείας από την Εξ. (3.1.4) με απλούς αλγεβρικούς χειρισμούς.

Παραεμπιπτόντως, σημειώστε ότι, χρησιμοποιώντας απλές αλγεβρικές ταυτότητες, ο τύπος (3.1.6) για την εκτίμηση του β_2 μπορεί να εκφραστεί ως²

$$\hat{\beta}_2 = \frac{\sum x_i y_i}{\sum x_i^2} = \frac{\sum x_i Y_i}{\sum X_i^2 - n\bar{X}^2} = \frac{\sum X_i y_i}{\sum X_i^2 - n\bar{X}^2} \quad (3.1.8)$$

Οι εκτιμητές που έχουν προκύψει είναι γνωστοί ως **εκτιμητές των ελαχίστων τετραγώνων** (least-squares estimators), καθώς προέρχονται από την αρχή των ελαχίστων τετραγώνων. Σημειώστε τις ακόλουθες **αριθμητικές ιδιότητες** των εκτιμητών που προκύπτουν από τη μέθοδο OLS: «Οι αριθμητικές ιδιότητες είναι εκείνες που ισχύουν λόγω της χρήσης των ελαχίστων τετραγώνων, ανεξάρτητα από το πώς προέκυψαν τα στοιχεία».³ Θα εξετάσουμε επίσης τις **στατιστικές ιδιότητες** των εκτιμητών της OLS, δηλαδή, τις ιδιότητες «που ισχύουν μόνο με βάση ορισμένες υποθέσεις σχετικά με τον τρόπο που προέκυψαν τα στοιχεία».⁴ (Βλ. το κλασικό γραμμικό υπόδειγμα παλινδρόμησης στην Ενότητα 3.2.)


- ✦ Οι εκτιμητές της OLS εκφράζονται μόνο σε όρους παρατηρήσιμων (δηλαδή, δειγματικών) ποσοτήτων (δηλαδή, των X και Y). Ως εκ τούτου, μπορούν να υπολογιστούν με ευκολία.
- ✦ Είναι **σημειακοί εκτιμητές** (point estimators): δηλαδή, δοθέντος του δείγματος, κάθε εκτιμητής θα παρέχει μόνο μία συγκεκριμένη (σημειακή) τιμή της σχετικής παραμέτρου του πληθυσμού. (Στο Κεφάλαιο 5 θα εξετάσουμε τους λεγόμενους **εκτιμητές διαστημάτων** (interval estimators), οι οποίοι παρέχουν ένα εύρος πιθανών τιμών για τις άγνωστες παραμέτρους του πληθυσμού.)
- ✦ Μόλις οι εκτιμητές της OLS προκύψουν από το δείγμα, η γραμμή παλινδρόμησης του δείγματος (Διάγραμμα 3.1) μπορεί να προκύψει πολύ εύκολα. Η γραμμή παλινδρόμησης που προκύπτει έχει τις ακόλουθες ιδιότητες:

²Σημείωση 1: $\sum x_i^2 = \sum (X_i - \bar{X})^2 = \sum X_i^2 - 2 \sum X_i \bar{X} + \sum \bar{X}^2 = \sum X_i^2 - 2\bar{X} \sum X_i + \sum \bar{X}^2$ καθώς $\bar{X}$ είναι μία σταθερά. Επιπλέον, επισημαίνουμε ότι, $\sum X_i = n\bar{X}$ και $\sum \bar{X}^2 = n\bar{X}^2$ καθώς $\bar{X}$ είναι μία σταθερά. Τελικά $\sum x_i^2 = \sum X_i^2 - n\bar{X}^2$.

Σημείωση 2: $\sum x_i y_i = \sum x_i (Y_i - \bar{Y}) = \sum x_i Y_i - \bar{Y} \sum x_i = \sum x_i Y_i - \bar{Y} \sum (X_i - \bar{X}) = \sum x_i Y_i$ καθώς $\bar{Y}$ είναι μία σταθερά και καθώς το άθροισμα των αποκλίσεων μίας μεταβλητής από τη μέση τιμή της [π.χ. $\sum (X_i - \bar{X})$] είναι πάντα μηδέν. Ομοίως, $\sum y_i = \sum (Y_i - \bar{Y}) = 0$

³Russell Davidson and James G. MacKinnon, *Estimation and Inference in Econometrics*, Oxford University Press, New York, 1993, σελ. 3.

⁴Ο.π.



ΔΙΑΓΡΑΜΜΑ 3.2 Το διάγραμμα δείχνει ότι η γραμμή παλινδρόμησης του δείγματος διέρχεται από τις μέσες τιμές των δειγμάτων των Y και X .

1. Διέρχεται από τις μέσες τιμές των δειγμάτων των Y και X . Το γεγονός αυτό είναι προφανές από την Εξ. (3.1.7), καθώς η τελευταία μπορεί να γραφεί ως $\bar{Y} = \hat{\beta}_1 + \hat{\beta}_2 \bar{X}$, το οποίο παρουσιάζεται στο Διάγραμμα 3.2.
2. Η μέση τιμή της εκτιμημένης $Y = \hat{Y}_i$ είναι ίση με τη μέση τιμή της πραγματικής Y για

$$\begin{aligned}\hat{Y}_i &= \hat{\beta}_1 + \hat{\beta}_2 X_i \\ &= (\bar{Y} - \hat{\beta}_2 \bar{X}) + \hat{\beta}_2 X_i \\ &= \bar{Y} + \hat{\beta}_2 (X_i - \bar{X})\end{aligned}\quad (3.1.9)$$

Αθροίζοντας τις δύο πλευρές αυτής της τελευταίας ισότητας με τις τιμές του δείγματος και διαιρώντας με το μέγεθος του δείγματος n παίρνουμε

$$\bar{\hat{Y}} = \bar{Y} \quad (3.1.10)^5$$

όπου χρησιμοποιείται η υπόθεση $\sum (X_i - \bar{X}) = 0$ (Γιατί;)

3. Η μέση τιμή των καταλοίπων $\hat{u}_i$ είναι μηδέν. Από το Παράρτημα 3Α, Ενότητα 3Α.1, η πρώτη εξίσωση είναι

$$-2 \sum (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i) = 0$$

Όμως, δεδομένου ότι $\hat{u}_i = Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i$, η προηγούμενη εξίσωση γίνεται $-2 \sum \hat{u}_i = 0$, όπου $\bar{\hat{u}} = 0$.⁶ Ως αποτέλεσμα της προηγούμενης ιδιότητας, η παλινδρόμηση του δείγματος (Εξ. 2.6.2)

$$Y_i = \hat{\beta}_1 + \hat{\beta}_2 X_i + \hat{u}_i$$

μπορεί να εκφραστεί μέσω μίας εναλλακτικής μορφής, όπου τόσο η Y όσο και η X εκφράζονται ως αποκλίσεις από τις μέσες τιμές τους. Για να το επιβεβαιώσετε αυτό, αθροίστε την Εξ. (2.6.2) και στις δύο πλευρές οπότε παίρνετε

⁵ Επισημαίνεται ότι το αποτέλεσμα αυτό ισχύει μόνο όταν το υπόδειγμα παλινδρόμησης περιλαμβάνει τον όρο β_1 . Όπως παρουσιάζεται στο **Παράρτημα 6Α, Εν. 6Α.1**, αυτό το αποτέλεσμα δεν είναι απαραίτητο να ισχύει όταν ο β_1 δεν περιλαμβάνεται στο υπόδειγμα.

⁶ Το αποτέλεσμα αυτό προϋποθέτει ότι το συντελεστής σταθεράς β_1 περιλαμβάνεται στο υπόδειγμα (βλ. **Παράρτημα 6Α, Εν. 6Α.1**).

$$\begin{aligned}\sum Y_i &= n\hat{\beta}_1 + \hat{\beta}_2 \sum X_i + \sum \hat{u}_i \\ &= n\hat{\beta}_1 + \hat{\beta}_2 \sum X_i \quad \text{καθώς} \quad \sum \hat{u}_i = 0\end{aligned}\quad (3.1.11)$$

Διαιρώντας την Εξίσωση 3.1.11 με n προκύπτει

$$\bar{Y} = \hat{\beta}_1 + \hat{\beta}_2 \bar{X} \quad (3.1.12)$$

η οποία είναι ίδια με την Εξ. (3.1.7). Αφαιρώντας την Εξίσωση 3.1.12 από την Εξ. (2.6.2), προκύπτει

$$Y_i - \bar{Y} = \hat{\beta}_2 (X_i - \bar{X}) + \hat{u}_i$$

ή

$$y_i = \hat{\beta}_2 x_i + \hat{u}_i \quad (3.1.13)$$

όπου y_i και x_i , ακολουθώντας την υπόθεσή μας, είναι οι αποκλίσεις από τις αντίστοιχες μέσες τιμές (του δείγματος).

Η Εξίσωση 3.1.13 είναι γνωστή ως η **μορφή των αποκλίσεων από τους μέσους** (deviation form). Παρατηρήστε ότι ο συντελεστής σταθεράς $\hat{\beta}_1$ δεν είναι πλέον παρόν στην εξίσωση. Όμως, ο συντελεστής σταθεράς μπορεί πάντα να εκτιμηθεί από την Εξ. (3.1.7), δηλαδή, από το γεγονός ότι η γραμμή παλινδρόμησης του δείγματος διέρχεται από τις μέσες τιμές των Y και X . Ένα πλεονέκτημα της μορφή των αποκλίσεων από τους μέσους είναι ότι συχνά απλοποιεί τους υπολογισμούς.

Παραεμπιπτόντως, σημειώστε ότι, στη μορφή των αποκλίσεων από τους μέσους, η SRF μπορεί να γραφεί ως

$$\hat{y}_i = \hat{\beta}_2 x_i \quad (3.1.14)$$

ενώ οι αρχικές μονάδες μέτρησης ήταν $\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i$, όπως φαίνεται στην Εξ. (2.6.1).

4. Τα κατάλοιπα $\hat{u}_i$ είναι ασυσχέτιστα με την προβλεπόμενη $\hat{Y}_i$. Αυτή η δήλωση μπορεί να επαληθευτεί ως εξής: χρησιμοποιώντας τη μορφή των αποκλίσεων από τους μέσους, μπορούμε να γράψουμε

$$\begin{aligned}\sum \hat{y}_i \hat{u}_i &= \hat{\beta}_2 \sum x_i \hat{u}_i \\ &= \hat{\beta}_2 \sum x_i (y_i - \hat{\beta}_2 x_i) \\ &= \hat{\beta}_2 \sum x_i y_i - \hat{\beta}_2^2 \sum x_i^2 \\ &= \hat{\beta}_2^2 \sum x_i^2 - \hat{\beta}_2^2 \sum x_i^2 \\ &= 0\end{aligned}\quad (3.1.15)$$

όπου γίνεται χρήση του γεγονότος ότι $\hat{\beta}_2 = \sum x_i y_i / \sum x_i^2$.

5. Το κατάλοιπο $\hat{u}_i$ είναι ασυσχέτιστα με τη X_i δηλαδή, $\sum \hat{u}_i X_i = 0$. Το γεγονός αυτό προκύπτει από την Εξ. (2) στο Παράρτημα 3Α, Ενότητα 3Α.1.

3.2 Το Κλασικό Γραμμικό Υπόδειγμα Παλινδρόμησης: Οι Υποθέσεις στις Οποίες Στηρίζεται η Μέθοδος των Ελαχίστων Τετραγώνων

Αν στόχος μας είναι να εκτιμηθούν μόνο οι β_1 και β_2 , η μέθοδος OLS που παρουσιάστηκε στην προηγούμενη ενότητα αρκεί. Υπενθυμίζεται όμως από το Κεφάλαιο 2 ότι στην ανάλυση παλινδρόμησης ο στόχος μας δεν είναι μόνο να υπολογίσουμε τους $\hat{\beta}_1$ και $\hat{\beta}_2$, αλλά να εξάγουμε συμπεράσματα και για τους πραγματικούς β_1 και β_2 . Για παράδειγμα, θα θέλαμε να γνωρίζουμε πόσο κοντά είναι οι $\hat{\beta}_1$ και $\hat{\beta}_2$ στους αντίστοιχούς τους στον πληθυσμό ή πόσο κοντά είναι ο $\hat{Y}_i$ στο πραγματικό $E(Y | X_i)$. Για το σκοπό αυτό, δεν πρέπει να προσδιορίσουμε μόνο τη συναρτησιακή μορφή του υποδείγματος, όπως στην Εξ. (2.4.2), αλλά να διατυπώσουμε επίσης ορισμένες υποθέσεις σχετικά με τον τρόπο που προκύπτει η Y_i . Για να δείτε γιατί απαιτείται

αυτό, εξετάστε την PRF: $Y_i = \beta_1 + \beta_2 X_i + u_i$. Δείχνει ότι η Y_i εξαρτάται τόσο από τη X_i όσο και από το u_i . Ως εκ τούτου, αν δεν είμαστε συγκεκριμένοι σχετικά με τον τρόπο που έχουν δημιουργηθεί ή προκύπτει η X_i και ο u_i , δεν μπορούμε να εξαγάγουμε χρήσιμα στατιστικά συμπεράσματα για τη Y_i , καθώς και, όπως θα δούμε, για τους β_1 και β_2 . Συνεπώς, οι υποθέσεις σχετικά με τη μεταβλητή X_i και τον όρο σφάλματος είναι εξαιρετικά σημαντικές για την έγκυρη ερμηνεία των εκτιμήσεων της παλινδρόμησης.

Το **Gaussian, τυπικό, ή κλασικό γραμμικό υπόδειγμα παλινδρόμησης** (CLRM), το οποίο είναι ο ακρογωνιαίος λίθος του μεγαλύτερου μέρους της οικονομετρικής θεωρίας, κάνει 7 υποθέσεις.⁷ Αρχικά αναλύουμε αυτές τις υποθέσεις στο πλαίσιο του διμεταβλητού υποδείγματος παλινδρόμησης· στο Κεφάλαιο 7 τις επεκτείνουμε σε υποδείγματα πολλαπλών παλινδρομήσεων, δηλαδή, σε υποδείγματα στα οποία υπάρχουν περισσότεροι του ενός παλινδρομητές.

ΥΠΟΘΕΣΗ 1: Γραμμικό Υπόδειγμα Παλινδρόμησης

Το υπόδειγμα παλινδρόμησης είναι **γραμμικό ως προς τις παραμέτρους**, ωστόσο μπορεί να είναι ή μπορεί να μην είναι γραμμικό ως προς τις μεταβλητές. Αυτό είναι το υπόδειγμα παλινδρόμησης, όπως παρουσιάζεται στην Εξ. (2.4.2):

$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

Όπως θα συζητηθεί στο Κεφάλαιο 7, το υπόδειγμα αυτό μπορεί να επεκταθεί ώστε να περιλαμβάνει περισσότερες ερμηνευτικές μεταβλητές.

Έχουμε ήδη συζητήσει το υπόδειγμα (2.4.2) στο Κεφάλαιο 2. Δεδομένου ότι τα γραμμικά ως προς τις παραμέτρους υποδείγματα παλινδρόμησης είναι το σημείο εκκίνησης για το κλασικό γραμμικό υπόδειγμα παλινδρόμησης (CLRM), θα διατηρήσουμε αυτήν την υπόθεση για το μεγαλύτερο μέρος αυτού του βιβλίου.⁸ Λάβετε υπόψη ότι η παλινδρομούμενη μεταβλητή Y και ο παλινδρομητής X μπορεί να είναι μη-γραμμικοί, όπως αναλύεται στο Κεφάλαιο 2.

ΥΠΟΘΕΣΗ 2 Σταθερές Τιμές της X ή Τιμές της X Ανεξάρτητες από τον Όρο Σφάλματος

Οι τιμές που παίρνει ο παλινδρομητής X μπορούν να θεωρηθούν σταθερές σε επαναλαμβανόμενα δείγματα (η περίπτωση του σταθερού παλινδρομητή) ή μπορεί η δειγματοληψία να πραγματοποιείται σε συνδυασμό με την εξαρτημένη μεταβλητή Y (η περίπτωση του στοχαστικού παλινδρομητή). Στην τελευταία περίπτωση, θεωρούμε ότι η(οι) μεταβλητή(ές) X και ο όρος σφάλματος είναι ανεξάρτητοι, δηλαδή, $\text{cov}(X_i, u_i) = 0$.

Αυτό μπορεί να εξηγηθεί μέσω του παραδείγματός που παρουσιάζεται στον Πίνακα 2.1. Εξετάστε τους διάφορους πληθυσμούς Y που αντιστοιχούν στα επίπεδα εισοδήματος που αναγράφονται στον πίνακα. Διατηρώντας την τιμή του εισοδήματος X σταθερή, π.χ. στο επίπεδο των \$80, επιλέγουμε τυχαία μία οικογένεια και παρατηρούμε ότι η εβδομαδιαία οικογενειακή κατανάλωση Y , είναι, για παράδειγμα, \$60. Διατηρώντας τη X στα \$80, επιλέγουμε τυχαία μία άλλη οικογένεια και παρατηρούμε ότι η εβδομαδιαία οικογενειακή κατανάλωση Y είναι \$75. Σε κάθε μία από αυτές τις επιλογές (δηλαδή, σε επαναλαμβανόμενη δειγματοληψία), η τιμή της X είναι σταθερή στα \$80. Μπορούμε να επαναλάβουμε αυτή τη διαδικασία για όλες τις τιμές της X που παρουσιάζονται στον Πίνακα 2.1. Στην πραγματικότητα, τα στοιχεία του δείγματος που παρουσιάζονται στους Πίνακες 2.4 και 2.5 επιλέχθηκαν με αυτό τον τρόπο.

Γιατί θεωρούμε ότι οι τιμές X είναι μη-στοχαστικές; Λαμβάνοντας υπόψη ότι, στις περισσότερες κοινωνικές επιστήμες, τα στοιχεία συνήθως συλλέγονται τυχαία τόσο για τη μεταβλητή Y όσο και για τη μεταβλητή X , φαίνεται φυσιολογικό να υποθέσουμε το αντίθετο – ότι η μεταβλητή X , όπως και η μεταβλητή Y , είναι επίσης τυχαία ή στοχαστική. Όμως, αρχικά υποθέτουμε ότι η(οι) μεταβλητή(ές) X είναι μη-στοχαστική(ές) για τους ακόλουθους λόγους:

- ♦ *Πρώτον*, αυτό γίνεται αρχικά για να απλοποιήσει την ανάλυση και για να εισαγάγει σταδιακά τον αναγνώστη στις πολυπλοκότητες της ανάλυσης παλινδρόμησης.
- ♦ *Δεύτερον*, σε πειραματικές συνθήκες μπορεί να μην είναι αβάσιμο να υποθέσει κάποιος ότι οι τιμές της X είναι σταθερές. Για παράδειγμα, ένας αγρότης μπορεί να χωρίσει τη γη του σε πολλά αγροτεμάχια και να χρησιμοποιήσει διαφορετικές ποσότητες λιπασμάτων σε αυτά τα αγροτεμάχια για να

⁷ Είναι κλασικό, με την έννοια ότι αναπτύχθηκε αρχικά από τον Gauss το 1821 και από τότε έχει καθιερωθεί ως ο κανόνας ή το πρότυπο με το οποίο μπορούν να συγκριθούν τα υποδείγματα παλινδρόμησης που δεν πληρούν τις υποθέσεις αυτές.

⁸ Ωστόσο, στο Κεφάλαιο 14 πραγματοποιείται μία σύντομη συζήτηση των μη γραμμικών ως προς τις παραμέτρους υποδειγμάτων παλινδρόμησης που απευθύνεται σε πιο προχωρημένους φοιτητές.

δει την επίδραση του λιπάσματος στην απόδοση των καλλιεργειών. Ομοίως, ένα πολυκατάστημα μπορεί να αποφασίσει να προσφέρει διαφορετικά ποσοστά έκπτωσης σε ένα προϊόν για να δει την επίδρασή της έκπτωσης στους καταναλωτές. Ορισμένες φορές ίσως επιθυμούμε να διατηρήσουμε τις τιμές της X σταθερές για ένα συγκεκριμένο σκοπό. Ας υποθέσουμε ότι προσπαθούμε να μάθουμε το μέσο εβδομαδιαίο εισόδημα εργαζομένων (Y) με διαφορετικά επίπεδα εκπαίδευσης (X), όπως στην περίπτωση των στοιχείων που παρουσιάζονται στον Πίνακα 2.6. Σε αυτή την περίπτωση, η μεταβλητή X μπορεί να θεωρηθεί σταθερή ή μη-τυχαία.

- ✦ *Τρίτον*, όπως θα δείξουμε στο Κεφάλαιο 13, ακόμη και αν η μεταβλητή X είναι στοχαστική, τα στατιστικά αποτελέσματα της γραμμικής παλινδρόμησης που βασίζονται στην υπόθεση των σταθερών παλινδρομητών ισχύουν επίσης όταν η X είναι τυχαία, υπό την προϋπόθεση ότι ικανοποιούνται ορισμένες συνθήκες. Η πρώτη συνθήκη είναι ότι ο παλινδρομητής X και ο όρος σφάλματος u_i είναι ανεξάρτητοι. Όπως επισημαίνει ο James Davidson, «...αυτό το υπόδειγμα [δηλαδή, υπόδειγμα στοχαστικών παλινδρομητών] 'μιμείται' το υπόδειγμα σταθερών παλινδρομητών, και... πολλές από τις στατιστικές ιδιότητες των ελαχίστων τετραγώνων εξακολουθούν να ισχύουν στο υπόδειγμα σταθερών παλινδρομητών».⁹

Για όλους αυτούς τους λόγους, θα συζητήσουμε πρώτα λεπτομερώς το CLRM (σταθερών παλινδρομητών). Ωστόσο, στο Κεφάλαιο 13 θα συζητήσουμε την περίπτωση των στοχαστικών παλινδρομητών και θα επισημάνουμε τις περιπτώσεις στις οποίες πρέπει να εξετάσουμε τα υποδείγματα στοχαστικών παλινδρομητών. Παρεμπιπτόντως, σημειώστε ότι αν η μεταβλητή X είναι στοχαστική, το υπόδειγμα που προκύπτει ονομάζεται **νεο-κλασικό γραμμικό υπόδειγμα παλινδρόμησης** (neo-classical linear regression model - NLRM),¹⁰ σε αντίθεση με το CLRM, όπου οι X αντιμετωπίζονται ως σταθερές ή μη-τυχαίες. Για τους σκοπούς της ανάλυσής μας, θα ονομάσουμε το πρώτο υπόδειγμα στοχαστικών παλινδρομητών και το δεύτερο υπόδειγμα σταθερών παλινδρομητών.

ΥΠΟΘΕΣΗ 3: Μηδενική Μέση Τιμή του Διαταρακτικού Όρου u_i

Δεδομένης της τιμής της X_i , η μέση ή η προσδοκώμενη τιμή του τυχαίου διαταρακτικού όρου u_i είναι μηδέν. Συμβολικά, έχουμε

$$E(u_i | X_i) = 0 \quad (3.2.1)$$

Η, εάν η X είναι μη-στοχαστική

$$E(u_i) = 0$$

Η Υπόθεση 3 δηλώνει ότι η μέση τιμή του u_i συναρτήσει της X_i είναι μηδέν. Γεωμετρικά, η υπόθεση αυτή μπορεί να παρουσιαστεί διαγραμματικά όπως στο Διάγραμμα 3.3, το οποίο δείχνει ορισμένες τιμές της μεταβλητής X και τους πληθυσμούς Y που σχετίζονται με κάθε μία από αυτές. Όπως παρουσιάζεται, κάθε πληθυσμός Y που αντιστοιχεί σε μία δεδομένη X κατανέμεται γύρω από τη μέση τιμή της (τα κυκλικά σημεία στην PRF), με ορισμένες τιμές της Y πάνω και ορισμένες κάτω από τη μέση τιμή. Οι αποστάσεις πάνω και κάτω από τις μέσες τιμές δεν είναι τίποτε άλλο από το u_i . Η Εξίσωση 3.2.1 προϋποθέτει ότι ο μέσος ή η μέση τιμή αυτών των αποκλίσεων που αντιστοιχεί σε κάθε δοθείσα X θα πρέπει να είναι μηδέν.


Αυτή η υπόθεση δεν πρέπει να είναι δύσκολο να κατανοηθεί λόγω της συζήτησης στην Ενότητα 2.4 (βλ. Εξ. [2.4.5]). Η Υπόθεση 3 λέει απλά ότι οι παράγοντες που δεν περιλαμβάνονται ρητά στο υπόδειγμα, και ως εκ τούτου εντάσσονται στο u_i , δεν επηρεάζουν συστηματικά τη μέση τιμή της Y . Με άλλα λόγια, οι θετικές τιμές του u_i εξουδετερώνουν τις αρνητικές τιμές του u_i , ώστε η μέση επίδραση τους στη Y είναι ίση με το μηδέν.¹¹ Παρεμπιπτόντως, σημειώστε ότι η υπόθεση $E(u_i | X_i) = 0$ σημαίνει ότι $E(Y_i | X_i) = \beta_1 + \beta_2 X_i$. (Γιατί;) Ως εκ τούτου, οι δύο υποθέσεις είναι ισοδύναμες.

Είναι σημαντικό να επισημάνουμε ότι η Υπόθεση 3 συνεπάγεται ότι δεν υπάρχει καμία **μεροληψία εξειδίκευσης** (specification bias) ή **σφάλμα εξειδίκευσης** (specification error) στο υπόδειγμα που χρησιμοποιείται στην εμπειρική ανάλυση. Με άλλα λόγια, το υπόδειγμα παλινδρόμησης έχει οριστεί σωστά.

⁹ James Davidson, *Econometric Theory*, Blackwell Publishers, U.K., 2000, σελ. 10.

¹⁰ Ένας όρος που εισήχθη από τον Arthur S. Goldberger, *A Course in Econometrics*, Harvard University Press, Cambridge, MA, 1991, σελ. 264.

¹¹ Για μία ποιο τεχνικά πλήρη εξήγηση γιατί η Υπόθεση 3 βλ. E. Malinvaud, *Statistical Methods of Econometrics*, Rand McNally, Chicago, 1966, σελ. 75. Βλ. επίσης Άσκηση 3.3.

ΔΙΑΓΡΑΜΜΑ 3.3 Υπό συνθήκη κατανομή των διαταρακτικών όρων u_i .

Ορισμένα παραδείγματα σφάλματος εξειδίκευσης είναι να παραλειφθούν σημαντικές ερμηνευτικές μεταβλητές, να συμπεριληφθούν περιττές μεταβλητές, ή να επιλεγθεί λανθασμένη συναρτησιακή μορφή της σχέσης μεταξύ των μεταβλητών Y και X . Το θέμα αυτό θα συζητηθεί λεπτομερώς στο Κεφάλαιο 13.

Σημειώστε επίσης ότι εάν η υπό συνθήκη μέση τιμή μίας τυχαίας μεταβλητής δεδομένης μίας άλλης τυχαίας μεταβλητής είναι μηδέν, η συνδιακύμανση μεταξύ των δύο μεταβλητών είναι μηδέν και, συνεπώς, οι δύο μεταβλητές είναι ασυσχέτιστες. Επομένως, η Υπόθεση 3 συνεπάγεται, ότι η X_i και ο u_i είναι ασυσχέτιστες μεταβλητές.¹²

Ο λόγος για τον οποίο υποθέτουμε ότι ο διαταρακτικός όρος u_i και η (οι) ερμηνευτική (-ές) μεταβλητή (-ές) X είναι ασυσχέτιστες είναι απλός. Όταν εκφράσαμε την PRF, όπως στην Εξ. (2.4.2), υποθέσαμε ότι η X και ο u (που αντιπροσωπεύει την επίδραση όλων των μεταβλητών που έχουν παραλειφθεί) έχουν ξεχωριστές (και πρόσθετες) επιδράσεις στη Y . Αν όμως η X και ο u συσχετίζονται, δεν είναι δυνατό να αξιολογηθούν οι μεμονωμένες επιπτώσεις τους στη Y . Επομένως, αν η X και ο u έχουν θετική συσχέτιση, η X αυξάνεται όταν αυξάνεται ο u και μειώνεται όταν μειώνεται ο u . Ομοίως, αν η X και ο u έχουν αρνητική συσχέτιση, η X αυξάνεται όταν μειώνεται ο u και μειώνεται όταν αυξάνεται ο u . Σε περιπτώσεις σαν αυτή είναι πολύ πιθανό ο όρος σφάλματος να περιλαμβάνει ορισμένες μεταβλητές που θα έπρεπε να είχαν συμπεριληφθεί ως επιπλέον παλινδρομητές στο υπόδειγμα. Αυτός είναι ο λόγος που η Υπόθεση 3 είναι ένας άλλος τρόπος να δηλώσουμε ότι δεν υπάρχει σφάλμα εξειδίκευσης στο υπόδειγμα παλινδρόμησης που επιλέχθηκε.

ΥΠΟΘΕΣΗ 4: Ομοσκεδαστικότητα ή Σταθερή Διακύμανση του u_i

Η διακύμανση του διαταρακτικού όρου ή όρου σφάλματος είναι η ίδια, ανεξάρτητα από την τιμή της X . Συμβολικά,

$$\begin{aligned} \text{var}(u_i) &= E[u_i - E(u_i | X_i)]^2 \\ &= E(u_i^2 | X_i), && \text{λόγω της Υπόθεσης 3} \\ &= E(u_i^2) && \text{αν η } X_i \text{ είναι μη-στοχαστική} \\ &= \sigma^2 \end{aligned} \quad 3.2.2$$

όπου var είναι η διακύμανση.

¹² Ωστόσο, το αντίστροφο δεν ισχύει επειδή η συσχέτιση είναι μόνο ένα μέτρο της γραμμικής σχέσης. Δηλαδή, ακόμα και αν X_i και u_i είναι ασυσχέτιστοι, ο υπό συνθήκη μέσος του u_i δοθείσης της X_i μπορεί να μην είναι μηδέν. Ωστόσο, αν X_i και u_i συσχετίζονται η $E(u_i | X_i)$ πρέπει να μην είναι μηδέν, παραβιάζοντας την Υπόθεση 3. Το σημείο αυτό επισημάνθηκε από τους Stock and Watson. Βλ. James H. Stock and Mark W. Watson, *Introduction to Econometrics*, Addison-Wesley, Boston, 2003, σσ. 104–105.


Η Εξίσωση 3.2.2 δηλώνει ότι η διακύμανση του u_i για κάθε X_i (δηλαδή, η υπό συνθήκη διακύμανση του u_i) είναι κάποιος θετικός σταθερός αριθμός ίσος με σ^2 . Τεχνικά, η Εξ. (3.2.2) αποτελεί την υπόθεση της **ομοσκεδαστικότητας** (homoskedasticity), ή ίσης (homo) διασποράς (scedasticity) ή *ίσης διακύμανσης*. Η λέξη προέρχεται από το ελληνικό ρήμα σκεδανύμι, που σημαίνει σκορπίζομαι. Περιγράφοντάς την διαφορετικά, η Εξ. (3.2.2) σημαίνει ότι οι πληθυσμοί Y που αντιστοιχούν σε διάφορες τιμές της X έχουν την ίδια διακύμανση. Πιο απλά, η διακύμανση γύρω από τη γραμμή παλινδρόμησης (που είναι η γραμμή της μέσης σχέσης μεταξύ των Y και X) είναι η ίδια για όλες τις τιμές της X : ούτε αυξάνεται ούτε μειώνεται καθώς η X μεταβάλλεται. Σχηματικά, η κατάσταση είναι όπως παρουσιάζεται στο Διάγραμμα 3.4.

Αντίθετα, εξετάστε το Διάγραμμα 3.5, όπου η υπό συνθήκη διακύμανση του πληθυσμού Y διαφοροποιείται ανάλογα με το X . Η κατάσταση αυτή είναι γνωστή ως **ετεροσκεδαστικότητα** (heteroskedasticity), ή *άνιση διασπορά*, ή *διακύμανση*. Συμβολικά, σε αυτή την περίπτωση, η Εξ. (3.2.2) μπορεί να γραφεί ως


$$\text{var}(u_i | X_i) = \sigma_i^2 \quad (3.2.3)$$

Παρατηρήστε τον υποδείκτη στη σ^2 στην εξίσωση (3.2.3), ο οποίος δείχνει ότι η διακύμανση του πληθυσμού Y δεν είναι πλέον σταθερή.

Για να γίνει σαφής η διαφορά μεταξύ των δύο καταστάσεων, ας υποθέσουμε ότι η Y αντιπροσωπεύει τις εβδομαδιαίες καταναλωτικές δαπάνες και η X το εβδομαδιαίο εισόδημα. Τα Διαγράμματα 3.4 και 3.5 δείχνουν ότι όσο αυξάνεται το εισόδημα, η μέση καταναλωτική δαπάνη αυξάνεται επίσης. Όμως στο Διάγραμμα 3.4 η διακύμανση των καταναλωτικών δαπανών παραμένει η ίδια σε όλα τα επίπεδα εισοδήματος, ενώ στο Διάγραμμα 3.5 αυξάνεται όσο αυξάνεται το εισόδημα. Με άλλα λόγια, οι πλουσιότερες οικογένειες καταναλώνουν κατά μέσο όρο περισσότερο από ότι οι φτωχότερες οικογένειες, όμως υπάρχει και μεγαλύτερη μεταβλητότητα στην καταναλωτική δαπάνη των πρώτων.



ΔΙΑΓΡΑΜΜΑ 3.4 Ομοσκεδαστικότητα



ΔΙΑΓΡΑΜΜΑ 3.5 Ετεροσκεδαστικότητα

Για να κατανοήσουμε τη λογική στην οποία βασίζεται αυτή η υπόθεση, εξετάστε το Διάγραμμα 3.5. Όπως δείχνει αυτό το διάγραμμα, $\text{var}(u | X_1) < \text{var}(u | X_2), \dots, < \text{var}(u | X_i)$. Ως εκ τούτου, η πιθανότητα είναι ότι οι παρατηρήσεις Y που προέρχονται από τον πληθυσμό με $X = X_1$ θα βρίσκονται πλησιέστερα στην PRF από ότι εκείνες που προέρχονται από πληθυσμούς για τους οποίους ισχύει $X = X_2, X = X_3$, και ούτω καθεξής. Με λίγα λόγια, δεν θα είναι όλες οι τιμές της Y που αντιστοιχούν στις διάφορες τιμές της X εξίσου αξιόπιστες, η αξιοπιστία κρίνεται από το πόσο κοντά ή μακριά κατανέμονται οι τιμές της Y γύρω από τους μέσους της, δηλαδή, τα σημεία επί της PRF. Αν αυτό πράγματι συμβαίνει, δε θα προτιμούσαμε να εξάγουμε το δείγμα μας από τους πληθυσμούς Y που βρίσκονται πιο κοντά στις μέσες τιμές τους από εκείνους που είναι ευρέως διεσπαρμένοι; Αυτό όμως, θα μπορούσε να περιορίσει τη διαφοροποίηση μεταξύν των τιμών της X .

Επικαλούμενοι την Υπόθεση 4, δηλώνουμε ότι στο παρόν στάδιο, όλες οι τιμές της Y που αντιστοιχούν στις διάφορες τιμές της X είναι εξίσου σημαντικές. Στο Κεφάλαιο 11 θα δούμε τι θα συμβεί εάν αυτό δεν ισχύει, δηλαδή, εάν υπάρχει ετεροσκεδαστικότητα.

Παρεμπιπτόντως, σημειώστε ότι η Υπόθεση 4 συνεπάγεται ότι οι υπό συνθήκη διακυμάνσεις της Y_i είναι επίσης ομοσκεδαστικές. Δηλαδή,

$$\text{var}(Y_i | X_i) = \sigma^2 \quad (3.2.4)$$

Φυσικά, η άνευ συνθήκης διακύμανση της Y είναι σ_Y^2 . Αργότερα θα μελετήσουμε τη σημασία της διάκρισης μεταξύ των υπό συνθήκη και άνευ συνθήκης διακυμάνσεων της Y (βλ. **Παράρτημα Α** για λεπτομέρειες αναφορικά με τις υπό συνθήκη και άνευ συνθήκης διακυμάνσεων).

ΥΠΟΘΕΣΗ 5: Δεν Υπάρχει Αυτοσυσχέτιση μεταξύ των Διαταρακτικών Όρων

Δοθέντων οποιονδήποτε δύο τιμών των X, X_i και X_j ($i \neq j$), η συσχέτιση μεταξύ οποιονδήποτε δύο u_i και u_j ($i \neq j$) είναι μηδέν. Εν ολίγοις, οι παρατηρήσεις περιέχονται σε ανεξάρτητα μεταξύ τους δείγματα. Συμβολικά,

$$\begin{aligned} \text{cov}(u_i, u_j | X_i, X_j) &= 0 \\ \text{cov}(u_i, u_j) &= 0 \text{ αν η } X \text{ είναι μη-στοχαστική} \end{aligned} \quad (3.2.5)$$


όπου i και j είναι δύο διαφορετικές παρατηρήσεις και όπου cov - σημαίνει συνδιακύμανση.

Με άλλα λόγια, σύμφωνα με την Εξίσωση 3.2.5 οι διαταρακτικοί όροι u_i και u_j είναι ασυσχέτιστοι. Από τεχνικής άποψης, αυτή είναι η υπόθεση της **μη σειριακής συσχέτισης** (no serial correlation), ή της **μη αυτοσυσχέτισης** (no autocorrelation). Αυτό σημαίνει ότι, δεδομένης της X_i , οι αποκλίσεις οποιονδήποτε δύο τιμών της Y από τη μέση τιμή της δεν παρουσιάζει πρότυπα όπως αυτά που παρουσιάζονται στα Διαγράμματα 3.6(α) και (β). Στο Διάγραμμα 3.6(α), βλέπουμε ότι οι u έχουν θετική συσχέτιση, ένας θετικός u ακολουθείται από έναν θετικό u ή ένας αρνητικός u ακολουθείται από έναν αρνητικό u . Στο Διάγραμμα 3.6(β), οι u έχουν **αρνητική συσχέτιση**, ένας θετικός u ακολουθείται από έναν αρνητικό u και το αντίστροφο.

Εάν οι διαταρακτικοί όροι (αποκλίσεις) ακολουθούν συστηματικά πρότυπα, όπως αυτά που απεικονίζονται στα Διαγράμματα 3.6(α) και (β), υπάρχει αυτοσυσχέτιση ή σειριακή συσχέτιση, και αυτό που απαιτεί η Υπόθεση 5 είναι να απουσιάζουν τέτοιες συσχετίσεις. Το Διάγραμμα 3.6(γ) δείχνει ότι δεν υπάρχει συστηματικό πρότυπο στους u , γεγονός που υποδεικνύει μηδενική συσχέτιση.

Η υπόθεση αυτή θα αναλυθεί διεξοδικά στο Κεφάλαιο 12. Διαισθητικά όμως, κάποιος μπορεί να εξηγήσει αυτήν την υπόθεση ως εξής. Ας υποθέσουμε ότι στην PRF μας ($Y_i = \beta_1 + \beta_2 X_i + u_i$) οι u_i και u_{i-1} παρουσιάζουν θετική συσχέτιση. Τότε η Y_i δεν εξαρτάται μόνο από τη X_i , αλλά και από το u_{i-1} , καθώς ο u_{i-1} καθορίζει σε κάποιο βαθμό το u_i . Σε αυτό το στάδιο της ανάπτυξης του θέματος, επικαλούμενοι την Υπόθεση 5, λέμε ότι θα εξετάσουμε τη συστηματική επίδραση, εάν υπάρχει, της X_i στη Y_i και δεν ανησυχούμε για τις άλλες επιδράσεις που μπορεί να ενεργούν στη Y , ως αποτέλεσμα των πιθανών συσχετίσεων που υπάρχουν μεταξύ των u . Όπως σημειώνεται όμως στο Κεφάλαιο 12, θα δούμε πώς οι συσχετίσεις μεταξύ των διαταρακτικών όρων μπορούν να εισαχθούν στην ανάλυση και με ποιες συνέπειες γίνεται αυτό.

Θα πρέπει όμως να αναφερθεί στο σημείο αυτό ότι η αιτιολόγηση αυτής της υπόθεσης εξαρτάται από το είδος των στοιχείων που χρησιμοποιούνται στην ανάλυση. Εάν τα στοιχεία είναι διαστρωματικά και αποτελούν ένα τυχαίο δείγμα του σχετικού πληθυσμού, η υπόθεση αυτή μπορεί να ευσταθεί.



ΔΙΑΓΡΑΜΜΑ 3.6 Πρότυπα συσχέτισης μεταξύ των διαταρακτικών όρων. (α) θετική σειριακή συσχέτιση· (β) αρνητική σειριακή συσχέτιση· (γ) μηδενική συσχέτιση.

Ωστόσο, εάν τα στοιχεία είναι χρονοσειρές, η υπόθεση της ανεξαρτησίας είναι δύσκολο να ευσταθεί, καθώς οι διαδοχικές παρατηρήσεις μίας χρονοσειράς, όπως το ΑΕΠ, παρουσιάζουν υψηλό βαθμό συσχέτισης. Όμως θα ασχοληθούμε με αυτό το ζήτημα όταν συζητήσουμε την οικονομετρική ανάλυση χρονοσειρών αργότερα στο παρόν βιβλίο.

ΥΠΟΘΕΣΗ 6: Ο Αριθμός των Παρατηρήσεων n Πρέπει να είναι Μεγαλύτερος από τον Αριθμό των Παραμέτρων που θα Εκτιμηθούν

Εναλλακτικά, ο αριθμός των παρατηρήσεων πρέπει να είναι μεγαλύτερος από τον αριθμό των ερμηνευτικών μεταβλητών.

Αυτή η υπόθεση δεν είναι τόσο ‘αθώα’ όσο φαίνεται. Στο υποθετικό παράδειγμα του Πίνακα 3.1, φανταστείτε ότι είχαμε μόνο το πρώτο ζευγάρι των παρατηρήσεων των Y και X (4 και 1). Από αυτή τη μοναδική παρατήρηση, δεν υπάρχει τρόπος να εκτιμήσουμε τους δύο αγνώστους, β_1 και β_2 . Χρειαζόμαστε τουλάχιστον δύο ζεύγη παρατηρήσεων για την εκτίμηση των δύο αγνώστων. Σε επόμενο κεφάλαιο θα ερευνήσουμε την καθοριστική σημασία της εν λόγω υπόθεσης.

ΥΠΟΘΕΣΗ 7: Η Φύση των Μεταβλητών X

Οι τιμές της X σε ένα δεδομένο δείγμα δεν πρέπει να είναι όλες οι ίδιες. Τεχνικά, $\text{var}(X)$ πρέπει να είναι ένας θετικός αριθμός. Επιπλέον, δε μπορεί να υπάρχουν **ακραίες τιμές** ή **έκτοπα** (outliers) στις τιμές της μεταβλητής X , δηλαδή, τιμές που είναι πολύ μεγάλες σε σχέση με τις υπόλοιπες παρατηρήσεις.

Η υπόθεση ότι υπάρχει μεταβλητότητα στις τιμές της X δεν είναι επίσης, τόσο ‘αθώα’ όσο φαίνεται. Παρατηρήστε την Εξ. (3.1.6). Αν όλες οι τιμές της X είναι ταυτόσημες, τότε $X_i = \bar{X}$ (Γιατί;) και ο παρονομαστής αυτής της εξίσωσης θα είναι μηδενικός, γεγονός που καθιστά αδύνατη την εκτίμηση του β_2 και συνεπώς και του β_1 . Διαισθητικά, μπορούμε εύκολα να καταλάβουμε γιατί αυτή η υπόθεση είναι σημαντική. Μελετώντας το παράδειγμα των καταναλωτικών δαπανών μίας οικογένειας στο Κεφάλαιο 2, αν υπάρχει πολύ μικρή μεταβολή στο οικογενειακό εισόδημα, δε θα είμαστε σε θέση να εξηγήσουμε ένα μεγάλο μέρος της μεταβολής των καταναλωτικών δαπανών. Ο αναγνώστης θα πρέπει να έχει κατά νου ότι η διακύμανση τόσο της Y όσο και της X είναι απαραίτητη για τη χρήση της ανάλυσης παλινδρόμησης ως ερευνητικό εργαλείο. Με λίγα λόγια, οι μεταβλητές πρέπει να διαφέρουν!

Η προϋπόθεση ότι δεν υπάρχουν ακραίες τιμές στις τιμές της X είναι για να αποφευχθεί το ενδεχόμενο τα αποτελέσματα παλινδρόμησης να κυριαρχούνται από τέτοια έκτοπα. Εάν υπάρχουν λίγες τιμές της X που είναι, για παράδειγμα, 20 φορές ο μέσος όρος των τιμών της X , οι εκτιμημένες γραμμές παλινδρόμησης, με ή χωρίς τέτοιες παρατηρήσεις θα μπορούσαν να είναι κατά πολύ διαφορετικές. Πολύ συχνά τέτοια έκτοπα είναι το αποτέλεσμα ανθρωπίνων λαθών αριθμητικής ή σύνθεσης δειγμάτων από διαφορετικούς πληθυσμούς. Στο Κεφάλαιο 13 θα συζητήσουμε περαιτέρω αυτό το ζήτημα.

Στο σημείο αυτό η συζήτησή μας αναφορικά με τις υποθέσεις στις οποίες βασίζεται το κλασικό γραμμικό υπόδειγμα παλινδρόμησης έχει πλέον ολοκληρωθεί. Είναι σημαντικό να σημειωθεί ότι όλες αυτές οι υποθέσεις αφορούν μόνο την PRF και όχι την SRF. Όμως είναι ενδιαφέρον να παρατηρήσουμε ότι η μέθοδος των ελαχίστων τετραγώνων που συζητήθηκε προηγουμένως έχει κάποιες ιδιότητες που είναι παρόμοιες με τις υποθέσεις που έχουμε κάνει για την PRF. Για παράδειγμα, η διαπίστωση ότι $\sum \hat{u}_i = 0$ και, ως εκ τούτου, $\bar{\hat{u}} = 0$, είναι παρόμοια με την υπόθεση ότι $E(u_i | X_i) = 0$. Ομοίως, η διαπίστωση ότι $\sum \hat{u}_i X_i = 0$ είναι παρόμοια με την υπόθεση ότι $\text{cov}(u_i, X_i) = 0$. Είναι παρήγορο να σημειωθεί ότι η μέθοδος των ελαχίστων τετραγώνων προσπαθεί να 'αντιγράψει' ορισμένες από τις υποθέσεις στις οποίες βασίζεται η PRF.

Φυσικά, η SRF δεν αντιγράφει όλες τις υποθέσεις του κλασικού γραμμικού υποδείγματος παλινδρόμησης. Όπως θα δείξουμε αργότερα, παρόλο που εξ' υποθέσεως $\text{cov}(u_i, u_j) = 0$ ($i \neq j$), δεν ισχύει στο δείγμα ότι $\text{cov}(\hat{u}_i, \hat{u}_j) = 0$ ($i \neq j$). Στην πραγματικότητα, θα δείξουμε στη συνέχεια ότι τα κατάλοιπα δεν είναι μόνο αυτοσυσχετιζόμενα αλλά είναι επίσης και ετεροσκεδαστικά (βλ. Κεφάλαιο 12).

Περίληπτική Παρουσίαση Αυτών των Υποθέσεων

Το σημαντικότερο ερώτημα είναι: Πόσο ρεαλιστικές είναι όλες αυτές οι υποθέσεις; Η «ρεαλιστικότητα των υποθέσεων», είναι ένα πανάρχαιο ερώτημα στη φιλοσοφία της επιστήμης. Ορισμένοι υποστηρίζουν ότι δεν έχει σημασία αν οι υποθέσεις είναι ρεαλιστικές. Αυτό που έχει σημασία είναι οι προβλέψεις που βασίζονται σε αυτές τις υποθέσεις. Ιδιαίτερα αξιοσημείωτη είναι η συμβολή του Milton Friedman στην «θέση της μη σχετικότητας των υποθέσεων». Για τον Friedman, η μη ρεαλιστικότητα των υποθέσεων είναι ένα θετικό πλεονέκτημα: «για να είναι σημαντική...μία υπόθεση πρέπει να είναι περιγραφικά ψευδής ως προς τις υποθέσεις της.»¹³

Κάποιος μπορεί να μην υποστηρίξει πλήρως αυτή την άποψη, αλλά υπενθυμίζεται ότι σε κάθε επιστημονική μελέτη διατυπώνουμε ορισμένες υποθέσεις επειδή αυτό διευκολύνει την ανάπτυξη του θέματος σε σταδιακά βήματα, και όχι επειδή είναι κατ' ανάγκην ρεαλιστικές, υπό την έννοια ότι αναπαράγουν ακριβώς την πραγματικότητα. Όπως σημειώνει ο Mark Blaug, «...αν η απλότητα είναι ένα επιθυμητό κριτήριο της σωστής θεωρίας, όλες οι σωστές θεωρίες εξιδανικεύουν και υπεραπλουστεύουν σε εξωφρενικό βαθμό.»¹⁴

Αυτό που σκοπεύουμε να κάνουμε είναι να μελετήσουμε αρχικά εκτενώς τις ιδιότητες του κλασικού γραμμικού υποδείγματος παλινδρόμησης, στη συνέχεια σε επόμενα κεφάλαια θα εξετάσουμε σε βάθος τι θα συμβεί εάν μία ή περισσότερες από τις υποθέσεις του κλασικού γραμμικού υποδείγματος παλινδρόμησης δεν πληρούνται. Στο τέλος του παρόντος κεφαλαίου παρουσιάζεται ο Πίνακας 3.4 ο οποίος αποτελεί έναν οδηγό για το τι συμβαίνει στο κλασικό γραμμικό υπόδειγμα παλινδρόμησης αν δεν ικανοποιείται μία συγκεκριμένη υπόθεση.

Όπως μας υπέδειξε ένας συνάδελφός μας, όταν μελετούμε την έρευνα κάποιου άλλου, πρέπει να εξετάσουμε κατά πόσον οι υποθέσεις που γίνονται από τον ερευνητή ανταποκρίνονται στα στοιχεία και στο πρόβλημα. Πάρα πολύ συχνά, οι δημοσιευμένες έρευνες βασίζονται σε σιωπηρές υποθέσεις σχετικά με το πρόβλημα και σε στοιχεία τα οποία δεν είναι πιθανώς σωστά και οδηγούν σε εκτιμήσεις που βασίζονται σε αυτές τις υποθέσεις. Σαφώς, ο πεπειραμένος αναγνώστης πρέπει, συνειδητοποιώντας τα προβλήματα αυτά, να υιοθετήσει ένα σκεπτικισμό απέναντι στην έρευνα αυτή. Επομένως, οι υποθέσεις που αναφέρονται στον Πίνακα 3.4 αποτελούν μία λίστα ελέγχου για την καθοδήγηση της έρευνάς μας και για την αξιολόγηση της έρευνας των άλλων.

¹³ Milton Friedman, *Essays in Positive Economics*, University of Chicago Press, Chicago, 1953, σελ. 14.

¹⁴ Mark Blaug, *The Methodology of Economics: Or How Economists Explain*, 2^η έκδοση, Cambridge University Press, New York, 1992, σελ. 92.

Έχοντας αυτό το υπόβαθρο, είμαστε πλέον έτοιμοι να μελετήσουμε το κλασικό γραμμικό υπόδειγμα παλινδρόμησης. Πιο συγκεκριμένα, θέλουμε να συγκρίνουμε τις **στατιστικές ιδιότητες** (statistical properties) της OLS με τις **αριθμητικές ιδιότητες** (numerical properties) που συζητήθηκαν νωρίτερα. Οι στατιστικές ιδιότητες της OLS βασίζονται στις υποθέσεις του κλασικού γραμμικού υποδείγματος παλινδρόμησης που έχουμε συζητήσει ήδη και διατηρούνται στο περίφημο **θεώρημα Gauss-Markov** (Gauss-Markov theorem). Πριν προχωρήσουμε όμως σε αυτό το θεώρημα, το οποίο παρέχει τη θεωρητική αιτιολόγηση για τη δημοτικότητα της OLS, πρέπει πρώτα να εξετάσουμε την **ακρίβεια** (precision) ή τα **τυπικά σφάλματα** (standard errors) των εκτιμήσεων των ελαχίστων τετραγώνων.

3.3 Ακρίβεια ή Τυπικά Σφάλματα των Εκτιμήσεων των Ελαχίστων Τετραγώνων

Από τις Εξισώσεις (3.1.6) και (3.1.7), είναι προφανές ότι οι εκτιμήσεις των ελαχίστων τετραγώνων είναι συνάρτηση του δείγματος των στοιχείων. Καθώς όμως τα στοιχεία είναι πιθανό να μεταβάλλονται από δείγμα σε δείγμα, οι εκτιμήσεις, εκ των πραγμάτων, θα αλλάξουν. Ως εκ τούτου, αυτό που χρειάζεται είναι ένα μέτρο της «αξιοπιστίας» ή της **ακρίβειας** των εκτιμητών $\hat{\beta}_1$ και $\hat{\beta}_2$. Στην στατιστική, η ακρίβεια μίας εκτίμησης μετράται με το τυπικό της σφάλμα (se).¹⁵ Δεδομένων των υποθέσεων του Gauss, στο Παράρτημα 3Α, Ενότητα 3Α.3 παρουσιάζεται ότι τα τυπικά σφάλματα των εκτιμήσεων της OLS προέρχονται από τις εξής σχέσεις:

$$\text{var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum x_i^2} \quad (3.3.1)$$

$$\text{se}(\hat{\beta}_2) = \frac{\sigma}{\sqrt{\sum x_i^2}} \quad (3.3.2)$$

$$\text{var}(\hat{\beta}_1) = \frac{\sum x_i^2}{n \sum x_i^2} \sigma^2 \quad (3.3.3)$$

$$\text{se}(\hat{\beta}_1) = \sqrt{\frac{\sum x_i^2}{n \sum x_i^2}} \sigma \quad (3.3.4)$$

όπου var = διακύμανση και se = τυπικό σφάλμα και όπου σ^2 είναι η συνεχής ή ομοσκεδαστική διακύμανση του u_i της Υπόθεσης 4.

Όλα τα μεγέθη που εισέρχονται στις προηγούμενες εξισώσεις, εκτός από τη σ^2 , μπορούν να εκτιμηθούν από τα στοιχεία. Όπως αναφέρεται στο Παράρτημα 3Α, Ενότητα 3Α.5, η σ^2 εκτιμάται από τον ακόλουθο τύπο:

$$\hat{\sigma}^2 = \frac{\sum \hat{u}_i^2}{n - 2} \quad (3.3.5)$$

όπου $\hat{\sigma}^2$ είναι ο εκτιμητής της OLS της πραγματικής αλλά άγνωστης σ^2 και όπου η έκφραση $n - 2$ είναι γνωστή ως ο **αριθμός των βαθμών ελευθερίας** (number of degrees of freedom – df), $\sum \hat{u}_i^2$ είναι το **άθροισμα των τετραγώνων των καταλοίπων ή RSS**.¹⁶

Μόλις γίνει γνωστό το $\sum \hat{u}_i^2$, ο $\hat{\sigma}^2$ μπορεί να υπολογιστεί εύκολα. Το $\sum \hat{u}_i^2$ μπορεί να υπολογιστεί είτε από την Εξ. (3.1.2) ή από την ακόλουθη εξίσωση (βλ. Ενότητα 3.5 για την απόδειξη):

¹⁵ Το **τυπικό σφάλμα** δεν είναι παρά η τυπική απόκλιση της κατανομής δειγματοληψίας του εκτιμητή, και η κατανομή δειγματοληψίας ενός εκτιμητή είναι απλά μία πιθανότητα ή συχνότητα κατανομής του εκτιμητή, δηλαδή, μία κατανομή του συνόλου των τιμών του εκτιμητή που προέρχεται από όλα τα πιθανά δείγματα του ίδιου μεγέθους από ένα συγκεκριμένο πληθυσμό. Οι κατανομές δειγματοληψίας χρησιμοποιούνται για να εξαχθούν συμπεράσματα σχετικά με τις τιμές των παραμέτρων του πληθυσμού, με βάση τις τιμές των εκτιμητών που υπολογίστηκαν από ένα ή περισσότερα δείγματα. (Για λεπτομέρειες, βλ. **Παράρτημα Α**)

¹⁶ Ο όρος **αριθμός των βαθμών ελευθερίας** είναι ο συνολικός αριθμός των παρατηρήσεων στο δείγμα ($= n$) μείον τον αριθμό των ανεξάρτητων (γραμμικών) περιορισμών ή των περιορισμών που τίθενται επί αυτών. Με άλλα λόγια, είναι ο αριθμός των ανεξάρτητων παρατηρήσεων από ένα σύνολο n παρατηρήσεων. Για παράδειγμα, πριν υπολογιστεί το RSS (3.1.2), πρέπει να υπάρχουν πρώτα οι $\hat{\beta}_1$ και $\hat{\beta}_2$. Επομένως, οι δύο αυτές εκτιμήσεις επιβάλλουν δύο περιορισμούς στο RSS. Ως εκ τούτου, υπάρχουν $n - 2$, και όχι n , ανεξάρτητες παρατηρήσεις για τον υπολογισμό του RSS. Ακολουθώντας αυτή τη λογική, στην παλινδρόμηση τριών μεταβλητών το RSS θα έχει $n - 3$ βαθμούς ελευθερίας, και για το υπόδειγμα k -μεταβλητών θα έχει $n - k$ βαθμούς ελευθερίας. Ο γενικός κανόνας είναι ο εξής: $\text{df} = (n - \text{αριθμό των παραμέτρων που εκτιμώνται})$.

$$\sum \hat{u}_i^2 = \sum y_i^2 - \hat{\beta}_2^2 \sum x_i^2 \quad (3.3.6)$$

Σε σύγκριση με την Εξ. (3.1.2), η Εξίσωση 3.3.6 είναι εύκολη στη χρήση της, καθώς δεν απαιτεί τον υπολογισμό των $\hat{u}_i$ για κάθε παρατήρηση παρόλο που ένας τέτοιος υπολογισμός θα είναι χρήσιμος (όπως θα δούμε στα Κεφάλαια 11 και 12).

Εφόσον

$$\hat{\beta}_2 = \frac{\sum x_i y_i}{\sum x_i^2}$$

μία εναλλακτική έκφραση για τον υπολογισμό του $\sum \hat{u}_i^2$ είναι

$$\sum \hat{u}_i^2 = \sum y_i^2 - \frac{(\sum x_i y_i)^2}{\sum x_i^2} \quad (3.3.7)$$

Παρεμπιπτόντως, η θετική τετραγωνική ρίζα του $\hat{\sigma}_2$

$$\hat{\sigma} = \sqrt{\frac{\sum \hat{u}_i^2}{n-2}} \quad (3.3.8)$$

είναι γνωστή ως το **τυπικό σφάλμα εκτίμησης** (standard error of estimate) ή το **τυπικό σφάλμα της παλινδρόμησης** (standard error of the regression) (se). Είναι απλώς η τυπική απόκλιση των τιμών της Y από την εκτιμημένη γραμμή παλινδρόμησης και χρησιμοποιείται συχνά ως ένα μέτρο για την «καλή προσαρμογή» (goodness of fit) της εκτιμημένης γραμμής παλινδρόμησης, ένα θέμα που συζητήθηκε στην Ενότητα 3.5.

Νωρίτερα επισημάναμε ότι, δοθείσης της X_i , η σ^2 αντιπροσωπεύει την (υπό συνθήκη) διακύμανση τόσο του u_i όσο και της Y_i . Ως εκ τούτου, το τυπικό σφάλμα της εκτίμησης μπορεί επίσης να ονομαστεί η (υπό συνθήκη) τυπική απόκλιση του u_i και της Y_i . Φυσικά, ως συνήθως, οι σ_X^2 και σ_Y αντιπροσωπεύουν, αντίστοιχα, την άνευ συνθήκης διακύμανση και την άνευ συνθήκης τυπική απόκλιση της Y .

Σημειώστε τα ακόλουθα χαρακτηριστικά των διακυμάνσεων (και ως εκ τούτου των τυπικών σφαλμάτων) των $\hat{\beta}_1$ και $\hat{\beta}_2$.

- 1 Η διακύμανση του $\hat{\beta}_2$ είναι ευθέως ανάλογη της σ^2 , αλλά αντιστρόφως ανάλογη του $\sum x_i^2$. Αυτό σημαίνει, δοθείσης της σ^2 , πως όσο μεγαλύτερη είναι η διακύμανση των τιμών της X , τόσο μικρότερη είναι η διακύμανση του $\hat{\beta}_2$ και ως εκ τούτου, τόσο μεγαλύτερη θα είναι η ακρίβεια με την οποία μπορεί να εκτιμηθεί ο β_2 . Με λίγα λόγια, δοθείσης της σ^2 , εάν υπάρχει σημαντική διακύμανση στις τιμές της X , ο β_2 μπορεί να μετρηθεί με μεγαλύτερη ακρίβεια από ότι όταν η X_i δε διαφέρει ουσιαστικά. Επίσης, δοθέντος του $\sum x_i^2$, όσο μεγαλύτερη είναι η διακύμανση της σ^2 , τόσο μεγαλύτερη θα είναι η διακύμανση του $\hat{\beta}_2$. Σημειώνεται ότι όσο αυξάνει το μέγεθος του δείγματος n , τόσο θα αυξάνει ο αριθμός των όρων στο σύνολο $\sum x_i^2$. Όσο αυξάνει το n , τόσο θα αυξάνει η ακρίβεια με την οποία μπορεί να εκτιμηθεί ο β_2 . (Γιατί;)
- 2 Η διακύμανση του $\hat{\beta}_1$ είναι ευθέως ανάλογη των σ^2 και $\sum X_i^2$ αλλά αντιστρόφως ανάλογη του $\sum x_i^2$ και του μεγέθους του δείγματος n .
- 3 Καθώς οι $\hat{\beta}_1$ και $\hat{\beta}_2$ είναι εκτιμητές, όχι μόνο θα διαφέρουν από δείγμα σε δείγμα, αλλά σε ένα δεδομένο δείγμα είναι πιθανό να εξαρτώνται ο ένας από τον άλλο, και αυτή η εξάρτηση μετράται από τη συνδιακύμανση μεταξύ τους. Στο Παράρτημα 3Α, Ενότητα 3Α.4 αποδεικνύεται ότι

$$\text{cov}(\hat{\beta}_1, \hat{\beta}_2) = -\bar{X} \text{var}(\hat{\beta}_2) = -\bar{X} \left(\frac{\sigma^2}{\sum x_i^2} \right) \quad (3.3.9)$$

Δεδομένου ότι η $\text{var}(\hat{\beta}_2)$ είναι πάντα θετική, όπως είναι η διακύμανση της οποιασδήποτε μεταβλητής, η φύση της συνδιακύμανσης μεταξύ των $\hat{\beta}_1$ και $\hat{\beta}_2$ εξαρτάται από το πρόσημο της $\bar{X}$. Εάν η $\bar{X}$ είναι θετική, τότε όπως δείχνει ο τύπος, η συνδιακύμανση θα είναι αρνητική. Συνεπώς, αν ο συντελεστής κλίσης β_2 *υπερεκτιμάται* (δηλαδή, η κλίση είναι πολύ απότομη), ο συντελεστής σταθεράς β_1 θα *υποεκτιμάται* (δηλαδή, ο συντελεστής σταθεράς θα είναι πολύ μικρός). Αργότερα (ειδικά στο κεφάλαιο για την πολυ-

συγγραμμικότητα, Κεφάλαιο 10), θα δούμε τη χρησιμότητα της μελέτης των συνδιακυμάνσεων μεταξύ των εκτιμημένων συντελεστών παλινδρόμησης.

Πώς επιτρέπουν οι διακυμάνσεις και τα τυπικά σφάλματα των εκτιμημένων συντελεστών παλινδρόμησης σε κάποιον να εξετάσει την αξιοπιστία αυτών των εκτιμήσεων; Αυτό είναι ένα πρόβλημα που αφορά τη συμπερασματική στατιστική, και θα εξεταστεί στα Κεφάλαια 4 και 5.

3.4 Ιδιότητες των Εκτιμητών των Ελαχίστων Τετραγώνων:

Το Θεώρημα Gauss-Markov

Όπως προαναφέρθηκε, λαμβάνοντας υπόψη τις υποθέσεις του κλασσικού γραμμικού υποδείγματος παλινδρόμησης, οι εκτιμήσεις των ελαχίστων τετραγώνων έχουν ορισμένες ιδανικές ή άριστες ιδιότητες. Αυτές οι ιδιότητες περιλαμβάνονται στο γνωστό **θεώρημα Gauss-Markov**¹⁷. Για να κατανοήσουμε αυτό το θεώρημα, πρέπει πρώτα να εξετάσουμε την ιδιότητα του **άριστου γραμμικού αμερόληπτου εκτιμητή** (best linear unbiased estimator - BLUE).¹⁸ Όπως εξηγείται στο **Παράρτημα Α**, ένας εκτιμητής, π.χ. ο εκτιμητής β_2 της OLS, λέγεται ότι είναι ο άριστος γραμμικός αμερόληπτος εκτιμητής (**BLUE**) του β_2 αν ισχύουν τα ακόλουθα:

- ❶ Είναι **γραμμικός**, δηλαδή, μία γραμμική συνάρτηση μίας τυχαίας μεταβλητής, όπως είναι η εξαρτημένη μεταβλητή Y στο υπόδειγμα παλινδρόμησης.
- ❷ Είναι **αμερόληπτος**, δηλαδή, η μέση ή προσδοκώμενη τιμή του, $E(\hat{\beta}_2)$, είναι ίση με την πραγματική τιμή, β_2 .
- ❸ Έχει ελάχιστη διακύμανση ανάμεσα στους αντίστοιχους γραμμικούς αμερόληπτους εκτιμητές. Ένας αμερόληπτος εκτιμητής με τη μικρότερη διακύμανση είναι γνωστός ως ένας **αποτελεσματικός εκτιμητής** (efficient coefficient).

Στο πλαίσιο της παλινδρόμησης μπορεί να αποδειχθεί ότι οι εκτιμητές της OLS είναι BLUE. Αυτή είναι η ουσία του περίφημου θεωρήματος Gauss-Markov, το οποίο μπορεί να διατυπωθεί ως εξής:

Το Θεώρημα Gauss-Markov

Λαμβάνοντας υπόψη τις υποθέσεις του κλασσικού γραμμικού υποδείγματος παλινδρόμησης, οι εκτιμητές των ελαχίστων τετραγώνων, από όλους τους αμερόληπτους γραμμικούς εκτιμητές, έχουν ελάχιστη διακύμανση, δηλαδή, είναι BLUE.

Η απόδειξη αυτού του θεωρήματος παρουσιάζεται στο **Παράρτημα 3Α, Ενότητα 3Α.6**. Η ολοκληρωμένη σημασία του θεωρήματος Gauss-Markov θα καταστεί σαφέστερη, καθώς προχωρούμε στο παρόν βιβλίο. Αυτό που αρκεί να σημειωθεί στο παρόν σημείο είναι ότι το θεώρημα έχει τόσο θεωρητική όσο και πρακτική σημασία.¹⁹

Η σημασία όλων των παραπάνω μπορεί να εξηγηθεί με τη βοήθεια του Διαγράμματος 3.7.


Στο Διάγραμμα 3.7(α) έχουμε δείξει την **κατανομή δειγματοληψίας** του εκτιμητή $\hat{\beta}_2$ της OLS, δηλαδή, την κατανομή των τιμών που λαμβάνονται από το $\hat{\beta}_2$ σε επαναλαμβανόμενες δειγματοληψίες (Πίνακας 3.1). Για λόγους ευκολίας έχουμε υποθέσει ότι ο $\hat{\beta}_2$ κατανέμεται συμμετρικά (όμως περισσότερα για αυτό το ζήτημα θα αναλυθούν στο Κεφάλαιο 4). Όπως φαίνεται στο σχήμα, ο μέσος όρος των τιμών του $\hat{\beta}_2$, $E(\hat{\beta}_2)$, ισούται με τον πραγματικό β_2 . Σε αυτή την κατάσταση λέμε ότι ο $\hat{\beta}_2$ είναι ένας **αμερόληπτος εκτιμητής** του β_2 .

Στο Διάγραμμα 3.7(β) έχουμε δείξει την κατανομή δειγματοληψίας του β_2^* , ενός εναλλακτικού εκτιμητή του β_2 που προκύπτει μέσω της χρήσης μίας άλλης (δηλαδή, άλλης από την OLS) μεθόδου. Για λόγους ευκολίας, ας υποθέσουμε ότι ο β_2^* , όπως και ο $\hat{\beta}_2$, είναι αμερόληπτοι, δηλαδή, η μέση ή προσδοκώμενη τιμή τους είναι ίση με β_2 . Υποθέτουμε περαιτέρω ότι τόσο ο $\hat{\beta}_2$ όσο και ο β_2^* είναι γραμμικοί εκτιμητές, δηλαδή, είναι γραμμικές συναρτήσεις της Y . Ποιον εκτιμητή θα επιλέγατε, τον $\hat{\beta}_2$ ή τον β_2^* ;

¹⁷ Μολονότι είναι γνωστό ως το θεώρημα Gauss-Markov, η προσέγγιση των ελαχίστων τετραγώνων του Gauss προηγείται χρονικά (1821) της προσέγγισης της ελάχιστης διακύμανσης του Markov (1900).

¹⁸ Ο αναγνώστης θα πρέπει να απευθυνθεί στο **Παράρτημα Α** για τη σημασία των γραμμικών εκτιμητών καθώς και για μία γενική συζήτηση για τις επιθυμητές ιδιότητες των στατιστικών εκτιμητών.

¹⁹ Για παράδειγμα, μπορεί να αποδειχθεί ότι κάθε γραμμικός συνδυασμός των β , όπως $(\beta_1 - 2\beta_2)$, μπορεί να εκτιμηθεί από $(\hat{\beta}_1 - 2\hat{\beta}_2)$, και αυτός ο εκτιμητής είναι BLUE. Για περισσότερες λεπτομέρειες, βλ. Henri Theil, *Introduction to Econometrics*, Prentice-Hall, Englewood Cliffs, NJ, 1978, σσ. 401-402. Επισημαίνεται ένα τεχνικό σημείο σχετικά με το θεώρημα Gauss-Markov: Παρέχει μόνο την επαρκή (αλλά όχι απαραίτητη) προϋπόθεση για να είναι αποτελεσματική η OLS. Είμαι ευγνώμων στον Michael McAleer του University of Western Australia ο οποίος μου επεσήμανε αυτό το σημείο.



ΔΙΑΓΡΑΜΜΑ 3.7 Κατανομή δειγματοληψίας του εκτιμητή $\hat{\beta}_2$ της OLS και εναλλακτικός εκτιμητής β_2^* .

Για να απαντήσουμε στο ερώτημα αυτό, παρουσιάζουμε τα δύο διαγράμματα μαζί στο Διάγραμμα 3.7(γ). Είναι προφανές ότι αν και οι δύο εκτιμητές, $\hat{\beta}_2$ και β_2^* είναι αμερόληπτοι, η κατανομή του β_2^* είναι πιο διεσπαρμένη ή διάχυτη γύρω από τη μέση τιμή σε σχέση με την κατανομή του $\hat{\beta}_2$. Με άλλα λόγια, η διακύμανση του β_2^* είναι μεγαλύτερη από την διακύμανση του $\hat{\beta}_2$. Τώρα με βάση δύο εκτιμητές οι οποίοι είναι τόσο γραμμικοί όσο και αμερόληπτοι, κάποιος θα επέλεγε τον εκτιμητή με τη μικρότερη διακύμανση, διότι είναι πιο πιθανό να είναι πιο κοντά στο β_2 από ότι ο εναλλακτικός εκτιμητής. Με λίγα λόγια, κάποιος θα επέλεγε τον εκτιμητή BLUE.

Είναι αξιοσημείωτο ότι το θεώρημα Gauss-Markov δεν κάνει καμία υπόθεση σχετικά με την κατανομή πιθανότητας της τυχαίας μεταβλητής u_i , και ως εκ τούτου της Y_i (στο επόμενο κεφάλαιο θα το εξετάσουμε εκτενέστερα). Εφ' όσον πληρούνται οι προϋποθέσεις του κλασικού γραμμικού υποδείγματος παλινδρόμησης, το θεώρημα ισχύει. Κατά συνέπεια, δε χρειάζεται να ψάξουμε για άλλο γραμμικό αμερόληπτο εκτιμητή, γιατί δε θα βρούμε άλλον παρόμοιο εκτιμητή, η διακύμανση του οποίου να είναι μικρότερη από ότι του εκτιμητή της OLS. Φυσικά, εάν μία ή περισσότερες από αυτές τις υποθέσεις δεν ισχύουν, το θεώρημα δεν είναι έγκυρο. Για παράδειγμα, αν αναλύσουμε μη-γραμμικά ως προς τις παραμέτρους υποδείγματα παλινδρόμησης (τα οποία αναλύονται στο Κεφάλαιο 14), μπορεί να έχουμε εκτιμητές οι οποίοι μπορεί να αποδίδουν καλύτερα από τους εκτιμητές της OLS. Επίσης, όπως θα δείξουμε στο κεφάλαιο για την ετεροσκεδαστικότητα, αν δεν πληρείται η υπόθεση της ομοσκεδαστικής διακύμανσης, οι εκτιμητές της OLS, αν και αμερόληπτοι και συνεπείς, δεν είναι πλέον εκτιμητές ελάχιστης διακύμανσης ακόμη και στην τάξη των γραμμικών εκτιμητών.


Οι στατιστικές ιδιότητες που μόλις συζητήσαμε είναι γνωστές ως **ιδιότητες πεπερασμένου δείγματος** (finite sample properties). Οι ιδιότητες αυτές ισχύουν, ανεξάρτητα από το μέγεθος του δείγματος στο οποίο στηρίζονται οι εκτιμητές. Αργότερα θα εξετάσουμε τις **ασυμπτωτικές ιδιότητες** (asymptotic properties), δηλαδή, τις ιδιότητες που ισχύουν μόνο αν το μέγεθος του δείγματος είναι πολύ μεγάλο (τεχνικά, άπειρο). Το **Παράρτημα Α** περιλαμβάνει μία γενική συζήτηση των ιδιοτήτων των εκτιμητών πεπερασμένων και μεγάλων δειγμάτων.

3.5 Ο Συντελεστής Προσδιορισμού r^2 : Ένα Μέτρο της «Καλής Προσαρμογής»

Μέχρι στιγμής ασχοληθήκαμε με το πρόβλημα της εκτίμησης των συντελεστών παλινδρόμησης, των τυπικών τους σφαλμάτων, και κάποιων από τις ιδιότητες τους. Στην παρούσα ενότητα εξετάζουμε την **καλή προσαρμογή** (goodness of fit) της γραμμής παλινδρόμησης σε ένα σύνολο στοιχείων· δηλαδή, θα μάθουμε πόσο ‘καλά’ προσαρμόζεται στα στοιχεία η γραμμή παλινδρόμησης του δείγματος. Από το Διάγραμμα 3.1, είναι σαφές ότι αν όλες οι παρατηρήσεις βρίσκονταν επί της γραμμής παλινδρόμησης, θα αποκτούσαμε μία «τέλεια» προσαρμογή, όμως αυτό συμβαίνει σπάνια. Σε γενικές γραμμές, θα υπάρχουν ορισμένα θετικά και ορισμένα αρνητικά u_i . Αυτό που ελπίζουμε είναι ότι αυτά τα κατάλοιπα που βρίσκονται γύρω από τη γραμμή παλινδρόμησης είναι όσο το δυνατόν μικρότερα. Ο **συντελεστής προσδιορισμού** (coefficient of determination) r^2 (στην περίπτωση δύο μεταβλητών) ή R^2 (σε πολλαπλή παλινδρόμηση) είναι ένα μέτρο που παρέχει συνοπτική πληροφόρηση σχετικά με το πόσο καλά προσαρμόζεται στα στοιχεία η γραμμή παλινδρόμησης του δείγματος.

Προτού δείξουμε πως υπολογίζεται ο R^2 , ας εξετάσουμε μία εμπειρική εξήγηση του r^2 χρησιμοποιώντας μία διαγραμματική μέθοδο, γνωστή ως **διάγραμμα Venn**, ή **Ballentine**, όπως αυτά που παρουσιάζονται στο Διάγραμμα 3.8.²⁰

Σε αυτό το Διάγραμμα, ο κύκλος Y αντιπροσωπεύει τη μεταβλητότητα της εξαρτημένης μεταβλητής Y και ο κύκλος X αντιπροσωπεύει τη μεταβλητότητα της ερμηνευτικής μεταβλητής X .²¹ Η επικάλυψη των δύο κύκλων (η σκιασμένη περιοχή) δείχνει το βαθμό στον οποίο η διακύμανση της Y εξηγείται από τη διακύμανση της X (δηλαδή, μέσω μίας παλινδρόμησης OLS). Όσο μεγαλύτερη είναι η έκταση της επικάλυψής τους, τόσο περισσότερο η διακύμανση της Y εξηγείται από τη X . Ο r^2 είναι απλώς μία αριθμητική μέτρηση αυτής της επικάλυψης. Στο σχήμα, καθώς κινούμαστε από τα αριστερά προς τα δεξιά, η έκταση της επικάλυψης αυξάνεται, δηλαδή, διαδοχικά μία μεγαλύτερη ποσότητα της μεταβλητότητας της Y εξηγείται από τη X . Με λίγα λόγια, ο r^2 αυξάνεται. Όταν δεν υπάρχει επικάλυψη, ο r^2 είναι προφανώς μηδέν, όταν όμως η επικάλυψη είναι πλήρης, ο r^2 είναι 1, αφού η μεταβλητότητα της Y εξηγείται από τη X κατά 100 τοις εκατό. Όπως θα δείξουμε σε λίγο, ο r^2 βρίσκεται μεταξύ του 0 και του 1.



ΔΙΑΓΡΑΜΜΑ 3.8 Η απεικόνιση του r^2 μέσω του διαγράμματος Ballentine: (α) $r^2 = 0$ και (f) $r^2 = 1$

Για να υπολογίσουμε αυτόν τον r^2 , προχωρούμε ως εξής: Υπενθυμίζεται ότι

$$Y_i = \hat{Y}_i + \hat{u}_i \quad (2.6.3)$$

ή στη μορφή των αποκλίσεων από τους μέσους

$$y_i = \hat{y}_i + \hat{u}_i \quad (3.5.1)$$

όπου γίνεται χρήση των Εξισώσεων (3.1.13) και (3.1.14). Υψώνοντας και τις δύο πλευρές της Εξίσωσης 3.5.1 στο τετράγωνο και αθροίζοντας σε όλο το δείγμα, παίρνουμε

²⁰ Βλ. Peter Kennedy, «Ballentine: A Graphical Aid for Econometrics» *Australian Economic Papers*, vol. 20, 1981, σσ. 414-416. Το όνομα Ballentine προέρχεται από το έμβλημα της γνωστής μπύρας Ballantine και τους κύκλους που έχει αυτό.

²¹ Οι όροι **μεταβλητότητα** και **διακύμανση** είναι διαφορετικοί. Μεταβλητότητα σημαίνει το άθροισμα των τετραγώνων των αποκλίσεων μίας μεταβλητής από τη μέση τιμή της. Διακύμανση είναι αυτό το άθροισμα των τετραγώνων το οποίο διαιρείται με τους κατάλληλους βαθμούς ελευθερίας. Εν ολίγοις, διακύμανση = μεταβλητότητα/βαθμούς ελευθερίας.

ή εναλλακτικά ως

$$r^2 = 1 - \frac{\sum \hat{u}_i^2}{\sum (Y_i - \bar{Y})^2} = 1 - \frac{\text{RSS}}{\text{TSS}} \quad (3.5.5a)$$

Η ποσότητα r^2 είναι γνωστή ως **συντελεστής προσδιορισμού** (coefficient of determination) (του δείγματος) και είναι το πιο συχνά χρησιμοποιούμενο μέτρο της ποιότητας προσαρμογής της γραμμής παλινδρόμησης. Ο r^2 μετρά την αναλογία ή το ποσοστό της συνολικής μεταβλητότητας της Y που εξηγείται από το υπόδειγμα παλινδρόμησης.

Μπορούμε να επισημάνουμε δύο ιδιότητες του r^2 :

- ❶ Πρόκειται για μία μη αρνητική ποσότητα. (Γιατί;)
- ❷ Τα όρια της είναι $0 \leq r^2 \leq 1$. Ένα r^2 ίσο με 1 σημαίνει τέλεια προσαρμογή, δηλαδή, $\hat{Y}_i = Y_i$ για κάθε i . Από την άλλη, ένας r^2 ίσος με μηδέν σημαίνει ότι δεν υπάρχει καμία σχέση μεταξύ της παλινδρομούμενης μεταβλητής και του παλινδρομητή (δηλαδή, $\beta_2 = 0$). Σε αυτή την περίπτωση, όπως δείχνει η Εξ. (3.1.9), $\hat{Y}_i = \hat{\beta}_1 = \bar{Y}$, η καλύτερη πρόβλεψη κάθε τιμής της Y είναι απλά η μέση τιμή της. Ως εκ τούτου, σε αυτήν την περίπτωση η γραμμή παλινδρόμησης θα είναι οριζόντια με τον άξονα X .

Παρόλο που ο r^2 μπορεί να υπολογιστεί απευθείας από τον ορισμό που δίνεται στην Εξίσωση 3.5.5, μπορεί να προκύψει πιο γρήγορα από τον ακόλουθο τύπο:

$$\begin{aligned} r^2 &= \frac{\text{ESS}}{\text{TSS}} = \frac{\sum \hat{y}_i^2}{\sum y_i^2} \\ &= \frac{\hat{\beta}_2^2 \sum x_i^2}{\sum y_i^2} = \hat{\beta}_2^2 \left(\frac{\sum x_i^2}{\sum y_i^2} \right) \end{aligned} \quad (3.5.6)$$

Αν διαιρέσουμε τον αριθμητή και τον παρονομαστή της Εξίσωσης 3.5.6 με το μέγεθος του δείγματος n (ή $n - 1$ αν το μέγεθος του δείγματος είναι μικρό), παίρνουμε

$$r^2 = \hat{\beta}_2^2 \left(\frac{S_x^2}{S_y^2} \right) \quad (3.5.7)$$

όπου S_y^2 και S_x^2 είναι οι διακυμάνσεις του δείγματος των Y και X , αντίστοιχα. Εφόσον $\hat{\beta}_2 = \sum x_i y_i / \sum x_i^2$, η Εξ. (3.5.6) μπορεί επίσης να εκφραστεί ως

$$r^2 = \frac{(\sum x_i y_i)^2}{\sum x_i^2 \sum y_i^2} \quad (3.5.8)$$

μια έκφραση που είναι υπολογιστικά εύκολο να προκύψει.

Λαμβάνοντας υπόψη τον ορισμό του r^2 , μπορούμε να εκφράσουμε τα ESS και RSS που συζητήθηκαν νωρίτερα ως εξής:

$$\text{ESS} = r^2 \cdot \text{TSS} = r^2 \sum y_i^2 \quad (3.5.9)$$

$$\begin{aligned} \text{RSS} &= \text{TSS} - \text{ESS} = \text{TSS}(1 - \text{ESS}/\text{TSS}) \\ &= \sum y_i^2 (1 - r^2) \end{aligned} \quad (3.5.10)$$

Επομένως, μπορούμε να γράψουμε

$$\begin{aligned} \text{TSS} &= \text{ESS} + \text{RSS} \\ \sum y_i^2 &= r^2 \sum y_i^2 + (1 - r^2) \sum y_i^2 \end{aligned} \quad (3.5.11)$$

μία σχέση που θα μας φανεί ιδιαίτερα χρήσιμη αργότερα.

Μια ποσότητα που συνδέεται στενά, αλλά είναι εννοιολογικά πολύ διαφορετική από το r^2 είναι ο **συντελεστής συσχέτισης** (coefficient of correlation), ο οποίος, όπως επισημαίνεται στο Κεφάλαιο 1, είναι ένα μέτρο του βαθμού συσχέτισης μεταξύ δύο μεταβλητών. Μπορεί να υπολογιστεί είτε από

$$r = \pm \sqrt{r^2} \quad (3.5.12)$$

είτε από τον ορισμό του

$$\begin{aligned} r &= \frac{\sum x_i y_i}{\sqrt{(\sum x_i^2)(\sum y_i^2)}} \\ &= \frac{n \sum X_i Y_i - (\sum X_i)(\sum Y_i)}{\sqrt{[n \sum X_i^2 - (\sum X_i)^2][n \sum Y_i^2 - (\sum Y_i)^2]}} \end{aligned} \quad (3.5.13)$$

ο οποίος είναι γνωστός ως ο **συντελεστής συσχέτισης του δείγματος** (sample correlation coefficient).²² Ορισμένες από τις ιδιότητες του r έχουν ως εξής (βλ. Διάγραμμα 3.10):

- ❶ Μπορεί να είναι θετικός ή αρνητικός, το πρόσημο εξαρτάται από το πρόσημο του όρου στον αριθμητή της Εξίσωσης 3.5.13, και μετρά τη *συμμεταβλητότητα* (covariation) στο δείγμα των δύο μεταβλητών.
- ❷ Βρίσκεται μεταξύ των ορίων του -1 και του +1, δηλαδή, $-1 \leq r \leq 1$.
- ❸ Είναι φύσει συμμετρικός, δηλαδή, ο συντελεστής συσχέτισης μεταξύ των X και Y , (r_{XY}), είναι ο ίδιος με εκείνον μεταξύ των Y και X (r_{YX}).
- ❹ Είναι ανεξάρτητος από το σταθερό όρο και την κλίμακα. Δηλαδή, αν ορίζουμε $X_i^* = aX_i + c$ και $Y_i^* = bY_i + d$, όπου $a > 0$, $b > 0$, και c και d είναι σταθερές, τότε ο r μεταξύ των X^* και Y^* είναι ο ίδιος με εκείνο μεταξύ των αρχικών μεταβλητών X και Y .
- ❺ Αν οι X και Y είναι στατιστικά ανεξάρτητες (βλ. **Παράρτημα Α** για τον ορισμό), ο συντελεστής συσχέτισης μεταξύ τους είναι μηδέν, όμως αν $r = 0$, αυτό δε σημαίνει ότι οι δύο μεταβλητές είναι ανεξάρτητες. Με άλλα λόγια, η **μηδενική συσχέτιση δε σημαίνει απαραίτητα ανεξαρτησία**. [Βλ. Διάγραμμα 3.10(η).]
- ❻ Είναι μόνο ένα μέτρο της γραμμικής σύνδεσης ή γραμμικής εξάρτησης και δεν έχει νόημα για την περιγραφή μη γραμμικών σχέσεων. Συνεπώς, στο Διάγραμμα 3.10(η), $Y = X^2$ είναι μία ακριβής σχέση ωστόσο ο r είναι μηδέν. (Γιατί;)
- ❼ Παρόλο που είναι ένα μέτρο της γραμμικής σύνδεσης μεταξύ των δύο μεταβλητών, δε συνεπάγεται κατ' ανάγκη κάποια σχέση αιτίας-αιτιατού, όπως σημειώνεται στο Κεφάλαιο 1.


Στο πλαίσιο της παλινδρόμησης, ο r^2 είναι πιο ουσιαστικό μέτρο από το r , καθώς ο πρώτος μας παρουσιάζει το ποσοστό της μεταβλητότητας της εξαρτημένης μεταβλητής που εξηγείται από τις ερμηνευτικές μεταβλητές και ως εκ τούτου παρέχει μία συνολική μέτρηση του βαθμού στον οποίο η μεταβλητότητα σε μία μεταβλητή καθορίζει τη μεταβλητότητα στην άλλη. Το δεύτερο δεν έχει τέτοια αξία.²³ Επιπλέον, όπως θα δούμε, η ερμηνεία του r ($= R$) σε ένα υπόδειγμα πολλαπλής παλινδρόμησης είναι αμφιβόλου αξίας. Ωστόσο, θα αναφερθούμε εκτενέστερα στο r^2 στο Κεφάλαιο 7.

Παρεμπιπτόντως, σημειώστε ότι ο r^2 όπως ορίζεται προηγουμένως μπορεί επίσης να υπολογισθεί ως το τετράγωνο του συντελεστή συσχέτισης μεταξύ της πραγματικής Y_i και της εκτιμημένης $\hat{Y}_i$, δηλαδή του $\hat{Y}_i$. Έτσι, χρησιμοποιώντας την Εξ. (3.5.13), μπορούμε να γράψουμε

$$r^2 = \frac{[\sum (Y_i - \bar{Y})(\hat{Y}_i - \bar{Y})]^2}{\sum (Y_i - \bar{Y})^2 \sum (\hat{Y}_i - \bar{Y})^2}$$

²² Ο συντελεστής συσχέτισης του πληθυσμού, που συμβολίζεται με ρ , ορίζεται στο **Παράρτημα Α**.

²³ Στην υποδειγματοποίηση της παλινδρόμησης, η υποκείμενη θεωρία θα υποδείξει την κατεύθυνση της αιτιότητας μεταξύ της Y και της X , η οποία, στο πλαίσιο των υποδειγμάτων μίας εξίσωσης, είναι γενικά από τη X στη Y .



ΔΙΑΓΡΑΜΜΑ 3.10 Πρότυπα συσχέτισης (προσαρμογή από το Henri Theil, *Introduction to Econometrics*, Prentice-Hall, EnglewoodCliffs, NJ, 1978, σελ. 86).

Δηλαδή

$$r^2 = \frac{(\sum y_i \hat{y}_i)^2}{(\sum y_i^2)(\sum \hat{y}_i^2)} \quad (3.5.14)$$

όπου Y_i = πραγματική Y , $\hat{Y}_i$ = εκτιμημένη Y , και $\bar{Y} = \bar{\hat{Y}} = 0$ μέσος της Y . Για την απόδειξη, βλ. Άσκηση 3.15. Η Εξίσωση 3.5.14 δικαιολογεί την περιγραφή του r^2 ως ένα μέτρο της καλής προσαρμογής, γιατί δείχνει πόσο κοντά είναι οι εκτιμημένες τιμές της Y στις πραγματικές τιμές της.

3.6 Ένα Αριθμητικό Παράδειγμα

Μέχρι το παρόν σημείο έχουμε παρουσιάσει την οικονομετρική θεωρία εξετάζοντας τα στοιχεία που προκύπτουν από τον Πίνακα 2.6, ο οποίος συνδέει το μέσο ωρομίσθιο (Y) με τα έτη φοίτησης (X). Η βασική θεωρία των οικονομικών της εργασίας μας λέει, ότι μεταξύ των διαφόρων μεταβλητών, η εκπαίδευση αποτελεί ένα σημαντικό προσδιοριστικό παράγοντα των μισθών.

Στον Πίνακα 3.2 παρουσιάζουμε τα απαραίτητα στοιχεία για την εκτίμηση της ποσοτικής επίδρασης της εκπαίδευσης στους μισθούς. Από τα στοιχεία που δίνονται στον παραπάνω πίνακα προκύπτει η ακόλουθη εκτιμημένη γραμμή παλινδρόμησης:

$$\hat{Y}_i = -0,0144 + 0,7240X_i \quad (3.6.1)$$

Γεωμετρικά, η εκτιμημένη γραμμή παλινδρόμησης είναι όπως παρουσιάζεται στο Διάγραμμα 3.11.

Όπως γνωρίζουμε, κάθε σημείο επί της γραμμής παλινδρόμησης δίνει μία εκτίμηση της μέσης τιμής της Y που αντιστοιχεί στην επιλεγμένη τιμή της X , δηλαδή, $\hat{Y}_i$ είναι μία εκτίμηση της $E(Y|X_i)$. Η τιμή $\beta_1 = 0,7240$, η οποία μετρά την κλίση της γραμμής, δείχνει ότι, εντός του εύρους δείγματος της X μεταξύ 6 και 18 ετών εκπαίδευσης, καθώς η X αυξάνεται κατά 1, η εκτιμημένη αύξηση στο μέσο ωρομίσθιο είναι περίπου 72 cents. Δηλαδή, κάθε επιπλέον έτος σχολικής φοίτησης, κατά μέσο όρο, αυξάνει το ωρομίσθιο κατά περίπου 72 cents.

ΠΙΝΑΚΑΣ 3.2 Στοιχεία που Βασίζονται στον Πίνακα 2.6

Παρατηρήσεις	Y	X	x	y	x_i^2	$y_i x_i$
1	4,4567	6	-6	-4,218	36	25,308
2	5,77	7	-5	-2,9047	25	14,5235
3	5,9787	8	-4	-2,696	16	10,784
4	7,3317	9	-3	-1,343	9	4,029
5	7,3182	10	-2	-1,3565	4	2,713
6	6,5844	11	-1	-2,0903	1	2,0903
7	7,8182	12	0	-0,8565	0	0
8	7,8351	13	1	-0,8396	1	-0,8396
9	11,0223	14	2	2,3476	4	4,6952
10	10,6738	15	3	1,9991	9	5,9973
11	10,8361	16	4	2,1614	16	8,6456
12	13,615	17	5	4,9403	25	24,7015
13	13,531	18	6	4,8563	36	29,1378
Σύνολο	112,7712	156	0	0	182	131,7856

Παρατηρήσεις	X_i^2	Y_i^2	$\hat{Y}_i$	$\hat{u}_i = Y_i - \hat{Y}$	$\hat{u}_i^2$
1	36	19,86217	4,165294	0,291406	0,084917
2	49	33,2929	4,916863	0,853137	0,727843
3	64	35,74485	5,668432	0,310268	0,096266
4	81	53,75382	6,420001	0,911699	0,831195
5	100	53,55605	7,17157	0,14663	0,0215
6	121	43,35432	7,923139	-1,33874	1,792222
7	144	61,12425	8,674708	-0,85651	0,733606
8	169	61,38879	9,426277	-1,59118	2,531844
9	196	121,4911	10,17785	0,844454	0,713103
10	225	113,93	10,92941	-0,25562	0,065339
11	256	117,4211	11,68098	-0,84488	0,713829
12	289	185,3682	12,43255	1,182447	1,398181
13	324	183,088	13,18412	0,346878	0,120324
Σύνολο	2054	1083,376	112,7712	≈ 0	9,83017

Σημείωση:

$$x_i = X_i - \bar{X}$$

$$y_i = Y_i - \bar{Y}$$

$$\hat{\beta}_2 = \frac{\sum y_i x_i}{\sum x_i^2} = \frac{131,7856}{182} = 0,7240967$$

$$\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X} = 8,674708 - 0,7240967 \times 12 = -0,01445$$

$$\hat{\sigma}^2 = \frac{\sum \hat{u}_i^2}{n-2} = \frac{9,83017}{11} = 0,893652$$

$$\hat{\sigma} = 0,945332$$

$$\text{var}(\hat{\beta}_2) = \frac{\hat{\sigma}^2}{\sum x_i^2} = \frac{0,893652}{182} = 0,004910$$


$$\text{se}(\hat{\beta}_2) = \sqrt{0,00490} = 0,070072$$

$$r^2 = 1 - \frac{\sum \hat{u}_i^2}{\sum (Y_i - \bar{Y})^2} = 1 - \frac{9,83017}{105,1188} = 0,9065$$

$$r = \sqrt{r^2} = 0,9521$$

$$\text{var}(\hat{\beta}_1) = \frac{\sum x_i^2}{n \sum x_i^2} = \frac{2054}{13(182)} = 0,868132$$

$$\text{se}(\hat{\beta}_1) = \sqrt{0,868132} = 0,9317359$$



ΔΙΑΓΡΑΜΜΑ 3.11 Εκτιμημένη γραμμή παλινδρόμησης για στοιχεία μισθών-εκπαίδευσης από τον Πίνακα 2.6.

Η τιμή του $\beta_1 = -0,0144$, που είναι ο συντελεστής σταθεράς της γραμμής, δείχνει το μέσο μισθολογικό επίπεδο όταν το επίπεδο της εκπαίδευσης είναι μηδενικό. Η συγκεκριμένη, κυριολεκτική, ερμηνεία του συντελεστή σταθεράς στην προκειμένη περίπτωση δεν έχει κανένα νόημα. Πώς θα μπορούσαν να υπάρξουν αρνητικοί μισθοί; Όπως θα δούμε σε όλο το παρόν βιβλίο, πολύ συχνά ο συντελεστής σταθεράς δεν έχει πρακτική έννοια. Εκτός αυτού, το μηδενικό επίπεδο εκπαίδευσης δεν αποτελεί επίπεδο που εξετάζουμε στο δείγμα μας. Όπως θα δούμε στο Κεφάλαιο 5, η παρατηρούμενη τιμή του συντελεστή σταθεράς δεν είναι στατιστικά διαφορετική από το μηδέν.

Η τιμή του r^2 , ύψους 0,90 δείχνει ότι η εκπαίδευση εξηγεί περίπου το 90 τοις εκατό της μεταβολής στο ωρομίσθιο. Λαμβάνοντας υπόψη ότι ο r^2 μπορεί να έχει μέγιστη τιμή το 1, η γραμμή παλινδρόμησης μας παρουσιάζει πολύ καλή προσαρμογή στα στοιχεία. Ο συντελεστής συσχέτισης, $r = 0,9521$, δείχνει ότι οι μισθοί και η εκπαίδευση εμφανίζουν υψηλή θετική συσχέτιση.

Ολοκληρώνοντας το παράδειγμά μας, πρέπει να σημειώσουμε ότι το υπόδειγμά μας είναι εξαιρετικά απλό. Σύμφωνα με τη θεωρία των οικονομικών της εργασίας, εκτός από την εκπαίδευση, άλλες μεταβλητές όπως το φύλο, η φυλή, η τοποθεσία, τα εργατικά συνδικάτα και η γλώσσα αποτελούν επίσης σημαντικούς παράγοντες για τον προσδιορισμό των ωρομισθίων. Αφότου εξετάσουμε την πολλαπλή παλινδρόμηση στα Κεφάλαια 7 και 8, θα εξετάσουμε ένα πιο εκτεταμένο υπόδειγμα προσδιορισμού των μισθών.

3.7 Επεξηγηματικά Παραδείγματα

Ας επανεξετάσουμε τα στοιχεία για το εισόδημα και την κατανάλωση που παρουσιάζονται στον Πίνακα I.1 της Εισαγωγής. Έχουμε ήδη δείξει τα στοιχεία στο Διάγραμμα 3, σε συνδυασμό με την εκτιμημένη γραμμή παλινδρόμησης στην Εξίσωση (3). Τώρα παρουσιάζουμε τα αποτελέσματα της παλινδρόμησης με τη χρήση της OLS, τα οποία προέκυψαν από την επεξεργασία των στοιχείων στο *EViews 6*. Σημειώνεται ότι Y = προσωπική καταναλωτική δαπάνη (PCE) και X = ακαθάριστο εγχώριο προϊόν (GDP), τα οποία μετρώνται σε δισεκατομμύρια δολάρια σε τιμές του 2000. Σε αυτό το παράδειγμα τα στοιχεία αυτά είναι στοιχεία χρονοσειρών.

$$\hat{Y}_t = -299,5913 + 0,7218X_t \quad (3.7.1)$$

Κεφάλαιο 7

Ανάλυση Πολλαπλής Παλινδρόμησης: Το πρόβλημα της Εκτίμησης

Το διμεταβλητό υπόδειγμα που μελετήθηκε εκτενώς στα προηγούμενα κεφάλαια είναι συχνά ανεπαρκές στην πράξη. Στο παράδειγμα κατανάλωσης-εισοδήματος (Παράδειγμα 3.1), για παράδειγμα, θεωρήθηκε σιωπηρά ότι μόνο το εισόδημα X σχετίζεται με την κατανάλωση Y . Ωστόσο, η οικονομική θεωρία σπάνια είναι τόσο απλή καθώς, εκτός από το εισόδημα, υπάρχει μία σειρά άλλων μεταβλητών που είναι επίσης πιθανό να επηρεάσει τις καταναλωτικές δαπάνες. Ένα προφανές παράδειγμα είναι ο πλούτος του καταναλωτή. Ένα επιπλέον παράδειγμα, είναι ότι η ζήτηση για ένα αγαθό είναι πιθανό να εξαρτάται όχι μόνο από τη δική του τιμή, αλλά και από τις τιμές άλλων ανταγωνιστικών ή συμπληρωματικών αγαθών, το εισόδημα του καταναλωτή, την κοινωνική θέση κ.λπ. Ως εκ τούτου, πρέπει να επεκτείνουμε το απλό διμεταβλητό υπόδειγμα παλινδρόμησης και να εξετάσουμε υποδείγματα στα οποία περιλαμβάνονται περισσότερες από δύο μεταβλητές. Η προσθήκη περισσότερων μεταβλητών μας οδηγεί στη συζήτηση για τα υποδείγματα πολλαπλής παλινδρόμησης, δηλαδή, τα υποδείγματα στα οποία η εξαρτημένη μεταβλητή, ή παλινδρομούμενη μεταβλητή, Y , εξαρτάται από δύο ή περισσότερες ερμηνευτικές μεταβλητές, ή παλινδρομητές.

Το απλούστερο δυνατό υπόδειγμα πολλαπλής παλινδρόμησης είναι το υπόδειγμα παλινδρόμησης τριών μεταβλητών, με μία εξαρτημένη μεταβλητή και δύο ερμηνευτικές μεταβλητές. Στο παρόν και στο επόμενο κεφάλαιο θα μελετήσουμε αυτό το υπόδειγμα. Στο σύνολο του βιβλίου, μας απασχολούν γραμμικά υποδείγματα πολλαπλής παλινδρόμησης, δηλαδή, υποδείγματα γραμμικά ως προς τις παραμέτρους: αυτά μπορεί να είναι ή μπορεί να μην είναι γραμμικά ως προς τις μεταβλητές.

7.1 Το Υπόδειγμα Τριών-Μεταβλητών: Συμβολισμός και Υποθέσεις

Γενικεύοντας τη διμεταβλητή συνάρτηση παλινδρόμησης του πληθυσμού (PRF) Εξ. (2.4.2), μπορούμε να γράψουμε την PRF τριών-μεταβλητών ως

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i \quad (7.1.1)$$

όπου Y είναι η εξαρτημένη μεταβλητή, X_2 και X_3 οι ερμηνευτικές μεταβλητές (ή παλινδρομητές), u ο στοχαστικός διαταρακτικός όρος, και i η $i^{\text{η}}$ παρατήρηση¹ στην περίπτωση που τα στοιχεία είναι χρονοσειρές, ο δείκτης t θα χαρακτηρίζει την $t^{\text{η}}$ παρατήρηση.¹

Στην Εξίσωση (7.1.1), ο β_1 είναι η σταθερά. Ως συνήθως, εκφράζει το μέσο ή τη μέση επίδραση στη Y του συνόλου των μεταβλητών που εξαιρούνται από το υπόδειγμα, αν και η ερμηνεία της είναι ότι αποτελεί τη μέση τιμή της Y όταν οι X_2 και X_3 ορίζονται ότι ισούνται με το μηδέν. Οι συντελεστές β_2 και β_3 ονομάζονται **συντελεστές μερικής παλινδρόμησης** (partial regression coefficients) και η σημασία τους θα εξηγηθεί σύντομα.

¹ Η Εξ. (7.1.1) μπορεί επίσης να γραφεί ως:

$$Y_i = \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i$$

με την προϋπόθεση ότι $X_{1i} = 1$ για όλα τα i .

Θα συνεχίσουμε να λειτουργούμε στο πλαίσιο του κλασικού γραμμικού υποδείγματος παλινδρόμησης που εισήχθη στο Κεφάλαιο 3. Ως υπενθύμιση, υποθέτουμε τα ακόλουθα:

ΥΠΟΘΕΣΕΙΣ

1. Γραμμικό υπόδειγμα παλινδρόμησης, ή γραμμικό ως προς τις παραμέτρους. (7.1.2)

2. Σταθερές τιμές της X ή τιμές της X ανεξάρτητες από τον όρο σφάλματος. Αυτό σημαίνει ότι ζητούμε μηδενική συνδιακύμανση μεταξύ u_i και κάθε μεταβλητής X .

$$\text{cov}(u_i, X_{2i}) = \text{cov}(u_i, X_{3i}) = 0 \quad (7.1.3)$$

3. Μηδενική μέση τιμή του διαταρακτικού όρου u_i .

$$E(u_i | X_{2i}, X_{3i}) = 0 \quad \text{για κάθε } i \quad (7.1.4)$$

4. Ομοσκεδαστικότητα ή σταθερή διακύμανση του u_i .

$$\text{var}(u_i) = \sigma^2 \quad (7.1.5)$$

5. Απουσία αυτοσυσχέτισης, ή σειριακής συσχέτισης, μεταξύ των διαταρακτικών όρων.

$$\text{cov}(u_i, u_j) = 0 \quad i \neq j \quad (7.1.6)$$

6. Ο αριθμός των παρατηρήσεων n πρέπει να είναι μεγαλύτερος από τον αριθμό των παραμέτρων που πρέπει να εκτιμηθούν, οι οποίες στην προκειμένη περίπτωση είναι 3. (7.1.7)

7. Πρέπει να υπάρχει διακύμανση στις τιμές των μεταβλητών X .

Θα εξετάσουμε επίσης άλλες δύο προϋποθέσεις. (7.1.8)

8. Δεν υπάρχει ακριβής συγγραμμικότητα μεταξύ των μεταβλητών X . Δηλαδή:

$$\text{Δεν υπάρχει ακριβής γραμμική σχέση μεταξύ } X_2 \text{ και } X_3 \quad (7.1.9)$$

Στην Ενότητα 7.7, θα μελετήσουμε εκτενέστερα την τελική υπόθεση.

9. Δεν υπάρχει σφάλμα εξειδίκευσης. Δηλαδή:

$$\text{Το υπόδειγμα έχει προσδιοριστεί σωστά.} \quad (7.1.10)$$

Το σκεπτικό για τις υποθέσεις από την (7.1.2) μέχρι την (7.1.10) είναι το ίδιο με αυτό που συζητήθηκε στην Ενότητα 3.2. Η Υπόθεση (7.1.9), ότι δεν υπάρχει ακριβής γραμμική σχέση μεταξύ X_2 και X_3 , είναι γνωστή ως η υπόθεση της μη-συγγραμμικότητας ή απουσίας πολυσυγγραμμικότητας εάν εμπλέκονται περισσότερες από μία ακριβείς γραμμικές σχέσεις. Άτυπα, η απουσία συγγραμμικότητας σημαίνει ότι κανένας από τους παλινδρομητές δε μπορεί να γραφεί ως ακριβής γραμμικός συνδυασμός των υπόλοιπων παλινδρομητών στο υπόδειγμα.

Τυπικά, η απουσία συγγραμμικότητας σημαίνει ότι δεν υπάρχει κανένα σύνολο αριθμών (διάφοροι του μηενός) λ_2 και λ_3 , ώστε

$$\lambda_2 X_{2i} + \lambda_3 X_{3i} = 0 \quad (7.1.11)$$

Εάν υπάρχει μία τέτοια ακριβής γραμμική σχέση, τότε οι X_2 και X_3 λέγεται ότι είναι **συγγραμμικές** ή γραμμικώς εξαρτημένες. Από την άλλη, εάν η Εξ. (7.1.11) ισχύει μόνο όταν $\lambda_2 = \lambda_3 = 0$, τότε οι X_2 και X_3 λέγεται ότι είναι **γραμμικά ανεξάρτητες**. Συνεπώς, εάν

$$X_{2i} = -4X_{3i} \quad \text{ή} \quad X_{2i} + 4X_{3i} = 0 \quad (7.1.12)$$

οι δύο μεταβλητές είναι γραμμικά εξαρτημένες, και εάν περιλαμβάνονται και οι δύο σε ένα υπόδειγμα παλινδρόμησης, θα έχουμε τέλεια συγγραμμικότητα ή ακριβή γραμμική σχέση μεταξύ των δύο παλινδρομητών.

Παρόλο που θα εξετάσουμε το πρόβλημα της πολυσυγγραμμικότητας σε βάθος στο Κεφάλαιο 10, διαπιστώνεται, η λογική πίσω από την υπόθεση της απουσίας πολυσυγγραμμικότητας δεν είναι πολύ δύσκολο να γίνει κατανοητή. Ας υποθέσουμε ότι στην Εξ. (7.1.1) οι Y , X_2 και X_3 αντιπροσωπεύουν τις καταναλωτικές δαπάνες, το εισόδημα, και τον πλούτο του καταναλωτή, αντίστοιχα. Αξιωνοντας ότι οι καταναλωτικές δαπάνες σχετίζονται γραμμικά με το εισόδημα και τον πλούτο, η οικονομική θεωρία υποθέτει ότι

ο πλούτος και το εισόδημα μπορεί να έχουν κάποια ανεξάρτητη επίδραση στην κατανάλωση. Αν όχι, δεν υπάρχει καμία λογική να συμπεριλάβουμε μεταβλητές τόσο εισοδήματος όσο και πλούτου στο υπόδειγμα. Σε εξαιρετικές περιπτώσεις, εάν υπάρχει μία ακριβής γραμμική σχέση μεταξύ του εισοδήματος και του πλούτου, έχουμε κατά βάση μόνο μία ανεξάρτητη μεταβλητή, όχι δύο, και δεν υπάρχει τρόπος να εκτιμηθεί η *ξεχωριστή* επιρροή του εισοδήματος και του πλούτου στην κατανάλωση. Για να φανεί αυτό καθαρά, έστω ότι $X_{3i} = 2X_{2i}$ στην παλινδρόμηση κατανάλωση-εισόδημα-πλούτος. Στη συνέχεια, η παλινδρόμηση (7.1.1) γίνεται

$$\begin{aligned} Y_i &= \beta_1 + \beta_2 X_{2i} + \beta_3 (2X_{2i}) + u_i \\ &= \beta_1 + (\beta_2 + 2\beta_3) X_{2i} + u_i \\ &= \beta_1 + \alpha X_{2i} + u_i \end{aligned} \quad (7.1.13)$$

όπου $\alpha = (\beta_2 + 2\beta_3)$. Δηλαδή, ουσιαστικά έχουμε ένα διμεταβλητό υπόδειγμα παλινδρόμησης και όχι ένα υπόδειγμα παλινδρόμησης τριών μεταβλητών. Επιπλέον, αν εκτιμήσουμε την παλινδρόμηση (7.1.13) και υπολογίσουμε το α , δεν υπάρχει τρόπος να εκτιμηθεί η ξεχωριστή επίδραση της $X_2 (= \beta_2)$ και της $X_3 (= \beta_3)$ στη Y , καθώς το α δίνει τη *συνδυασμένη επίδραση* των X_2 και X_3 στη Y .²

Με λίγα λόγια, η υπόθεση της απουσίας πολυσυγγραμμικότητας προβλέπει ότι στην PRF συμπεριλαμβάνουμε μόνο τις μεταβλητές εκείνες που δεν είναι ακριβείς γραμμικές συναρτήσεις μίας ή περισσότερων μεταβλητών στο υπόδειγμα. Παρά το γεγονός ότι θα συζητήσουμε αυτό το θέμα εκτενέστερα στο Κεφάλαιο 10, μπορούμε να επισημάνουμε ορισμένα σημεία:

- ♦ η υπόθεση απουσίας πολυσυγγραμμικότητας αναφέρεται στο θεωρητικό (δηλαδή, PRF) μας υπόδειγμα. Στην πράξη, όταν συλλέγουμε στοιχεία για την εμπειρική ανάλυση δεν υπάρχει καμία εγγύηση ότι δε θα υπάρχουν συσχετίσεις μεταξύ των παλινδρομητών. Μάλιστα, στις περισσότερες εφαρμοσμένες μελέτες είναι σχεδόν αδύνατο να βρεθούν δύο ή περισσότερες (οικονομικές) μεταβλητές οι οποίες να μην παρουσιάζουν συσχέτιση σε κάποιο βαθμό, όπως θα δείξουμε στα παραδείγματά μας αργότερα στο κεφάλαιο. Αυτό που χρειαζόμαστε είναι να μην υπάρχουν ακριβείς γραμμικές σχέσεις μεταξύ των παλινδρομητών, όπως στην Εξ. (7.1.12).
- ♦ αναφερόμαστε μόνο σε τέλεια γραμμικές σχέσεις μεταξύ δύο ή περισσότερων μεταβλητών. Η πολυσυγγραμμικότητα δεν αποκλείει το ενδεχόμενο να υπάρχουν *μη γραμμικές* σχέσεις μεταξύ των μεταβλητών. Ας υποθέσουμε ότι $X_{3i} = X_{2i}^2$. Αυτό δεν παραβιάζει την υπόθεση της μη τέλει συγγραμμικότητας, δεδομένου ότι η σχέση μεταξύ των μεταβλητών στη συγκεκριμένη περίπτωση είναι μη γραμμική.

7.2 Ερμηνεία της Εξίσωσης Πολλαπλής Παλινδρόμησης

Λαμβάνοντας υπόψη τις υποθέσεις της κλασικού υποδείγματος παλινδρόμησης, προκύπτει ότι, παίρνοντας την υπό συνθήκη προσδοκία της Y και στις δύο πλευρές της Εξίσωσης (7.1.1), παίρνουμε

$$E(Y_i | X_{2i}, X_{3i}) = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} \quad (7.2.1)$$

Με άλλα λόγια, η Εξ. (7.2.1) δίνει την *υπό συνθήκη μέση ή προσδοκώμενη τιμή της Y η οποία εξαρτάται από τις δοθείσες ή σταθερές τιμές των X_2 και X_3* . Ως εκ τούτου, όπως και στη διμεταβλητή περίπτωση, η ανάλυση πολλαπλής παλινδρόμησης εξαρτάται από τις σταθερές τιμές των παλινδρομητών, και αυτό που παίρνουμε είναι ο μέσος όρος ή η μέση τιμή της Y ή η μέση απόκριση της Y στις δοθείσες τιμές των παλινδρομητών.

7.3 Η Έννοια των Συντελεστών Μερικής Παλινδρόμησης

Όπως προαναφέρθηκε, οι συντελεστές παλινδρόμησης β_2 και β_3 είναι γνωστοί ως *συντελεστές μερικής παλινδρόμησης ή μερικής κλίσης*. Η έννοια του συντελεστή μερικής παλινδρόμησης είναι η εξής: ο β_2 μέτρα τη *μεταβολή* της μέσης τιμής της Y , $E(Y)$, ανά μονάδα μεταβολής της X_2 , διατηρώντας την τιμή της X_3 σταθερή. Με άλλα λόγια, δίνει το «άμεσο» ή «καθαρό» αποτέλεσμα μίας μοναδιαίας μεταβολής της X_2 στη μέση τιμή της Y , μετά την αφαίρεση τυχόν επιδράσεων που μπορεί να έχει η X_3 στο μέσο της Y . Ομοί-

² Από μαθηματικής άποψης, $\alpha = (\beta_2 + 2\beta_3)$ είναι μία εξίσωση με δύο αγνώστους και δεν υπάρχει κανένας μοναδικός τρόπος εκτίμησης των β_2 και β_3 από το εκτιμημένο α .

ως το β_3 μέτρα τη μεταβολή της μέσης τιμής της Y για κάθε μοναδιαία μεταβολή στη X_3 , διατηρώντας την τιμή της X_2 σταθερή.³ Δηλαδή, δίνει το «άμεσο» ή «καθαρό» αποτέλεσμα μίας μοναδιαίας μεταβολής της X_3 στη μέση τιμή της Y , μετά την αφαίρεση τυχόν επιδράσεων που μπορεί να έχει η X_2 στο μέσο της Y .⁴

Πώς μπορούμε να διατηρήσουμε την επιρροή ενός παλινδρομητή σταθερή; Για να το εξηγήσουμε αυτό, ας επανέλθουμε στο παράδειγμα της παιδικής θνησιμότητας (Παράδειγμα 6.6). Υπενθυμίζουμε ότι σε αυτό το παράδειγμα, Y = παιδική θνησιμότητα (CM), X_2 = κατά κεφαλήν ΑΕΠ (PGNP), και X_3 = ποσοστό αλφαριθμητισμού των γυναικών (FLR). Ας υποθέσουμε ότι θέλετε να διατηρήσετε την επιρροή της FLR σταθερή. Δεδομένου ότι η FLR μπορεί να έχει κάποια επίδραση στη CM καθώς και στη PGNP σε κάθε δοθέν σύνολο στοιχείων, αυτό που μπορούμε να κάνουμε είναι να αφαιρέσουμε τη (γραμμική) επίδραση της FLR και από τη CM και από τη PGNP εκτιμώντας την παλινδρόμηση της CM με την FLR και της PGNP με την FLR χωριστά και στη συνέχεια να εξετάσουμε τα κατάλοιπα που προέρχονται από αυτές τις παλινδρομήσεις. Χρησιμοποιώντας τα στοιχεία που παρατίθενται στον Πίνακα 6.4, παίρνουμε τις ακόλουθες παλινδρομήσεις:

$$\widehat{CM}_i = 263,8635 - 2,3905 FLR_i + \hat{u}_{1i} \quad (7.3.1)$$

$$se = (12,2249) \quad (0,2133) \quad r^2 = 0,6695$$

όπου $\hat{u}_{1i}$ αντιπροσωπεύει τα κατάλοιπα αυτής της παλινδρόμησης.

$$\widehat{PGNP}_i = -39,3033 + 28,1427 FLR_i + \hat{u}_{2i} \quad (7.3.2)$$

$$se = (734,9526) \quad (12,8211) \quad r^2 = 0,0721$$

όπου $\hat{u}_{2i}$ αντιπροσωπεύει τα κατάλοιπα αυτής της παλινδρόμησης.

Τώρα

$$\hat{u}_{1i} = (CM_i - 263,8635 + 2,3905 FLR_i) \quad (7.3.3)$$

αντιπροσωπεύει το μέρος εκείνο της CM που απομένει απαλείφοντας τη (γραμμική) επίδραση της FLR. Ομοίως,

$$\hat{u}_{2i} = (PGNP_i + 39,3033 - 28,1427 FLR_i) \quad (7.3.4)$$

αντιπροσωπεύει το μέρος εκείνο της PGNP που απομένει απαλείφοντας τη (γραμμική) επίδραση της FLR.

Ως εκ τούτου, εάν παλινδρομήσουμε τώρα τα $\hat{u}_{1i}$ με τα $\hat{u}_{2i}$, τα οποία είναι «καθαρά» από τη (γραμμική) επίδραση της FLR, δε θα καταλήξουμε στο καθαρό αποτέλεσμα της PGNP επί της CM; Αυτό ισχύει στην πραγματικότητα (βλ. Παράρτημα 7Α, Ενότητα 7Α.2). Τα αποτελέσματα της παλινδρόμησης έχουν ως εξής:

$$\hat{\hat{u}}_{1i} = -0,0056 \hat{u}_{2i} \quad (7.3.5)$$

$$se = (0,0019) \quad r^2 = 0,1152$$

Σημείωση: Αυτή η παλινδρόμηση δεν έχει σταθερό όρο, διότι η μέση τιμή των καταλοίπων της OLS, $\hat{u}_{1i}$ και $\hat{u}_{2i}$, είναι μηδέν. (Γιατί;)

Ο συντελεστής κλίσης που ισούται με -0,0056 δίνει τώρα την «πραγματική» ή καθαρή επίδραση της μοναδιαίας μεταβολής της PGNP στη CM ή την πραγματική κλίση της CM σε σχέση με τη PGNP. Δηλαδή, δίνει το συντελεστή μερικής παλινδρόμησης της CM σε σχέση με την PGNP, το β_2 .

Οι αναγνώστες που θέλουν να βρουν το συντελεστή μερικής παλινδρόμησης της CM ως προς την FLR μπορούν να αναπαράγουν την παραπάνω διαδικασία παλινδρομώντας αρχικά τη CM με τη PGNP και παίρνοντας τα κατάλοιπα από αυτή την παλινδρόμηση ($\hat{u}_{1i}$), και παλινδρομώντας στη συνέχεια την FLR με την PGNP και παίρνοντας τα κατάλοιπα από αυτή την παλινδρόμηση ($\hat{u}_{2i}$), και τέλος παλινδρομώντας τα $\hat{u}_{1i}$ με τα $\hat{u}_{2i}$.

³ Ο αναγνώστης με γνώσεις διαφορικού λογισμού θα παρατηρήσει αμέσως ότι β_2 και β_3 είναι οι μερικές παράγωγοι της $E(Y | X_2, X_3)$ ως προς τις X_2 και X_3 .

⁴ Παρεμπιπτόντως, οι όροι διατηρώντας σταθερά, ελέγχοντας για, λαμβάνοντας υπόψη την επίδραση της, ελέγχοντας την επίδραση του, και απαλείφοντας την επίδραση του είναι συνώνυμοι και θα χρησιμοποιούνται εναλλακτικά στο παρόν βιβλίο.

Πρέπει να κάνουμε όλη αυτή τη διαδικασία κάθε φορά που θέλουμε να βρούμε τον πραγματικό συντελεστή μερικής παλινδρόμησης; Ευτυχώς, όχι, καθώς η ίδια διαδικασία μπορεί να γίνει σχετικά γρήγορα και συστηματικά μέσω της μεθόδου της OLS που παρουσιάζεται στην επόμενη ενότητα. Η διαδικασία πολλαπλών βημάτων που μόλις περιγράφηκε γίνεται μόνο για ενημερωτικούς σκοπούς προκειμένου να γίνει κατανοητή η έννοια του συντελεστή «μερικής» παλινδρόμησης.

7.4 Εκτίμηση OLS και ML των Συντελεστών Μερικής Παλινδρόμησης

Για να εκτιμήσουμε τις παραμέτρους του υποδείγματος παλινδρόμησης τριών μεταβλητών (7.1.1), αρχικά εξετάζουμε τη μέθοδο των ελαχίστων τετραγώνων (OLS) που παρουσιάστηκε στο Κεφάλαιο 3 και στη συνέχεια εξετάζουμε εν συντομία την μέθοδο της μέγιστης πιθανοφάνειας (ML) που παρουσιάστηκε στο Κεφάλαιο 4.

Οι Εκτιμητές της OLS

Για να βρούμε τους εκτιμητές της OLS, γράφουμε αρχικά τη συνάρτηση παλινδρόμησης του δείγματος (SRF) που αντιστοιχεί στην PRF της Εξίσωσης (7.1.1):

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \hat{u}_i \quad (7.4.1)$$

όπου $\hat{u}_i$ είναι τα κατάλοιπα, το αντίστοιχο του στοχαστικού διαταρακτικού όρου u_i .

Όπως αναφέρεται στο Κεφάλαιο 3, η διαδικασία OLS αποτελείται από την επιλογή των τιμών των αγνώστων παραμέτρων, ούτως ώστε το άθροισμα των τετραγώνων των καταλοίπων (RSS) $\sum \hat{u}_i^2$ να είναι όσο το δυνατόν μικρότερο. Συμβολικά,

$$\min \sum \hat{u}_i^2 = \sum (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_{2i} - \hat{\beta}_3 X_{3i})^2 \quad (7.4.2)$$

όπου η έκφραση για το RSS προκύπτει με απλούς αλγεβρικούς χειρισμούς της Εξ. (7.4.1).

Η πιο απλή διαδικασία για την απόκτηση των εκτιμητών που θα ελαχιστοποιήσουν την Εξ. (7.4.2) είναι να την παραγωγίσουμε ως προς τους αγνώστους, να θέσουμε τις σχέσεις που θα προκύψουν ίσες με το μηδέν, και να τις επιλύσουμε ταυτόχρονα. Όπως φαίνεται στο Παράρτημα 7Α, Ενότητα 7Α.1, η διαδικασία αυτή δίνει τις ακόλουθες κανονικές εξισώσεις [Εξισώσεις (3.1.4) και (3.1.5)]:

$$\bar{Y} = \hat{\beta}_1 + \hat{\beta}_2 \bar{X}_2 + \hat{\beta}_3 \bar{X}_3 \quad (7.4.3)$$

$$\sum Y_i X_{2i} = \hat{\beta}_1 \sum X_{2i} + \hat{\beta}_2 \sum X_{2i}^2 + \hat{\beta}_3 \sum X_{2i} X_{3i} \quad (7.4.4)$$

$$\sum Y_i X_{3i} = \hat{\beta}_1 \sum X_{3i} + \hat{\beta}_2 \sum X_{2i} X_{3i} + \hat{\beta}_3 \sum X_{3i}^2 \quad (7.4.5)$$

Από την Εξίσωση (7.4.3), βλέπουμε αμέσως ότι

$$\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X}_2 - \hat{\beta}_3 \bar{X}_3 \quad (7.4.6)$$

που είναι ο εκτιμητής της OLS της σταθεράς β_1 του πληθυσμού.

Ακολουθώντας τη σύμβαση ότι τα πεζά γράμματα δηλώνουν τις αποκλίσεις από τις μέσες τιμές του δείγματος, μπορεί κανείς να αντλήσει τους ακόλουθους τύπους από τις κανονικές εξισώσεις (7.4.3) μέχρι (7.4.5):

$$\hat{\beta}_2 = \frac{(\sum y_i x_{2i})(\sum x_{3i}^2) - (\sum y_i x_{3i})(\sum x_{2i} x_{3i})}{(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i} x_{3i})^2} \quad (7.4.7)^5$$

⁵ Ο συγκεκριμένος εκτιμητής είναι ίσος με αυτόν της Εξ. (7.3.5), όπως φαίνεται στο Παρ. 7Α, Ενότητα 7Α.2.

$$\hat{\beta}_3 = \frac{(\sum y_i x_{3i})(\sum x_{2i}^2) - (\sum y_i x_{2i})(\sum x_{2i} x_{3i})}{(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i} x_{3i})^2} \quad (7.4.8)$$

οι οποίες δίνουν τους εκτιμητές της OLS των συντελεστών μερικής παλινδρόμησης του πληθυσμού, β_2 και β_3 , αντίστοιχα.

Παρεμπιπτόντως, σημειώστε τα ακόλουθα:

- ♦ οι Εξισώσεις (7.4.7) και (7.4.8) είναι φύσει συμμετρικές επειδή η μία μπορεί να προκύψει από την άλλη με εναλλαγή των ρόλων των X_2 και X_3
- ♦ οι παρονομαστές αυτών των δύο εξισώσεων είναι ίδιοι και
- ♦ η περίπτωση των τριών μεταβλητών είναι μία φυσική επέκταση της διμεταβλητής περίπτωσης.

Διακυμάνσεις και Τυπικά Σφάλματα των Εκτιμητών της OLS

Έχοντας λάβει τους εκτιμητές της OLS των συντελεστών μερικής παλινδρόμησης, μπορούμε να υπολογίσουμε τις διακυμάνσεις και τα τυπικά σφάλματα αυτών των εκτιμητών όπως παρουσιάζεται στο Παράρτημα 3Α.3. Όπως και στη διμεταβλητή περίπτωση, χρειαζόμαστε τα τυπικά σφάλματα για δύο βασικούς λόγους: για τη δημιουργία διαστημάτων εμπιστοσύνης και για τον έλεγχο στατιστικών υποθέσεων. Οι σχετικοί τύποι είναι οι εξής:⁶

$$\text{var}(\hat{\beta}_1) = \left[\frac{1}{n} + \frac{\bar{X}_2^2 \sum x_{3i}^2 + \bar{X}_3^2 \sum x_{2i}^2 - 2\bar{X}_2\bar{X}_3 \sum x_{2i}x_{3i}}{\sum x_{2i}^2 \sum x_{3i}^2 - (\sum x_{2i}x_{3i})^2} \right] \cdot \sigma^2 \quad (7.4.9)$$

$$\text{se}(\hat{\beta}_1) = +\sqrt{\text{var}(\hat{\beta}_1)} \quad (7.4.10)$$

$$\text{var}(\hat{\beta}_2) = \frac{\sum x_{3i}^2}{(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i}x_{3i})^2} \sigma^2 \quad (7.4.11)$$

ή, ισοδύναμα

$$\text{var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum x_{2i}^2 (1 - r_{23}^2)} \quad (7.4.12)$$

όπου r_{23} είναι ο συντελεστής συσχέτισης του δείγματος μεταξύ των X_2 και X_3 όπως ορίζεται στο Κεφάλαιο 3.⁷

$$\text{se}(\hat{\beta}_2) = +\sqrt{\text{var}(\hat{\beta}_2)} \quad (7.4.13)$$

$$\text{var}(\hat{\beta}_3) = \frac{\sum x_{2i}^2}{(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i}x_{3i})^2} \sigma^2 \quad (7.4.14)$$

ή, ισοδύναμα

$$\text{var}(\hat{\beta}_3) = \frac{\sigma^2}{\sum x_{3i}^2 (1 - r_{23}^2)} \quad (7.4.15)$$

$$\text{se}(\hat{\beta}_3) = +\sqrt{\text{var}(\hat{\beta}_3)} \quad (7.4.16)$$

⁶ Τα αποτελέσματα αυτών των τύπων προκύπτουν πιο εύκολα χρησιμοποιώντας μήτρες. Οι προχωρημένοι αναγνώστες μπορούν να μελετήσουν το Παράρτημα Γ.

⁷ Χρησιμοποιώντας τον ορισμό του r που δίνεται στο Κεφάλαιο 3, έχουμε $r_{23}^2 = \frac{(\sum x_{2i} x_{3i})^2}{\sum x_{2i}^2 \sum x_{3i}^2}$

$$\text{cov}(\hat{\beta}_2, \hat{\beta}_3) = \frac{-r_{23}\sigma^2}{(1 - r_{23}^2)\sqrt{\sum x_{2i}^2}\sqrt{\sum x_{3i}^2}} \quad (7.4.17)$$

Σε όλους αυτούς τους τύπους, σ^2 είναι η (ομοσκεδαστική) διακύμανση των διαταρακτικών όρων του πληθυσμού u_i .

Ακολουθώντας το επιχείρημα του Παραρτήματος 3Α, στην Ενότητα 3Α.5, ο αναγνώστης μπορεί να επαληθεύσει ότι ένας αμερόληπτος εκτιμητής της σ^2 δίνεται από

$$\hat{\sigma}^2 = \frac{\sum \hat{u}_i^2}{n - 3} \quad (7.4.18)$$

Σημειώστε την ομοιότητα μεταξύ αυτού του εκτιμητή της σ^2 και του διμεταβλητού ομολόγου της $[\hat{\sigma}^2 = (\sum \hat{u}_i^2)/(n - 2)]$. Οι βαθμοί ελευθερίας είναι τώρα $(n - 3)$, διότι κατά την εκτίμηση του $\sum \hat{u}_i^2$ πρέπει πρώτα να εκτιμήσουμε τους β_1 , β_2 , και β_3 , οπότε χάνουμε 3 βαθμούς ελευθερίας. (Το επιχείρημα είναι αρκετά γενικό. Επομένως, στην περίπτωση τεσσάρων μεταβλητών οι βαθμοί ελευθερίας θα είναι $n - 4$.)

Ο εκτιμητής $\hat{\sigma}^2$ μπορεί να υπολογιστεί από την Εξίσωση (7.4.18) αφού γίνουν γνωστά τα κατάλοιπα, αλλά μπορεί επίσης να προκύψει πιο εύκολα, χρησιμοποιώντας την ακόλουθη σχέση (για την απόδειξη, βλ. Παράρτημα 7Α, Ενότητα 7Α.3):

$$\sum \hat{u}_i^2 = \sum y_i^2 - \hat{\beta}_2 \sum y_i x_{2i} - \hat{\beta}_3 \sum y_i x_{3i} \quad (7.4.19)$$

που είναι η αντίστοιχη σχέση τριών μεταβλητών της Εξίσωσης (3.3.6).

Ιδιότητες των Εκτιμητών της OLS

Οι ιδιότητες των εκτιμητών της OLS του υποδείγματος πολλαπλής παλινδρόμησης είναι αντίστοιχες με αυτές του διμεταβλητού υποδείγματος. Συγκεκριμένα:

- ❶ Η γραμμή παλινδρόμησης (επιφάνεια) τριών μεταβλητών διατρέχει τους μέσους $\bar{Y}$, $\bar{X}_2$, και $\bar{X}_3$, το οποίο είναι εμφανές από την Εξ. (7.4.3) (βλ. Εξ. [3.1.7] του διμεταβλητού υποδείγματος). Αυτή η ιδιότητα ισχύει γενικά. Επομένως, στο γραμμικό υπόδειγμα παλινδρόμησης k -μεταβλητών (μία παλινδρομούμενη μεταβλητή και $[k - 1]$ παλινδρομητές)

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \dots + \beta_k X_{ki} + u_i \quad (7.4.20)$$

έχουμε

$$\hat{\beta}_1 = \bar{Y} - \beta_2 \bar{X}_2 - \beta_3 \bar{X}_3 - \dots - \beta_k \bar{X}_k \quad (7.4.21)$$

- ❷ Η μέση τιμή του εκτιμημένου $\hat{Y}_i (= \hat{Y}_i)$ είναι ίση με τη μέση τιμή του πραγματικού Y_i , το οποίο αποδεικνύεται εύκολα:

$$\begin{aligned} \hat{Y}_i &= \hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \hat{\beta}_3 X_{3i} \\ &= (\bar{Y} - \hat{\beta}_2 \bar{X}_2 + \hat{\beta}_3 \bar{X}_3) + \hat{\beta}_2 X_{2i} + \hat{\beta}_3 X_{3i} \quad (\text{Γιατί;}) \\ &= \bar{Y} + \hat{\beta}_2 (X_{2i} - \bar{X}_2) + \hat{\beta}_3 (X_{3i} - \bar{X}_3) \\ &= \bar{Y} + \hat{\beta}_2 x_{2i} + \hat{\beta}_3 x_{3i} \end{aligned} \quad (7.4.22)$$

όπου, ως συνήθως, τα πεζά γράμματα υποδεικνύουν τις τιμές των μεταβλητών ως αποκλίσεις από τους αντίστοιχους μέσους τους. Αθροίζοντας τα δύο μέλη της Εξίσωσης (7.4.22) με τις τιμές του δείγματος και διαιρώντας τις με το μέγεθος n του δείγματος παίρνουμε $\bar{\hat{Y}} = \bar{Y}$. (Σημείωση: $\sum x_{2i} = \sum x_{3i} = 0$. Γιατί;) Παρατηρήστε ότι λόγω της Εξ. (7.4.22) μπορούμε να γράψουμε

$$\hat{y}_i = \hat{\beta}_2 x_{2i} + \hat{\beta}_3 x_{3i} \quad (7.4.23)$$

όπου

$$\hat{y}_i = (\hat{Y}_i - \bar{Y})$$

Επομένως η SRF (7.4.1) μπορεί να εκφραστεί στη μορφή των αποκλίσεων από τους μέσους ως

$$y_i = \hat{y}_i + \hat{u}_i = \hat{\beta}_2 x_{2i} + \hat{\beta}_3 x_{3i} + \hat{u}_i \quad (7.4.24)$$

- ③ $\sum u_i = \bar{u} = 0$, το οποίο μπορεί να επαληθευτεί από την Εξ. (7.4.24). (Συμβουλή: Αθροίστε και τις δύο πλευρές της Εξ. [7.4.24] με τις δειγματικές τιμές).
- ④ Τα κατάλοιπα $\hat{u}_i$ είναι ασυσχέτιστα με τις X_{2i} και X_{3i} , δηλαδή, $\sum \hat{u}_i X_{2i} = \sum \hat{u}_i X_{3i} = 0$ (Βλ. Παράρτημα 7Α.1 για την απόδειξη).
- ⑤ Τα κατάλοιπα $\hat{u}_i$ είναι ασυσχέτιστα με το $\hat{Y}_i$, δηλαδή, $\sum \hat{u}_i \hat{Y}_i = 0$. Γιατί; (Υπόδειξη: Πολλαπλασιάστε την Εξ. [7.4.23] και στις δύο πλευρές με $\hat{u}_i$, και προσθέστε τις τιμές του δείγματος.)
- ⑥ Από τις Εξισώσεις (7.4.12) και (7.4.15) είναι προφανές ότι καθώς ο r_{23} , ο συντελεστής συσχέτισης μεταξύ των X_2 και X_3 , αυξάνει προς το 1, οι διακυμάνσεις των $\hat{\beta}_2$ και $\hat{\beta}_3$ αυξάνονται για δεδομένες τιμές των σ^2 και $\sum x_{2i}^2$ ή $\sum x_{3i}^2$. Στο όριο, όταν $r_{23} = 1$ (δηλαδή, τέλεια συγγραμμικότητα), αυτές οι διακυμάνσεις γίνονται άπειρες. Οι επιπτώσεις αυτού θα διερευνηθούν πλήρως στο Κεφάλαιο 10, αλλά διαισθητικά ο αναγνώστης μπορεί να δει ότι καθώς ο r_{23} αυξάνει θα είναι όλο και πιο δύσκολο να γνωρίζουμε ποιες είναι οι πραγματικές τιμές των β_2 και β_3 . (Περισσότερα για αυτό στο επόμενο κεφάλαιο, όμως μπορείτε να εξετάσετε την Εξ. [7.1.13].)
- ⑦ Είναι επίσης σαφές από τις Εξ. (7.4.12) και (7.4.15) ότι για δεδομένες τιμές των r_{23} και $\sum x_{2i}^2$ ή $\sum x_{3i}^2$, οι διακυμάνσεις των εκτιμητών της OLS είναι ευθέως ανάλογες με τη σ^2 , δηλαδή, αυξάνονται καθώς αυξάνεται η σ^2 . Ομοίως, για δεδομένες τιμές των σ^2 και r_{23} , η διακύμανση του $\hat{\beta}_2$ είναι αντιστρόφως ανάλογη με το $\sum x_{2i}^2$, δηλαδή, όσο μεγαλύτερη είναι η διακύμανση των τιμών του δείγματος της X_2 , τόσο μικρότερη είναι η διακύμανση του $\hat{\beta}_2$ και ως εκ τούτου ο β_2 μπορεί να εκτιμηθεί με μεγαλύτερη ακρίβεια. Μία παρόμοια δήλωση μπορεί να γίνει για τη διακύμανση του $\hat{\beta}_3$.
- ⑧ Λαμβάνοντας υπόψη τις υποθέσεις του κλασικού γραμμικού υποδείγματος παλινδρόμησης, τις οποίες διατυπώσαμε στην Ενότητα 7.1, μπορούμε να αποδείξουμε ότι οι εκτιμητές της OLS των συντελεστών μερικής παλινδρόμησης όχι μόνο είναι γραμμικοί και αμερόληπτοι, αλλά έχουν επίσης ελάχιστη διακύμανση στην τάξη όλων των γραμμικών αμερόληπτων εκτιμητών. Εν ολίγοις, είναι BLUE. Με άλλα λόγια, πληρούν τις προϋποθέσεις του θεωρήματος Gauss-Markov. (Η απόδειξη είναι αντίστοιχη με τη διμεταβλητή περίπτωση, η απόδειξη της οποία παρατίθεται στο Παράρτημα 3Α, Ενότητα 3Α.6 και θα παρουσιαστεί συνοπτικά χρησιμοποιώντας μήτρες στο Παράρτημα Γ.)

Εκτιμητές Μέγιστης Πιθανοφάνειας

Σημειώσαμε στο Κεφάλαιο 4 ότι, με βάση την υπόθεση ότι οι u_i , οι διαταρακτικοί όροι του πληθυσμού, ακολουθούν την κανονική κατανομή με μηδενικό μέσο και σταθερή διακύμανση σ^2 , οι εκτιμητές της μέγιστης πιθανοφάνειας (ML) και οι εκτιμητές της OLS των συντελεστών παλινδρόμησης του διμεταβλητού υποδείγματος είναι πανομοιότυποι. Αυτή η ιδιότητα επεκτείνεται σε υποδείγματα που περιέχουν οποιονδήποτε αριθμό μεταβλητών. (Για την απόδειξη, βλ. Παράρτημα 7Α, Ενότητα 7Α.4.) Ωστόσο, αυτό δεν ισχύει για τον εκτιμητή της σ^2 . Μπορεί να αποδειχθεί ότι ο εκτιμητής της ML της σ^2 είναι $\sum \hat{u}_i^2 / n$ ανεξάρτητα από τον αριθμό των μεταβλητών που υπάρχουν στο υπόδειγμα, ενώ ο εκτιμητής της OLS της σ^2 είναι $\sum \hat{u}_i^2 / (n-2)$ στη διμεταβλητή περίπτωση, $\sum \hat{u}_i^2 / (n-3)$ στην περίπτωση τριών μεταβλητών, και $\sum \hat{u}_i^2 / (n-k)$ στην περίπτωση του υποδείγματος k -μεταβλητών (7.4.20). Εν ολίγοις, ο εκτιμητής της OLS της σ^2 λαμβάνει υπόψη τον αριθμό των βαθμών ελευθερίας, ενώ ο εκτιμητής της ML δεν το κάνει. Φυσικά, αν το n είναι πολύ μεγάλο, οι εκτιμητές της ML και της OLS της σ^2 , θα τείνουν να είναι κοντά ο ένας στον άλλο. (Γιατί;)

7.5 Ο Συντελεστής Πολλαπλού Προσδιορισμού R^2 και ο Συντελεστής Πολλαπλής Συσχέτισης R

Στη διμεταβλητή περίπτωση είδαμε ότι ο r^2 , όπως ορίζεται στην Εξ. (3.5.5) μετρά το πόσο καλή είναι η προσαρμογή της εξίσωσης παλινδρόμησης. Δηλαδή, δίνει την αναλογία ή το ποσοστό της συνολικής διακύμανσης της εξαρτημένης μεταβλητής Y που εξηγείται από τη (μοναδική) ερμηνευτική μεταβλητή X .

Ο συμβολισμός του r^2 μπορεί εύκολα να επεκταθεί και σε υποδείγματα παλινδρόμησης που περιέχουν περισσότερες από δύο μεταβλητές. Επομένως, στο υπόδειγμα τριών μεταβλητών θα θέλαμε να γνωρίζουμε την αναλογία της διακύμανσης στη Y που εξηγείται από κοινού από τις μεταβλητές X_2 και X_3 . Η ποσότητα που δίνει αυτές τις πληροφορίες είναι γνωστή ως ο **συντελεστής πολλαπλού προσδιορισμού** (multiple coefficient of determination) και συμβολίζεται με R^2 που εννοιολογικά είναι παρόμοιος με τον r^2 .

Για να προκύψει το R^2 , μπορούμε να ακολουθήσουμε τον υπολογισμό του r^2 που παρουσιάζεται στην Ενότητα 3.5. Θυμηθείτε ότι

$$\begin{aligned} Y_i &= \hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \hat{\beta}_3 X_{3i} + \hat{u}_i \\ &= \hat{Y}_i + \hat{u}_i \end{aligned} \quad (7.5.1)$$

όπου $\hat{Y}_i$ είναι η εκτιμημένη τιμή του Y_i από την εκτιμημένη καμπύλη παλινδρόμησης και είναι ένας εκτιμητής του πραγματικού $E(Y_i | X_{2i}, X_{3i})$. Μετατρέποντας τη σχέση σε πεζά γράμματα για να δείξουμε τις αποκλίσεις από τις μέσες τιμές, η Εξ. (7.5.1) μπορεί να γραφεί ως

$$\begin{aligned} y_i &= \hat{\beta}_2 x_{2i} + \hat{\beta}_3 x_{3i} + \hat{u}_i \\ &= \hat{y}_i + \hat{u}_i \end{aligned} \quad (7.5.2)$$

Τετραγωνίζοντας την Εξ. (7.5.2) και στις δύο πλευρές και αθροίζοντας τις τιμές του δείγματος, παίρνουμε

$$\begin{aligned} \sum y_i^2 &= \sum \hat{y}_i^2 + \sum \hat{u}_i^2 + 2 \sum \hat{y}_i \hat{u}_i \\ &= \sum \hat{y}_i^2 + \sum \hat{u}_i^2 \quad (\text{Γιατί;}) \end{aligned} \quad (7.5.3)$$

Η Εξ. (7.5.3) αναφέρει ότι το συνολικό άθροισμα των τετραγώνων (TSS) ισούται με το άθροισμα των τετραγώνων της παλινδρόμησης (ESS), και το άθροισμα των τετραγώνων των καταλοίπων (RSS). Αντικαθιστώντας το $\sum \hat{u}_i^2$ από την Εξ. (7.4.19), παίρνουμε

$$\sum y_i^2 = \sum \hat{y}_i^2 + \sum y_i^2 - \hat{\beta}_2 \sum y_i x_{2i} - \hat{\beta}_3 \sum y_i x_{3i}$$

το οποίο, μετά από αντιμετάθεση, γίνεται

$$ESS = \sum \hat{y}_i^2 = \hat{\beta}_2 \sum y_i x_{2i} + \hat{\beta}_3 \sum y_i x_{3i} \quad (7.5.4)$$

Τώρα, εξ' ορισμού

$$\begin{aligned} R^2 &= \frac{ESS}{TSS} \\ &= \frac{\hat{\beta}_2 \sum y_i x_{2i} + \hat{\beta}_3 \sum y_i x_{3i}}{\sum y_i^2} \end{aligned} \quad (7.5.5)^8$$

(Εξ. [7.5.5] με Εξ. [3.5.6]).

Δεδομένου ότι οι ποσότητες που εισάγονται στην Εξ. (7.5.5) υπολογίζονται γενικά συστηματικά, ο R^2 μπορεί να υπολογιστεί με ευκολία. Σημειώστε ότι ο R^2 , όπως και ο r^2 , βρίσκεται μεταξύ του 0 και του 1. Αν είναι 1, η εκτιμημένη γραμμή παλινδρόμησης εξηγεί το 100 τοις εκατό της μεταβολής της Y . Από την άλλη, αν είναι 0, το υπόδειγμα δεν εξηγεί καθόλου τη μεταβολή της Y . Ωστόσο, συνήθως, ο R^2 βρίσκεται μεταξύ αυτών των ακραίων τιμών. Η προσαρμογή του υποδείγματος λέγεται ότι είναι «καλύτερη» όσο πιο κοντά στο 1 είναι ο R^2 .

⁸ Σημείωση: ο R^2 μπορεί επίσης να υπολογισθεί ως εξής: $R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{\sum \hat{u}_i^2}{\sum y_i^2} = 1 - \frac{(n-3)\sigma^2}{(n-1)s_Y^2}$

Υπενθυμίζεται ότι στη διμεταβλητή περίπτωση ορίσαμε την ποσότητα r ως το συντελεστή συσχέτισης και αναφέραμε ότι μετρά το βαθμό της (γραμμικής) σχέσης μεταξύ δύο μεταβλητών. Το ανάλογο τριών ή περισσότερων μεταβλητών του r είναι ο **συντελεστής πολλαπλής συσχέτισης** (multiple correlation), που συμβολίζεται με το R , και είναι ένα μέτρο του βαθμού συσχέτισης μεταξύ της Y και όλων των ερμηνευτικών μεταβλητών, από κοινού. Παρόλο που ο r μπορεί να είναι θετικός ή αρνητικός, ο R θεωρείται πάντα ότι είναι θετικός. Ωστόσο, στην πράξη, ο R έχει μικρή σημασία. Το πιο σημαντικό μέγεθος είναι το R^2 .

Πριν προχωρήσουμε περαιτέρω, ας σημειώσουμε την εξής σχέση μεταξύ του R^2 και της διακύμανσης του συντελεστή μερικής παλινδρόμησης στο υπόδειγμα πολλαπλής παλινδρόμησης k -μεταβλητών που δίνεται στην Εξ. (7.4.20):

$$\text{var}(\hat{\beta}_j) = \frac{\sigma^2}{\sum x_j^2} \left(\frac{1}{1 - R_j^2} \right) \quad (7.5.6)$$

όπου $\hat{\beta}_j$ είναι ο συντελεστής μερικής παλινδρόμησης του παλινδρομητή X_j και R_j^2 είναι ο R^2 στην παλινδρόμηση της X_j για τους υπόλοιπους $(k-2)$ παλινδρομητές. (Σημείωση: Υπάρχουν $[k-1]$ παλινδρομητές στο υπόδειγμα παλινδρόμησης k -μεταβλητών.) Αν και η χρησιμότητα της Εξ. (7.5.6) θα γίνει προφανής στο Κεφάλαιο 10 που αναφέρεται στην πολυσυγγραμμικότητα, παρατηρούμε ότι αυτή η εξίσωση είναι απλά μία επέκταση του τύπου που δίνεται στην Εξ. (7.4.12) ή στην Εξ. (7.4.15) για το υπόδειγμα παλινδρόμησης τριών μεταβλητών, μία παλινδρομούμενη μεταβλητή και δύο παλινδρομητές.

7.6 Ένα Χαρακτηριστικό Παράδειγμα

ΠΑΡΑΔΕΙΓΜΑ 7.1 Η Παιδική Θνησιμότητα σε Σχέση με το Κατά Κεφαλήν ΑΕΠ και το Ποσοστό Αλφαριθμητισμού του Γυναικείου Πληθυσμού

Στο Κεφάλαιο 6 εξετάσαμε τη συμπεριφορά της παιδικής θνησιμότητας (CM) σε σχέση με το κατά κεφαλήν ΑΕΠ (PGNP). Εκεί διαπιστώσαμε ότι η PGNP έχει αρνητική επίδραση στη CM, όπως είναι αναμενόμενο. Τώρα, εισάγουμε τον αλφαριθμητισμό του γυναικείου πληθυσμού, όπως αυτός μετράται από το ποσοστό αλφαριθμητισμού του γυναικείου πληθυσμού (FLR). *A priori*, αναμένουμε ότι και η FLR θα έχει αρνητική επίδραση στη CM. Τώρα, όταν εισάγουμε και τις δύο μεταβλητές στο υπόδειγμα μας, πρέπει να διευκρινίσουμε την επίδραση του κάθε παλινδρομητή. Δηλαδή, πρέπει να εκτιμήσουμε τους συντελεστές (μερικής) παλινδρόμησης κάθε παλινδρομητή. Συνεπώς, το υπόδειγμα μας είναι το:

$$CM_i = \beta_1 + \beta_2 PGNP_i + \beta_3 FLR_i + u_i \quad (7.6.1)$$

Τα στοιχεία παρατίθενται στον Πίνακα 6.4. Λάβετε υπόψη ότι CM είναι ο αριθμός των θανάτων των παιδιών κάτω των πέντε ετών ανά 1000 γεννήσεις ζωντανών βρεφών, PGNP είναι το κατά κεφαλήν ΑΕΠ το 1980, και ο δείκτης FLR μετράται σε ποσοστά. Το δείγμα μας αποτελείται από 64 χώρες.

Χρησιμοποιώντας το στατιστικό πακέτο *EViews6*, καταλήξαμε στα ακόλουθα αποτελέσματα:

$$\begin{aligned} \widehat{CM}_i &= 263,6416 - 0,0056 PGNP_i - 2,2316 FLR_i \\ \text{se} &= (11,5932) \quad (0,0019) \quad (0,2099) \quad R^2 = 0,7077 \\ &\quad \bar{R}^2 = 0,6981^9 \end{aligned} \quad (7.6.2)$$

Όπου οι αριθμοί στις παρενθέσεις είναι τα εκτιμημένα τυπικά σφάλματα. Πριν ερμηνεύσουμε αυτή την παλινδρόμηση, παρατηρούμε το συντελεστή μερικής κλίσης της PGNP, δηλαδή, $-0,0056$. Δεν είναι ακριβώς ο ίδιος με εκείνο που προκύπτει από τη διαδικασία τριών σταδίων που συζητήθηκε στην προηγούμενη ενότητα (βλ. Εξ. [7.3.5]); Πρέπει όμως αυτό να μας εκπλήσσει; Επιπλέον, τα δύο τυπικά σφάλματα είναι ακριβώς τα ίδια, το οποίο και πάλι δεν προκαλεί έκπληξη. Όμως το επιτύχαμε χωρίς να προσφύγουμε στην περίπλοκη διαδικασία των τριών σταδίων.

⁹ Για αυτό, βλ. Ενότητα 7.8.

Ας ερμηνεύσουμε τώρα αυτούς τους συντελεστές παλινδρόμησης:

- ✦ $-0,0056$ είναι ο συντελεστής μερικής παλινδρόμησης της PGNP και μας λέει ότι με την επίδραση της FLR να παραμένει σταθερή, καθώς η PGNP αυξάνεται, για παράδειγμα, κατά μέσο όρο κατά ένα δολάριο, η παιδική θνησιμότητα μειώνεται κατά $0,0056$ μονάδες. Για να γίνει πιο κατανοητό στα πλαίσια των οικονομικών, εάν το κατά κεφαλήν ΑΕΠ αυξηθεί κατά χίλια δολάρια, κατά μέσο όρο, ο αριθμός των θανάτων των παιδιών κάτω των 5 ετών μειώνεται κατά περίπου $5,6$ ανά χίλιες γεννήσεις.
- ✦ Ο συντελεστής $-2,2316$ μας λέει ότι διατηρώντας την επίδραση της PGNP σταθερή, κατά μέσο όρο, ο αριθμός των θανάτων των παιδιών κάτω των 5 ετών μειώνεται κατά περίπου $2,23$ ανά χίλιες γεννήσεις ζωντανών βρεφών καθώς το ποσοστό αλφαριθμητισμού του γυναικείου πληθυσμού αυξάνεται κατά μία ποσοστιαία μονάδα.
- ✦ Η τιμή του σταθερού όρου (περίπου 263), ερμηνεύεται μηχανικά, και σημαίνει ότι αν οι τιμές της PGNP και της FLR ήταν μηδενικές, το μέσο ποσοστό παιδικής θνησιμότητας είναι περίπου 263 θάνατοι ανά χίλιες γεννήσεις. Φυσικά, μία τέτοια ερμηνεία θα πρέπει να γίνεται δεκτή με σχετική επιφύλαξη. Αυτό που θα μπορούσε να συμπεράνει κανείς είναι ότι εάν οι τιμές των δύο παλινδρομητών ήταν σταθερές στο μηδέν, η παιδική θνησιμότητα θα είναι αρκετά υψηλή, γεγονός που έχει πρακτικό νόημα.
- ✦ Η τιμή του R^2 που είναι περίπου $0,71$ σημαίνει ότι περίπου 71 τοις εκατό της μεταβολής της παιδικής θνησιμότητας εξηγείται από τη PGNP και τη FLR, η οποία είναι μία αρκετά υψηλή τιμή δεδομένου ότι η μέγιστη τιμή της R^2 μπορεί να είναι το πολύ 1 . Συνολικά, τα αποτελέσματα της παλινδρόμησης έχουν νόημα.

Τι συμβαίνει με τη στατιστική σημαντικότητα των εκτιμημένων συντελεστών; Θα εξετάσουμε το συγκεκριμένο ζήτημα στο Κεφάλαιο 8. Όπως θα δούμε, το συγκεκριμένο κεφάλαιο θα είναι μία προέκταση του Κεφαλαίου 5, το οποίο ασχολήθηκε με το διμεταβλητό υπόδειγμα. Όπως θα δείξουμε επίσης, υπάρχουν ορισμένες σημαντικές διαφορές στη συμπερασματική στατιστική (δηλαδή, στον έλεγχο υποθέσεων) μεταξύ των διμεταβλητών και των πολυμεταβλητών υποδειγμάτων παλινδρόμησης.

Παλινδρόμηση με Τυποποιημένες Μεταβλητές

Στο προηγούμενο κεφάλαιο παρουσιάσαμε το ζήτημα της παλινδρόμησης των τυποποιημένων μεταβλητών και αναφέραμε ότι η ανάλυση μπορεί να επεκταθεί σε πολυμεταβλητές παλινδρομήσεις. Υπενθυμίζεται ότι μία μεταβλητή λέγεται ότι είναι τυποποιημένη ή σε μονάδες τυπικής απόκλισης αν είναι εκφρασμένη σε όρους απόκλισης από το μέσο της και διαιρείται με την τυπική της απόκλιση.

Στο παράδειγμα που αναφέρεται στην παιδική θνησιμότητα, τα αποτελέσματα είναι τα εξής:

$$\begin{aligned} \widehat{CM}^* &= -0,2026 PGNP_i^* - 0,7639 FLR_i^* & (7.6.3) \\ se &= (0,0713) & (0,0713) & r^2 = 0,7077 \end{aligned}$$

Σημείωση: Οι μεταβλητές με αστερίσκο είναι τυποποιημένες μεταβλητές. Επίσης, σημειώστε ότι δεν υπάρχει σταθερός όρος στο υπόδειγμα για λόγους που έχουν ήδη συζητηθεί στο προηγούμενο κεφάλαιο.

Όπως μπορείτε να δείτε από αυτή την παλινδρόμηση, με την FLR να παραμένει σταθερή, μία αύξηση στην τυπική απόκλιση της PGNP οδηγεί, κατά μέσο όρο, σε μία μείωση της τυπικής απόκλισης της CM κατά $0,2026$. Ομοίως, διατηρώντας τη PGNP σταθερή, μία αύξηση της τυπικής απόκλισης της FLR, κατά μέσο όρο, οδηγεί σε μία μείωση της τυπικής απόκλισης της CM κατά $0,7639$. Γενικά, μπορούμε να πούμε πως ο αλφαριθμητισμός του γυναικείου πληθυσμού έχει μεγαλύτερη επίδραση στην παιδική θνησιμότητα από ότι το κατά κεφαλήν ΑΕΠ. Εδώ επισημαίνεται το πλεονέκτημα της χρήσης τυποποιημένων μεταβλητών, καθώς η τυποποίηση βάζει όλες τις μεταβλητές στην ίδια βάση, καθώς όλες οι τυποποιημένες μεταβλητές έχουν μηδενικούς μέσους και μοναδιαίες διακυμάνσεις.

Επίδραση στην Εξαρτημένη Μεταβλητή μίας Μοναδιαίας Μεταβολής σε Περισσότερους από Ένα Παλινδρομητές

Πριν προχωρήσουμε περαιτέρω, ας υποθέσουμε ότι θέλουμε να μάθουμε τι θα συμβεί με το ποσοστό παιδικής θνησιμότητας εάν αυξάνονταν οι PGNP και FLR ταυτόχρονα. Ας υποθέσουμε ότι το κατά κεφαλήν

ΑΕΠ αυξανόταν κατά ένα δολάριο και την ίδια στιγμή το ποσοστό αλφαριθμητισμού των γυναικών επρόκειτο να αυξηθεί έως και κατά μία ποσοστιαία μονάδα. Ποιες θα ήταν οι επιπτώσεις αυτής της ταυτόχρονης μεταβολής στο ποσοστό παιδικής θνησιμότητας; Για να το βρούμε, το μόνο που έχουμε να κάνουμε είναι να πολλαπλασιάσουμε τους συντελεστές των PGNP και FLR με τις προτεινόμενες μεταβολές και να προσθέσουμε τους όρους που θα προκύψουν. Στο παράδειγμά μας, αυτό μας δίνει:

$$-0,0056(1) - 2,2316(1) = -2,2372$$

Δηλαδή, ως αποτέλεσμα αυτής της ταυτόχρονης μεταβολής στη PGNP και στη FLR, ο αριθμός των θανάτων των παιδιών κάτω των 5 ετών θα μειωνόταν κατά περίπου 2,24 θανάτους.

Γενικότερα, αν θέλουμε να μάθουμε τη συνολική επίδραση της μοναδιαίας μεταβολής σε περισσότερους από έναν παλινδρομητές στην εξαρτημένη μεταβλητή, το μόνο που πρέπει να κάνουμε είναι να πολλαπλασιάσουμε τους συντελεστές αυτών των παλινδρομητών με τις προτεινόμενες μεταβολές και να προσθέσουμε τα γινόμενα. Σημειώστε ότι ο σταθερός όρος δεν εισέρχεται σε αυτούς τους υπολογισμούς. (Γιατί;)

7.7 Απλή Παλινδρόμηση στο Πλαίσιο της Πολλαπλής Παλινδρόμησης: Εισαγωγή στη Μεροληψία Εξειδίκευσης

Υπενθυμίζεται ότι η υπόθεση (7.1.10) του κλασικού γραμμικού υποδείγματος παλινδρόμησης αναφέρει ότι το υπόδειγμα παλινδρόμησης που χρησιμοποιείται στην ανάλυση είναι «σωστά» εξειδικευμένο· δηλαδή, δεν υπάρχει **κανένα σφάλμα ή μεροληψία εξειδίκευσης** (specification bias or specification error) (βλ. Κεφάλαιο 3 για ορισμένες εισαγωγικές παρατηρήσεις). Παρόλο που το ζήτημα του σφάλματος εξειδίκευσης θα συζητηθεί εκτενέστερα στο Κεφάλαιο 13, το παράδειγμα που παρατίθεται στην προηγούμενη ενότητα αποτελεί μία θαυμάσια ευκαιρία όχι μόνο για να καταλήξουμε στη σημασία της υπόθεσης (Εξ. 7.1.10), αλλά και για να προσδιορίσουμε την έννοια του συντελεστή μερικής παλινδρόμησης και να προσφέρουμε μία σχετικά άτυπη εισαγωγή στο θέμα της μεροληψίας εξειδίκευσης.

Ας υποθέσουμε ότι η Εξ. (7.6.1) είναι το «πραγματικό» υπόδειγμα που εξηγεί τη συμπεριφορά της παιδικής θνησιμότητας σε σχέση με το κατά κεφαλήν ΑΕΠ και το ποσοστό αλφαριθμητισμού των γυναικών (FLR). Ας υποθέσουμε όμως ότι αγνοούμε την FLR και εκτιμούμε την εξής απλή παλινδρόμηση:

$$Y_i = \alpha_1 + \alpha_2 X_{2i} + u_{1i} \quad (7.7.1)$$

όπου $Y = CM$ και $X_2 = PGNP$.

Εφόσον η Εξίσωση (7.6.1) είναι το πραγματικό υπόδειγμα, η εκτίμηση της Εξ. (7.7.1) θα αποτελούσε ένα σφάλμα εξειδίκευσης· το σφάλμα εδώ συνίσταται στην *παράλειψη* της μεταβλητής X_3 , το ποσοστό του γυναικείου αλφαριθμητισμού. Παρατηρήστε ότι χρησιμοποιούμε διαφορετικά σύμβολα για τις παραμέτρους (τα α ς) στην Εξ. (7.7.1) για να τις διακρίνουμε από τις πραγματικές παραμέτρους (τα β ς) που παρουσιάζει η Εξ. (7.6.1).

Θα παρέχει ο α_2 μία αμερόληπτη εκτίμηση της πραγματικής επίδρασης της PGNP, η οποία δίνεται από το β_2 στο υπόδειγμα (7.6.1); Θα ισχύει $E(\hat{\alpha}_2) = \beta_2$, όπου $\hat{\alpha}_2$ είναι η εκτιμημένη τιμή του α_2 ; Με άλλα λόγια, θα παρέχει ο συντελεστής της PGNP στην Εξ. (7.7.1) μία αμερόληπτη εκτίμηση της πραγματικής επίδρασης της PGNP στη CM, γνωρίζοντας ότι έχουμε παραλείψει τη μεταβλητή X_3 (FLR) από το υπόδειγμα; Όπως θα υποψιάζεστε, σε γενικές γραμμές, ο $\hat{\alpha}_2$ δε θα είναι ένας αμερόληπτος εκτιμητής του πραγματικού β_2 . Για να δώσουμε μία εικόνα της μεροληψίας, ας εκτιμήσουμε την παλινδρόμηση (7.7.1), η οποία δίνει τα ακόλουθα αποτελέσματα.

$$\begin{aligned} \widehat{CM}_i &= 157,4244 - 0,0114 PGNP_i \\ se &= (9,8455) \quad (0,0032) \quad r^2 = 0,1662 \end{aligned} \quad (7.7.2)$$

Παρατηρούμε διάφορα σε αυτή την παλινδρόμηση σε σχέση με την «πραγματική» πολλαπλή παλινδρόμηση (7.6.1):

- ❶ Σε απόλυτους όρους (δηλαδή, χωρίς να λαμβάνεται υπόψη το πρόσημο), ο συντελεστής PGNP έχει αυξηθεί από 0,0056 σε 0,0114, σχεδόν δύο φορές περισσότερο.
- ❷ Τα τυπικά σφάλματα είναι διαφορετικά.

- ③ Οι τιμές των σταθερών όρων είναι διαφορετικές.
- ④ Οι τιμές των r^2 είναι εντελώς διαφορετικές, παρόλο που ισχύει γενικά ότι, καθώς ο αριθμός των παλινδρομητών στο υπόδειγμα αυξάνεται, αυξάνεται η τιμή του r^2 .

Ας υποθέσουμε ότι παλινδρομείτε την παιδική θνησιμότητα με το ποσοστό αλφαριθμητισμού των γυναικών, χωρίς να λαμβάνετε υπόψη σας την επίδραση της PGNP. Θα καταλήξετε στα ακόλουθα αποτελέσματα:

$$\begin{aligned}\widehat{CM}_i &= 263,8635 - 2,3905 FLR_i \\ se &= (21,2249) \quad (0,2133) \quad r^2 = 0,6696\end{aligned}\quad (7.7.3)$$

Και σε αυτή την περίπτωση αν συγκρίνετε τα αποτελέσματα αυτής της (λανθασμένα εξειδικευμένης) παλινδρόμησης με την «πραγματική» πολλαπλή παλινδρόμηση, θα δείτε ότι τα αποτελέσματα είναι διαφορετικά, αν και η διαφορά εδώ δεν είναι τόσο χαρακτηριστική όπως είναι στην περίπτωση της παλινδρόμησης (7.7.2).

Το σημαντικό σημείο που πρέπει να επισημάνουμε εδώ είναι ότι μπορεί να προκύψουν σοβαρές συνέπειες εάν ένα υπόδειγμα δεν έχει καλή προσαρμογή. Θα εξετάσουμε αυτό το θέμα πιο διεξοδικά στο Κεφάλαιο 13, που αναφέρεται στα σφάλματα εξειδίκευσης.

7.8 R^2 και Διορθωμένο R^2

Μια σημαντική ιδιότητα του R^2 είναι ότι πρόκειται για μία μη φθίνουσα συνάρτηση του αριθμού των ερμηνευτικών μεταβλητών ή παλινδρομητών που υπάρχουν στο υπόδειγμα, εκτός εάν η επιπλέον μεταβλητή είναι τέλεια συγγραμμική με τους άλλους παλινδρομητές. Καθώς ο αριθμός των παλινδρομητών αυξάνεται, ο R^2 αυξάνεται σχεδόν σταθερά και δε μειώνεται ποτέ. Με άλλα λόγια, μία επιπλέον μεταβλητή X δε θα μειώσει το R^2 . Συγκρίνετε, για παράδειγμα, την παλινδρόμηση (7.7.2) ή την (7.7.3) με την (7.6.2). Για να το δείτε αυτό, θυμηθείτε τον ορισμό του συντελεστή προσδιορισμού:

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS} = 1 - \frac{\sum \hat{u}_i^2}{\sum y_i^2} \quad (7.8.1)$$

Το $\sum y_i^2$ είναι ανεξάρτητο από τον αριθμό των μεταβλητών X στο υπόδειγμα, επειδή είναι απλώς $\sum (Y_i - \bar{Y})^2$. Το RSS , $\sum \hat{u}_i^2$, ωστόσο, εξαρτάται από τον αριθμό των παλινδρομητών που υπάρχουν στο υπόδειγμα. Διαισθητικά, είναι σαφές ότι όσο ο αριθμός των μεταβλητών X αυξάνεται, το $\sum \hat{u}_i^2$ είναι πιθανό να μειωθεί (τουλάχιστον δε θα αυξηθεί)· ως εκ τούτου, το R^2 , όπως ορίζεται στην Εξ. (7.8.1) θα αυξηθεί. Λαμβάνοντας υπόψη αυτό, όταν συγκρίνουμε δύο υποδείγματα παλινδρόμησης με την ίδια εξαρτημένη μεταβλητή, αλλά με διαφορετικό αριθμό μεταβλητών X , πρέπει να είμαστε πολύ προσεκτικοί όσον αφορά την επιλογή του υποδείγματος με τον υψηλότερο R^2 .

Για να συγκρίνουμε δύο όρους R^2 , πρέπει να λάβουμε υπόψη τον αριθμό των μεταβλητών X που υπάρχουν στο υπόδειγμα. Αυτό μπορεί να γίνει εύκολα αν σκεφτούμε έναν εναλλακτικό συντελεστή προσδιορισμού, ο οποίος είναι ο εξής:

$$\bar{R}^2 = 1 - \frac{\sum \hat{u}_i^2 / (n - k)}{\sum y_i^2 / (n - 1)} \quad (7.8.2)$$

όπου k = ο αριθμός των παραμέτρων του υποδείγματος, συμπεριλαμβανομένου του σταθερού όρου. (Στην παλινδρόμηση τριών μεταβλητών, $k = 3$. Γιατί;) Ο R^2 όταν ορίζεται έτσι, είναι γνωστός ως ο **διορθωμένος R^2** (adjusted R^2), συμβολίζεται με $\bar{R}^2$. Ο όρος **διορθωμένος** σημαίνει διόρθωση ως προς τους βαθμούς ελευθερίας που σχετίζονται με τα αθροίσματα των τετραγώνων που εισέρχονται στην Εξ. (7.8.1): Το $\sum \hat{u}_i^2$ έχει $n - k$ βαθμούς ελευθερίας σε ένα υπόδειγμα που αφορά k παραμέτρους, το οποίο περιλαμβάνει το σταθερό όρο, και το $\sum y_i^2$ έχει $n - 1$ βαθμούς ελευθερίας. (Γιατί;) Για την περίπτωση των τριών μεταβλητών, γνωρίζουμε ότι το $\sum \hat{u}_i^2$ έχει $n - 3$ βαθμούς ελευθερίας. Η εξίσωση (7.8.2) μπορεί επίσης να γραφτεί ως

$$\bar{R}^2 = 1 - \frac{\hat{\sigma}^2}{S_Y^2} \quad (7.8.3)$$

όπου $\hat{\sigma}^2$ είναι η διακύμανση των καταλοίπων, ένας αμερόληπτος εκτιμητής της πραγματικής σ^2 , και S_Y^2 είναι η διακύμανση του δείγματος της Y .

Κεφάλαιο 11

Ετεροσκεδαστικότητα: Τι Συμβαίνει αν η Διακύμανση Σφάλματος δεν είναι Σταθερή;

Μια σημαντική υπόθεση του κλασικού γραμμικού υποδείγματος παλινδρόμησης (Υπόθεση 4) είναι ότι οι διαταρακτικοί όροι u_i που εμφανίζονται στη συνάρτηση παλινδρόμησης του πληθυσμού είναι ομοσκεδαστικοί, δηλαδή, έχουν όλοι την ίδια διακύμανση. Σε αυτό το κεφάλαιο θα εξετάσουμε την εγκυρότητα αυτής της υπόθεσης και θα εξετάσουμε τι θα συμβεί αν αυτή η υπόθεση δεν ικανοποιείται. Όπως και στο Κεφάλαιο 10, αναζητούμε απαντήσεις στα ακόλουθα ερωτήματα:

- ❶ Ποια είναι η φύση της ετεροσκεδαστικότητας;
- ❷ Ποιες είναι οι συνέπειές της;
- ❸ Πώς μπορεί κάποιος να την εντοπίσει;
- ❹ Ποια είναι τα μέτρα αντιμετώπισης;

11.1 Η Φύση της Ετεροσκεδαστικότητας

Όπως επισημάνθηκε στο Κεφάλαιο 3, μία από τις σημαντικότερες υποθέσεις του κλασικού γραμμικού υποδείγματος παλινδρόμησης είναι ότι η διακύμανση του κάθε διαταρακτικού όρου u_i , ο οποίος αποτελεί συνάρτηση των τιμών των ερμηνευτικών μεταβλητών, είναι κάποιος σταθερός αριθμός ίσος με σ^2 . Αυτή είναι η υπόθεση της **ομοσκεδαστικότητας**, ή *ίση (ομο) εξάπλωση* (σκεδαστικότητα), δηλαδή, *ίση διακύμανση*. Συμβολικά,


$$E(u_i^2) = \sigma^2 \quad i = 1, 2, \dots, n \quad (11.1.1)$$

Διαγραμματικά, στο διμεταβλητό υπόδειγμα παλινδρόμησης, η ομοσκεδαστικότητα μπορεί να παρουσιαστεί όπως στο Διάγραμμα 3.4, το οποίο, για λόγους ευκολίας, αναπαράγεται ως Διάγραμμα 11.1. Όπως δείχνει το Διάγραμμα 11.1, η υπό συνθήκη διακύμανση της Y_i (η οποία είναι ίση με αυτή του u_i), συναρτήσει της X_i , παραμένει η ίδια, ανεξάρτητα από τις τιμές που παίρνει η μεταβλητή X . Αντίθετα, εξετάστε το Διάγραμμα 11.2, το οποίο δείχνει ότι η υπό συνθήκη διακύμανση της Y_i αυξάνει όσο αυξάνει η X . Εδώ, οι διακυμάνσεις της Y_i δεν είναι οι ίδιες. Ως εκ τούτου, δεν υπάρχει ετεροσκεδαστικότητα. Συμβολικά,


$$E(u_i^2) = \sigma_i^2 \quad (11.1.2)$$

Παρατηρήστε το δείκτη της σ^2 , ο οποίος μας υπενθυμίζει ότι οι υπό συνθήκη διακυμάνσεις του u_i (= υπό συνθήκη διακυμάνσεις της Y_i) δεν είναι πλέον σταθερές.

Για να καταστήσουμε σαφή τη διαφορά μεταξύ ομοσκεδαστικότητας και ετεροσκεδαστικότητας, έστω ότι στο διμεταβλητό υπόδειγμα $Y_i = \beta_1 + \beta_2 X_i + u_i$, η Y αντιπροσωπεύει την αποταμίευση και η X αντιπροσωπεύει το εισόδημα. Τα Διαγράμματα 11.1 και 11.2 δείχνουν ότι καθώς αυξάνεται το εισόδημα, κατά μέσο όρο, αυξάνεται επίσης και η αποταμίευση. Όμως στο Διάγραμμα 11.1 η διακύμανση της αποταμίευσης παραμένει η ίδια σε όλα τα επίπεδα εισοδήματος, ενώ στο Διάγραμμα 11.2 αυξάνει με το εισόδημα. Φαίνεται ότι στο Διάγραμμα 11.2, οι οικογένειες υψηλότερου εισοδήματος αποταμιεύουν κατά μέσο όρο περισσότερα από τις οικογένειες χαμηλού εισοδήματος, αλλά υπάρχει επίσης και μεγαλύτερη μεταβλητότητα στις αποταμιεύσεις τους.




ΔΙΑΓΡΑΜΜΑ 11.1 Ομοσκεδαστικοί διαταρακτικοί όροι



ΔΙΑΓΡΑΜΜΑ 11.2 Ετεροσκεδαστικοί διαταρακτικοί όροι

Υπάρχουν διάφοροι λόγοι για τους οποίους οι διακυμάνσεις του u_i μπορεί να μεταβάλλονται, μερικοί εκ των οποίων είναι οι ακόλουθοι.¹

- ❶ Ακολουθώντας τα υποδείγματα σφάλματος-γνώσης, καθώς οι άνθρωποι μαθαίνουν, τα λάθη στη συμπεριφορά τους περιορίζονται με την πάροδο του χρόνου ή ο αριθμός των σφαλμάτων τους γίνεται πιο συνεπής. Στην περίπτωση αυτή, η σ_i^2 αναμένεται να μειωθεί. Για παράδειγμα, εξετάστε το Διάγραμμα 11.3, το οποίο συνδέει τον αριθμό των τυπογραφικών λαθών που γίνονται σε μία δοθείσα χρονική στιγμή σε ένα τεστ, με τις ώρες που διαθέτει κάποιος για να εξασκηθεί στην πληκτρολόγηση. Όπως δείχνει το Διάγραμμα 11.3, καθώς αυξάνει ο αριθμός των ωρών εξάσκησης στη δακτυλογράφηση, ο μέσος αριθμός των τυπογραφικών λαθών, καθώς και οι διακυμάνσεις τους, μειώνονται.




ΔΙΑΓΡΑΜΜΑ 11.3 Διαγραμματική απεικόνιση της ετεροσκεδαστικότητας.

¹ Βλ. Stefan Valavanis, *Econometrics*, McGraw-Hill, New York, 1959, σελ. 48.

- ② Καθώς το εισόδημα αυξάνεται, οι άνθρωποι έχουν περισσότερο διαθέσιμο εισόδημα (discretionary income)² και ως εκ τούτου μεγαλύτερο περιθώριο επιλογών σχετικά με τη διάθεση του εισοδήματός τους. Ως εκ τούτου, η σ_i^2 είναι πιθανό να αυξηθεί με την αύξηση του εισοδήματος. Συνεπώς, στην παλινδρόμηση της αποταμίευσης με το εισόδημα είναι πιθανό να βρούμε ότι η σ_i^2 αυξάνεται με το εισόδημα (όπως στο Διάγραμμα 11.2), επειδή οι άνθρωποι έχουν περισσότερες επιλογές αναφορικά με τη συμπεριφορά τους σε σχέση με την αποταμίευση. Ομοίως, οι εταιρείες με υψηλά κέρδη αναμένεται, σε γενικές γραμμές, να επιδεικνύουν μεγαλύτερη μεταβλητότητα στις πολιτικές μερισμάτων τους από ότι οι εταιρείες με χαμηλότερα κέρδη. Επίσης, οι εταιρείες που στοχεύουν πρωταρχικά στη μεγέθυνσή τους, είναι πιθανό να παρουσιάζουν μεγαλύτερη μεταβλητότητα στο ποσοστό αποπληρωμής μερισμάτων τους από ότι οι καθιερωμένες εταιρείες στον ίδιο κλάδο.
- ③ Καθώς οι τεχνικές συλλογής στοιχείων βελτιώνονται, η σ_i^2 είναι πιθανό να μειώνεται. Συνεπώς, οι τράπεζες που έχουν προηγμένο εξοπλισμό για την επεξεργασία στοιχείων είναι πιθανόν να διαπράξουν λιγότερα λάθη στις μηνιαίες ή τριμηνιαίες καταστάσεις των πελατών τους σε σχέση με τράπεζες που δε διαθέτουν τον αντίστοιχο εξοπλισμό.
- ④ Η ετεροσκεδαστικότητα μπορεί επίσης να προκύψει ως αποτέλεσμα της παρουσίας έκτοπων (ακραίων τιμών). Μία παρατήρηση που αποτελεί έκτοπο, είναι μία παρατήρηση που είναι πολύ διαφορετική (είτε πολύ μικρή είτε πολύ μεγάλη) σε σχέση με τις παρατηρήσεις του δείγματος. Πιο συγκεκριμένα, ένα έκτοπο είναι μία παρατήρηση από ένα διαφορετικό πληθυσμό σε σχέση με αυτόν που παράγει τις υπόλοιπες δειγματικές παρατηρήσεις.³ Η εισαγωγή ή η απαλοιφή μίας τέτοιας παρατήρησης, ειδικά εάν το μέγεθος του δείγματος είναι μικρό, μπορεί να μεταβάλει σημαντικά τα αποτελέσματα της ανάλυσης παλινδρόμησης.

Για παράδειγμα, σκεφτείτε το διάγραμμα διασποράς που παρουσιάζεται στο Διάγραμμα 11.4. Με βάση τα στοιχεία που παρατίθενται στον Πίνακα 11.9 στην Άσκηση 11.22, το διάγραμμα αυτό παρουσιάζει ποσοστιαίους ρυθμούς μεταβολής των τιμών των μετοχών (Y) και των τιμών καταναλωτή (X) για την περίοδο μετά το Δεύτερο Παγκόσμιο Πόλεμο μέχρι το 1969 για 20 χώρες. Σε αυτό το διάγραμμα η παρατήρηση σχετικά με τη Y και τη X για τη Χιλή μπορεί να θεωρηθεί ότι αποτελεί ακραία τιμή, επειδή οι τιμές για τη Y και τη X είναι πολύ μεγαλύτερες από ό,τι για τις υπόλοιπες χώρες. Σε καταστάσεις σαν και αυτή, θα ήταν δύσκολο να διατηρήσουμε την υπόθεση της ομοσκεδαστικότητας. Στην Άσκηση 11.22, σας ζητείται να βρείτε τι συμβαίνει με τα αποτελέσματα της παλινδρόμησης, αν οι παρατηρήσεις για τη Χιλή απαλειφθούν από την ανάλυση.



ΔΙΑΓΡΑΜΜΑ 11.4 Η σχέση μεταξύ των τιμών των μετοχών και των τιμών καταναλωτή.

² Όπως το θέτει ο Valavanis, "Το εισόδημα αυξάνεται και οι άνθρωποι πλέον αντιμετωπίζουν τα δολάρια σχεδόν όπως αντιμετώπιζαν τις δεκάρες," ό.π., σελ. 48.

³ Είμαι ευγνώμων στον Michael McAleer που μου επεσήμανε το συγκεκριμένο σημείο.


- 5 Μία άλλη πηγή ετεροσκεδαστικότητας προκύπτει από την παραβίαση της Υπόθεσης 9 του κλασικού γραμμικού υποδείγματος παλινδρόμησης (CLRM), δηλαδή, ότι το υπόδειγμα παλινδρόμησης παρουσιάζει τη σωστή εξειδίκευση. Παρά το γεγονός ότι θα συζητήσουμε το θέμα των σφαλμάτων εξειδίκευσης αναλυτικότερα στο Κεφάλαιο 13, πολύ συχνά αυτό που μοιάζει με ετεροσκεδαστικότητα μπορεί να οφείλεται στο γεγονός ότι ορισμένες σημαντικές μεταβλητές απαλείφονται από το υπόδειγμα. Συνεπώς, στη συνάρτηση ζήτησης για ένα αγαθό, αν δε συμπεριλάβουμε τις τιμές των αγαθών που είναι συμπληρωματικά ή ανταγωνιστικά του εν λόγω αγαθού (το σφάλμα παράλειψης μεταβλητών), τα κατάλοιπα που προκύπτουν από την παλινδρόμηση μπορεί να δώσουν την εντύπωση ότι η διακύμανση του σφάλματος μπορεί να μην είναι σταθερή. Αν όμως οι μεταβλητές που παραλείπονται τελικά περιληφθούν στο υπόδειγμα, η εντύπωση αυτή μπορεί να εξαφανιστεί.

Ως ένα χαρακτηριστικό παράδειγμα, θυμηθείτε τη μελέτη μας για τις εμφανίσεις των διαφημίσεων (Y) σε σχέση με τις διαφημιστικές δαπάνες (X). (Βλ. Άσκηση 8.32.) Αν παλινδρομήσετε τη Y μόνο με τη X και παρατηρήσετε τα κατάλοιπα αυτής της παλινδρόμησης, θα δείτε ένα πρότυπο, αλλά αν παλινδρομήσετε τη Y με τη X και τη X^2 , θα δείτε ένα άλλο πρότυπο, το οποίο μπορεί να φανεί ευκρινώς από το Διάγραμμα 11.5. Έχουμε ήδη δει ότι η X^2 έχει θέση στο υπόδειγμα. (Βλ. Άσκηση 8.32.)

- 6 Μία άλλη πηγή ετεροσκεδαστικότητας είναι η **ασυμμετρία** (skewness) στην κατανομή ενός ή περισσότερων παλινδρομητών που περιλαμβάνονται στο υπόδειγμα. Παραδείγματα είναι οι οικονομικές μεταβλητές όπως το εισόδημα, ο πλούτος, και η εκπαίδευση. Είναι γνωστό ότι η κατανομή του εισοδήματος και του πλούτου στις περισσότερες κοινωνίες είναι άνιση, με το μεγαλύτερο μέρος του εισοδήματος και του πλούτου να ανήκουν σε λίγα άτομα.
- 7 Άλλες πηγές ετεροσκεδαστικότητας: Όπως επισημαίνει ο David Hendry, η ετεροσκεδαστικότητα μπορεί επίσης να προκύψει λόγω
- ♦ λανθασμένου μετασχηματισμού των στοιχείων (π.χ., μετασχηματισμοί σε λόγους ή σε πρώτες διαφορές) και
 - ♦ σε λανθασμένη συναρτησιακή μορφή (π.χ., γραμμικά έναντι λογαριθμικών-γραμμικών υποδειγμάτων).⁴

Σημειώστε ότι το πρόβλημα της ετεροσκεδαστικότητας είναι πιθανό να είναι πιο σύνηθες σε διαστρωματικά στοιχεία σε σχέση με στοιχεία χρονοσειρών. Σε διαστρωματικά στοιχεία, κάποιος συνήθως μελετά τα μέλη ενός πληθυσμού σε μία δεδομένη χρονική στιγμή, όπως για παράδειγμα μεμονωμένους καταναλωτές ή τις οικογένειές τους, επιχειρήσεις, κλάδους, ή γεωγραφικές υποδιαιρέσεις όπως περιφέρειες, χώρες, πόλεις, κ.λπ. Επιπλέον, αυτά τα μέλη μπορεί να είναι διαφόρων μεγεθών, όπως είναι μικρές, μεσαίες ή μεγάλες επιχειρήσεις, ή χαμηλό, μεσαίο, ή υψηλό εισόδημα. Σε στοιχεία χρονοσειρών, από την άλλη πλευρά, οι μεταβλητές τείνουν να είναι παρόμοιων τάξεων μεγέθους γιατί κάποιος συλλέγει γενικά στοιχεία για την ίδια οντότητα στη διάρκεια μίας χρονικής περιόδου. Τα παραδείγματα είναι το ακαθάριστο εθνικό προϊόν (ΑΕΠ), οι καταναλωτικές δαπάνες, η αποταμίευση, ή η απασχόληση, για παράδειγμα στην περίοδο 1955-2005.

Ως ένα παράδειγμα της ετεροσκεδαστικότητας που ενδέχεται να προκύψει στην ανάλυση διαστρωματικών στοιχείων, εξετάστε τον Πίνακα 11.1. Ο πίνακας παραθέτει στοιχεία σχετικά με τις αποδοχές ανά εργαζόμενο σε 10 μεταποιητικούς κλάδους μη διαρκών αγαθών, που ταξινομούνται κατά το μέγεθος της απασχόλησης της επιχείρησης για το έτος 1958. Επίσης, στον πίνακα παρατίθενται στοιχεία για τη μέση παραγωγικότητα για εννέα βαθμίδες μεγέθους απασχόλησης.



ΔΙΑΓΡΑΜΜΑ 11.5 Κατάλοιπα από την παλινδρόμηση (α) των εμφανίσεων των διαφημίσεων με τις διαφημιστικές δαπάνες και (β) των εμφανίσεων με τις μεταβλητές $Adexp$ και $Adexp^2$.


⁴ David F. Hendry, *Dynamic Econometrics*, Oxford University Press, 1995, σελ. 45.

ΠΙΝΑΚΑΣ 11.1 Αποδοχές ανά Εργαζόμενο (\$) σε Κλάδους Μεταποίησης Μη διαρκών Αγαθών Σύμφωνα με το Μέγεθος της Απασχόλησης της Επιχείρησης, 1958

Κλάδος	Μέγεθος Απασχόλησης (μέσος αριθμός απασχολουμένων)								
	1-4	5-9	10-19	20-49	50-99	100-249	250-499	500-999	1,000-2,499
Τρόφιμα και συγγενή προϊόντα	2.994	3.295	3.565	3.907	4.189	4.486	4.676	4.968	5.342
Προϊόντα καπνού	1.721	2.057	3.336	3.320	2.980	2.848	3.072	2.969	3.822
Κλωστοϋφαντουργικά προϊόντα	3.600	3.657	3.674	3.437	3.340	3.334	3.225	3.163	3.168
Ένδυση και συναφή προϊόντα	3.494	3.787	3.533	3.215	3.030	2.834	2.750	2.967	3.453
Χαρτί και συναφή προϊόντα	3.498	3.847	3.913	4.135	4.445	4.885	5.132	5.342	5.326
Εκτυπώσεις και εκδόσεις	3.611	4.206	4.695	5.083	5.301	5.269	5.182	5.395	5.552
Χημικές ουσίες και συναφή προϊόντα	3.875	4.660	4.930	5.005	5.114	5.248	5.630	5.870	5.876
Πετρέλαιο και προϊόντα άνθρακα	4.616	5.181	5.317	5.337	5.421	5.710	6.316	6.455	6.347
Καουτσούκ και πλαστικά προϊόντα	3.538	3.984	4.014	4.287	4.221	4.539	4.721	4.905	5.481
Δέρμα και δερμάτινα προϊόντα	3.016	3.196	3.149	3.317	3.414	3.254	3.177	3.346	4.067
Μέσες αποδοχές	3.396	3.787	4.013	4.104	4.146	4.241	4.388	4.538	4.843
Τυπική απόκλιση	742,2	851,4	727,8	805,06	929,9	1.080,6	1.241,2	1.307,7	1.110,7
Μέση παραγωγικότητα	9.355	8.584	7.962	8.275	8.389	9.418	9.795	10.281	11.750

Πηγή: *The Census of Manufacturers*, U.S. Department of Commerce, 1958 (οι υπολογισμοί έγιναν από το συγγραφέα).

Παρόλο που οι κλάδοι διαφέρουν ως προς τη σύνθεση της εκροής τους, ο Πίνακας 11.1 δείχνει σαφώς ότι κατά μέσο όρο οι μεγάλες επιχειρήσεις πληρώνουν περισσότερο από τις μικρές επιχειρήσεις. Για παράδειγμα, οι επιχειρήσεις που απασχολούσαν από έναν έως τέσσερις υπαλλήλους, κατέβαλλαν κατά μέσο όρο περίπου \$3.396, ενώ αυτές που απασχολούσαν από 1.000 έως 2.499 εργαζομένους κατέβαλλαν κατά μέσο όρο περίπου \$4.843. Παρατηρήστε όμως, ότι υπάρχει σημαντική μεταβλητότητα όσον αφορά τα κέρδη μεταξύ των διαφόρων βαθμίδων απασχόλησης, όπως προκύπτει από τις εκτιμημένες τυπικές αποκλίσεις των αποδοχών. Αυτό φαίνεται επίσης από το Διάγραμμα 11.6, στο οποίο παρουσιάζεται η τυπική απόκλιση των αποδοχών και οι μέσες αποδοχές σε κάθε βαθμίδα απασχόλησης. Όπως φαίνεται, κατά μέσο όρο, η τυπική απόκλιση των αποδοχών αυξάνεται με τη μέση τιμή των αποδοχών.



ΔΙΑΓΡΑΜΜΑ 11.6 Τυπική απόκλιση των αποδοχών και μέσες αποδοχές.

11.2 Εκτίμηση OLS με την Παρουσία Ετεροσκεδαστικότητας

Τι θα συμβεί στους εκτιμητές των ελαχίστων τετραγώνων (OLS) και στις διακυμάνσεις τους, εάν εισάγουμε την ετεροσκεδαστικότητα, δηλαδή $E(u_i^2) = \sigma_i^2$, αλλά διατηρήσουμε όλες τις άλλες υποθέσεις του κλασικού υποδείγματος; Για να απαντήσουμε στο ερώτημα αυτό, ας επανέλθουμε στο διμεταβλητό υπόδειγμα:

$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

Εφαρμόζοντας το συνήθη τύπο, ο εκτιμητής της OLS του β_2 είναι

$$\hat{\beta}_2 = \frac{\sum x_i y_i}{\sum x_i^2} = \frac{n \sum X_i Y_i - \sum X_i \sum Y_i}{n \sum X_i^2 - (\sum X_i)^2} \quad (11.2.1)$$

αλλά η διακύμανσή του δίνεται τώρα από τον ακόλουθο τύπο (βλ. Παράρτημα 11Α, Ενότητα 11Α.1):

$$\text{var}(\hat{\beta}_2) = \frac{\sum x_i^2 \sigma_i^2}{(\sum x_i^2)^2} \quad (11.2.2)$$

που είναι προφανώς διαφορετικός από το συνηθισμένο τύπο της διακύμανσης που προκύπτει υπό την υπόθεση της ομοσκεδαστικότητας, δηλαδή,

$$\text{var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum x_i^2} \quad (11.2.3)$$

Ασφαλώς, εάν $\sigma_i^2 = \sigma^2$ για κάθε i , οι δύο τύποι θα είναι ίδιοι. (Γιατί;)

Θυμηθείτε ότι $\hat{\beta}_2$ είναι ο άριστος γραμμικός αμερόληπτος εκτιμητής (BLUE) εάν ισχύουν οι υποθέσεις του κλασικού υποδείγματος, συμπεριλαμβανομένης της ομοσκεδαστικότητας. Θα εξακολουθεί, όμως, να είναι BLUE όταν θα απαλείψουμε μόνο την υπόθεση της ομοσκεδαστικότητας και την αντικαταστήσουμε με την υπόθεση της ετεροσκεδαστικότητας; Είναι εύκολο να αποδειχθεί ότι ο $\hat{\beta}_2$ εξακολουθεί να είναι γραμμικός και αμερόληπτος. Μάλιστα, όπως αποδεικνύεται στο Παράρτημα 3Α, Ενότητα 3Α.2, για να αποδείξουμε την αμεροληψία του $\hat{\beta}_2$ δεν είναι απαραίτητο οι διαταρακτικοί όροι (u_i) να είναι ομοσκεδαστικοί. Στην πραγματικότητα, είτε η διακύμανση του u_i είναι ομοσκεδαστική είτε ετεροσκεδαστική, δε διαδραματίζει κανένα ρόλο στον καθορισμό της ιδιότητας της αμεροληψίας. Υπενθυμίζεται ότι στο Παράρτημα 3Α, Ενότητα 3Α.7, δείξαμε ότι ο $\hat{\beta}_2$ είναι ένας συνεπής εκτιμητής βάσει των υποθέσεων του κλασικού γραμμικού υποδείγματος παλινδρόμησης. Αν και δε θα το αποδείξουμε, μπορεί να αποδειχθεί ότι ο $\hat{\beta}_2$ είναι ένας συνεπής εκτιμητής παρά την ετεροσκεδαστικότητα· δηλαδή, καθώς το μέγεθος του δείγματος αυξάνεται επ' άπειρο, ο εκτιμημένος β_2 συγκλίνει προς την πραγματική του τιμή. Επιπλέον, μπορεί επίσης να αποδειχθεί ότι, σύμφωνα με ορισμένες συνθήκες (που ονομάζονται συνθήκες κανονικότητας), ο $\hat{\beta}_2$ ακολουθεί ασυμπτωτικά την κανονική κατανομή. Φυσικά, ό, τι έχει ειπωθεί για το $\hat{\beta}_2$, ισχύει, επίσης, και για τις υπόλοιπες παραμέτρους ενός υποδείγματος πολλαπλής παλινδρόμησης.

Με δεδομένο ότι ο $\hat{\beta}_2$ εξακολουθεί να είναι γραμμικά αμερόληπτος και συνεπής, είναι «αποτελεσματικός» ή «άριστος»; Δηλαδή, έχει ελάχιστη διακύμανση της τάξης των αμερόληπτων εκτιμητών; Και αυτή η ελάχιστη διακύμανση δίνεται από την Εξ. (11.2.2); Η απάντηση και στα δύο ερωτήματα είναι όχι: ο $\hat{\beta}_2$ δεν είναι πλέον άριστος και η ελάχιστη διακύμανση δε δίνεται από την Εξίσωση (11.2.2). Τότε πως είναι BLUE με την παρουσία ετεροσκεδαστικότητας; Η απάντηση δίνεται στην επόμενη ενότητα.

11.3 Η Γενικευμένη Μέθοδος των Ελαχίστων Τετραγώνων (GLS)

Για ποιο λόγο ο συνήθης εκτιμητής του β_2 της OLS που δίνεται στην Εξίσωση (11.2.1) δεν είναι άριστος, παρόλο που εξακολουθεί να είναι αμερόληπτος; Διαισθητικά, μπορούμε να δούμε το λόγο από τον Πίνακα 11.1. Όπως φαίνεται στον πίνακα, υπάρχει σημαντική μεταβλητότητα στις αποδοχές μεταξύ των βαθμίδων απασχόλησης. Αν επρόκειτο να παλινδρομήσουμε τις αποδοχές ανά εργαζόμενο με το μέγεθος της απασχόλησης, θα θέλαμε να χρησιμοποιήσουμε τη γνώση ότι υπάρχει σημαντική μεταβλητότητα στα έσοδα μεταξύ των διαφόρων βαθμίδων. Ιδανικά, θα θέλαμε να κατασκευάσουμε το σχέδιο εκτίμησης κατά τέτοιο τρόπο ώστε οι παρατηρήσεις που προέρχονται από πληθυσμούς με μεγαλύτερη μεταβλητό-

τητα να έχουν λιγότερη βαρύτητα από εκείνες που προέρχονται από πληθυσμούς με μικρότερη μεταβλητότητα. Εξετάζοντας τον Πίνακα 11.1, θα θέλαμε να σταθμίσουμε τις παρατηρήσεις που προέρχονται από τις βαθμίδες απασχόλησης 10-19 και 20-49 με μεγαλύτερα σταθμά από αυτές που προέρχονται από τις βαθμίδες απασχόλησης 5-9 και 250-499, καθώς οι πρώτες δύο είναι περισσότερο συγκεντρωμένες γύρω από τις μέσες τιμές σε σχέση με τις τελευταίες, κάτι που θα μας επιτρέψει να εκτιμήσουμε τη συνάρτηση παλινδρόμησης του πληθυσμού (PRF) με μεγαλύτερη ακρίβεια.

Δυστυχώς, η συνήθης μέθοδος της OLS δεν ακολουθεί αυτή τη στρατηγική και, συνεπώς, δε χρησιμοποιεί τις «πληροφορίες» που περιέχονται στην άνιση μεταβλητότητα της εξαρτημένης μεταβλητής Y , για παράδειγμα, τις αποδοχές των εργαζομένων από τον Πίνακα 11.1: Προσδιορίζει την ίδια βαρύτητα ή σημασία σε κάθε παρατήρηση. Όμως, μία μέθοδος εκτίμησης, που είναι γνωστή ως **γενικευμένη μέθοδος των ελαχίστων τετραγώνων** (generalized least squares - GLS), λαμβάνει τις πληροφορίες αυτές υπόψη ρητά και, συνεπώς, έχει τη δυνατότητα να οδηγήσει σε εκτιμητές που είναι BLUE. Για να δείτε πώς επιτυγχάνεται αυτό, ας συνεχίσουμε με το διμεταβλητό υπόδειγμα με το οποίο είμαστε πλέον εξοικειωμένοι:

$$Y_i = \beta_1 + \beta_2 X_i + u_i \quad (11.3.1)$$

το οποίο για λόγους ευκολίας γράφουμε ως

$$Y_i = \beta_1 X_{0i} + \beta_2 X_i + u_i \quad (11.3.2)$$

όπου $X_{0i} = 1$ για κάθε i . Ο αναγνώστης μπορεί να διαπιστώσει ότι αυτοί οι δύο τύποι είναι πανομοιότυποι.

Ας υποθέσουμε τώρα ότι οι ετεροσκεδαστικές διακυμάνσεις σ_i^2 είναι γνωστές. Διαιρούμε και τα δύο μέλη της Εξίσωσης (11.3.2) με σ_i και παίρνουμε

$$\frac{Y_i}{\sigma_i} = \beta_1 \left(\frac{X_{0i}}{\sigma_i} \right) + \beta_2 \left(\frac{X_i}{\sigma_i} \right) + \left(\frac{u_i}{\sigma_i} \right) \quad (11.3.3)$$

που για ευκολία γράφεται ως

$$Y_i^* = \beta_1^* X_{0i}^* + \beta_2^* X_i^* + u_i^* \quad (11.3.4)$$

όπου οι μεταβλητές με αστερίσκο, ή μετασχηματισμένες μεταβλητές είναι οι αρχικές μεταβλητές προς (το γνωστό) σ_i . Χρησιμοποιούμε τα σύμβολα β_1^* και β_2^* , για τις παραμέτρους του μετασχηματισμένου υποδείγματος, για να τις διακρίνουμε από τις συνήθεις παραμέτρους β_1 και β_2 της OLS.

Ποιος είναι ο σκοπός του μετασχηματισμού του αρχικού υποδείγματος; Για να απαντήσουμε σε αυτό, παρατηρήστε το εξής χαρακτηριστικό του μετασχηματισμένου όρου σφάλματος u_i^* :

$$\begin{aligned} \text{var}(u_i^*) &= E(u_i^*)^2 = E\left(\frac{u_i}{\sigma_i}\right)^2 \quad \text{καθώς } E(u_i^*) = 0 \\ &= \frac{1}{\sigma_i^2} E(u_i^2) \quad \text{καθώς η } \sigma_i^2 \text{ είναι γνωστή} \\ &= \frac{1}{\sigma_i^2} (\sigma_i^2) \quad \text{καθώς } E(u_i^2) = \sigma_i^2 \\ &= 1 \end{aligned} \quad (11.3.5)$$

που είναι μία σταθερά. Δηλαδή, η διακύμανση του μετασχηματισμένου διαταρακτικού όρου u_i^* είναι τώρα ομοσκεδαστική. Από τη στιγμή που διατηρούμε ακόμη τις υπόλοιπες υποθέσεις του κλασικού υποδείγματος, το εύρημα ότι u_i^* είναι ομοσκεδαστικό δείχνει ότι αν εφαρμόσουμε την OLS στο μετασχηματισμένο υπόδειγμα (11.3.3) θα παράγει εκτιμητές οι οποίοι είναι BLUE. Εν ολίγοις, είναι οι εκτιμημένες παράμετροι β_1^* και β_2^* αυτές που είναι BLUE και όχι οι εκτιμητές $\hat{\beta}_1$ και $\hat{\beta}_2$ της OLS.

Η διαδικασία του μετασχηματισμού των αρχικών μεταβλητών με τέτοιο τρόπο ώστε οι μετασχηματισμένες μεταβλητές να ικανοποιούν τις υποθέσεις του κλασικού υποδείγματος και στη συνέχεια, η εφαρμογή της OLS σε αυτές είναι γνωστή ως η γενικευμένη μέθοδος των ελαχίστων τετραγώνων (GLS). *Με λίγα λόγια, η GLS είναι η OLS επί των μετασχηματισμένων μεταβλητών που ικανοποιούν τις τοπικές υποθέσεις των ελαχίστων τετραγώνων.* Επομένως, οι εκτιμητές που προκύπτουν είναι γνωστοί ως **εκτιμητές της GLS**, και είναι αυτοί οι εκτιμητές οι οποίοι είναι BLUE.

Ο πραγματικός μηχανισμός εκτίμησης των β_1^* και β_2^* είναι ο εξής. Πρώτον, γράφουμε τη συνάρτηση παλινδρόμησης του δείγματος (SRF) της Εξ. (11.3.3)

$$\begin{aligned} \frac{Y_i}{\sigma_i} &= \hat{\beta}_1^* \left(\frac{X_{0i}}{\sigma_i} \right) + \hat{\beta}_2^* \left(\frac{X_i}{\sigma_i} \right) + \left(\frac{\hat{u}_i}{\sigma_i} \right) \\ \text{ή} \\ Y_i^* &= \hat{\beta}_1^* X_{0i}^* + \hat{\beta}_2^* X_i^* + \hat{u}_i^* \end{aligned} \quad (11.3.6)$$

Τώρα, για να πάρουμε τους εκτιμητές της GLS, ελαχιστοποιούμε

$$\begin{aligned} \sum \hat{u}_i^{2*} &= \sum (Y_i^* - \hat{\beta}_1^* X_{0i}^* - \hat{\beta}_2^* X_i^*)^2 \\ \text{δηλαδή} \\ \sum \left(\frac{\hat{u}_i}{\sigma_i} \right)^2 &= \sum \left[\frac{Y_i}{\sigma_i} - \hat{\beta}_1^* \left(\frac{X_{0i}}{\sigma_i} \right) - \hat{\beta}_2^* \left(\frac{X_i}{\sigma_i} \right) \right]^2 \end{aligned} \quad (11.3.7)$$

Οι πραγματικοί μηχανισμοί για την ελαχιστοποίηση της Εξ. (11.3.7) ακολουθούν τις τυπικές τεχνικές του λογισμού και παρουσιάζονται στο Παράρτημα 11Α, Ενότητα 11Α.2. Όπως παρουσιάζεται εκεί, ο εκτιμητής της GLS β_2^* είναι

$$\hat{\beta}_2^* = \frac{(\sum w_i)(\sum w_i X_i Y_i) - (\sum w_i X_i)(\sum w_i Y_i)}{(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2} \quad (11.3.8)$$

και η διακύμανσή του δίνεται από

$$\text{var}(\hat{\beta}_2^*) = \frac{\sum w_i}{(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2} \quad (11.3.9)$$

όπου $w_i = 1/\sigma_i^2$.

Διαφορά μεταξύ OLS και GLS

Υπενθυμίζεται από το Κεφάλαιο 3 ότι στην OLS ελαχιστοποιούμε

$$\sum \hat{u}_i^2 = \sum (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i)^2 \quad (11.3.10)$$

αλλά στη GLS ελαχιστοποιούμε τον τύπο (11.3.7) που μπορεί επίσης να γραφεί ως:

$$\sum w_i \hat{u}_i^2 = \sum w_i (Y_i - \hat{\beta}_1^* X_{0i} - \hat{\beta}_2^* X_i)^2 \quad (11.3.11)$$

όπου $w_i = 1/\sigma_i^2$ (βεβαιωθείτε ότι οι Εξ. [11.3.11] και [11.3.7] είναι πανομοιότυπες).

Επομένως, στη GLS ελαχιστοποιούμε ένα σταθμισμένο άθροισμα των καταλοίπων τετραγώνων με $w_i = 1/\sigma_i^2$ να είναι τα σταθμά, αλλά στην OLS ελαχιστοποιούμε ένα μη σταθμισμένο ή (αυτό που ισοδυναμεί με το ίδιο) εξίσου σταθμισμένο άθροισμα των τετραγώνων των καταλοίπων (RSS). Όπως δείχνει η Εξ. (11.3.7), στη GLS η στάθμιση που αναλογεί σε κάθε παρατήρηση είναι αντιστρόφως ανάλογη με τη σ_i της, δηλαδή, οι παρατηρήσεις που προέρχονται από έναν πληθυσμό με μεγαλύτερες σ_i θα πάρουν μία σχετικά μικρότερη στάθμιση και εκείνες που προέρχονται από έναν πληθυσμό με μικρότερες σ_i θα πάρουν αναλογικά μεγαλύτερη στάθμιση κατά την ελαχιστοποίηση του RSS (11.3.11). Για να δείτε τη διαφορά μεταξύ των OLS και GLS, εξετάστε το υποθετικό διάγραμμα διασποράς που παρουσιάζεται στο Διάγραμμα 11.7.

Στη (μη σταθμισμένη) OLS, κάθε $\hat{u}_i^2$ που σχετίζεται με τα σημεία A , B , και Γ , θα λάβει την ίδια στάθμιση κατά την ελαχιστοποίηση του RSS. Προφανώς, στην περίπτωση αυτή το $\hat{u}_i^2$ που σχετίζεται με το σημείο Γ θα υπερिशύσει στο RSS. Αλλά στη GLS η ακραία παρατήρηση Γ θα πάρει σχετικά μικρότερη στάθμιση από τις άλλες δύο παρατηρήσεις. Όπως προαναφέρθηκε, αυτή είναι η σωστή στρατηγική, καθώς για την εκτίμηση της συνάρτησης παλινδρόμησης του πληθυσμού (PRF) πιο αξιόπιστα, θα θέλαμε να δώσουμε περισσότερη βαρύτητα στις παρατηρήσεις που είναι συγκεντρωμένες γύρω από το μέσο τους (του πληθυσμού τους) σε σχέση με εκείνες που είναι διασκορπισμένες σε μεγάλο εύρος.

Εκτίμηση OLS Χωρίς να Λαμβάνεται Υπόψη η Ετεροσκεδαστικότητα

Η κατάσταση μπορεί να γίνει σοβαρή, αν χρησιμοποιούμε όχι μόνο το $\hat{\beta}_2$, αλλά αν συνεχίσουμε να χρησιμοποιούμε το συνήθη (ομοσκεδαστικό) τύπο της διακύμανσης που δίνεται στην Εξίσωση (11.2.3), ακόμη και αν υπάρχει ή υπάρχουν υπόνοιες ότι υπάρχει ετεροσκεδαστικότητα: Σημειώστε ότι αυτή είναι η πιο πιθανή περίπτωση των δύο που συζητάμε εδώ, επειδή όταν εργαζόμαστε σε παλινδρόμηση OLS σε ένα τυπικό οικονομετρικό πακέτο και αγνοούμε (ή δε γνωρίζουμε) την ύπαρξη ετεροσκεδαστικότητας, αυτή θα υπολογίσει τη διακύμανση του $\hat{\beta}_2$, σύμφωνα με την Εξ. (11.2.3). Πρώτα απ' όλα, η $\text{var}(\hat{\beta}_2)$ που δίνεται στην Εξίσωση (11.2.3) είναι ένας *μεροληπτικός* εκτιμητής της $\text{var}(\hat{\beta}_2)$ που δίνεται στην Εξίσωση (11.2.2), δηλαδή, κατά μέσο όρο υπερεκτιμά ή υποεκτιμά την τελευταία, και σε γενικές γραμμές δε μπορούμε να πούμε εάν η μεροληψία είναι θετική (υπερεκτίμηση) ή αρνητική (υποεκτίμηση), επειδή εξαρτάται από τη φύση της σχέσης μεταξύ σ_i^2 και των τιμών που παίρνει η ερμηνευτική μεταβλητή X , όπως φαίνεται σαφώς από την Εξ. (11.2.2) (βλ. Άσκηση 11.9). Η μεροληψία προκύπτει από το γεγονός ότι $\hat{\sigma}^2$, ο συμβατικός εκτιμητής της σ^2 , δηλαδή, $\sum \hat{u}_i^2 / (n - 2)$ δεν είναι πλέον ένας αμερόληπτος εκτιμητής της τελευταίας, όταν υπάρχει ετεροσκεδαστικότητα (βλ. Παράρτημα 11Α.3). Ως αποτέλεσμα, δε μπορούμε πλέον να βασιστούμε στα συμβατικά υπολογισμένα διαστήματα εμπιστοσύνης και στους συμβατικούς ελέγχους t και F .⁶ **Με λίγα λόγια, αν επιμένουμε στη χρήση των συνηθισμένων διαδικασιών ελέγχου παρά την ύπαρξη ετεροσκεδαστικότητας, οποιαδήποτε είναι τα αποτελέσματα ή τα συμπεράσματα στα οποία θα καταλήξουμε αυτά μπορεί να είναι πολύ παραπλανητικά.**

Για να ρίξουμε περισσότερο φως σε αυτό το θέμα, αναφερόμαστε σε μία μελέτη Monte Carlo που πραγματοποιήθηκε από τους Davidson and MacKinnon.⁷ Εξετάζουν το εξής απλό υπόδειγμα, το οποίο είναι

$$Y_i = \beta_1 + \beta_2 X_i + u_i \quad (11.4.1)$$

Υποθέτουν ότι $\beta_1 = 1$, $\beta_2 = 1$, και $u_i \sim N(0, X_i^\alpha)$. Όπως δείχνει η τελευταία σχέση, υποθέτουν ότι η διακύμανση του σφάλματος είναι ετεροσκεδαστική και έχει σχέση με την τιμή του παλινδρομητή X υψωμένη στην α . Αν, για παράδειγμα, $\alpha = 1$, η διακύμανση του σφάλματος είναι ανάλογη με την τιμή της μεταβλητής X , αν $\alpha = 2$, η διακύμανση του σφάλματος είναι ανάλογη με το τετράγωνο της τιμής της X , και ούτω καθεξής. Στην Ενότητα 11.6 θα εξετάσουμε τη λογική στην οποία στηρίζεται μία τέτοια διαδικασία. Βασιζόμενοι σε 20.000 επαναλήψεις και επιτρέποντας στο α να πάρει διάφορες τιμές, βρίσκουν τα τυπικά σφάλματα των δύο συντελεστών παλινδρόμησης χρησιμοποιώντας την OLS (βλ. Εξ. [11.2.3]), την OLS με την παρουσία ετεροσκεδαστικότητας (βλ. Εξ. [11.2.2]), και τη GLS (βλ. Εξ. [11.3.9]). Παραθέτουμε τα αποτελέσματα τους για επιλεγμένες τιμές του α :

Τιμή του α	Τυπικό σφάλμα του β_1			Τυπικό σφάλμα του β_2		
	OLS	OLS _{het}	GLS	OLS	OLS _{het}	GLS
0,5	0,164	0,134	0,110	0,285	0,277	0,243
1,0	0,142	0,101	0,048	0,246	0,247	0,173
2,0	0,116	0,074	0,0073	0,200	0,220	0,109
3,0	0,100	0,064	0,0013	0,173	0,206	0,056
4,0	0,089	0,059	0,0003	0,154	0,195	0,017

Σημείωση: OLS_{het} σημαίνει OLS με την παρουσία ετεροσκεδαστικότητας.

Το πιο εντυπωσιακό χαρακτηριστικό αυτών των αποτελεσμάτων είναι ότι η OLS, με ή χωρίς διόρθωση για ετεροσκεδαστικότητα, συστηματικά υπερεκτιμά το πραγματικό τυπικό σφάλμα που προκύπτει από τη (σωστή) διαδικασία GLS, ειδικά για τις μεγάλες τιμές του α , αποδεικνύοντας έτσι την ανωτερότητα της GLS. Αυτά τα αποτελέσματα δείχνουν επίσης ότι αν δε χρησιμοποιήσουμε τη GLS και βασιστούμε στην OLS-επιτρέποντας ή όχι την ύπαρξη ετεροσκεδαστικότητας-η εικόνα είναι σύνθετη. Τα συνήθη τυπικά σφάλματα της OLS είναι είτε πολύ μεγάλα (για το συντελεστή σταθεράς) ή γενικά πολύ μικρά (για το συντελεστή κλίσης) σε σχέση με εκείνα που προκύπτουν από την OLS με την παρουσία ετεροσκεδαστι-

⁶ Από την Εξ. (5.3.6) γνωρίζουμε ότι το $100(1 - \alpha)\%$ διάστημα εμπιστοσύνης για το β_2 είναι $[\hat{\beta}_2 \pm t_{\alpha/2} \text{se}(\hat{\beta}_2)]$. Αλλά αν το $\text{se}(\hat{\beta}_2)$ δε μπορεί να εκτιμηθεί αμερόληπτα, τι εμπιστοσύνη μπορούμε να δείξουμε στο συμβατικά υπολογισμένο διάστημα εμπιστοσύνης;

⁷ Russell Davidson and James G. MacKinnon, *Estimation and Inference in Econometrics*, Oxford University Press, New York, 1993, σσ. 549–550.

κότητας. Το μήνυμα είναι σαφές: Όταν υπάρχει ετεροσκεδαστικότητα, χρησιμοποιούμε GLS. Ωστόσο, για λόγους που θα αναλυθούν αργότερα στο παρόν κεφάλαιο, δεν είναι πάντα πρακτικά εύκολο να εφαρμοστεί η GLS. Επίσης, όπως θα συζητήσουμε αργότερα, εκτός και αν η ετεροσκεδαστικότητα είναι πολύ σοβαρή, κάποιος ίσως να μην πρέπει να εγκαταλείψει την OLS υπέρ της GLS ή της WLS.

Από την προηγούμενη συζήτηση, είναι σαφές ότι η ετεροσκεδαστικότητα είναι δυνητικά ένα σοβαρό πρόβλημα και ο ερευνητής πρέπει να γνωρίζει κατά πόσο είναι παρούσα σε μία δεδομένη κατάσταση. Αν έχει εντοπιστεί η παρουσία της, τότε μπορεί κανείς να λάβει διορθωτικά μέτρα, όπως η χρήση της σταθμισμένης παλινδρόμησης των ελαχίστων τετραγώνων ή κάποια άλλη τεχνική. Πριν στραφούμε στην εξέταση των διαφόρων διορθωτικών διαδικασιών, όμως, πρέπει πρώτα να μάθουμε εάν η ετεροσκεδαστικότητα είναι παρούσα ή είναι πιθανό να είναι παρούσα σε μία δεδομένη περίπτωση. Αυτό το ζήτημα συζητείται στην επόμενη ενότητα.

Μια Τεχνική Σημείωση

Παρόλο που έχουμε δηλώσει ότι, σε περιπτώσεις ετεροσκεδαστικότητας, είναι η GLS και όχι η OLS, που είναι BLUE, υπάρχουν παραδείγματα όπου η OLS μπορεί να είναι BLUE, παρά την ετεροσκεδαστικότητα.⁸ Τέτοια παραδείγματα όμως είναι σπάνια.

11.5 Ανίχνευση της Ετεροσκεδαστικότητας

Όπως και με την πολυσυγγραμμικότητα, το σημαντικό πρακτικό ερώτημα είναι: Πώς μπορεί κάποιος να γνωρίζει ότι η ετεροσκεδαστικότητα είναι παρούσα σε μία συγκεκριμένη περίπτωση; Και πάλι, όπως στην περίπτωση της πολυσυγγραμμικότητας, δεν υπάρχουν συγκεκριμένοι κανόνες για την ανίχνευση της ετεροσκεδαστικότητας, μόνο ορισμένοι εμπειρικοί κανόνες. Όμως η κατάσταση αυτή είναι αναπόφευκτη, επειδή η σ_i^2 μπορεί να είναι γνωστή μόνο αν έχουμε το συνολικό πληθυσμό Y που αντιστοιχεί στα επιλεγμένα X , όπως ο πληθυσμός που διακρίνεται στον Πίνακα 2.1 ή στον Πίνακα 11.1. Όμως, τα στοιχεία αυτά αποτελούν την εξαίρεση και όχι τον κανόνα στις περισσότερες οικονομικές έρευνες. Βάσει αυτού ο οικονομήτρης διαφέρει από επιστήμονες σε τομείς όπως η γεωργία και η βιολογία, όπου οι ερευνητές έχουν ένα σχετικά καλό έλεγχο του αντικειμένου τους. Τις περισσότερες φορές, σε οικονομικές μελέτες υπάρχει μόνο μία δειγματική τιμή Y που αντιστοιχεί σε μία συγκεκριμένη τιμή της X . Και δεν υπάρχει τρόπος κάποιος να μπορεί να γνωρίζει τη σ_i^2 μόνο από μία παρατήρηση της Y . Ως εκ τούτου, στις περισσότερες περιπτώσεις που αφορούν οικονομετρικές έρευνες, η ετεροσκεδαστικότητα μπορεί να είναι ένα θέμα διαίσθησης, εμπειριστατωμένης εικασίας, προηγούμενης εμπειρίας, ή καθαρής εικασίας.

Έχοντας κατά νου την προηγούμενη προειδοποίηση, ας εξετάσουμε ορισμένες από τις τυπικές και άτυπες μεθόδους για την ανίχνευση της ετεροσκεδαστικότητας. Όπως θα αποκαλύψει η ακόλουθη συζήτηση, οι περισσότερες από αυτές τις μεθόδους βασίζονται στην εξέταση των καταλοίπων $\hat{u}_i$ της OLS, δεδομένου ότι είναι αυτοί που παρατηρούμε, και όχι οι διαταρακτικοί όροι u_i . Κάποιος μπορεί να ελπίζει ότι είναι καλές εκτιμήσεις του u_i , μία ελπίδα που μπορεί να εκπληρωθεί αν το μέγεθος του δείγματος είναι αρκετά μεγάλο.

Ατυπες Μέθοδοι

Η Φύση του Προβλήματος

Πολύ συχνά η φύση του υπό εξέταση προβλήματος δείχνει αν είναι πιθανό να συναντήσουμε ετεροσκεδαστικότητα. Για παράδειγμα, μετά την πρωτοποριακή εργασία των Prais and Houthakker σε μελέτες για τον οικογενειακό προϋπολογισμό, όπου βρήκαν ότι η διακύμανση των καταλοίπων γύρω από την παλινδρόμηση της κατανάλωσης με το εισόδημα αυξάνεται καθώς το εισόδημα αυξάνει, υποθέτουμε πλέον ότι


⁸ Ο λόγος για αυτό είναι ότι το θεώρημα Gauss-Markov παρέχει την ικανή (αλλά όχι αναγκαία) συνθήκη ούτως ώστε να είναι αποτελεσματική η OLS. Η αναγκαία και ικανή συνθήκη ούτως ώστε να είναι BLUE η OLS δίνεται από το **θεώρημα του Kruskal**. Όμως αυτό το θέμα είναι πέρα από το πεδίο ανάλυσης του παρόντος βιβλίου. Είμαι ευγνώμων στον Michael McAleer ο οποίος μου το επεσήμανε. Για περισσότερες λεπτομέρειες, βλ. Denzil G. Fiebig, Michael McAleer, and Robert Bartels, "Properties of Ordinary Least Squares Estimators in Regression Models with Nonspherical Disturbances," *Journal of Econometrics*, vol. 54, No. 1-3, Οκτ.-Δεκ., 1992, σσ. 321-334. Για το φοιτητή που έχει έφεση στα μαθηματικά, το παρόν ζήτημα αναλύεται περαιτέρω στο **Παράρτημα Γ**, με τη χρήση άλγεβρας μητρώων.

σε παρόμοιες έρευνες θα πρέπει να αναμένουμε άνισες διακυμάνσεις μεταξύ των διαταρακτικών όρων.⁹ Μάλιστα, σε διαστρωματικά στοιχεία που αφορούν ανομοιογενείς μονάδες, η ετεροσκεδαστικότητα μπορεί να είναι ο κανόνας και όχι η εξαίρεση. Επομένως, σε μία ανάλυση διαστρωματικών στοιχείων που αφορά τις επενδυτικές δαπάνες σε σχέση με τις πωλήσεις, το επιτόκιο, κ.λπ., αναμένεται η ύπαρξη ετεροσκεδαστικότητας, αν το συνολικό δείγμα περιλαμβάνει μικρές, μεσαίες και μεγάλες επιχειρήσεις.

Μάλιστα, έχουμε ήδη εξετάσει αντίστοιχα παραδείγματα. Στο Κεφάλαιο 2 συζητήσαμε τη σχέση μεταξύ του μέσου ωρομισθίου σε σχέση με τα έτη φοίτησης στις Η.Π.Α.. Σε αυτό το κεφάλαιο συζητήσαμε επίσης τη σχέση μεταξύ δαπανών για τρόφιμα και συνολικών δαπανών για 55 οικογένειες στην Ινδία (βλ. Άσκηση 11.16).

Γραφική Μέθοδος

Εάν δεν υπάρχουν *a priori* ή εμπειρικές πληροφορίες για τη φύση της ετεροσκεδαστικότητας, στην πράξη κάποιος μπορεί να πραγματοποιήσει την ανάλυση παλινδρόμησης με βάση την υπόθεση ότι δεν υπάρχει ετεροσκεδαστικότητα και ακολούθως να κάνει μία εξέταση του τετραγώνου των καταλοίπων $\hat{u}_i^2$ για να διαπιστωθεί αν παρουσιάζουν κάποιο συστηματικό πρότυπο. Παρά το γεγονός ότι τα $\hat{u}_i^2$ δεν είναι τα ίδια με τα u_i^2 , μπορούν να χρησιμοποιηθούν ως προσεγγίσεις ιδιαίτερα αν το μέγεθος του δείγματος είναι αρκετά μεγάλο.¹⁰ Μία εξέταση των $\hat{u}_i^2$ μπορεί να αποκαλύψει πρότυπα όπως αυτά που παρουσιάζονται στο Διάγραμμα 11.8.




ΔΙΑΓΡΑΜΜΑ 11.8 Υποθετικά πρότυπα των εκτιμημένων τετραγώνων των καταλοίπων.

Στο Διάγραμμα 11.8, τα $\hat{u}_i^2$ παρουσιάζονται σε σχέση με τη $\hat{Y}_i$, την εκτιμημένη Y_i από τη γραμμή παλινδρόμησης, προκειμένου να διαπιστωθεί αν η εκτιμημένη μέση τιμή της Y σχετίζεται συστηματικά με το κατάλοιπο στο τετράγωνο. Στο Διάγραμμα 11.8α βλέπουμε ότι δεν υπάρχει κάποιο συστηματικό πρότυπο μεταξύ των δύο μεταβλητών, γεγονός που υποδηλώνει ότι ίσως δεν υπάρχει ετεροσκεδαστικότητα στα στοιχεία. Ωστόσο τα Διαγράμματα από το 11.8β μέχρι το 11.8ε, εμφανίζουν σαφή πρότυπα. Για παράδειγμα, το Διάγραμμα 11.8γ προτείνει μία γραμμική σχέση, ενώ τα Διαγράμματα 11.8δ και 11.8ε δείχνουν μία τετραγωνική σχέση μεταξύ των $\hat{u}_i^2$ και του $\hat{Y}_i$. Χρησιμοποιώντας αυτή τη γνώση, έστω και άτυπα, κάποιος μπορεί να μετασχηματίσει τα στοιχεία με τέτοιο τρόπο ώστε τα μετασχηματισμένα στοιχεία να μην παρουσιάζουν ετεροσκεδαστικότητα. Στην Ενότητα 11.6 θα εξετάσουμε αρκετούς τέτοιους μετασχηματισμούς.

⁹ S. J. Prais and H. S. Houthakker, *The Analysis of Family Budgets*, Cambridge University Press, New York, 1955.

¹⁰ Για τη σχέση μεταξύ $\hat{u}_i$ και u_i , βλ. E. Malinvaud, *Statistical Methods of Econometrics*, North Holland Publishing Company, Amsterdam, 1970, σσ. 88–89.

Αντί να παρουσιάζουμε τα $\hat{u}_i^2$ σε σχέση με το $\hat{Y}_i$, μπορούμε να τα παρουσιάζουμε σε σχέση με μία από τις ερμηνευτικές μεταβλητές, ειδικά αν η παρουσίαση του $\hat{u}_i^2$ σε σχέση με το $\hat{Y}_i$ έχει σαν αποτέλεσμα το πρότυπο που παρουσιάζεται στο Διάγραμμα 11.8α. Ένα τέτοιο διάγραμμα, όπως το Διάγραμμα 11.9, μπορεί να αποκαλύψει πρότυπα παρόμοια με εκείνα που παρουσιάζονται στο Διάγραμμα 11.8. (Στην περίπτωση του διμεταβλητού υποδείγματος, η διαγραμματική απεικόνιση των $\hat{u}_i^2$ σε σχέση με το $\hat{Y}_i$ είναι ισοδύναμη με τη διαγραμματική απεικόνιση του σε σχέση με τη X_i , και ως εκ τούτου το Διάγραμμα 11.9 είναι παρόμοιο με το Διάγραμμα 11.8. Όμως αυτό δεν ισχύει όταν εξετάζουμε ένα υπόδειγμα που περιλαμβάνει δύο ή περισσότερες μεταβλητές X . Σε αυτήν την περίπτωση, τα $\hat{u}_i^2$ μπορούν να παρουσιαστούν διαγραμματικά σε σχέση με την οποιαδήποτε μεταβλητή X που περιλαμβάνεται στο υπόδειγμα.)



ΔΙΑΓΡΑΜΜΑ 11.9 Διάγραμμα διασποράς των εκτιμημένων τετραγώνων των καταλοίπων έναντι της X .

Ένα πρότυπο όπως αυτό που παρουσιάζεται στο Διάγραμμα 11.9γ, για παράδειγμα, δείχνει ότι η διακύμανση του διαταρακτικού όρου σχετίζεται γραμμικά με τη μεταβλητή X . Συνεπώς, αν στην παλινδρόμηση της αποταμίευσης σε σχέση με το εισόδημα κάποιος βρει ένα πρότυπο όπως αυτό που φαίνεται στο Διάγραμμα 11.9γ, αυτό δείχνει ότι η ετεροσκεδαστική διακύμανση μπορεί να είναι *ανάλογη* με την τιμή της μεταβλητής του εισοδήματος. Αυτή η γνώση μπορεί να μας βοηθήσει στο μετασχηματισμό των στοιχείων μας κατά τέτοιο τρόπο ώστε στην παλινδρόμηση των μετασχηματισμένων στοιχείων, η διακύμανση του διαταρακτικού όρου να είναι ομοσκεδαστική. Θα πρέπει να επιστρέψουμε σε αυτό το θέμα στην επόμενη ενότητα.

Τυπικές Μέθοδοι

Έλεγχος Park¹¹

Ο Park τυποποιεί τη διαγραμματική μέθοδο προτείνοντας ότι σ_i^2 είναι κάποια συνάρτηση της ερμηνευτικής μεταβλητής X_i . Η συναρτησιακή μορφή που προτείνει

$$\sigma_i^2 = \sigma^2 X_i^\beta e^{v_i}$$

ή

$$\ln \sigma_i^2 = \ln \sigma^2 + \ln X_i + \ln v_i \quad (11.5.1)$$

όπου v_i είναι ο στοχαστικός διαταρακτικός όρος.

¹¹ R. E. Park, "Estimation with Heteroscedastic Error Terms," *Econometrica*, vol. 34, no. 4, Οκτώβριος 1966, σελ. 888. Ο έλεγχος Park αποτελεί μία ειδική περίπτωση του γενικού ελέγχου που προτείνεται από τον A. C. Harvey in "Estimating Regression Models with Multiplicative Heteroscedasticity," *Econometrica*, vol. 44, no. 3, 1976, σσ. 461–465.

Καθώς η σ_i^2 δεν είναι γενικά γνωστή, ο Park προτείνει τη χρήση των $\hat{u}_i^2$ ως μία προσέγγιση και εκτιμά την ακόλουθη παλινδρόμηση:

$$\ln \hat{u}_i^2 = \ln \sigma^2 + \beta \ln X_i + v_i = \alpha + \beta \ln X_i + v_i \quad (11.5.2)$$

Αν ο β αποδειχθεί ότι είναι στατιστικά σημαντικός, θα υποδεικνύει ότι υπάρχει ετεροσκεδαστικότητα στα στοιχεία. Εάν αποδειχθεί ότι δεν είναι σημαντικός, μπορεί να αποδεχτούμε την υπόθεση της ομοσκεδαστικότητας. Ο **έλεγχος Park** είναι συνεπώς μία διαδικασία δύο σταδίων. Στο πρώτο στάδιο, εκτιμούμε την παλινδρόμηση OLS αγνοώντας το ζήτημα της ετεροσκεδαστικότητας. Έχουμε υπολογίσει τα $\hat{u}_i$ από αυτή την παλινδρόμηση, και στη συνέχεια στο δεύτερο στάδιο εκτιμούμε την παλινδρόμηση (11.5.2).

Παρόλο που είναι εμπειρικά ελκυστικός, ο έλεγχος Park έχει κάποια προβλήματα. Οι Goldfeld and Quandt έχουν υποστηρίξει ότι ο όρος σφάλματος v_i που χρησιμοποιείται στην Εξ. (11.5.2) ενδέχεται να μην ικανοποιεί τις υποθέσεις της OLS και μπορεί να είναι ετεροσκεδαστικός.¹² Παρ' όλα αυτά, κάποιος μπορεί να χρησιμοποιήσει τον έλεγχο Park, ως μία αυστηρά ερμηνευτική μέθοδο.

ΠΑΡΑΔΕΙΓΜΑ 11.1 Σχέση Μεταξύ Αποδοχών και Παραγωγικότητας

Για να φανεί η προσέγγιση του Park, χρησιμοποιούμε τα στοιχεία που δίνονται στον Πίνακα 11.1 για να εκτιμήσουμε την ακόλουθη παλινδρόμηση:

$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

όπου Y = μέσες αποδοχές σε χιλιάδες δολάρια, X = μέση παραγωγικότητα σε χιλιάδες δολάρια, και i = μέγεθος της επιχείρησης σύμφωνα με την απασχόληση. Τα αποτελέσματα της παλινδρόμησης έχουν ως εξής:

$$\begin{aligned} \hat{Y}_i &= 1992,3452 + 0,2329X_i \\ \text{se} &= (936,4791) \quad (0,0998) \\ t &= (2,1275) \quad (2,333) \quad R^2 = 0,4375 \end{aligned} \quad (11.5.3)$$

Τα αποτελέσματα αποκαλύπτουν ότι ο εκτιμημένος συντελεστής κλίσης είναι σημαντικός στο επίπεδο του 5 τοις εκατό με βάση ένα μονόπλευρο έλεγχο t . Η εξίσωση δείχνει ότι καθώς η παραγωγικότητα της εργασίας αυξάνεται κατά, για παράδειγμα, ένα δολάριο, οι αποδοχές αυξάνονται κατά μέσο όρο κατά περίπου 23 cents.

Τα κατάλοιπα που προκύπτουν από την παλινδρόμηση (11.5.3), στη συνέχεια παλινδρομούνται με τη X_i , όπως προτείνεται στην Εξ. (11.5.2), η οποία δίνει τα ακόλουθα αποτελέσματα:

$$\begin{aligned} \widehat{\ln \hat{u}_i^2} &= 35,817 - 2,8099 \ln X_i \\ \text{se} &= (38,319) \quad (4,216) \\ t &= (0,934) \quad (-0,667) \quad R^2 = 0,0595 \end{aligned} \quad (11.5.4)$$

Προφανώς, δεν υπάρχει στατιστικά σημαντική σχέση μεταξύ των δύο μεταβλητών. Ακολουθώντας τον έλεγχο Park, μπορεί κανείς να συμπεράνει ότι δεν υπάρχει ετεροσκεδαστικότητα στη διακύμανση του σφάλματος.¹³

Έλεγχος Glejser¹⁴

Ο **έλεγχος Glejser** είναι παρόμοιος λογικής με τον έλεγχο Park. Μετά την απόκτηση των καταλοίπων $\hat{u}_i$ από την παλινδρόμηση OLS, ο Glejser προτείνει την παλινδρόμηση των απόλυτων τιμών των $\hat{u}_i$ με τη

¹² Stephen M. Goldfeld and Richard E. Quandt, *Nonlinear Methods in Econometrics*, North Holland Publishing Company, Amsterdam, 1972, σσ. 93–94.

¹³ Η συγκεκριμένη συναρτησιακή μορφή που επιλέχθηκε από τον Park είναι ενδεικτική. Μία διαφορετική συναρτησιακή μορφή μπορεί να αποκαλύψει σημαντικές σχέσεις. Για παράδειγμα, κάποιος μπορεί να χρησιμοποιήσει $\hat{u}_i^2$ αντί για $\ln \hat{u}_i^2$ ως την εξαρτημένη μεταβλητή.

¹⁴ H. Glejser, "A New Test for Heteroscedasticity," *Journal of the American Statistical Association*, vol. 64, 1969, σσ. 316–323.

μεταβλητή X που θεωρείται ότι σχετίζεται άμεσα με τη σ_i^2 . Στα πειράματά του ο Glejser χρησιμοποιεί τις ακόλουθες συναρτησιακές μορφές:

$$|\hat{u}_i| = \beta_1 + \beta_2 X_i + v_i$$

$$|\hat{u}_i| = \beta_1 + \beta_2 \sqrt{X_i} + v_i$$

$$|\hat{u}_i| = \beta_1 + \beta_2 \frac{1}{X_i} + v_i$$

$$|\hat{u}_i| = \beta_1 + \beta_2 \frac{1}{\sqrt{X_i}} + v_i$$

$$|\hat{u}_i| = \sqrt{\beta_1 + \beta_2 X_i} + v_i$$

$$|\hat{u}_i| = \sqrt{\beta_1 + \beta_2 X_i^2} + v_i$$

όπου v_i είναι ο όρος σφάλματος.

Και πάλι ως ένα εμπειρικό ή πρακτικό θέμα, κάποιος μπορεί να χρησιμοποιήσει την προσέγγιση του Glejser. Αλλά οι Goldfeld and Quandt επισημαίνουν ότι ο όρος σφάλματος v_i έχει ορισμένα προβλήματα λόγω του ότι η προσδοκώμενη τιμή του είναι μη μηδενική, εμφανίζει σειριακή συσχέτιση (βλ. Κεφάλαιο 12), και, ειρωνικά, είναι ετεροσκεδαστικός.¹⁵ Μία επιπλέον δυσκολία της μεθόδου του Glejser είναι ότι υποδείγματα, όπως τα

$$|\hat{u}_i| = \sqrt{\beta_1 + \beta_2 X_i} + v_i$$

και

$$|\hat{u}_i| = \sqrt{\beta_1 + \beta_2 X_i^2} + v_i$$

είναι μη γραμμικά ως προς τις παραμέτρους και ως εκ τούτου δε μπορούν να εκτιμηθούν με τη συνήθη διαδικασία της OLS. Ο Glejser διαπίστωσε ότι για μεγάλα δείγματα, τα πρώτα τέσσερα από τα προηγούμενα υποδείγματα δίνουν γενικά ικανοποιητικά αποτελέσματα στην ανίχνευση της ετεροσκεδαστικότητας. Ως ένα πρακτικό ζήτημα, ως εκ τούτου, η τεχνική του Glejser μπορεί να χρησιμοποιηθεί για μεγάλα δείγματα και μπορεί να χρησιμοποιηθεί στα μικρά δείγματα αυστηρά, ως μία ποιοτική προσέγγιση για να μάθουμε σχετικά με την ετεροσκεδαστικότητα.

ΠΑΡΑΔΕΙΓΜΑ 11.2 Σχέση Μεταξύ Αποδοχών και Παραγωγικότητας: Ο Έλεγχος Glejser

Συνεχίζοντας με το Παράδειγμα 11.1, η απόλυτη τιμή των καταλοίπων που προέρχονται από την παλινδρόμηση (11.5.3) παλινδρομήθηκαν με τη μέση παραγωγικότητα (X), δίνοντας τα ακόλουθα αποτελέσματα:

$$\begin{aligned} |\hat{u}_i| &= 407,2783 - 0,0203X_i \\ \text{se} &= (633,1621) \quad (0,0675) \quad r^2 = 0,0127 \\ t &= (0,6432) \quad (-0,3012) \end{aligned} \quad (11.5.5)$$

Όπως μπορείτε να δείτε από αυτή την παλινδρόμηση, δεν υπάρχει καμία σχέση μεταξύ της απόλυτης τιμής των καταλοίπων και του παλινδρομητή, της μέσης παραγωγικότητας. Αυτό ενισχύει το συμπέρασμα που βασίζεται στον έλεγχο Park.

¹⁵ Για λεπτομέρειες, βλ. Goldfeld and Quandt, ό.π., Κεφάλαιο 3.

Έλεγχος Συσχέτισης του Spearman

Στην Άσκηση 3.8 ορίσαμε το **συντελεστή συσχέτισης του Spearman** ως

$$r_s = 1 - 6 \left[\frac{\sum d_i^2}{n(n^2 - 1)} \right] \quad (11.5.6)$$

όπου d_i = η διαφορά στην κατάταξη που έχει οριστεί σε δύο διαφορετικά χαρακτηριστικά του ατόμου ή φαινομένου i και n = αριθμός των ατόμων ή των φαινομένων που κατατάσσονται. Ο προηγούμενος συντελεστής συσχέτισης μπορεί να χρησιμοποιηθεί για την ανίχνευση της ετεροσκεδαστικότητας ως εξής: Έστω ότι

$$Y_i = \beta_0 + \beta_1 X_i + u_i,$$

Βήμα 1. Εκτιμήστε την παλινδρόμηση με τα στοιχεία για τις Y και X και υπολογίστε τα κατάλοιπα $\hat{u}_i$.

Βήμα 2. Αγνοώντας το πρόσημο των $\hat{u}_i$, δηλαδή, παίρνοντας την απόλυτη τιμή τους, κατατάξτε τόσο την $|\hat{u}_i|$ όσο και τη X_i (ή το $\hat{Y}_i$), σύμφωνα με μία αύξουσα ή φθίνουσα σειρά και υπολογίστε το συντελεστή συσχέτισης του Spearman που δόθηκε προηγουμένως.

Βήμα 3. Υποθέτοντας ότι ο συντελεστής συσχέτισης του πληθυσμού ρ_s είναι μηδέν και $n > 8$, η σημασία του r_s του δείγματος μπορεί να ελεγχθεί με τον έλεγχο t ως εξής:¹⁶

$$t = \frac{r_s \sqrt{n-2}}{\sqrt{1-r_s^2}} \quad \text{με } df = n-2. \quad (11.5.7)$$

Εάν η εκτιμημένη τιμή- t υπερβαίνει την κρίσιμη τιμή- t , μπορεί να δεχθούμε την υπόθεση της ετεροσκεδαστικότητας, ειδάλλως μπορεί να την απορρίψουμε. Αν το υπόδειγμα παλινδρόμησης περιλαμβάνει περισσότερες από μία μεταβλητές X , ο r_s μπορεί να υπολογιστεί μεταξύ της $|\hat{u}_i|$ και κάθε μίας από τις μεταβλητές X ξεχωριστά και μπορεί να ελεγχθεί για στατιστική σημαντικότητα μέσω του ελέγχου t που δίνεται στην Εξίσωση (11.5.7).

ΠΑΡΑΔΕΙΓΜΑ 11.3 Παρουσίαση του Ελέγχου του Συντελεστή Συσχέτισης

Για να παρουσιάσουμε τον έλεγχο του συντελεστή συσχέτισης, εξετάζουμε τα στοιχεία που δίνονται στον Πίνακα 11.2. Τα στοιχεία αφορούν τη μέση ετήσια απόδοση (E , %) και την τυπική απόκλιση της ετήσιας απόδοσης (σ , %), 10 αμοιβαίων κεφαλαίων.

ΠΙΝΑΚΑΣ 11.2 Έλεγχος Διαβάθμισης Συσχέτισης Ετεροσκεδαστικότητας

Όνομα Αμοιβαίου Κεφαλαίου	E_i Μέση Ετήσια Απόδοση, %	σ_i Τυπική Απόκλιση Ετήσιας Απόδοσης, %	$\hat{E}_i^\dagger$	$ \hat{u}_i ^\ddagger$ Κατάλοιπα $ E_i - \hat{E}_i $	Κατάταξη της $ \hat{u}_i $	Κατάταξη της σ_i	d Διαφορά μεταξύ των Δύο Κατατάξεων	d^2
Boston	12,4	12,1	11,37	1,03	9	4	5	25
Delaware	14,4	21,4	15,64	1,24	10	9	1	1
Equity	14,6	18,7	14,40	0,20	4	7	-3	9
Fundamental	16,0	21,7	15,78	0,22	5	10	-5	25
Investors	11,3	12,5	11,56	0,26	6	5	1	1
Loomis-Sales	10,0	10,4	10,59	0,59	7	2	5	25
Massachusetts	16,2	20,8	15,37	0,83	8	8	0	0
New	10,4	10,2	10,50	0,10	3	1	2	4
Putnam	13,1	16,0	13,16	0,06	2	6	-4	16
Wellington	11,3	12,0	11,33	0,03	1	3	-2	4
Total							0	110

[†]Προέκυψε από την παλινδρόμηση: $\hat{E}_i = 5,8194 + 0,4590\sigma_i$

[‡]Απόλυτη τιμή των καταλοίπων

Σημείωση: Η κατάταξη είναι σε αύξουσα κλίμακα των τιμών

¹⁶ Βλ. G. Udny Yule and M. G. Kendall, *An Introduction to the Theory of Statistics*, Charles Griffin & Company, London, 1953, σελ. 455.

Η γραμμή της κεφαλαιαγοράς (CML) της θεωρίας χαρτοφυλακίου αξιώνει μία γραμμική σχέση μεταξύ της αναμενόμενης απόδοσης (E_i) και του κινδύνου (όπως μετράται από την τυπική απόκλιση, σ) ενός χαρτοφυλακίου ως εξής:

$$E_i = \beta_i + \beta_2 \sigma_i$$

Χρησιμοποιώντας τα στοιχεία του Πίνακα 11.2, εκτιμήθηκε το προηγούμενο υπόδειγμα και υπολογίστηκαν τα κατάλοιπα του. Δεδομένου ότι τα στοιχεία αφορούν 10 αμοιβαία κεφάλαια διαφορετικών μεγεθών και επενδυτικών στόχων, ενδεχομένως να αναμέναμε *a priori* την παρουσία ετεροσκεδαστικότητας. Για να ελέγξουμε αυτή την υπόθεση, εφαρμόζουμε τον έλεγχο συσχέτισης. Οι απαραίτητοι υπολογισμοί δίνονται στον Πίνακα 11.2.

Εφαρμόζοντας τον τύπο (11.5.6), παίρνουμε

$$r_s = 1 - 6 \frac{110}{10(100 - 1)} = 0,3333 \quad (11.5.8)$$

Εφαρμόζοντας τον έλεγχο t που παρουσιάζεται στην Εξίσωση (11.5.7), παίρνουμε

$$t = \frac{(0,3333)(\sqrt{8})}{\sqrt{1 - 0,1110}} = 0,9998 \quad (11.5.9)$$

Για 8 βαθμούς ελευθερίας αυτή η τιμή- t δεν είναι σημαντική, ακόμη και στο επίπεδο σημαντικότητας του 10 τοις εκατό (η τιμή- p είναι 0,17). Επομένως, δεν υπάρχουν ενδείξεις συστηματικής σχέσης μεταξύ της ερμηνευτικής μεταβλητής και των απολύτων τιμών των καταλοίπων, κάτι που θα μπορούσε να υποδηλώνει ότι δεν υπάρχει ετεροσκεδαστικότητα.

Έλεγχος Goldfeld-Quandt¹⁷

Αυτή η δημοφιλής μέθοδος εφαρμόζεται αν υποθεθεί ότι η ετεροσκεδαστική διακύμανση, σ_i^2 , σχετίζεται θετικά με μία από τις ερμηνευτικές μεταβλητές στο υπόδειγμα παλινδρόμησης. Για λόγους απλότητας, εξετάστε το σύννητες διμεταβλητό υπόδειγμα:

$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

Ας υποθέσουμε ότι η σ_i^2 σχετίζεται θετικά με X_i ως

$$\sigma_i^2 = \sigma^2 X_i^2 \quad (11.5.10)$$

όπου σ^2 είναι μία σταθερά.¹⁸

Σύμφωνα με την Υπόθεση (11.5.10), η σ_i^2 είναι ανάλογη με το τετράγωνο της μεταβλητής X . Η υπόθεση αυτή έχει φανεί ιδιαίτερα χρήσιμη στους Prais and Houthakker στη μελέτη τους για τους οικογενειακούς προϋπολογισμούς. (Δείτε την Ενότητα 11.5, Άτυπες μέθοδοι.)

Αν η Εξ. (11.5.10) είναι κατάλληλη, αυτό θα σήμαινε ότι η σ_i^2 θα ήταν μεγαλύτερη, όσο μεγαλύτερες είναι οι τιμές της X_i . Σε περίπτωση που αποδεικνύεται ότι αυτό ισχύει, είναι πιθανό να υπάρχει ετεροσκεδαστικότητα στο υπόδειγμα. Για να ελεγχθεί αυτό άμεσα, οι Goldfeld και Quandt προτείνουν τα ακόλουθα βήματα:

- Βήμα 1.** Κατατάξτε τις παρατηρήσεις ανάλογα με τις τιμές της X_i , αρχίζοντας με τη χαμηλότερη τιμή X .
- Βήμα 2.** Παραλείψτε c κεντρικές παρατηρήσεις, όπου c είναι *a priori* προσδιορισμένες, και διαιρέστε τις υπόλοιπες $(n - c)$ παρατηρήσεις σε δύο ομάδες κάθε μία από τις οποίες περιέχει $(n - c)/2$ παρατηρήσεις.
- Βήμα 3.** Εκτιμήστε ξεχωριστές παλινδρομήσεις OLS για τις πρώτες $(n - c)/2$ παρατηρήσεις και για τις τελευταίες $(n - c)/2$ παρατηρήσεις, και βρείτε τα αντίστοιχα αθροίσματα των τετραγώνων των καταλοίπων και RSS_1 , RSS_2 , όπου το RSS_1 αντιπροσωπεύει το RSS από την παλινδρόμηση που αντιστοιχεί στις μικρότερες τιμές X_i (η ομάδα που εμφανίζει μικρή διακύμανση) και όπου RSS_2

¹⁷ Goldfeld and Quandt, ό.π., Κεφάλαιο 3.

¹⁸ Αυτή είναι μόνο μία εύλογη υπόθεση. Στην πραγματικότητα, αυτό που απαιτείται είναι η σ_i^2 να σχετίζεται μονοτονικά με τη X_i .

αντιπροσωπεύει το RSS από την παλινδρόμηση που αντιστοιχεί στις μεγαλύτερες τιμές X_i (η ομάδα που εμφανίζει μεγάλη διακύμανση). Καθένα από αυτά τα RSS έχει

$$\frac{(n-c)}{2} - k \quad \text{ή} \quad \left(\frac{n-c-2k}{2}\right) df$$

όπου k είναι ο αριθμός των παραμέτρων που πρέπει να εκτιμηθούν, συμπεριλαμβανομένης της σταθεράς. (Γιατί;) Για τη διμεταβλητή περίπτωση το k είναι φυσικά 2.

Βήμα 4. Υπολογίστε το λόγο

$$\lambda = \frac{RSS_2/df}{RSS_1/df} \quad (11.5.11)$$

Αν υποθέσουμε ότι οι u_i ακολουθούν την κανονική κατανομή (κάτι που συμβαίνει συνήθως), και αν η υπόθεση της ομοσκεδαστικότητας είναι έγκυρη, τότε μπορεί να αποδειχθεί ότι το λ της Εξ. (11.5.10) ακολουθεί την κατανομή F με $(n-c-2k)/2$ βαθμούς ελευθερίας για τον αριθμητή και τον παρονομαστή.

Εάν σε μία εφαρμογή το εκτιμημένο λ ($= F$) είναι μεγαλύτερο από την κρίσιμη τιμή F στο επιλεγμένο επίπεδο σημαντικότητας, μπορούμε να απορρίψουμε την υπόθεση της ομοσκεδαστικότητας, δηλαδή, μπορούμε να πούμε ότι η παρουσία ετεροσκεδαστικότητας είναι πολύ πιθανή.

Πριν παρουσιάσουμε τον έλεγχο, είναι απαραίτητη μία αναφορά για την απαλοιφή των c κεντρικών παρατηρήσεων. Αυτές οι παρατηρήσεις απαλείφονται προκειμένου να γίνει ακριβέστερη ή να αναδειχθεί η διαφορά μεταξύ της ομάδας που χαρακτηρίζεται από μικρή διακύμανση (δηλαδή, RSS_1) και της ομάδας που χαρακτηρίζεται από μεγάλη διακύμανση (δηλαδή, RSS_2). Όμως η ικανότητα του ελέγχου Goldfeld-Quandt προκειμένου να γίνει αυτό με επιτυχία εξαρτάται από το πώς επιλέγεται το c .¹⁹ Για το διμεταβλητό υπόδειγμα, τα πειράματα Monte Carlo που γίνονται από τους Goldfeld και Quandt υποδεικνύουν ότι το c είναι περίπου 8 αν το μέγεθος του δείγματος είναι περίπου 30, και είναι περίπου 16, εάν το μέγεθος του δείγματος είναι περίπου 60. Αλλά οι Judge *et al.* επισημαίνουν ότι τα $c = 4$, για $n = 30$ και $c = 10$, για n περίπου 60 είναι ικανοποιητικά στην πράξη.²⁰

Πριν προχωρήσουμε, πρέπει να σημειωθεί ότι σε περίπτωση που υπάρχουν περισσότερες από μία μεταβλητές X στο υπόδειγμα, η κατάταξη των παρατηρήσεων, που αποτελεί το πρώτο βήμα του ελέγχου, μπορεί να γίνει σύμφωνα με μία από αυτές. Επομένως, στο υπόδειγμα: $Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + u_i$, μπορούμε να κατατάξουμε τα στοιχεία σύμφωνα με οποιαδήποτε από αυτές τις X . Εάν *a priori* δεν είμαστε βέβαιοι ποια μεταβλητή X είναι η κατάλληλη, μπορούμε να διεξάγουμε τον έλεγχο για κάθε μία από τις μεταβλητές X , ή μέσω ενός ελέγχου Park σε κάθε X .

ΠΑΡΑΔΕΙΓΜΑ 11.4 Ο Έλεγχος Goldfeld-Quandt

Για να παρουσιάσουμε τον έλεγχο Goldfeld-Quandt, παρουσιάζουμε στον Πίνακα 11.3 στοιχεία για τις καταναλωτικές δαπάνες σε σχέση με το εισόδημα για 30 οικογένειες. Έστω ότι κάνουμε την υπόθεση ότι οι καταναλωτικές δαπάνες σχετίζονται γραμμικά με το εισόδημα, αλλά ότι τα στοιχεία παρουσιάζουν ετεροσκεδαστικότητα. Επιπλέον, υποθέτουμε ότι η φύση της ετεροσκεδαστικότητας είναι, όπως παρουσιάζεται στην Εξ. (5.11.10). Η αναγκαία αναδιάταξη των στοιχείων για την εφαρμογή του ελέγχου παρουσιάζεται επίσης στον Πίνακα 11.3.

¹⁹ Σε τεχνικούς όρους, η ισχύς του ελέγχου εξαρτάται από το πώς επιλέγεται το c . Στη στατιστική, η ισχύς ενός ελέγχου μετράται από την πιθανότητα απόρριψης της μηδενικής υπόθεσης όταν είναι ψευδής (δηλαδή, από $1 - \text{Prob}[\text{σφάλμα τύπου II}]$). Εδώ η μηδενική υπόθεση είναι ότι οι διακυμάνσεις των δύο ομάδων είναι οι ίδιες, δηλαδή, έχουμε ομοσκεδαστικότητα. Για μία εκτενέστερη συζήτηση, βλ. M. M. Ali and C. Giaccotto, "A Study of Several New and Existing Tests for Heteroscedasticity in the General Linear Model," *Journal of Econometrics*, vol. 26, 1984, σσ. 355-373.

²⁰ George G. Judge, R. Carter Hill, William E. Griffiths, Helmut Lütkepohl, and Tsoung-Chao Lee, *Introduction to the Theory and Practice of Econometrics*, John Wiley & Sons, New York, 1982, σελ. 422.

ΠΙΝΑΚΑΣ 11.3 Υποθετικά στοιχεία για τις Καταναλωτικές Δαπάνες Y (\$) και το εισόδημα X (\$) για να Παρουσιάσουμε τον Έλεγχο Goldfeld-Quandt

Y	X	Στοιχεία Ταξινομημένα κατά τις Τιμές του X	
		Y	X
55	80	55	80
65	100	70	85
70	85	75	90
80	110	65	100
79	120	74	105
84	115	80	110
98	130	84	115
95	140	79	120
90	125	90	125
75	90	98	130
74	105	95	140
110	160	108	145
113	150	113	150
125	165	110	160
108	145	125	165
115	180	115	180
140	225	130	185
120	200	135	190
145	240	120	200
130	185	140	205
152	220	144	210
144	210	152	220
175	245	140	225
180	260	137	230
135	190	145	240
140	205	175	245
178	265	189	250
191	270	180	260
137	230	178	265
189	250	191	270

Μεσαίες 4
παρατηρήσεις

Απαλείφοντας τις 4 ενδιάμεσες παρατηρήσεις, οι παλινδρομήσεις OLS με βάση τις πρώτες 13 και τις τελευταίες 13 παρατηρήσεις και τα αθροίσματα των τετραγώνων των καταλοίπων τους, είναι όπως παρουσιάζονται ακολούθως (τυπικά σφάλματα στις παρενθέσεις).

Η παλινδρόμηση που βασίζεται στις πρώτες 13 παρατηρήσεις:

$$\hat{Y}_i = 3,4094 + 0,6968X_i$$

(8,7049) (0,0744) $r^2 = 0,8887$ $RSS_1 = 377,17$ $df = 11$

Η παλινδρόμηση που βασίζεται στις τελευταίες 13 παρατηρήσεις:

$$\hat{Y}_i = -28,0272 + 0,7941X_i$$

(30,6421) (0,1319) $r^2 = 0,7681$ $RSS_2 = 1536,8$ $df = 11$

Από αυτά τ'αποτελέσματα έχουμε:

$$\lambda = [RSS_2/df] / [RSS_1/df] = (1536,8/11) / (377,17/11) = 4,07$$

Η κρίσιμη τιμή F για 11 βαθμούς ελευθερίας του αριθμητή και 11 βαθμούς ελευθερίας του παρονομαστή στο επίπεδο του 5 τοις εκατό είναι 2,82. Δεδομένου ότι η εκτιμημένη τιμή F ($= \lambda$) δεν υπερβαίνει την κρίσιμη τιμή, μπορούμε να συμπεράνουμε ότι υπάρχει ετεροσκεδαστικότητα στη διακύμανση του σφάλματος. Ωστόσο, εάν το επίπεδο σημαντικότητας οριστεί στο 1 τοις εκατό, μπορεί να μην απορρίψουμε την υπόθεση της ομοσκεδαστικότητας. (Γιατί;) Σημειώστε ότι η τιμή- p του παρατηρούμενου λ είναι 0,014.

Έλεγχος Breusch-Pagan-Godfrey²¹

Η επιτυχία του ελέγχου Goldfeld-Quandt δεν εξαρτάται μόνο από την τιμή του c (ο αριθμός των κεντρικών παρατηρήσεων που πρέπει να απαλειφθούν), αλλά και από τον προσδιορισμό της σωστής μεταβλητής X με την οποία θα ταξινομηθούν οι παρατηρήσεις. Ο περιορισμός αυτού του ελέγχου μπορεί να αποφευχθεί εάν χρησιμοποιήσουμε τον έλεγχο **Breusch-Pagan-Godfrey (BPG)**.

Για να παρουσιάσουμε αυτόν τον έλεγχο, εξετάστε το γραμμικό υπόδειγμα παλινδρόμησης k -μεταβλητών

$$Y_i = \beta_1 + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + u_i \quad (11.5.12)$$

Έστω ότι η διακύμανση του σφάλματος σ_i^2 περιγράφεται ως

$$\sigma_i^2 = f(\alpha_1 + \alpha_2 Z_{2i} + \dots + \alpha_m Z_{mi}) \quad (11.5.13)$$

δηλαδή, η σ_i^2 είναι συνάρτηση των μη στοχαστικών μεταβλητών Z : ορισμένες ή όλες οι X μπορούν να χρησιμοποιηθούν ως Z . Συγκεκριμένα, ας υποθέσουμε ότι

$$\sigma_i^2 = \alpha_1 + \alpha_2 Z_{2i} + \dots + \alpha_m Z_{mi} \quad (11.5.14)$$

δηλαδή, η σ_i^2 είναι μία γραμμική συνάρτηση των Z . Αν $\alpha_2 = \alpha_3 = \dots = \alpha_m = 0$, $\sigma_i^2 = \alpha_1$, η οποία είναι μία σταθερά. Ως εκ τούτου, για να ελέγξουμε αν η σ_i^2 είναι ομοσκεδαστική, μπορούμε να ελέγξουμε την υπόθεση ότι $\alpha_2 = \alpha_3 = \dots = \alpha_m = 0$. Αυτή είναι η βασική ιδέα στην οποία βασίζεται ο έλεγχος Breusch-Pagan-Godfrey. Η πραγματική διαδικασία του ελέγχου είναι η εξής.

Βήμα 1. Εκτιμήστε την Εξ. (11.5.12) χρησιμοποιώντας την OLS και υπολογίστε τα κατάλοιπα $\hat{u}_1, \hat{u}_2, \dots, \hat{u}_n$.

Βήμα 2. Βρείτε το $\tilde{\sigma}^2 = \sum \hat{u}_i^2 / n$. Υπενθυμίζεται από το Κεφάλαιο 4 ότι αυτός είναι ο εκτιμητής της μέγιστης πιθανοφάνειας (ML) της σ^2 . (Σημείωση: Ο εκτιμητής της OLS είναι $\sum \hat{u}_i^2 / [n - k]$.)

Βήμα 3. Δημιουργήστε τις μεταβλητές p_i που ορίζονται ως

$$p_i = \hat{u}_i^2 / \tilde{\sigma}^2$$

το οποίο είναι απλά κάθε κατάλοιπο στο τετράγωνο προς το $\tilde{\sigma}^2$.

Βήμα 4. Παλινδρομήστε το p_i που προέκυψε με τη Z ως

$$p_i = \alpha_1 + \alpha_2 Z_{2i} + \dots + \alpha_m Z_{mi} + v_i \quad (11.5.15)$$

όπου v_i είναι ο όρος των καταλοίπων αυτής της παλινδρόμησης.

Βήμα 5. Υπολογίστε το ESS (άθροισμα των τετραγώνων της παλινδρόμησης) από την Εξ. (11.05.15) και ορίστε

$$\Theta = 1/2(\text{ESS}) \quad (11.5.16)$$

Υποθέτοντας ότι τα u_i ακολουθούν την κανονική κατανομή, κάποιος μπορεί να δείξει ότι εάν υπάρχει ομοσκεδαστικότητα και αν το μέγεθος του δείγματος n αυξάνεται επ' άπειρο, τότε

$$\Theta \underset{\text{asy}}{\sim} \chi_{m-1}^2 \quad (11.5.17)$$

δηλαδή το Θ ακολουθεί την κατανομή χ^2 με $(m - 1)$ βαθμούς ελευθερίας. (Σημείωση: asy σημαίνει ασυμπτωτικά). Επομένως, εάν σε μία εφαρμογή το υπολογισμένο Θ ($= \chi^2$) υπερβαίνει την κρίσιμη τιμή χ^2 στο επιλεγμένο επίπεδο σημαντικότητας, κάποιος μπορεί να απορρίψει την υπόθεση της ομοσκεδαστικότητας· ειδικά δεν την απορρίπτει.

Ο αναγνώστης μπορεί να αναρωτιέται γιατί οι BPG επέλεξαν το $1/2$ ESS, ως τη στατιστική ελέγχου. Το σκεπτικό είναι ελαφρώς πολύπλοκο και αφήνεται για τα βιβλία που χρησιμοποιούμε ως παραπομπές.²²

²¹ T. Breusch and A. Pagan, "A Simple Test for Heteroscedasticity and Random Coefficient Variation," *Econometrica*, vol. 47, 1979, σσ. 1287–1294. Βλ. επίσης L. Godfrey, "Testing for Multiplicative Heteroscedasticity," *Journal of Econometrics*, vol. 8, 1978, σσ. 227–236. Λόγω ομοιότητας, οι συγκεκριμένοι έλεγχοι είναι γνωστοί ως έλεγχοι Breusch-Pagan-Godfrey της ετεροσκεδαστικότητας.

²² Βλ. Adrian C. Darnell, *A Dictionary of Econometrics*, Edward Elgar, Cheltenham, U.K., 1994, σσ. 178–179.

ΠΑΡΑΔΕΙΓΜΑ 11.5 Ο Έλεγχος Breusch- Pagan-Godfrey (BPG)

Ως ένα παράδειγμα, ας επανεξετάσουμε τα στοιχεία (Πίνακας 11.3) που χρησιμοποιήσαμε για να παρουσιάσουμε τον έλεγχο ετεροσκεδαστικότητας Goldfeld-Quandt. Παλινδρομώντας τη Y με τη X , παίρνουμε τα εξής:

Βήμα 1.

$$\hat{Y}_i = 9,2903 + 0,6378X_i$$

$$se = (5,2314) \quad (0,0286) \quad RSS = 2361,153 \quad R^2 = 0,9466 \quad (11.5.18)$$

Βήμα 2.

$$\hat{\sigma}^2 = \sum \hat{u}_i^2 / 30 = 2361,153 / 30 = 78,7051$$

Βήμα 3. Διαιρέστε το τετράγωνο των καταλοίπων $\hat{u}_i$ που προέρχονται από την παλινδρόμηση (11.5.18) με 78,7051 προκειμένου να κατασκευάσετε τη μεταβλητή p_i .

Βήμα 4. Υποθέτοντας ότι τα p_i σχετίζονται γραμμικά με τη X_i ($= Z_i$), όπως συμβαίνει στην Εξ. (11.5.14), παίρνουμε την παλινδρόμηση

$$\hat{p}_i = -0,7426 + 0,0101X_i$$

$$se = (0,7529) \quad (0,0041) \quad ESS = 10,4280 \quad R^2 = 0,18 \quad (11.5.19)$$

Βήμα 5.

$$\Theta = 1/2(ESS) = 5,2140 \quad (11.5.20)$$

Σύμφωνα με τις υποθέσεις του ελέγχου BPG το Θ στην Εξ. (11.5.20) ακολουθεί ασυμπτωτικά την κατανομή χ^2 με 1 βαθμό ελευθερίας. (Σημείωση: Υπάρχει μόνο ένας παλινδρομητής στην εξίσωση [11.5.19]) Τώρα από τον πίνακα χ^2 διαπιστώνουμε ότι για 1 βαθμό ελευθερίας η κρίσιμη τιμή χ^2 στο 5 τοις εκατό είναι 3,8414 και στο 1 τοις εκατό είναι 6,6349. Επομένως, η παρατηρούμενη τιμή χ^2 του 5,2140 είναι σημαντική στο επίπεδο σημαντικότητας του 5 τοις εκατό, αλλά όχι σε αυτό του 1 τοις εκατό. Ως εκ τούτου, καταλήγουμε στο ίδιο συμπέρασμα με τον έλεγχο Goldfeld-Quandt. Πρέπει όμως να έχετε κατά νου ότι, ο έλεγχος BPG είναι ένας ασυμπτωτικός, ή μεγάλου-δείγματος έλεγχος και στο συγκεκριμένο παράδειγμα, οι 30 παρατηρήσεις μπορεί να μην αποτελούν ένα μεγάλο δείγμα. Θα πρέπει επίσης να επισημανθεί ότι σε μικρά δείγματα ο έλεγχος είναι ευαίσθητος στην υπόθεση ότι οι διαταρακτικοί όροι u_i ακολουθούν την κανονική κατανομή. Φυσικά, μπορούμε να ελέγξουμε την υπόθεση της κανονικότητας μέσω των ελέγχων που συζητήθηκαν στο Κεφάλαιο 5.²³

Γενικός Έλεγχος Ετεροσκεδαστικότητας του White

Σε αντίθεση με τον έλεγχο Goldfeld-Quandt, ο οποίος απαιτεί την αναδιάταξη των παρατηρήσεων σε σχέση με τη μεταβλητή X που υποτίθεται ότι προκάλεσε την ετεροσκεδαστικότητα, ή τον έλεγχο BPG, ο οποίος είναι ευαίσθητος στην υπόθεση της κανονικότητας, ο γενικός έλεγχος της ετεροσκεδαστικότητας που πρότεινε ο White δε βασίζεται στην υπόθεση της κανονικότητας και μπορεί να εφαρμοστεί με ευκολία.²⁴ Ως ένα παράδειγμα της βασικής ιδέας, σκεφτείτε το εξής υπόδειγμα παλινδρόμησης τριών μεταβλητών (είναι απλή η γενίκευση στο υπόδειγμα k -μεταβλητών):

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i \quad (11.5.21)$$

Ο έλεγχος του White ακολουθεί τα εξής βήματα:

Βήμα 1. Λαμβάνοντας υπόψη τα στοιχεία, εκτιμούμε την Εξ. (11.05.21) και παίρνουμε τα κατάλοιπα, $\hat{u}_i$.

²³ Σχετικά με αυτό, βλ. R. Koenker, "A Note on Studentizing a Test for Heteroscedasticity," *Journal of Econometrics*, vol. 17, 1981, σσ. 1180–1200.

²⁴ H. White, "A Heteroscedasticity Consistent Covariance Matrix Estimator and a Direct Test of Heteroscedasticity," *Econometrica*, vol. 48, 1980, σσ. 817–818.

Βήμα 2. Στη συνέχεια, εκτιμούμε την ακόλουθη (βοηθητική) παλινδρόμηση:

$$\hat{u}_i^2 = \alpha_1 + \alpha_2 X_{2i} + \alpha_3 X_{3i} + \alpha_4 X_{2i}^2 + \alpha_5 X_{3i}^2 + \alpha_6 X_{2i} X_{3i} + v_i \quad (11.5.22)^{25}$$

Δηλαδή, τα τετράγωνα των καταλοίπων από την αρχική παλινδρόμηση παλινδρομούνται με τις αρχικές μεταβλητές ή παλινδρομητές X , τις τετραγωνικές τιμές τους, και το διανυσματικό τους γινόμενο των παλινδρομητών. Μπορούν να χρησιμοποιηθούν επίσης υψηλότερες δυνάμεις παλινδρομητών. Σημειώστε ότι υπάρχει ένα σταθερός όρος σε αυτήν την εξίσωση παρόλο που η αρχική παλινδρόμηση μπορεί είτε να τον περιέχει είτε όχι. Υπολογίστε το R^2 από αυτή τη (βοηθητική) παλινδρόμηση.

Βήμα 3. Υπό τη μηδενική υπόθεση ότι δεν υπάρχει ετεροσκεδαστικότητα, μπορεί να αποδειχθεί ότι το μέγεθος του δείγματος (n) επί το R^2 που προκύπτει από τη βοηθητική παλινδρόμηση ακολουθεί ασυμπτωτικά την κατανομή χ^2 με βαθμούς ελευθερίας ίσους με τον αριθμό των παλινδρομητών (εξαιρουμένου του σταθερού όρου) της βοηθητικής παλινδρόμησης. Δηλαδή,

$$n \cdot R^2_{\text{asy}} \sim \chi^2_{\text{df}} \quad (11.5.23)$$

όπου οι βαθμοί ελευθερίας ορίζονται όπως προηγουμένως. Στο παράδειγμά μας, υπάρχουν 5 βαθμοί ελευθερίας, δεδομένου ότι υπάρχουν 5 παλινδρομητές στη βοηθητική παλινδρόμηση.

Βήμα 4. Αν η τιμή χ^2 που προκύπτει από την Εξ. (11.5.23) υπερβαίνει την κρίσιμη τιμή χ^2 στο επιλεγμένο επίπεδο σημαντικότητας, το συμπέρασμα είναι ότι υπάρχει ετεροσκεδαστικότητα. Αν δεν υπερβαίνει την κρίσιμη τιμή χ^2 , δεν υπάρχει ετεροσκεδαστικότητα, το οποίο σημαίνει ότι στη βοηθητική παλινδρόμηση (11.5.22), $\alpha_2 = \alpha_3 = \alpha_4 = \alpha_5 = \alpha_6 = 0$ (βλ. υποσημείωση 25).

Από διαστρωματικά στοιχεία για 41 χώρες, ο Stephen Lewis εκτίμησε το εξής υπόδειγμα παλινδρόμησης:²⁶

$$\ln Y_i = \beta_1 + \beta_2 \ln X_{2i} + \beta_3 \ln X_{3i} + u_i \quad (11.5.24)$$

όπου Y = λόγος των φόρων επί του εμπορίου (φόροι επί των εισαγωγών και των εξαγωγών) προς το σύνολο των κρατικών εσόδων, X_2 = λόγος του αθροίσματος των εξαγωγών και των εισαγωγών προς το ΑΕΠ, και X_3 = κατά κεφαλήν ΑΕΠ ($\ln$ είναι ο φυσικός λογάριθμος). Οι υποθέσεις του ήταν ότι οι Y και X_2 θα έχουν θετική σχέση μεταξύ τους (όσο μεγαλύτερος είναι ο όγκος του εμπορίου, τόσο υψηλότερα θα είναι τα φορολογικά έσοδα του εμπορίου) και ότι οι Y και X_3 θα έχουν αρνητική σχέση μεταξύ τους (καθώς αυξάνεται το εισόδημα, είναι ευκολότερο για την κυβέρνηση να συγκεντρώσει άμεσους φόρους-για παράδειγμα, φόρο εισοδήματος-από ό, τι είναι να βασίζεται σε φόρους επί του εμπορίου).

Τα εμπειρικά αποτελέσματα υποστήριξαν τις υποθέσεις. Για το σκοπό μας, το σημαντικό σημείο είναι αν υπάρχει ετεροσκεδαστικότητα στα στοιχεία. Εφόσον τα στοιχεία είναι διαστρωματικά και αφορούν ετερογενείς μεταξύ τους χώρες, κάποιος θα περίμενε, *a priori*, ετεροσκεδαστικότητα στη διακύμανση του σφάλματος. Εφαρμόζοντας τον έλεγχο ετεροσκεδαστικότητας του White στα κατάλοιπα που προέρχονται από την παλινδρόμηση (11.5.24), προέκυψαν τα ακόλουθα αποτελέσματα:²⁷

$$\begin{aligned} \widehat{u}_i^2 = & -5,8417 + 2,5629 \ln \text{Trade}_i + 0,6918 \ln \text{GNP}_i - 0,4081 (\ln \text{Trade}_i)^2 - 0,0491 (\ln \text{GNP}_i)^2 \\ & + 0,0015 (\ln \text{Trade}_i)(\ln \text{GNP}_i) \quad R^2 = 0,1148 \end{aligned} \quad (11.5.25)$$

²⁵ Αυτό που υποδηλώνεται σε αυτή τη διαδικασία είναι η υπόθεση ότι το σφάλμα της διακύμανσης των u_i , σ_i^2 , σχετίζεται συναρτησιακά με τους παλινδρομητές, τα τετράγωνα τους, και τα διανυσματικά τους γινόμενα. Εάν όλοι οι συντελεστές μερικής κλίσης σε αυτήν την παλινδρόμηση είναι ταυτόχρονα ίσοι με το μηδέν, τότε η διακύμανση του σφάλματος είναι μία ομοσκεδαστική σταθερά που ισούται με α_1 .

²⁶ Stephen R. Lewis, "Government Revenue from Foreign Trade," *Manchester School of Economics and Social Studies*, vol. 31, 1963, σσ. 39–47.

²⁷ Τα αποτελέσματα αυτά, με διαφορετικά σύμβολα, αναπαράγονται από το William F. Lott and Subhash C. Ray, *Applied Econometrics: Problems with Data Sets, Instructor's Manual*, Κεφάλαιο 22, σσ. 137–140.

Σημείωση: Δεν παραθέτουμε τα τυπικά σφάλματα, καθώς δεν είναι σχετικά με το επίκεντρο της ανάλυσής μας στο παρόν σημείο.

Τώρα $n \times R^2 = 41(0,1148) = 4,7068$, που ακολουθεί, ασυμπτωτικά, μία κατανομή χ^2 με 5 βαθμούς ελευθερίας (γιατί;). Η κρίσιμη τιμή χ^2 στο 5 τοις εκατό για 5 βαθμούς ελευθερίας είναι 11,0705, η κρίσιμη τιμή στο 10 τοις εκατό είναι 9,2363, και η κρίσιμη τιμή στο 25 τοις εκατό είναι 6,62568. Για πρακτικούς λόγους, μπορεί κανείς να συμπεράνει, με βάση τον έλεγχο του White, ότι δεν υπάρχει ετεροσκεδαστικότητα.

Πρέπει να διατυπώσουμε ένα σχόλιο όσον αφορά τον έλεγχο White. Αν ένα υπόδειγμα έχει αρκετούς παλινδρομητές, τότε αν χρησιμοποιήσουμε όλους τους παλινδρομητές, τα τετράγωνά τους (ή υψηλότερες δυνάμεις), και τα διανυσματικά τους γινόμενα τότε μπορεί να «καταναλώσουμε» βαθμούς ελευθερίας. Ως εκ τούτου, κάποιος πρέπει να είναι προσεκτικός όταν χρησιμοποιεί τον έλεγχο.²⁸

Στις περιπτώσεις κατά τις οποίες η στατιστική ελέγχου White που δίνεται στην Εξ. (11.5.25) είναι στατιστικά σημαντική, μπορεί να μην υπάρχει κατ' ανάγκη ετεροσκεδαστικότητα, αλλά σφάλματα εξειδίκευσης, για τα οποία θα αναφερθούμε εκτενέστερα στο Κεφάλαιο 13 (υπενθυμίζεται το σημείο 5 της Ενότητας 11.1). Με άλλα λόγια, **ο έλεγχος White μπορεί να είναι ένας έλεγχος της (καθαρής) ετεροσκεδαστικότητας ή του σφάλματος εξειδίκευσης ή και των δύο**. Έχει υποστηριχθεί ότι αν δεν υπάρχουν όροι διανυσματικών γινομένων στη διαδικασία ελέγχου White, τότε είναι ένας κατεξοχήν έλεγχος της ετεροσκεδαστικότητας. Εάν υπάρχουν όροι διανυσματικών γινομένων, τότε είναι ένας έλεγχος τόσο ετεροσκεδαστικότητα όσο και σφάλματος εξειδίκευσης.²⁹

Άλλοι Έλεγχοι Ετεροσκεδαστικότητας

Υπάρχουν πολλοί άλλοι έλεγχοι ετεροσκεδαστικότητας, κάθε ένας από τους οποίους στηρίζεται σε ορισμένες υποθέσεις. Ο αναγνώστης που επιθυμεί να ασχοληθεί περαιτέρω με αυτούς μπορεί να εξετάσει τις ακόλουθες παραπομπές.³⁰ Θα αναφερθούμε σε έναν ακόμα έλεγχο λόγω της απλότητάς του. Αυτός είναι ο **έλεγχος Koenker-Bassett (KB)**. Όπως οι έλεγχοι ετεροσκεδαστικότητας Park, Breusch-Pagan-Godfrey, και White, ο έλεγχος KB βασίζεται στο τετράγωνο των καταλοίπων, $\hat{u}_i^2$, αντί όμως να παλινδρομηθούν με έναν ή περισσότερους παλινδρομητές, τα τετράγωνα των καταλοίπων παλινδρομούνται με τα τετράγωνα των εκτιμημένων τιμών της παλινδρομούμενης μεταβλητής. Συγκεκριμένα, εάν το αρχικό υπόδειγμα είναι:

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \dots + \beta_k X_{ki} + u_i \quad (11.5.26)$$

εκτιμάτε αυτό το υπόδειγμα, βρίσκετε τα $\hat{u}_i$ από αυτό το υπόδειγμα, και στη συνέχεια εκτιμάτε

$$\hat{u}_i^2 = \alpha_1 + \alpha_2 (\hat{Y}_i)^2 + v_i \quad (11.5.27)$$

όπου $\hat{Y}_i$ είναι οι εκτιμημένες τιμές από το υπόδειγμα (11.5.26). Η μηδενική υπόθεση είναι ότι $\alpha_2 = 0$. Εάν αυτό δεν απορριφθεί, τότε θα μπορούσε κανείς να συμπεράνει ότι δεν υπάρχει ετεροσκεδαστικότητα. Η μηδενική υπόθεση μπορεί να ελεγχθεί με το συνήθη έλεγχο t ή τον έλεγχο F . (Σημειώστε ότι η $F_{1,k} = t_k^2$). Εάν το υπόδειγμα (11.5.26) είναι διπλο-λογαριθμικό, τότε τα τετράγωνα των καταλοίπων παλινδρομούνται με το $(\log \hat{Y}_i)^2$. Ένα άλλο πλεονέκτημα του ελέγχου KB είναι ότι μπορεί να εφαρμοστεί ακόμη και αν ο όρος σφάλματος στο αρχικό υπόδειγμα (11.5.26) δεν ακολουθεί την κανονική κατανομή. Αν εφαρμόσετε τον έλεγχο KB στο Παράδειγμα 11.1, θα βρείτε ότι ο συντελεστής κλίσης της παλινδρόμησης των τετραγώνων των καταλοίπων που προκύπτουν από την Εξ. (11.5.3) με την εκτιμημένη $\hat{Y}_i^2$ από την Εξ. (11.5.3) δεν είναι στατιστικά διαφορετικός από το μηδέν, ενισχύοντας έτσι τον έλεγχο Park. Το αποτέλεσμα αυτό δεν πρέπει να προκαλεί έκπληξη δεδομένου ότι στην προκειμένη περίπτωση έχουμε μόνο έναν παλινδρομητή. Αλλά ο έλεγχος KB είναι εφαρμόσιμος είτε εάν υπάρχει ένας παλινδρομητής είτε πολλοί.

²⁸ Ενίοτε ο έλεγχος τροποποιείται προκειμένου να διατηρήσουμε βαθμούς ελευθερίας. Βλ. Άσκηση 11.18.

²⁹ Βλ. Richard Harris, *Using Cointegration Analysis in Econometrics Modelling*, Prentice Hall & Harvester Wheatsheaf, U.K., 1995, σελ. 68.

³⁰ Βλ. M. J. Harrison and B. P. McCabe, "A Test for Heteroscedasticity Based on Ordinary Least Squares Residuals," *Journal of the American Statistical Association*, vol. 74, 1979, σσ. 494–499' J. Szroeter, "A Class of Parametric Tests for Heteroscedasticity in Linear Econometric Models," *Econometrica*, vol. 46, 1978, σσ. 1311–1327' M. A. Evans and M. L. King, "A Further Class of Tests for Heteroscedasticity," *Journal of Econometrics*, vol. 37, 1988, σσ. 265–276' and R. Koenker and G. Bassett, "Robust Tests for Heteroscedasticity Based on Regression Quantiles," *Econometrica*, vol. 50, 1982, σσ. 43–61.

Μία Επισήμανση Αναφορικά με τους Ελέγχους Ετεροσκεδαστικότητας

Έχουμε αναλύσει πολλούς ελέγχους ετεροσκεδαστικότητας στην παρούσα ενότητα. Πώς θα αποφασίσουμε με επομένως, ποιος είναι ο καλύτερος έλεγχος; Η απάντηση σε αυτό το ερώτημα δεν είναι εύκολη, καθώς αυτοί οι έλεγχοι βασίζονται σε διάφορες υποθέσεις. Όταν συγκρίνουμε αυτούς τους ελέγχους, πρέπει να επιστήσουμε την προσοχή μας στο μέγεθός τους (ή το επίπεδο σημαντικότητας), στην ισχύ τους (την πιθανότητα να απορρίψουμε μία ψευδή υπόθεση), και την ευαισθησία τους σε ακραίες τιμές.

Έχουμε ήδη επισημάνει κάποιους από τους περιορισμούς του, δημοφιλούς και εύκολου στην εφαρμογή, ελέγχου ετεροσκεδαστικότητας White. Ως αποτέλεσμα αυτών των περιορισμών, μπορεί να έχει χαμηλή ισχύ έναντι των εναλλακτικών ελέγχων. Άλλωστε, ο έλεγχος δεν επαρκεί προκειμένου να εντοπίσουμε τους παράγοντες ή τις μεταβλητές που προκαλούν ετεροσκεδαστικότητα.

Ομοίως, ο έλεγχος Breusch-Pagan-Godfrey είναι ευαίσθητος ως προς την υπόθεση της κανονικότητας. Αντίθετα, ο έλεγχος Koenker-Bassett δε στηρίζεται στην υπόθεση της κανονικότητας και μπορεί συνεπώς να είναι ισχυρός.³¹ Στον έλεγχο Goldfeld-Quandt, αν απαλείψουμε πάρα πολλές παρατηρήσεις, μπορεί να μειώσουμε την ισχύ του ελέγχου.

Είναι πέρα από το πεδίο ανάλυσης του παρόντος βιβλίου να παρέχουμε μία συγκριτική ανάλυση των διαφόρων ελέγχων ετεροσκεδαστικότητας. Ο αναγνώστης που ενδιαφέρεται να εξετάσει περαιτέρω το εν λόγω ζήτημα, μπορεί να διαβάσει το άρθρο των John Lyon and Chin-Ling Tsai για να διαμορφώσει μία πιο ολοκληρωμένη εικόνα σχετικά με τα δυνατά και τα αδύνατα σημεία των διάφορων ελέγχων ετεροσκεδαστικότητας.³²

11.6 Διορθωτικά Μέτρα

Όπως έχουμε δει, η ετεροσκεδαστικότητα δεν καταστρέφει τις ιδιότητες της αμεροληψίας και της συνέπειας των εκτιμητών της OLS, αλλά δεν είναι πλέον αποτελεσματικοί, ούτε καν ασυμπτωτικά (δηλαδή, σε μεγάλο μέγεθος δείγματος). Αυτή η έλλειψη αποτελεσματικότητας κάνει τη συνηθισμένη διαδικασία ελέγχου υποθέσεων να είναι αμφιβόλου αξίας. Ως εκ τούτου, πρέπει να αναζητηθούν διορθωτικά μέτρα. Υπάρχουν δύο προσεγγίσεις για τη διόρθωση: όταν η σ_i^2 είναι γνωστή και όταν η σ_i^2 δεν είναι γνωστή.

Όταν η σ_i^2 Είναι Γνωστή: Η Σταθμισμένη Μέθοδος των Ελαχίστων Τετραγώνων

Όπως είδαμε στην Ενότητα 11.3, αν η σ_i^2 είναι γνωστή, η πιο απλή μέθοδος διόρθωσης της ετεροσκεδαστικότητας είναι μέσω των σταθμισμένων ελαχίστων τετραγώνων, καθώς οι εκτιμητές που προκύπτουν είναι BLUE.

Για να παρουσιάσουμε τη μέθοδο, ας υποθέσουμε ότι θέλουμε να μελετήσουμε τη σχέση μεταξύ αποδοχών και μεγέθους της απασχόλησης για τα στοιχεία που παρουσιάζονται στον Πίνακα 11.1. Για λόγους απλούστευσης, μετράμε το μέγεθος της απασχόλησης ως 1 (1-4 εργαζόμενοι), 2 (5-9 υπάλληλοι), ..., 9 (1.000-2499 εργαζόμενοι), αν και θα μπορούσαμε να το μετρήσουμε επίσης από το μέσο των διαφόρων κατηγοριών απασχόλησης που δίνονται στον πίνακα. Έστω τώρα ότι η Y αντιπροσωπεύει τις μέσες αποδοχές ανά εργαζόμενο (\$) και η X το μέγεθος της απασχόλησης. Εκτιμούμε την παρακάτω παλινδρόμηση (βλ. εξίσωση [11.3.6].):

$$Y_i/\sigma_i = \hat{\beta}_1^*(1/\sigma_i) + \hat{\beta}_2^*\left(X_i/\sigma_i\right) + \left(\hat{u}_i/\sigma_i\right) \quad (11.6.1)$$

όπου σ_i οι τυπικές αποκλίσεις των μισθών όπως αναφέρονται στον Πίνακα 11.1. Τα απαραίτητα πρωτογενή στοιχεία για την εκτίμηση αυτής της παλινδρόμησης δίνονται στον Πίνακα 11.4.

³¹ Για περισσότερες λεπτομέρειες, βλ. William H. Green, *Econometric Analysis*, 6^η έκδοση, Pearson/Prentice Hall, New Jersey, 2008, σσ. 165–167.

³² Βλ. "A Comparison of Tests of Heteroscedasticity," *The Statistician*, vol. 45, no. 3, 1996, σσ. 337–349.

ΠΙΝΑΚΑΣ 11.4 Παρουσίαση της Παλινδρόμησης των Σταθμισμένων Ελαχίστων Τετραγώνων

Y	X	σ_i	Y_i/σ_i	X_i/σ_i
3.396	1	742,2	4,5664	0,0013
3.787	2	851,4	4,4480	0,0023
4.013	3	727,8	5,5139	0,0041
4.104	4	805,06	5,0978	0,0050
4.146	5	929,9	4,4585	0,0054
4.241	6	1.080,6	3,9247	0,0055
4.387	7	1.241,2	3,5288	0,0056
4.538	8	1.307,7	3,4702	0,0061
4.843	9	1.110,7	4,3532	0,0081

Σημείωση: Στην παλινδρόμηση (11.6.2), η εξαρτημένη μεταβλητή είναι (Y_i/σ_i) και οι ανεξάρτητες μεταβλητές είναι $(1/\sigma_i)$ και (X_i/σ_i) .
 Πηγή: Τα στοιχεία για τη Y και τη σ_i (τυπική απόκλιση των αποδοχών) προέρχονται από τον Πίνακα 11.1. Μέγεθος απασχόλησης: 1 = 1–4 εργαζόμενοι, 2 = 5–9 εργαζόμενοι, κλπ. Τα τελευταία στοιχεία προέρχονται επίσης από τον Πίνακα 11.1.

Πριν προχωρήσουμε όμως στα αποτελέσματα της παλινδρόμησης, παρατηρήστε ότι η Εξ. (11.6.1), δεν έχει σταθερά. (Γιατί;) Ως εκ τούτου, πρέπει να χρησιμοποιήσουμε το υπόδειγμα παλινδρόμησης χωρίς σταθερό όρο για να εκτιμήσουμε τα β_1^* και β_2^* , ένα θέμα που συζητήθηκε στο Κεφάλαιο 6. Όμως τα περισσότερα υπολογιστικά πακέτα πλέον διαθέτουν την επιλογή απαληφής του όρου της σταθεράς (βλ., για παράδειγμα, το *Minitab* ή το *EViews*). Σημειώστε, επίσης, ένα άλλο ενδιαφέρον χαρακτηριστικό της Εξ. (11.6.1): Έχει δύο ερμηνευτικές μεταβλητές, τις $(1/\sigma_i)$ και (X_i/σ_i) , ενώ εάν επρόκειτο να χρησιμοποιήσουμε την OLS, παλινδρομώντας τις αποδοχές με το μέγεθος της απασχόλησης, αυτή η παλινδρόμηση θα είχε μία ερμηνευτική μεταβλητή, τη X_i . (Γιατί;)

Τα αποτελέσματα της παλινδρόμησης της WLS έχουν ως εξής:

$$\begin{aligned}
 (\widehat{Y_i/\sigma_i}) &= 3406,639 (1/\sigma_i) + 154,153 (X_i/\sigma_i) \\
 &\quad (80,983) \quad (16,959) \\
 t &= (42,066) \quad (9,090) \quad R^2 = 0,9993^{33}
 \end{aligned}
 \tag{11.6.2}$$

Για λόγους σύγκρισης, παραθέτουμε τα συνηθισμένα ή μη σταθμισμένα αποτελέσματα της παλινδρόμησης OLS:

$$\begin{aligned}
 \hat{Y}_i &= 3417,833 + 148,767X_i \\
 &\quad (81,136) \quad (14,418) \\
 t &= (42,125) \quad (10,318) \quad R^2 = 0,9383
 \end{aligned}
 \tag{11.6.3}$$

Στην Άσκηση 11.7 θα σας ζητηθεί να συγκρίνετε αυτές τις δύο παλινδρομήσεις.

Όταν η σ_i^2 Δεν Είναι Γνωστή

Όπως προαναφέρθηκε, αν η πραγματική σ_i^2 είναι γνωστή, μπορούμε να χρησιμοποιήσουμε τη μέθοδο WLS για την απόκτηση BLUE εκτιμητών. Δεδομένου ότι η πραγματική σ_i^2 είναι σπάνια γνωστή, υπάρχει κάποιος τρόπος να επιτύχουμε συνεπείς (με τη στατιστική έννοια) εκτιμήσεις των διακυμάνσεων και των συνδιακυμάνσεων των εκτιμητών της OLS, ακόμη και αν δεν υπάρχει ετεροσκεδαστικότητα; Η απάντηση είναι ναι.

Συνεπείς ως προς την Ετεροσκεδαστικότητα Διακυμάνσεις και Τυπικά Σφάλματα του White

Ο White έχει δείξει ότι αυτή η εκτίμηση μπορεί να γίνει έτσι ώστε να μπορούν να εξαχθούν ασυμπτωτικά (δηλαδή, μεγάλου δείγματος) έγκυρα στατιστικά συμπεράσματα σχετικά με τις πραγματικές τιμές των

³³ Όπως σημειώνεται στην υποσημείωση 3 του Κεφαλαίου 6, ο R^2 της παλινδρόμησης χωρίς σταθερό όρο δεν είναι άμεσα συγκρίσιμος με το R^2 του υποδείγματος με σταθερό όρο. Ο αναφερόμενος R^2 , 0,9993, λαμβάνει υπόψη του αυτή τη διαφορά. (Δείτε τα διάφορα πακέτα για περαιτέρω λεπτομέρειες σχετικά με το πώς ο R^2 διορθώνεται προκειμένου να λάβει υπόψη του την απουσία του όρου της σταθεράς. Βλ. επίσης το Παράρτημα 6Α, Εν. 6Α1.)

παραμέτρων.³⁴ Δε θα παρουσιάσουμε τις μαθηματικές λεπτομέρειες, γιατί δεν αποτελούν αντικείμενο του παρόντος βιβλίου. Ωστόσο, το Παράρτημα 11Α.4 περιγράφει τη διαδικασία του White. Πλέον, πολλά υπολογιστικά πακέτα παρουσιάζουν τις διορθωμένες ως προς την ετεροσκεδαστικότητα διακυμάνσεις και τυπικά σφάλματα, μαζί με την συνήθεις διακυμάνσεις και τα τυπικά σφάλματα της OLS.³⁵ Παρεμπιπτόντως, οι διορθωμένες ως προς την ετεροσκεδαστικότητα διακυμάνσεις και τυπικά σφάλματα του White είναι επίσης γνωστή ως **ανθεκτικά τυπικά σφάλματα** (robust standard errors).

Ως παράδειγμα, παραθέτουμε τα ακόλουθα αποτελέσματα του Greene:³⁶

	$\hat{Y}_i = 832,91 - 1834,2 (\text{Income}) + 1587,04 (\text{Income})^2$		
OLS	se = (327,3)	(829,0)	(519,1)
	t = (2,54)	(2,21)	(3,06)
White	se = (460,9)	(1243,0)	(830,0)
	t = (1,81)	(-1,48)	(1,91)

(11.6.4)

όπου Y = κατά κεφαλήν δαπάνες για τα δημόσια σχολεία ανά πολιτεία το 1979 και Income = κατά κεφαλήν εισόδημα ανά πολιτεία το 1979. Το δείγμα αποτελούνταν από 50 πολιτείες και την Washington, DC.

Όπως προκύπτει από τα προηγούμενα αποτελέσματα, τα ετεροσκεδαστικά-διορθωμένα τυπικά σφάλματα (του White) είναι σημαντικά μεγαλύτερα από τα τυπικά σφάλματα της OLS και ως εκ τούτου οι εκτιμημένες τιμές t είναι πολύ μικρότερες από εκείνες που προκύπτουν από την OLS. Βάσει των τελευταίων, και οι δύο παλινδρομητές είναι στατιστικά σημαντικοί στο επίπεδο του 5 τοις εκατό, ενώ βάσει των εκτιμητών του White δεν είναι. Ωστόσο, πρέπει να επισημανθεί ότι τα ετεροσκεδαστικά-διορθωμένα τυπικά σφάλματα του White ενδέχεται να είναι μεγαλύτερα ή μικρότερα από τα μη διορθωμένα τυπικά σφάλματα.

Καθώς οι ετεροσκεδαστικά-συνεπείς εκτιμητές των διακυμάνσεων του White είναι πλέον διαθέσιμοι σε πολλά στατιστικά πακέτα, προτείνεται στον αναγνώστη να τα αναφέρει. Όπως επισημαίνουν οι Wallace και Silver:

Σε γενικές γραμμές, θα ήταν καλό να χρησιμοποιήσετε την επιλογή WHITE [που διατίθεται σε στατιστικά προγράμματα], συγκρίνοντας ίσως την εκροή με την εκροή της OLS ως έναν έλεγχο για να δείτε αν η ετεροσκεδαστικότητα είναι ένα σοβαρό πρόβλημα σε ένα συγκεκριμένο σύνολο στοιχείων.³⁷

Εύλογες Υποθέσεις για το Πρότυπο της Ετεροσκεδαστικότητας

Εκτός από το γεγονός ότι είναι μία διαδικασία για μεγάλα δείγματα, ένα μειονέκτημα της διαδικασίας του White είναι ότι οι εκτιμητές που προκύπτουν μπορεί να μην είναι τόσο αποτελεσματικοί όπως εκείνοι που προέκυψαν από μεθόδους που μετασχημάτισαν τα στοιχεία ώστε να αντικατοπτρίζουν συγκεκριμένους τύπους ετεροσκεδαστικότητας. Για να φανεί αυτό, ας επανέλθουμε στο διμεταβλητό υπόδειγμα παλινδρόμησης:

$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

Ακολούθως εξετάζουμε διάφορες υποθέσεις σχετικά με το πρότυπο της ετεροσκεδαστικότητας.

ΥΠΟΘΕΣΗ 1: Η διακύμανση του σφάλματος είναι ανάλογη με X_i^2 :

$$E(u_i^2) = \sigma^2 X_i^2 \quad (11.6.5)^{38}$$


³⁴ Βλ. H. White, ό.π.

³⁵ Με περισσότερο τεχνικούς όρους, είναι γνωστή ως **ετεροσκεδαστικά συνεπής εκτιμήτρια μήτρα συνδιακυμάνσεων** (heteroscedasticity-consistent covariance matrix estimators).

³⁶ William H. Greene, *Econometric Analysis*, 2^η έκδοση, Macmillan, New York, 1993, σελ. 385.

³⁷ T. Dudley Wallace and J. Lew Silver, *Econometrics: An Introduction*, Addison Wesley, Reading, Mass., 1988, σελ. 265.

³⁸ Υπενθυμίζεται ότι έχουμε ήδη αναφερθεί σε αυτήν την υπόθεση στη συζήτησή μας για τον έλεγχο Goldfeld-Quandt.

ΔΙΑΓΡΑΜΜΑ 11.10 Η διακύμανση του σφάλματος ανάλογη με τη X^2 .

Εάν, είτε ως ζήτημα εικασίας, είτε γραφικών μεθόδων, ή προσεγγίσεων των Park και Glejser, θεωρείται ότι η διακύμανση των u_i είναι ανάλογη με το τετράγωνο της ερμηνευτικής μεταβλητής X (βλ. Διάγραμμα 11.10), κάποιος μπορεί να μετασχηματίσει το αρχικό υπόδειγμα ως εξής. Διαιρέστε το αρχικό υπόδειγμα με τη X_i :

$$\frac{Y_i}{X_i} = \frac{\beta_1}{X_i} + \beta_2 + \frac{u_i}{X_i} = \beta_1 \frac{1}{X_i} + \beta_2 + v_i \quad (11.6.6)$$

όπου v_i είναι ο μετασχηματισμένος διαταρακτικός όρος, που ισούται με u_i/X_i . Τώρα είναι εύκολο να επαληθεύσουμε ότι

$$E(v_i^2) = E\left(\frac{u_i}{X_i}\right)^2 = \frac{1}{X_i^2} E(u_i^2) = \sigma^2$$

Οπότε, η διακύμανση του v_i είναι τώρα ομοσκεδαστική, και κάποιος μπορεί να προχωρήσει στην εφαρμογή της OLS στη μετασχηματισμένη εξίσωση (11.6.6), παλινδρομώντας το Y_i/X_i με το $1/X_i$.

Παρατηρήστε ότι στη μετασχηματισμένη παλινδρόμηση, ο όρος της σταθεράς β_2 είναι ο συντελεστής κλίσης στην αρχική εξίσωση και ο συντελεστής κλίσης β_1 είναι ο όρος της σταθεράς στο αρχικό υπόδειγμα. Ως εκ τούτου, για να επιστρέψουμε στο αρχικό υπόδειγμα θα πρέπει να πολλαπλασιάσουμε την εκτιμημένη Εξ. (11.6.6) με X_i . Μία εφαρμογή αυτού του μετασχηματισμού δίνεται στην Άσκηση 11.20.

ΥΠΟΘΕΣΗ 2: Η διακύμανση του σφάλματος είναι ανάλογη με τη X_i . Ο μετασχηματισμός τετραγωνικής ρίζας:


$$E(u_i^2) = \sigma^2 X_i \quad (11.6.7)$$

Αν θεωρηθεί ότι η διακύμανση του u_i , αντί να είναι ανάλογη με το τετράγωνο του X_i , είναι ανάλογη με το ίδιο το X_i , τότε το αρχικό υπόδειγμα μπορεί να μετασχηματιστεί ως εξής (βλέπε Διάγραμμα 11.11):

$$\frac{Y_i}{\sqrt{X_i}} = \frac{\beta_1}{\sqrt{X_i}} + \beta_2 \sqrt{X_i} + \frac{u_i}{\sqrt{X_i}} = \beta_1 \frac{1}{\sqrt{X_i}} + \beta_2 \sqrt{X_i} + v_i \quad (11.6.8)$$

όπου $v_i = u_i/\sqrt{X_i}$ και όπου $X_i > 0$.

Δοθείσης της Υπόθεσης 2, κάποιος μπορεί να επαληθεύσει με ευκολία ότι $E(v_i^2) = \sigma^2$, μία κατάσταση ομοσκεδαστικότητας. Ως εκ τούτου, κάποιος μπορεί να προχωρήσει στην εφαρμογή της OLS στην Εξίσωση (11.6.8), παλινδρομώντας το $Y_i/\sqrt{X_i}$ με τα $1/\sqrt{X_i}$ και $\sqrt{X_i}$.

ΔΙΑΓΡΑΜΜΑ 11.11 Διακύμανση του σφάλματος ανάλογη με το X .

Σημειώστε ένα σημαντικό χαρακτηριστικό του μετασχηματισμένου υποδείγματος: Δεν έχει όρο σταθεράς. Ως εκ τούτου, κάποιος θα πρέπει να χρησιμοποιήσει το υπόδειγμα παλινδρόμησης χωρίς σταθερό όρο για την εκτίμηση των β_1 και β_2 . Έχοντας εκτιμήσει την Εξ. (11.6.8), μπορεί να επιστρέψει στο αρχικό υπόδειγμα πολλαπλασιάζοντας απλά την Εξ. (11.6.8) με $\sqrt{X_i}$.

Μια ενδιαφέρουσα περίπτωση είναι το υπόδειγμα με μηδενική σταθερά, δηλαδή, $Y_i = \beta_2 X_i + u_i$. Σε αυτή την περίπτωση, η Εξ. (11.6.8) γίνεται:

$$\frac{Y_i}{\sqrt{X_i}} = \beta_2 \sqrt{X_i} + \frac{u_i}{\sqrt{X_i}} \quad (11.6.8\alpha)$$

Και μπορεί να αποδειχθεί ότι

$$\hat{\beta}_2 = \frac{\bar{Y}}{\bar{X}} \quad (11.6.8\beta)$$

Δηλαδή, ο σταθμισμένος εκτιμητής των ελαχίστων τετραγώνων είναι απλά ο λόγος των μέσων της εξαρτημένης και των ερμηνευτικών μεταβλητών. (Για να αποδείξουμε την Εξ. [11.6.8β], εφαρμόστε απλώς την παλινδρόμηση χωρίς σταθερό όρο που δίνεται στην Εξ. [6.1.6].)

ΥΠΟΘΕΣΗ 3: Η διακύμανση του σφάλματος είναι ανάλογη με το τετράγωνο της μέσης τιμής της Y :

$$E(u_i^2) = \sigma^2 [E(Y_i)]^2 \quad (11.6.9)$$

Σύμφωνα με την Εξίσωση (11.6.9), η διακύμανση του u_i είναι ανάλογη με το τετράγωνο της προσδοκώμενης τιμής της Y (βλ. Διάγραμμα 11.8ε). Τώρα

$$E(Y_i) = \beta_1 + \beta_2 X_i$$

Ως εκ τούτου, εάν μετασχηματίσουμε την αρχική εξίσωση ως εξής,

$$\frac{Y_i}{E(Y_i)} = \frac{\beta_1}{E(Y_i)} + \beta_2 \frac{X_i}{E(Y_i)} + \frac{u_i}{E(Y_i)} = \beta_1 \left(\frac{1}{E(Y_i)} \right) + \beta_2 \frac{X_i}{E(Y_i)} + v_i \quad (11.6.10)$$

όπου $v_i = u_i/E(Y_i)$, τότε $E(v_i^2) = \sigma^2$, δηλαδή, οι διαταρακτικοί όροι v_i είναι ομοσκεδαστικοί. Ως εκ τούτου, είναι η παλινδρόμηση (11.6.10) εκείνη που θα ικανοποιήσει την υπόθεση της ομοσκεδαστικότητας του κλασικού γραμμικού υποδείγματος παλινδρόμησης.

Ο μετασχηματισμός (11.6.10) είναι, ωστόσο, μη λειτουργικός επειδή η $E(Y_i)$ εξαρτάται από τους β_1 και β_2 , που είναι άγνωστοι. Φυσικά, γνωρίζουμε ότι $\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i$, που είναι ένας εκτιμητής της $E(Y_i)$. Ως εκ τούτου, μπορούμε να προχωρήσουμε σε δύο βήματα: Πρώτον, εκτιμούμε τη συνήθη παλινδρόμηση OLS, χωρίς να λαμβάνουμε υπόψη το πρόβλημα της ετεροσκεδαστικότητας, και παίρνουμε το $\hat{Y}_i$. Στη συνέχεια, χρησιμοποιώντας την εκτιμημένη $\hat{Y}_i$, μετασχηματίζουμε το υπόδειγμα μας, ως εξής:

$$\frac{Y_i}{\hat{Y}_i} = \beta_1 \left(\frac{1}{\hat{Y}_i} \right) + \beta_2 \frac{X_i}{\hat{Y}_i} + v_i \quad (11.6.11)$$

όπου $v_i = (u_i/\hat{Y}_i)$. Στο Βήμα 2, εκτιμούμε την παλινδρόμηση (11.6.11). Παρόλο που οι $\hat{Y}_i$ δεν είναι ακριβώς οι $E(Y_i)$, είναι *συνεπείς εκτιμητές*, δηλαδή, καθώς το μέγεθος του δείγματος αυξάνεται επ' άπειρο, συγκλίνουν στην πραγματική $E(Y_i)$. Ως εκ τούτου, ο μετασχηματισμός (11.6.11) θα λειτουργεί ικανοποιητικά στην πράξη, εάν το μέγεθος του δείγματος είναι αρκετά μεγάλο.

ΥΠΟΘΕΣΗ 4: Ένας λογαριθμικός μετασχηματισμός όπως:

$$\ln Y_i = \beta_1 + \beta_2 \ln X_i + u_i \quad (11.6.12)$$

πολύ συχνά μειώνει την ετεροσκεδαστικότητα σε σύγκριση με την παλινδρόμηση:

$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

Το αποτέλεσμα αυτό προκύπτει επειδή ο λογαριθμικός μετασχηματισμός συμπίπτει τις κλίμακες στις οποίες μετρώνται οι μεταβλητές, μειώνοντας έτσι μία δεκαπλάσια διαφορά μεταξύ δύο τιμών σε μία διπλάσια διαφορά. Έτσι, ο αριθμός 80 είναι 10 φορές ο αριθμός 8, αλλά $\ln 80 (= 4,3280)$ είναι περίπου διπλάσιος σε σχέση με το $\ln 8 (= 2,0794)$.

Ένα πρόσθετο πλεονέκτημα του λογαριθμικού μετασχηματισμού είναι ότι ο συντελεστής κλίσης β_2 μετρά την ελαστικότητα της Y ως προς τη X , δηλαδή, την ποσοστιαία μεταβολή στη Y για μία ποσοστιαία μεταβολή στη X . Για παράδειγμα, αν Y είναι η κατανάλωση και X είναι το εισόδημα, ο β_2 στην Εξ. (11.6.12) θα μετρά την εισοδηματική ελαστικότητα, ενώ στο αρχικό υπόδειγμα ο β_2 μέτρα μόνο το ποσοστό της μεταβολής της μέσης κατανάλωσης για μία μεταβολή του εισοδήματος κατά μία μονάδα. Αυτός είναι ένας από τους λόγους για τους οποίους τα λογαριθμικά υποδείγματα είναι αρκετά δημοφιλή στην εμπειρική οικονομετρία. (Για ορισμένα από τα προβλήματα που συνδέονται με το λογαριθμικό μετασχηματισμό, βλ. Άσκηση 11.4.)

Για να ολοκληρώσουμε την ανάλυσή μας για τα διορθωτικά μέτρα, θα επαναλάβουμε ότι όλοι οι μετασχηματισμοί που συζητήθηκαν προηγουμένως είναι *ad hoc*: ουσιαστικά, κάνουμε εικασίες σχετικά με τη φύση της σ_i^2 . Το ποιοι από τους μετασχηματισμούς που συζητήθηκαν προηγουμένως θα λειτουργήσουν θα εξαρτηθεί από τη φύση του προβλήματος και τη σοβαρότητα της ετεροσκεδαστικότητας. Υπάρχουν ορισμένα πρόσθετα προβλήματα αναφορικά με τους μετασχηματισμούς τα οποία πρέπει να έχουμε κατά νου:

- ❶ Όταν κινούμαστε πέρα από το διμεταβλητό υπόδειγμα, μπορεί να μη γνωρίζουμε εκ των προτέρων ποια από τις μεταβλητές X θα πρέπει να επιλεγεί για το μετασχηματισμό των στοιχείων.³⁹
- ❷ Ο λογαριθμικός μετασχηματισμός, όπως συζητήθηκε στην Υπόθεση 4 δε μπορεί να εφαρμοστεί εάν κάποιες από τις τιμές των Y και X είναι μηδενικές ή αρνητικές.⁴⁰
- ❸ Στη συνέχεια, υπάρχει το πρόβλημα της **νόθου ή κύβδωλης ή πλασματικής ή ψευδούς συσχέτισης** (spurious correlation). Ο όρος αυτός, ο οποίος εισήχθη από τον Karl Pearson, αναφέρεται στην κατάσταση κατά την οποία βρέθηκε να υπάρχει συσχέτιση μεταξύ των λόγων των μεταβλητών παρόλο που οι αρχικές μεταβλητές είναι ασυσχέτιστες ή τυχαίες.⁴¹ Επομένως, στο υπόδειγμα $Y_i =$

³⁹ Ωστόσο, ως ένα πρακτικό ζήτημα, κάποιος μπορεί να παρουσιάσει διαγραμματικά το $\hat{u}_i^2$ σε σχέση με κάθε μεταβλητή και να αποφασίσει ποια μεταβλητή X μπορεί να χρησιμοποιηθεί για το μετασχηματισμό των στοιχείων. (Βλ. Διαγ. 11.9.)

⁴⁰ Ορισμένες φορές μπορούμε να χρησιμοποιήσουμε το $\ln(Y_i + k)$ ή το $\ln(X_i + k)$, όπου k είναι ένας θετικός αριθμός που έχει επιλεγεί με τέτοιο τρόπο ώστε όλες οι τιμές των Y και X να είναι θετικές.

⁴¹ Για παράδειγμα, αν X_1 , X_2 και X_3 είναι αμοιβαία ασυσχέτιστες $r_{12} = r_{13} = r_{23} = 0$ και βρίσκουμε ότι οι (τιμές των) λόγων X_1/X_3 και X_2/X_3 συσχετίζονται, τότε υπάρχει πλασματική συσχέτιση. «Γενικότερα, μία συσχέτιση μπορεί να περιγραφεί ως πλασματική, αν προκαλείται από τη μέθοδο χειρισμού των στοιχείων και δεν είναι παρούσα στο αρχικό υλικό» M. G. Kendall and W. R. Buckland, *A Dictionary of Statistical Terms*, Hafner Publishing, New York, 1972, σελ. 143.


$\beta_1 + \beta_2 X_i + u_i$, οι Y και X μπορεί να μη συσχετίζονται, αλλά στο μετασχηματισμένο υπόδειγμα $Y_i/X_i = \beta_1 (1/X_i) + \beta_2$, οι όροι Y_i/X_i και $1/X_i$ εμφανίζουν συχνά συσχέτιση.

- ④ Όταν οι σ_i^2 δεν είναι άμεσα γνωστές και εκτιμώνται από έναν ή από περισσότερους από τους μετασχηματισμούς από όσους εξετάσαμε νωρίτερα, όλες οι διαδικασίες ελέγχου μας χρησιμοποιώντας τους ελέγχους t , F , κ.λπ., ισχύουν, σε γενικές γραμμές, μόνο σε μεγάλα δείγματα. Ως εκ τούτου, πρέπει να είμαστε προσεκτικοί στην ερμηνεία των αποτελεσμάτων με βάση τους διάφορους μετασχηματισμούς σε μικρά ή πεπερασμένα δείγματα.⁴²

11.7 Καταληκτικά Παραδείγματα

Ολοκληρώνοντας την ανάλυσή μας όσον αφορά την ετεροσκεδαστικότητα παραθέτουμε τρία παραδείγματα που παρουσιάζουν τα κύρια σημεία που εξετάσαμε στο παρόν κεφάλαιο.

Ας επανέλθουμε στο παράδειγμα της παιδικής θνησιμότητας στο οποίο έχουμε αναφερθεί πολλές φορές. Από στοιχεία για 64 χώρες, καταλήξαμε στα αποτελέσματα παλινδρόμησης που δίνονται στην Εξίσωση (8.1.4). Καθώς τα στοιχεία είναι διαστρωματικά, συμπεριλαμβάνοντας διαφορετικές χώρες με διαφορετικά μεγέθη παιδικής θνησιμότητας, είναι πιθανό να συναντήσουμε ετεροσκεδαστικότητα. Για να το βρούμε αυτό, ας εξετάσουμε πρώτα τα κατάλοιπα που προέρχονται από την Εξ. (8.1.4). Αυτά τα κατάλοιπα απεικονίζονται στο Διάγραμμα 11.12.



ΔΙΑΓΡΑΜΜΑ 11.12 Κατάλοιπα της παλινδρόμησης (8.1.4).

Από αυτό το διάγραμμα φαίνεται ότι τα κατάλοιπα δεν παρουσιάζουν κανένα συγκεκριμένο πρότυπο το οποίο θα μπορούσε να υποδηλώνει την παρουσία ετεροσκεδαστικότητας. Παρ' όλα αυτά, τα φαινόμενα απατούν. Οπότε, ας εφαρμόσουμε τους ελέγχους Park, Glejser και White για να δούμε αν υπάρχει οποιαδήποτε ένδειξη ετεροσκεδαστικότητας.

Έλεγχος Park: Δεδομένου ότι υπάρχουν δύο παλινδρομητές, οι GNP και FLR, μπορούμε να παλινδρομήσουμε τα τετράγωνα των καταλοίπων από την παλινδρόμηση (8.1.4) με οποιαδήποτε από αυτές τις μεταβλητές. Ή, μπορούμε να τα παλινδρομήσουμε με τις εκτιμημένες τιμές $CM (= \widehat{CM})$ από την παλινδρόμηση (8.1.4). Χρησιμοποιώντας την τελευταία, καταλήξαμε στα ακόλουθα αποτελέσματα.

$$\begin{aligned} \widehat{u_i^2} &= 854,4006 + 5,7016\widehat{CM}_i \\ t &= \quad (1,2010) \quad (1,2428) \quad r^2 = 0,024 \end{aligned} \quad (11.7.1)$$

Σημείωση: $\widehat{u_i}$ είναι τα κατάλοιπα που προέρχονται από την παλινδρόμηση (8.1.4) και $\widehat{CM}$ είναι οι εκτιμημένες τιμές της CM από την παλινδρόμηση (8.1.4).

Όπως δείχνει αυτή η παλινδρόμηση, δεν υπάρχει συστηματική σχέση μεταξύ των τετραγώνων των καταλοίπων και των εκτιμημένων τιμών CM (γιατί;), γεγονός που υποδηλώνει ότι η υπόθεση της ομοσκεδαστικότητας μπορεί να είναι έγκυρη. Παρεμπιπτόντως, η παλινδρόμηση του λογαρίθμου των τετραγώνων των τιμών των καταλοίπων με το λογάριθμο του $\widehat{CM}$ δεν άλλαξε τα αποτελέσματα.

⁴² Για μία εκτενέστερη συζήτηση, βλ. George G. Judge et al., ό.π., Ενότητα 14.4, σσ. 415–420.

Ο αναγνώστης θα βρει πολλές ομοιότητες του παρόντος κεφαλαίου με το προηγούμενο κεφάλαιο για την ετεροσκεδαστικότητα στο πλαίσιο ότι τόσο υπό ετεροσκεδαστικότητα και αυτοσυσχέτιση οι συνήθεις εκτιμητές της OLS, αν και γραμμικοί, αμερόληπτοι, και ακολουθώντας ασυμπτωτικά (δηλαδή, σε μεγάλα δείγματα) την κανονική κατανομή,¹ δεν έχουν πλέον ελάχιστη διακύμανση μεταξύ όλων των γραμμικών αμερόληπτων εκτιμητών. Με λίγα λόγια, δεν είναι αποτελεσματικοί σε σχέση με άλλους γραμμικούς και αμερόληπτους εκτιμητές. Με άλλα λόγια, μπορεί να μην είναι άριστοι γραμμικοί αμερόληπτοι εκτιμητές (BLUE). Ως αποτέλεσμα, οι συνηθισμένες στατιστικές, t , F , και χ^2 μπορεί να μην είναι έγκυρες.

12.1 Η Φύση του Προβλήματος

Ο όρος **αυτοσυσχέτιση** (autocorrelation) μπορεί να οριστεί ως «συσχέτιση μεταξύ των μελών μίας σειράς παρατηρήσεων διατεταγμένων στο χρόνο [όπως σε χρονοσειρές] ή στο χώρο [όπως σε διαστρωματικά στοιχεία]».² Στο πλαίσιο της παλινδρόμησης, το κλασικό γραμμικό υπόδειγμα παλινδρόμησης υποθέτει ότι δεν υπάρχει τέτοια αυτοσυσχέτιση στους διαταρακτικούς όρους u_i . Συμβολικά,

$$\text{cov}(u_i, u_j | x_i, x_j) = E(u_i u_j) = 0 \quad i \neq j \quad (3.2.5)$$

Με απλά λόγια, το κλασικό υπόδειγμα υποθέτει ότι ο διαταρακτικός όρος που σχετίζεται με οποιαδήποτε παρατήρηση δεν επηρεάζεται από τον διαταρακτικό όρο που σχετίζεται με οποιαδήποτε άλλη παρατήρηση. Για παράδειγμα, αν έχουμε να κάνουμε με τριμηνιαία στοιχεία χρονοσειρών που αφορούν την παλινδρόμηση της εκροής με τις εισροές εργασία και κεφάλαιο και αν, για παράδειγμα, υπάρχει μία απεργία των εργαζομένων που επηρεάζει την παραγωγή κατά τη διάρκεια ενός τριμήνου, δεν υπάρχει κανένας λόγος να πιστεύουμε ότι αυτή η αναταραχή θα συνεχιστεί και στο επόμενο τρίμηνο. Δηλαδή, εάν η εκροή είναι χαμηλότερη στο παρόν τρίμηνο, δεν υπάρχει λόγος να αναμένουμε να είναι χαμηλότερη στο επόμενο τρίμηνο. Ομοίως, αν εξετάζουμε διαστρωματικά στοιχεία που αφορούν την παλινδρόμηση των οικογενειακών καταναλωτικών δαπανών με το οικογενειακό εισόδημα, η επίδραση της αύξησης των εσόδων μίας οικογένειας στις καταναλωτικές δαπάνες της δεν αναμένεται να επηρεάσει τις καταναλωτικές δαπάνες μίας άλλης οικογένειας.

Ωστόσο, αν υπάρχει μία τέτοια εξάρτηση, έχουμε αυτοσυσχέτιση. Συμβολικά,

$$E(u_i u_j) \neq 0 \quad i \neq j \quad (12.1.1)$$

Σε αυτήν την περίπτωση, η διαταραχή που προκαλείται από μία απεργία στο παρόν τρίμηνο είναι πολύ πιθανό να επηρεάσει την εκροή στο επόμενο τρίμηνο, ή οι αυξήσεις των καταναλωτικών δαπανών μίας οικογένειας μπορεί να οδηγήσουν μία άλλη οικογένεια στην αύξηση των καταναλωτικών της δαπανών, εάν θέλει να συμβαδίζει με την πρώτη οικογένεια.

Προτού ερευνήσουμε διεξοδικότερα τους λόγους που υπάρχει αυτοσυσχέτιση, είναι απαραίτητο να ξεκαθαρίσουμε ορισμένα ερωτήματα ορολογίας. Παρόλο που είναι πλέον μία κοινή πρακτική να αντιμετωπίζουμε τους όρους **αυτοσυσχέτιση** και **σειριακή συσχέτιση** ως συνώνυμους, ορισμένοι συγγραφείς προτιμούν να τους διαχωρίζουν. Για παράδειγμα, ο Tintner ορίζει την αυτοσυσχέτιση ως «συσχέτιση υστέρησης της συγκεκριμένης σειράς με τον εαυτό της, με χρονική υστέρηση ενός αριθμού μονάδων χρόνου,» ενώ όσον αφορά τον όρο **σειριακή συσχέτιση** τον ορίζει ως «συσχέτιση υστέρησης μεταξύ δύο διαφορετικών σειρών.»³ Επομένως, η συσχέτιση μεταξύ δύο χρονοσειρών όπως $u_1, u_2, \dots, u_{10}$ και $u_2, u_3, \dots, u_{11}$, όπου η πρώτη είναι η τελευταία σειρά με χρονική υστέρηση μίας χρονικής περιόδου, είναι **αυτοσυσχέτιση**, ενώ η συσχέτιση μεταξύ χρονοσειρών, όπως $u_1, u_2, \dots, u_{10}$ και $v_2, v_3, \dots, v_{11}$, όπου οι u και v είναι δύο διαφορετικές χρονοσειρές, ονομάζεται **σειριακή συσχέτιση**. Παρά το γεγονός ότι η διάκριση μεταξύ των δύο όρων μπορεί να είναι χρήσιμη, στο παρόν βιβλίο θα τις αντιμετωπίσουμε ως συνώνυμες.


Ας απεικονίσουμε ορισμένα από τα εύλογα πρότυπα της αυτοσυσχέτισης και της μη αυτοσυσχέτισης, τα οποία παρατίθενται στο Διάγραμμα 12.1. Τα Διαγράμματα από 12.1α μέχρι και δ δείχνουν ότι υπάρχει ένα

¹ Για το συγκεκριμένο, βλ. William H. Greene, *Econometric Analysis*, 4^η έκδοση, Prentice Hall, NJ, 2000, Κεφάλαιο 11, και Paul A. Rudd, *An Introduction to Classical Econometric Theory*, Oxford University Press, 2000, Κεφάλαιο 19.

² Maurice G. Kendall and William R. Buckland, *A Dictionary of Statistical Terms*, Hafner Publishing Company, New York, 1971, σελ. 8.

³ Gerhard Tintner, *Econometrics*, John Wiley & Sons, New York, 1965.

διακριτό πρότυπο μεταξύ των u . Το Διάγραμμα 12.1α παρουσιάζει ένα κυκλικό πρότυπο, τα Διαγράμματα 12.1β και γ παρουσιάζουν μία ανοδική ή πτωτική γραμμική τάση στους διαταρακτικούς όρους, ενώ το Διάγραμμα 12.1δ δείχνει ότι υπάρχουν παρόντες στους διαταρακτικούς όρους τόσο γραμμικοί όσο και τετραγωνικοί όροι τάσης. Μόνο το Διάγραμμα 12.1ε δείχνει ότι δεν υπάρχει συστηματικό πρότυπο, υποστηρίζοντας την υπόθεση μη αυτοσυσχέτισης του κλασικού γραμμικού υποδείγματος παλινδρόμησης.



ΔΙΑΓΡΑΜΜΑ 12.1 Πρότυπα αυτοσυσχέτισης και μη-αυτοσυσχέτισης.

Η φυσική ερώτηση είναι: Γιατί προκύπτει η σειριακή συσχέτιση; Υπάρχουν διάφοροι λόγοι, ορισμένοι από τους οποίους είναι οι ακόλουθοι:

Αδράνεια

Ένα εξέχον χαρακτηριστικό των περισσότερων οικονομικών χρονοσειρών είναι η αδράνεια, ή νωθρότητα. Όπως είναι γνωστό, οι χρονοσειρές, όπως το ΑΕΠ, οι δείκτες τιμών, η παραγωγή, η απασχόληση και η ανεργία εμφανίζουν (επιχειρηματικούς) κύκλους. Ξεκινώντας από το κατώτατο σημείο της ύφεσης, όταν αρχίζει η οικονομική ανάκαμψη, οι περισσότερες από αυτές τις σειρές αρχίζουν να κινούνται ανοδικά. Σε αυτή την ανοδική τάση, η τιμή μίας σειράς σε ένα σημείο στο χρόνο είναι μεγαλύτερη από την προηγούμενη τιμή της. Συνεπώς, υπάρχει ενσωματωμένη σε αυτή μία «δυναμική», η οποία συνεχίζεται έως ότου συμβεί κάτι (π.χ., αύξηση του επιτοκίου ή των φόρων ή και των δύο) το οποίο τις επιβραδύνει. Ως εκ τούτου, σε παλινδρομήσεις που αφορούν χρονοσειρές, οι διαδοχικές παρατηρήσεις είναι πιθανό να είναι αλληλοεξαρτώμενες.

Σφάλμα Εξειδίκευσης: Η Υπόθεση των Μη Συμπεριλαμβανομένων Μεταβλητών

Στην εμπειρική ανάλυση, ο ερευνητής συχνά ξεκινά με ένα αληθοφανές υπόδειγμα παλινδρόμησης το οποίο μπορεί να μην είναι το πλέον «τέλειο». Μετά την ανάλυση παλινδρόμησης, ο ερευνητής πραγματοποιεί τη «νεκροψία» για να διαπιστώσει αν τα αποτελέσματα συμφωνούν με τις *a priori* προσδοκίες. Αν όχι, ξεκινά το «χειρουργείο». Για παράδειγμα, ο ερευνητής μπορεί να παρουσιάσει διαγραμματικά τα κατάλοιπα $\hat{u}_i$ που προκύπτουν από την εκτιμηθείσα παλινδρόμηση και μπορεί να παρατηρήσει πρότυπα όπως αυτά που φαίνονται στα Διαγράμματα 12.1α μέχρι και δ. Αυτά τα κατάλοιπα (τα οποία είναι προσεγγίσεις των u_i) μπορεί να υποδεικνύουν ότι ορισμένες μεταβλητές που ήταν αρχικά υποψήφιες, αλλά δε συμπεριλήφθηκαν τελικά στο υπόδειγμα, για διάφορους λόγους, θα πρέπει να συμπεριληφθούν. Αυτή είναι η περίπτωση του σφάλματος εξειδίκευσης των **μη συμπεριλαμβανομένων μεταβλητών** (excluded variable specification bias). Συχνά, η εισαγωγή αυτών των μεταβλητών αφαιρεί το πρότυπο συσχέτισης που παρατηρείται μεταξύ των καταλοίπων. Για παράδειγμα, ας υποθέσουμε έχουμε το ακόλουθο υπόδειγμα ζήτησης:

$$Y_t = \beta_1 + \beta_2 X_{2t} + \beta_3 X_{3t} + \beta_4 X_{4t} + u_t \quad (12.1.2)$$

όπου Y = ζητούμενη ποσότητα βοείου κρέατος, X_2 = τιμή βοείου κρέατος, X_3 = εισόδημα των καταναλωτών, X_4 = τιμή χοιρινού κρέατος, και t = χρόνος.⁴ Ωστόσο, για κάποιο λόγο εκτιμούμε την ακόλουθη παλινδρόμηση:

$$Y_t = \beta_1 + \beta_2 X_{2t} + \beta_3 X_{3t} + v_t \quad (12.1.3)$$

Τώρα, αν η Εξ. (12.1.2) είναι το 'σωστό' υπόδειγμα ή η 'πραγματική' σχέση, η εκτίμηση της Εξ. (12.1.3) ισοδυναμεί με το να θεωρήσουμε ότι $v_t = \beta_4 X_{4t} + u_t$. Και στο βαθμό που η τιμή του χοιρινού κρέατος επηρεάζει την κατανάλωση βοείου κρέατος, το σφάλμα ή διαταρακτικός όρος v θα αντανakλά ένα συστηματικό πρότυπο, δημιουργώντας έτσι (ψευδή) αυτοσυσχέτιση. Ένας απλός έλεγχος αυτού θα ήταν να εκτιμήσουμε και τις δύο Εξισώσεις (12.1.2) και (12.1.3) και να δούμε αν η αυτοσυσχέτιση, αν υπάρχει, που παρατηρήθηκε στο υπόδειγμα (12.1.3) εξαφανίζεται όταν εκτιμάται το υπόδειγμα (12.1.2).⁵ Ο πραγματικός μηχανισμός για την ανίχνευση της αυτοσυσχέτισης θα συζητηθεί στην Ενότητα 12.6, όπου θα δείξουμε ότι ένα διάγραμμα των καταλοίπων των παλινδρομήσεων (12.1.2) και (12.1.3) θα συντελέσει αποφασιστικά στην αποκρυστάλλωση της παρουσίας ή όχι σειριακής συσχέτισης.

Σφάλμα εξειδίκευσης: Εσφαλμένη Συναρτησιακή Μορφή

Ας υποθέσουμε ότι το «πραγματικό» ή σωστό υπόδειγμα σε μία μελέτη οριακού κόστους-εκροής έχει ως εξής:

$$\text{Οριακό κόστος}_i = \beta_1 + \beta_2 \text{εκροή}_i + \beta_3 \text{εκροή}_i^2 + u_i \quad (12.1.4)$$

όμως εκτιμούμε το ακόλουθο υπόδειγμα:


$$\text{Οριακό κόστος}_i = \alpha_1 + \alpha_2 \text{εκροή}_i + v_i \quad (12.1.5)$$

Η καμπύλη οριακού κόστους που αντιστοιχεί στο 'πραγματικό' υπόδειγμα παρουσιάζεται στο Διάγραμμα 12.2 μαζί με την 'εσφαλμένη' γραμμική καμπύλη κόστους.

Όπως δείχνει το Διάγραμμα 12.2, μεταξύ των σημείων A και B , η γραμμική καμπύλη οριακού κόστους θα υπερεκτιμά σταθερά το πραγματικό οριακό κόστος, ενώ πέρα από αυτά τα σημεία θα υποεκτιμά σταθερά το πραγματικό οριακό κόστος. Το αποτέλεσμα αυτό είναι αναμενόμενο, γιατί ο διαταρακτικός όρος v_i είναι, στην πραγματικότητα, ίσος με $\text{εκροή}_i^2 + u_i$, και ως εκ τούτου θα συλλάβει τη συστηματική επίδραση του όρου εκροή_i^2 στο οριακό κόστος. Σε αυτήν την περίπτωση, ο v_i θα αντανakλά την αυτοσυσχέτιση λόγω της χρήσης μίας εσφαλμένης συναρτησιακής μορφής. Στο Κεφάλαιο 13 θα εξετάσουμε διάφορες μεθόδους για την ανίχνευση τους σφάλματος εξειδίκευσης.

⁴ Χρησιμοποιούμε συμβατικά το δείκτη t για στοιχεία χρονοσειρών και το δείκτη i για διαστρωματικά στοιχεία.

⁵ Αν διαπιστωθεί ότι το πραγματικό πρόβλημα είναι πρόβλημα σφάλματος εξειδίκευσης, και όχι αυτοσυσχέτισης, τότε, όπως θα δείξουμε στο Κεφάλαιο 13, οι εκτιμητές της OLS των παραμέτρων της Εξ. (12.1.3) μπορεί να είναι μεροληπτικοί, καθώς και ασυνεπείς.



ΔΙΑΓΡΑΜΜΑ 12.2 Σφάλμα εξειδίκευσης: εσφαλμένη συναρτησιακή μορφή.

Φαινόμενο Ιστός αράχνης

Η προσφορά πολλών βασικών γεωργικών προϊόντων εκφράζει το λεγόμενο φαινόμενο του ιστού της αράχνης, όπου η προσφορά ανταποκρίνεται στην τιμή με χρονική υστέρηση μίας χρονικής περιόδου, επειδή οι αποφάσεις για την προσφορά απαιτούν χρόνο προκειμένου να εφαρμοστούν (η περίοδος καλλιέργειας). Συνεπώς, κατά την έναρξη της περιόδου καλλιέργειας του τρέχοντος έτους καλλιεργειών, οι αγρότες, επηρεάζονται από την τιμή που επικράτησε κατά το προηγούμενο έτος, με αποτέλεσμα η συνάρτηση προσφοράς τους να είναι

$$\text{Προσφορά}_t = \beta_1 + \beta_2 P_{t-1} + u_t \quad (12.1.6)$$

Ας υποθέσουμε ότι στο τέλος της περιόδου t , η τιμή P_t καταλήγει να είναι χαμηλότερη από P_{t-1} . Ως εκ τούτου, κατά την περίοδο $t+1$ οι γεωργοί ενδέχεται να αποφασίσουν να παράγουν λιγότερο από ό,τι κατά την περίοδο t . Προφανώς, σε αυτήν την κατάσταση, οι διαταρακτικοί όροι u_t δεν αναμένεται να είναι τυχαίοι διότι αν οι αγρότες υπερπαράγουν κατά το έτος t , είναι πιθανό να μειώσουν την παραγωγή τους σε $t+1$, και ούτω καθεξής, με αποτέλεσμα να οδηγούμαστε σε ένα πρότυπο ιστού αράχνης.

Υστερήσεις

Σε μία παλινδρόμηση χρονοσειρών των καταναλωτικών δαπανών με το εισόδημα, δεν είναι ασυνήθιστο να διαπιστώσουμε ότι οι καταναλωτικές δαπάνες κατά την τρέχουσα περίοδο εξαρτώνται, μεταξύ άλλων, από τις καταναλωτικές δαπάνες της προηγούμενης περιόδου. Δηλαδή,

$$\text{Κατανάλωση}_t = \beta_1 + \beta_2 \text{εισόδημα}_t + \beta_3 \text{κατανάλωση}_{t-1} + u_t \quad (12.1.7)$$

Μια παλινδρόμησης όπως η Εξ. (12.1.7) είναι γνωστή ως **αυτοπαλινδρόμηση** (autoregression) επειδή μία από τις ερμηνευτικές μεταβλητές είναι η τιμή της εξαρτημένης μεταβλητής με χρονική υστέρηση. (Θα μελετήσουμε τέτοια υποδείγματα στο Κεφάλαιο 17.) Η λογική για ένα υπόδειγμα όπως αυτό της Εξ. (12.1.7) είναι απλή. Οι καταναλωτές δε μεταβάλλουν τις καταναλωτικές τους συνήθειες εύκολα για ψυχολογικούς, τεχνολογικούς ή θεσμικούς λόγους. Αν αμελήσουμε τον όρο της χρονικής υστέρησης στην Εξ. (12.1.7), ο όρος σφάλματος που θα προκύψει θα αντικατοπτρίζει ένα συστηματικό πρότυπο, λόγω της επίδρασης της χρονικής υστέρησης της κατανάλωσης στην τρέχουσα κατανάλωση.

‘Χειραγώγηση’ των Στοιχείων

Είναι συνηθισμένο στην εμπειρική ανάλυση, τα ανεπεξέργαστα στοιχεία να ‘χειραγωγούνται’. Για παράδειγμα, σε παλινδρομήσεις χρονοσειρών που αφορούν τριμηνιαία στοιχεία, τα στοιχεία αυτά συνήθως προέρχονται από μηνιαία στοιχεία με την απλή προσθήκη τριών μηνιαίων παρατηρήσεων και τη διαίρεση του αθροίσματος με το 3. Αυτή η διαδικασία εισάγει μία ομαλότητα στα στοιχεία μετριάζοντας τις διακυμάνσεις στα μηνιαία στοιχεία. Ως εκ τούτου, το διάγραμμα που παρουσιάζει τα τριμηνιαία στοιχεία φαίνεται πολύ πιο ομαλό από αυτό που παρουσιάζει τα μηνιαία στοιχεία, και αυτή η ομαλότητα μπορεί να εφαρμοστεί σε ένα συστηματικό πρότυπο των διαταρακτικών όρων, εισάγοντας συνεπώς την αυτοσυσχέ-

τιση. Μία άλλη πηγή της χειραγώγησης είναι η **παρεμβολή** ή **παρεκβολή** στα στοιχεία. Για παράδειγμα, η Απογραφή του Πληθυσμού πραγματοποιείται κάθε 10 χρόνια, η τελευταία ήταν το 2001 και η προηγούμενη το 1991. Αν υπάρχει η ανάγκη να συγκεντρωθούν στοιχεία για κάποιο έτος μεταξύ των δύο ετών στα οποία πραγματοποιήθηκε η απογραφή, 1991-2001, η κοινή πρακτική είναι να παρεμβάλλουμε με βάση κάποιες *ad hoc* υποθέσεις. Όλες αυτές οι τεχνικές ‘μάλαξης’ ενδεχομένως να επιβάλουν στα στοιχεία ένα συστηματικό πρότυπο που μπορεί να μην υπάρχει στα αρχικά στοιχεία.⁶

Μετασχηματισμός των Στοιχείων

Ως παράδειγμα αυτού, εξετάστε το ακόλουθο υπόδειγμα:

$$Y_t = \beta_1 + \beta_2 X_t + u_t \quad (12.1.8)$$

όπου, για παράδειγμα, Y = καταναλωτικές δαπάνες και X = εισόδημα. Δεδομένου ότι η Εξ. (12.1.8) ισχύει σε κάθε χρονική περίοδο, ισχύει επίσης κατά την προηγούμενη χρονική περίοδο, $(t - 1)$. Έτσι, μπορούμε να γράψουμε την Εξ. (12.1.8)

$$Y_{t-1} = \beta_1 + \beta_2 X_{t-1} + u_{t-1} \quad (12.1.9)$$

οι όροι Y_{t-1} , X_{t-1} , και u_{t-1} είναι γνωστοί ως οι **χρονικές υστερήσεις** των Y , X , και u , αντίστοιχα, οι οποίες παρουσιάζουν υστέρηση μίας χρονικής περιόδου. Θα δούμε τη σημασία των χρονικών υστερήσεων αργότερα στο κεφάλαιο καθώς και σε διάφορα σημεία του βιβλίου.

Τώρα, εάν αφαιρέσουμε την Εξ. (12.1.9) από την Εξ. (12.1.8), παίρνουμε

$$\Delta Y_t = \beta_2 \Delta X_t + \Delta u_t \quad (12.1.10)$$

όπου ο Δ , ο οποίος είναι γνωστός ως **τελεστής πρώτης διαφοράς** (first difference operator), μας υποδεικνύει να πάρουμε τις διαδοχικές διαφορές των συγκεκριμένων μεταβλητών. Επομένως, $\Delta Y_t = (Y_t - Y_{t-1})$, $\Delta X_t = (X_t - X_{t-1})$, και $\Delta u_t = (u_t - u_{t-1})$. Για εμπειρικούς σκοπούς, γράφουμε την Εξ. (12.1.10), ως

$$\Delta Y_t = \beta_2 \Delta X_t + v_t \quad (12.1.11)$$

όπου $v_t = \Delta u_t = (u_t - u_{t-1})$.

Η Εξ. (12.1.9) είναι γνωστή ως η **μορφή επιπέδων** (level form) και η Εξ. (12.1.10) είναι γνωστή ως η **μορφή (πρώτων) διαφορών** (first difference form). Και οι δύο μορφές χρησιμοποιούνται συχνά στην εμπειρική ανάλυση. Για παράδειγμα, αν στην Εξ. (12.1.9) οι Y και X αντιπροσωπεύουν τους λογάριθμους των καταναλωτικών δαπανών και του εισοδήματος, τότε, στην Εξ. (12.1.10) οι ΔY και ΔX θα αντιπροσωπεύουν τις μεταβολές στους λογάριθμους των καταναλωτικών δαπανών και του εισοδήματος. Όπως γνωρίζουμε, όμως, μία μεταβολή στο λογάριθμο μίας μεταβλητής είναι μία σχετική μεταβολή, ή μία ποσοστιαία μεταβολή, αν η πρώτη πολλαπλασιαστεί επί 100. Έτσι, αντί να μελετούμε σχέσεις μεταξύ μεταβλητών στη μορφή των επιπέδων, μπορεί να ενδιαφερόμαστε για τις σχέσεις τους στη μορφή μεταβολής.

Εάν τώρα, ο όρος σφάλματος στην Εξ. (12.1.8) πληροί τις συνήθεις υποθέσεις της OLS, ιδιαίτερα την υπόθεση της μη αυτοσυσχέτισης, μπορεί να αποδειχθεί ότι ο όρος σφάλματος v_t στην Εξ. (12.1.11) εμφανίζει αυτοσυσχέτιση. (Η απόδειξη παρατίθεται στο Παράρτημα 12Α, Ενότητα 12Α.1.) Πρέπει να σημειωθεί εδώ ότι τα υποδείγματα όπως αυτό της Εξ. (12.1.11) είναι γνωστά ως **δυναμικά υποδείγματα παλινδρόμησης** (dynamic regression models), δηλαδή, υποδείγματα που περιλαμβάνουν υστερήσεις ως παλινδρομούμενες μεταβλητές. Θα μελετήσουμε εκτενώς τέτοια υποδείγματα στο Κεφάλαιο 17.

Το βασικό σημείο του προηγούμενου παραδείγματος είναι ότι ορισμένες φορές η αυτοσυσχέτιση μπορεί να προκληθεί ως αποτέλεσμα του μετασχηματισμού του αρχικού υποδείγματος.

Μη στασιμότητα

Όπως αναφέραμε στο Κεφάλαιο 1, ενώ ασχολούμαστε με στοιχεία χρονοσειρών, μπορεί να πρέπει να βρούμε εάν μία συγκεκριμένη χρονοσειρά είναι στάσιμη. Παρά το γεγονός ότι θα συζητήσουμε το θέμα των μη στάσιμων χρονοσειρών διεξοδικότερα στα κεφάλαια που αφορούν τις χρονοσειρές στο **Πέμπτο Μέρος** του βιβλίου, σε γενικές γραμμές, μία χρονοσειρά είναι στάσιμη, αν τα χαρακτηριστικά της (π.χ. η


⁶ Για το συγκεκριμένο, βλ. William H. Greene, ό.π., σελ. 526.

μέση τιμή, η διακύμανση και η συνδιακύμανση) είναι *χρονικά αμετάβλητα*: δηλαδή, δε μεταβάλλονται με την πάροδο του χρόνου. Αν αυτό δεν ισχύει, έχουμε μία μη στάσιμη χρονοσειρά.

Όπως θα συζητήσουμε στο **Πέμπτο Μέρος**, σε ένα υπόδειγμα παλινδρόμησης, όπως η Εξ. (12.1.8), είναι αρκετά πιθανό τόσο η Y όσο και το X να είναι μη στάσιμες και κατά συνέπεια το σφάλμα u να είναι επίσης μη στάσιμο.⁷ Σε αυτήν την περίπτωση, ο όρος σφάλματος θα παρουσιάζει αυτοσυσχέτιση.

Εν κατακλείδι, υπάρχουν πολλοί λόγοι για τους οποίους ο όρος σφάλματος σε ένα υπόδειγμα παλινδρόμησης μπορεί να εμφανίζει αυτοσυσχέτιση. Στο υπόλοιπο του παρόντος κεφαλαίου ερευνούμε με αρκετή λεπτομέρεια τα προβλήματα που θέτει η αυτοσυσχέτιση και τι μπορεί να γίνει γι' αυτά.

Θα πρέπει να σημειωθεί επίσης ότι η αυτοσυσχέτιση μπορεί να είναι θετική (Διάγραμμα 12.3α), καθώς και αρνητική, παρόλο που οι περισσότερες οικονομικές χρονοσειρές εμφανίζουν θετική αυτοσυσχέτιση επειδή οι περισσότερες από αυτές κινούνται ανοδικά ή πτωτικά για μεγάλες χρονικές περιόδους και δεν παρουσιάζουν σταθερή ανοδική ή καθοδική κίνηση όπως αυτή που παρουσιάζεται στο Διάγραμμα 12.3β.



ΔΙΑΓΡΑΜΜΑ 12.3 (α) Θετική και (β) αρνητική αυτοσυσχέτιση.

12.2 Εκτίμηση OLS Παρουσία Αυτοσυσχέτισης

Τι συμβαίνει με τους εκτιμητές της OLS και τις διακυμάνσεις τους, αν εισάγουμε την αυτοσυσχέτιση στους διαταρακτικούς όρους με την υπόθεση ότι $E(u_t u_{t+s}) \neq 0$ ($s \neq 0$), αλλά διατηρήσουμε όλες τις άλλες υποθέσεις του κλασικού υποδείγματος;⁸ Σημειώνεται πάλι ότι χρησιμοποιούμε το δείκτη t στους διαταρακτικούς όρους για να τονίσουμε ότι ασχολούμαστε με στοιχεία χρονοσειρών.

Επανερχόμαστε για ακόμη μία φορά στο διμεταβλητό υπόδειγμα παλινδρόμησης, προκειμένου να εξηγήσουμε τις βασικές ιδέες που εμπλέκονται, δηλαδή, $Y_t = \beta_1 + \beta_2 X_t + u_t$. Για να μπορέσουμε να προχωρήσουμε, πρέπει να υποθέσουμε το μηχανισμό που παράγει το u_t , καθώς η $E(u_t u_{t+s}) \neq 0$ ($s \neq 0$) είναι μία πολύ γενική υπόθεση για να έχει την οποιαδήποτε πρακτική χρήση. Ως σημείο εκκίνησης, ή πρώτης προσέγγισης, μπορεί να υποθεθεί ότι οι διαταρακτικοί όροι, ή όροι σφάλματος προκύπτουν από τον ακόλουθο μηχανισμό.

⁷ Όπως θα δούμε επίσης στο **Πέμπτο Μέρος**, παρόλο που οι Y και X είναι μη στάσιμες, είναι πιθανό να βρούμε ότι οι διαταρακτικοί όροι, u , είναι στάσιμοι. Θα διερευνήσουμε τις επιπτώσεις αυτού στη συνέχεια.

⁸ Αν $s = 0$, παίρνουμε $E(u_t^2)$. Δεδομένου ότι η $E(u_t) = 0$ εξ' υποθέσεως, $E(u_t^2)$ θα αντιπροσωπεύει τη διακύμανση του όρου σφάλματος, η οποία είναι προφανώς μη μηδενική (γιατί).

$$u_t = \rho u_{t-1} + \varepsilon_t \quad -1 < \rho < 1 \quad (12.2.1)$$

όπου ρ είναι γνωστός ως **συντελεστής αυτοσυνδιακύμανσης** (coefficient of autocovariance) και όπου ε_t είναι ο στοχαστικός διαταρακτικός όρος ο οποίος ικανοποιεί τις τυπικές υποθέσεις της OLS, δηλαδή,

$$\begin{aligned} E(\varepsilon_t) &= 0 \\ \text{var}(\varepsilon_t) &= \sigma_\varepsilon^2 \end{aligned} \quad (12.2.2)$$

$$\text{cov}(\varepsilon_t, \varepsilon_{t+s}) = 0 \quad s \neq 0$$

Στη βιβλιογραφία, ένας όρος σφάλματος με τις προηγούμενες ιδιότητες ονομάζεται συνήθως **όρος σφάλματος λευκού θορύβου** (white noise error term). Αυτό που δηλώνει η Εξ. (12.2.1) είναι ότι η τιμή του διαταρακτικού όρου κατά την περίοδο t είναι ίση με την τιμή του κατά την προηγούμενη περίοδο επί ρ συν ένα καθαρά τυχαίο όρο σφάλματος.

Το σχήμα (12.2.1) είναι γνωστό ως **αυτοπαλίνδρομο σχήμα πρώτης τάξης Markov** (Markov first-order autoregressive scheme), ή απλά **αυτοπαλίνδρομο σχήμα πρώτης τάξης** (first-order autoregressive scheme), που συνήθως συμβολίζεται ως **AR(1)**. Ο όρος αυτοπαλίνδρομο είναι κατάλληλος επειδή η Εξ. (12.2.1) μπορεί να ερμηνευθεί ως η παλινδρόμηση του u_t με τον εαυτό της με χρονική υστέρηση μίας περιόδου. Είναι πρώτης τάξης, επειδή ο u_t και η προηγούμενη τιμή του σχετίζονται, δηλαδή, η μέγιστη υστέρηση είναι 1. Αν το υπόδειγμα ήταν $u_t = \rho_1 u_{t-1} + \rho_2 u_{t-2} + \varepsilon_t$, θα ήταν AR(2), ή αυτοπαλίνδρομο σχήμα δεύτερης τάξης, και ούτω καθεξής. Θα εξετάσουμε τέτοια σχήματα υψηλότερης τάξης στα κεφάλαια που αφορούν τις χρονοσειρές στο **Πέμπτο Μέρος**.

Παρεμπιπτόντως, σημειώστε ότι ρ , ο συντελεστής αυτοσυνδιακύμανσης στην Εξ. (12.2.1), μπορεί να ερμηνευθεί επίσης ως **συντελεστής αυτοσυσχέτισης πρώτης τάξης** (first-order coefficient of autocorrelation), ή ακριβέστερα, **συντελεστής αυτοσυσχέτισης με 1 υστέρηση**.⁹

Δεδομένου του σχήματος AR(1), μπορεί να αποδειχθεί ότι (βλ. Παράρτημα 12Α, Ενότητα 12Α.2):

$$\text{var}(u_t) = E(u_t^2) = \sigma_\varepsilon^2 / (1 - \rho^2) \quad (12.2.3)$$

$$\text{cov}(u_t, u_{t+s}) = E(u_t u_{t+s}) = \rho^s (\sigma_\varepsilon^2 / (1 - \rho^2)) \quad (12.2.4)$$

$$\text{cor}(u_t, u_{t+s}) = \rho^s \quad (12.2.5)$$

όπου $\text{cov}(u_t, u_{t+s})$ σημαίνει συνδιακύμανση μεταξύ των όρων σφάλματος μεταξύ s περιόδων και όπου $\text{cor}(u_t, u_{t+s})$ σημαίνει συσχέτιση μεταξύ των όρων σφάλματος μεταξύ s περιόδων. Σημειώστε ότι, λόγω της ιδιότητας της συμμετρίας των συνδιακυμάνσεων και των συσχετίσεων, $\text{cov}(u_t, u_{t+s}) = \text{cov}(u_t, u_{t-s})$ και $\text{cor}(u_t, u_{t+s}) = \text{cor}(u_t, u_{t-s})$.

Δεδομένου ότι το ρ είναι μία σταθερά μεταξύ -1 και $+1$, η Εξ. (12.2.3) δείχνει ότι, σύμφωνα με το σχήμα AR(1), η διακύμανση του u_t είναι *ακόμη ομοσκεδαστική*, αλλά ο u_t σχετίζεται όχι μόνο με την αμέσως προηγούμενη τιμή του, αλλά με τις τιμές του σε αρκετές προηγούμενες περιόδους. Είναι *κρίσιμο* να σημειωθεί ότι $|\rho| < 1$, δηλαδή η απόλυτη τιμή του ρ είναι μικρότερη από 1. Αν, για παράδειγμα, ρ είναι 1, οι διακυμάνσεις και συνδιακυμάνσεις που παρατίθενται παραπάνω δεν ορίζονται. Αν $|\rho| < 1$, λέμε ότι η διαδικασία AR(1) που δίνεται στην Εξίσωση (12.2.1) είναι *στάσιμη*, δηλαδή, η μέση τιμή, η διακύμανση, και η συνδιακύμανση του u_t δε μεταβάλλονται με την πάροδο του χρόνου. Αν η $|\rho|$ είναι μικρότερη από 1, τότε είναι σαφές από την Εξ. (12.2.4) ότι η τιμή της συνδιακύμανσης θα μειωθεί καθώς πηγαίνουμε προς το μακρινό παρελθόν. Θα δούμε τη χρησιμότητα των προηγούμενων αποτελεσμάτων σύντομα.

Ο λόγος που χρησιμοποιούμε τη διαδικασία AR(1) δεν είναι μόνο λόγω της απλότητάς της σε σύγκριση με σχήματα AR ανώτερης τάξης, αλλά και επειδή σε πολλές εφαρμογές έχει αποδειχθεί ότι είναι αρκετά χρήσιμη. Επιπλέον, έχει πραγματοποιηθεί μία σημαντική ποσότητα θεωρητικών και εμπειρικών εργασιών επί του σχήματος AR(1).

⁹ Το όνομα αυτό μπορεί να δικαιολογηθεί με ευκολία. Εξ' ορισμού, ο συντελεστής συσχέτισης (του πληθυσμού) μεταξύ των u_t και u_{t-1} είναι

$$\rho = \frac{E\{[u_t - E(u_t)][u_{t-1} - E(u_{t-1})]\}}{\sqrt{\text{var}(u_t)}\sqrt{\text{var}(u_{t-1})}} = \frac{E(u_t u_{t-1})}{\text{var}(u_{t-1})}$$

καθώς $E(u_t) = 0$ για κάθε t και $\text{var}(u_t) = \text{var}(u_{t-1})$, επειδή διατηρούμε την υπόθεση της ομοσκεδαστικότητας. Ο αναγνώστης μπορεί να δει ότι ο ρ είναι επίσης ο συντελεστής κλίσης στην παλινδρόμηση του u_t με το u_{t-1} .

Ας επιστρέψουμε στο διμεταβλητό υπόδειγμα παλινδρόμησης: $Y_t = \beta_1 + \beta_2 X_t + u_t$. Γνωρίζουμε από το Κεφάλαιο 3 ότι ο εκτιμητής της OLS του συντελεστή κλίσης είναι

$$\hat{\beta}_2 = \frac{\sum x_t y_t}{\sum x_t^2} \quad (12.2.6)$$

και η διακύμανση του δίνεται από

$$\text{var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum x_t^2} \quad (12.2.7)$$

όπου τα πεζά γράμματα υποδηλώνουν ως συνήθως την απόκλιση από τις μέσες τιμές.

Τώρα στα πλαίσια του σχήματος AR(1), μπορεί να αποδειχθεί ότι η διακύμανση αυτού του εκτιμητή είναι:

$$\text{var}(\hat{\beta}_2)_{\text{AR1}} = \frac{\sigma^2}{\sum x_t^2} \left[1 + 2\rho \frac{\sum x_t x_{t-1}}{\sum x_t^2} + 2\rho^2 \frac{\sum x_t x_{t-2}}{\sum x_t^2} + \dots + 2\rho^{n-1} \frac{x_1 x_n}{\sum x_t^2} \right] \quad (12.2.8)$$

όπου $\text{var}(\hat{\beta}_2)_{\text{AR1}}$ σημαίνει η διακύμανση του $\hat{\beta}_2$ στο πλαίσιο του αυτοπαλινδρομου σχήματος πρώτης τάξης.

Μία σύγκριση της Εξ. (12.2.8) με την Εξ. (12.2.7) δείχνει ότι το πρώτο είναι ίσο με το τελευταίο επί έναν όρο που εξαρτάται από το ρ , καθώς και τις αυτοσυσχετίσεις του δείγματος μεταξύ των τιμών που παίρνει ο παλινδρομητής X σε διάφορες υστερήσεις.¹⁰ Σε γενικές γραμμές δε μπορούμε να προβλέψουμε αν $\text{var}(\hat{\beta}_2)$ είναι μικρότερη ή μεγαλύτερη από $\text{var}(\hat{\beta}_2)_{\text{AR1}}$ (βλ. όμως Εξ. [12.4.1] παρακάτω). Φυσικά, εάν ο ρ είναι μηδέν, οι δύο τύποι θα συμπίπτουν, όπως θα έπρεπε (γιατί;). Επίσης, εάν οι συσχετίσεις μεταξύ των διαδοχικών τιμών του παλινδρομητή είναι πολύ μικρές, η συνήθης OLS διακύμανση του εκτιμητή κλίσης δε θα εμφανίζει σοβαρή μεροληψία. Ως γενική αρχή, όμως, οι δύο διακυμάνσεις δε θα είναι ίδιες.

Για να δώσουμε μία γενική ιδέα για τη διαφορά μεταξύ των διακυμάνσεων που αναφέρονται στις Εξισώσεις (12.2.7) και (12.2.8), ας υποθέσουμε ότι ο παλινδρομητής X ακολουθεί επίσης το αυτοπαλινδρομο σχήμα πρώτης τάξης με συντελεστή αυτοσυσχέτισης r . Στη συνέχεια, μπορεί να αποδειχθεί ότι η Εξ. (12.2.8) γίνεται:

$$\text{var}(\hat{\beta}_2)_{\text{AR(1)}} = \frac{\sigma^2}{\sum x_t^2} \left(\frac{1 + r\rho}{1 - r\rho} \right) = \text{var}(\hat{\beta}_2)_{\text{OLS}} \left(\frac{1 + r\rho}{1 - r\rho} \right) \quad (12.2.9)$$

Αν, για παράδειγμα, $r = 0,6$ και $\rho = 0,8$, χρησιμοποιώντας την Εξίσωση (12.2.9) μπορούμε να ελέγξουμε ότι

$$\text{var}(\hat{\beta}_2)_{\text{AR(1)}} = 2,8461 \text{var}(\hat{\beta}_2)_{\text{OLS}}$$

Για να το θέσουμε διαφορετικά,

$$\text{var}(\hat{\beta}_2)_{\text{OLS}} = \frac{1}{2,8461} \text{var}(\hat{\beta}_2)_{\text{AR(1)}} = 0,3513 \text{var}(\hat{\beta}_2)_{\text{AR(1)}}$$

Δηλαδή, ο συνήθης τύπος της OLS (δηλαδή, Εξ. [12.2.7]) θα υποεκτιμά τη διακύμανση του $(\hat{\beta}_2)_{\text{AR(1)}}$ κατά περίπου 65 τοις εκατό. Όπως θα διαπιστώσετε, αυτή η απάντηση είναι συγκεκριμένη για τις δοθείσες τιμές των r και ρ . Όμως το ζήτημα της παρούσας άσκησης είναι να σας προειδοποιήσει ότι μία τυφλή εφαρμογή των συνηθισμένων τύπων της OLS προκειμένου να υπολογιστούν οι διασπορές και τα τυπικά σφάλματα των εκτιμητών της OLS, θα μπορούσε να οδηγήσει σε παραπλανητικά αποτελέσματα.

Ας υποθέσουμε ότι συνεχίζουμε να χρησιμοποιούμε τον εκτιμητή της OLS $\hat{\beta}_2$ και προσαρμόζουμε το συνήθη τύπο της διακύμανσης λαμβάνοντας υπόψη το σχήμα AR(1). Δηλαδή, χρησιμοποιούμε το $\hat{\beta}_2$ που προκύπτει από την Εξ. (12.2.6) αλλά χρησιμοποιούμε τον τύπο της διακύμανσης που δίνεται από την Εξ. (12.2.8). Ποιες θα είναι τώρα οι ιδιότητες του $\hat{\beta}_2$; Είναι εύκολο να αποδείξουμε ότι ο $\hat{\beta}_2$ είναι ακόμα γραμμικός και αμερόληπτος. Μάλιστα, όπως αναφέρεται στο Παράρτημα 3Α, Ενότητα 3Α.2, η υπόθεση της μη σειριακής συσχέτισης, όπως και η υπόθεση της απουσίας ετεροσκεδαστικότητας, δεν είναι απαραίτητη προκειμένου να αποδείξουμε ότι ο $\hat{\beta}_2$ είναι αμερόληπτος. Εξακολουθεί να είναι BLUE ο $\hat{\beta}_2$; Δυ-

¹⁰ Παρατηρήστε ότι ο όρος $r = \sum x_t x_{t+1} / \sum x_t^2$ είναι η συσχέτιση μεταξύ X_t και X_{t+1} (ή X_{t-1} , δεδομένου ότι ο συντελεστής συσχέτισης είναι συμμετρικός). $r^2 = \sum x_t x_{t+2} / \sum x_t^2$ είναι η συσχέτιση μεταξύ των δύο χρονικών υστερήσεων της X και ούτω καθεξής.

στυχώς, όχι· δεν έχει ελάχιστη διακύμανση στην τάξη των γραμμικών αμερόληπτων εκτιμητών. Με λίγα λόγια, ο $\hat{\beta}_2$, αν και γραμμικός-αμερόληπτος, δεν είναι αποτελεσματικός (σε σχετικούς όρους, φυσικά). Ο αναγνώστης θα παρατηρήσει ότι το συγκεκριμένο εύρημα είναι αρκετά παρόμοιο με τη διαπίστωση ότι ο $\hat{\beta}_2$ είναι λιγότερο αποτελεσματικός όταν υπάρχει ετεροσκεδαστικότητα. Είδαμε ότι ήταν ο σταθμισμένος εκτιμητής των ελαχίστων τετραγώνων $\hat{\beta}_2^*$ της Εξ. (11.3.8), ο οποίος ήταν μία ειδική περίπτωση του εκτιμητή των γενικευμένων ελαχίστων τετραγώνων (GLS), αυτός που ήταν αποτελεσματικός. Μπορούμε να βρούμε έναν εκτιμητή που είναι BLUE στην περίπτωση της αυτοσυσχέτισης; Η απάντηση είναι ναι, όπως φαίνεται από τη συζήτηση που ακολουθεί στην επόμενη ενότητα.

12.3 Ο BLUE Εκτιμητής Παρουσία Αυτοσυσχέτισης

Συνεχίζοντας με το διμεταβλητό υπόδειγμα και αν υποθεθεί ότι ακολουθείται η διαδικασία AR(1), μπορούμε να δείξουμε ότι ο BLUE εκτιμητής του β_2 δίνεται από τον ακόλουθο τύπο:¹¹

$$\hat{\beta}_2^{\text{GLS}} = \frac{\sum_{t=2}^n (x_t - \rho x_{t-1})(y_t - \rho y_{t-1})}{\sum_{t=2}^n (x_t - \rho x_{t-1})^2} + C \quad (12.3.1)$$

όπου C είναι ένας παράγοντας διόρθωσης που μπορεί να μη ληφθεί υπόψη στην πράξη. Σημειώστε ότι ο δείκτης t τώρα κυμαίνεται από $t = 2$ έως $t = n$. Και η διακύμανση του δίνεται από

$$\text{var} \hat{\beta}_2^{\text{GLS}} = \frac{\sigma^2}{\sum_{t=2}^n (x_t - \rho x_{t-1})^2} + D \quad (12.3.2)$$

όπου D είναι επίσης ένας παράγοντας διόρθωσης που μπορεί επίσης να μη ληφθεί υπόψη στην πράξη. (Βλ. Άσκηση 12.18.)

Ο εκτιμητής $\hat{\beta}_2^{\text{GLS}}$, όπως υποδεικνύει ο εκθέτης, λαμβάνεται με τη μέθοδο GLS. Όπως σημειώνεται στο Κεφάλαιο 11, στη GLS ενσωματώνουμε οποιεσδήποτε πρόσθετες πληροφορίες έχουμε (π.χ., τη φύση της ετεροσκεδαστικότητας ή της αυτοσυσχέτισης) απευθείας στη διαδικασία εκτίμησης μέσω του μετασχηματισμού των μεταβλητών, ενώ στην OLS οι παράπλευρες αυτές πληροφορίες δε λαμβάνονται άμεσα υπόψη. Όπως μπορεί να δει ο αναγνώστης, ο εκτιμητής GLS του β_2 που δίνεται στην Εξ. (12.3.1) ενσωματώνει την παράμετρο αυτοσυσχέτισης ρ στον τύπο που εκτιμάται, ενώ ο τύπος της OLS που δίνεται στην Εξ. (12.2.6) απλώς την παραβλέπει. Διαισθητικά, αυτός είναι ο λόγος που είναι BLUE ο εκτιμητής της GLS και όχι ο εκτιμητής της OLS, ο εκτιμητής της GLS χρησιμοποιεί εκτενώς τις διαθέσιμες πληροφορίες.¹² Δε χρειάζεται φυσικά να προστεθεί ότι, αν $\rho = 0$, δεν υπάρχουν πρόσθετες πληροφορίες που πρέπει να ληφθούν υπόψη και ως εκ τούτου, οι εκτιμητές τόσο της GLS όσο και της OLS είναι πανομοιότυποι.

Εν ολίγοις, παρουσία αυτοσυσχέτισης, είναι ο εκτιμητής της GLS που δίνεται στην Εξ. (12.3.1) αυτός που είναι BLUE, και η ελάχιστη διακύμανση δίνεται τώρα από την Εξ. (12.3.2) και όχι από την Εξ. (12.2.8) και προφανώς όχι από την Εξ. (12.2.7).

Μια τεχνική σημείωση

Όπως σημειώσαμε στο προηγούμενο κεφάλαιο, το θεώρημα Gauss-Markov παρέχει μόνο την επαρκή συνθήκη για να είναι BLUE η OLS. Οι ικανές και επαρκείς συνθήκες για να είναι η OLS BLUE δίνονται από το **θεώρημα του Kruskal**, που παρουσιάζεται στο προηγούμενο κεφάλαιο. Ως εκ τούτου, σε ορισμένες περιπτώσεις μπορεί να συμβεί η OLS να είναι BLUE παρά την αυτοσυσχέτιση. Αλλά οι περιπτώσεις αυτές είναι σπάνιες στην πράξη.

Τι θα συμβεί αν συνεχίσουμε να εργαζόμαστε επιπόλαιο με τη συνήθη διαδικασία της OLS, παρά την αυτοσυσχέτιση; Η απάντηση προσφέρεται στην επόμενη ενότητα.

¹¹ Για τις αποδείξεις, βλ. Jan Kmenta, *Elements of Econometrics*, Macmillan, New York, 1971, σσ. 274–275. Ο παράγοντας διόρθωσης C αναφέρεται στην πρώτη παρατήρηση, (Y_1, X_1) . Βλ. σχετικά την Άσκηση 12.18.

¹² Η τυπική απόδειξη ότι ο $\hat{\beta}_2^{\text{GLS}}$ είναι BLUE μπορεί να βρεθεί στο Kmenta, ό.π. Όμως η ανιαρή αλγεβρική απόδειξη μπορεί να απλοποιηθεί σημαντικά με τη χρήση μητρώων. Βλ. J. Johnston, *Econometric Methods*, 3^η έκδοση, McGraw-Hill, New York, 1984, σσ. 291–293.


12.4 Συνέπειες από τη Χρήση της OLS Παρουσία Αυτοσυσχέτισης

Όπως και στην περίπτωση της ετεροσκεδαστικότητας, με την παρουσία αυτοσυσχέτισης οι εκτιμητές της OLS εξακολουθούν να είναι γραμμικοί αμερόληπτοι και συνεπείς και να ακολουθούν ασυμπτωτικά την κανονική κατανομή, όμως δεν είναι πλέον αποτελεσματικοί (δηλαδή, ελάχιστη διακύμανση). Τι θα συμβεί στη συνέχεια, με τις συνήθεις διαδικασίες ελέγχου υποθέσεων αν συνεχίσουμε να χρησιμοποιούμε τους εκτιμητές της OLS; Και πάλι, όπως στην περίπτωση της ετεροσκεδαστικότητας, διακρίνουμε δύο περιπτώσεις. Για παιδαγωγικούς λόγους συνεχίζουμε να εργαζόμαστε με το διμεταβλητό υπόδειγμα, αν και η ακόλουθη συζήτηση μπορεί να επεκταθεί σε πολλαπλές παλινδρομήσεις χωρίς ιδιαίτερο πρόβλημα.¹³

Εκτίμηση OLS Λαμβάνοντας Υπόψη την Αυτοσυσχέτιση

Όπως σημειώνεται, ο $\hat{\beta}_2$ δεν είναι BLUE, και ακόμα και αν χρησιμοποιήσουμε τη $\text{var}(\hat{\beta}_2)_{AR(1)}$, τα διαστήματα εμπιστοσύνης που προκύπτουν είναι πιθανό να είναι ευρύτερα από αυτά που βασίζονται στη διαδικασία της GLS. Όπως δείχνει ο Kmenta, αυτό είναι πιθανό να προκύψει ακόμα και αν το μέγεθος του δείγματος αυξάνει επ' άπειρο.¹⁴ Δηλαδή, ο $\hat{\beta}_2$ δεν είναι ασυμπτωτικά αποτελεσματικός. Η σημασία αυτού του ευρήματος για τον έλεγχο υποθέσεων είναι σαφής: Είναι πιθανό να κηρύξουμε ένα συντελεστή στατιστικά μη σημαντικό (δηλαδή, όχι διαφορετικό από το μηδέν) αν και στην πραγματικότητα (δηλαδή, με βάση τη σωστή διαδικασία GLS) μπορεί να είναι. Αυτή η διαφορά μπορεί να φανεί ευδιάκριτα από το Διάγραμμα 12.4. Σε αυτό το Διάγραμμα δείχνουμε τα διαστήματα εμπιστοσύνης του 95% της OLS [AR(1)] και της GLS υποθέτοντας ότι $\beta_2 = 0$. Σκεφτείτε μία συγκεκριμένη εκτίμηση του β_2 , για παράδειγμα, b_2 . Καθώς ο b_2 βρίσκεται στο διάστημα εμπιστοσύνης της OLS, θα μπορούσαμε να δεχθούμε την υπόθεση ότι ο πραγματικός β_2 είναι μηδέν με εμπιστοσύνη 95 τοις εκατό. Αν ήταν όμως να χρησιμοποιήσουμε το (σωστό) διάστημα εμπιστοσύνης της GLS, θα μπορούσαμε να απορρίψουμε τη μηδενική υπόθεση ότι ο πραγματικός β_2 είναι μηδέν, καθώς ο b_2 βρίσκεται στην περιοχή απόρριψης.

Το μήνυμα είναι: Για να ορίσει κάποιος διαστήματα εμπιστοσύνης και για να ελέγξει υποθέσεις, θα πρέπει να χρησιμοποιήσει τη GLS και όχι την OLS, παρόλο που οι εκτιμητές που προκύπτουν από την τελευταία είναι αμερόληπτοι και συνεπείς. (Ωστόσο, βλ. Ενότητα 12.11.)



ΔΙΑΓΡΑΜΜΑ 12.4 GLS και OLS διαστήματα εμπιστοσύνης του 95%.

Εκτίμηση OLS Αγνοώντας την Αυτοσυσχέτιση

Η κατάσταση είναι δυνητικά πολύ σοβαρή, αν όχι μόνο χρησιμοποιήσουμε το $\hat{\beta}_2$, αλλά και αν συνεχίσουμε να χρησιμοποιούμε τη $\text{var}(\hat{\beta}_2) = \sigma^2 / \sum x_t^2$, η οποία αγνοεί πλήρως το πρόβλημα της αυτοσυσχέτισης, δηλαδή, πιστεύουμε λανθασμένα ότι ισχύουν οι συνήθεις υποθέσεις του κλασικού υποδείγματος. Θα προκύψουν σφάλματα για τους ακόλουθους λόγους:

- ❶ Η διακύμανση των καταλοίπων $\hat{\sigma}^2 / \sum \hat{u}_t^2 / (n - 2)$ είναι πιθανό να υποεκτιμά την πραγματική σ^2 .
- ❷ Ως εκ τούτου, είναι πιθανόν να υπερεκτιμούμε το R^2 .
- ❸ Ακόμα κι αν η σ^2 δεν έχει υποεκτιμηθεί, η $\text{var}(\hat{\beta}_2)$ ενδέχεται να υποεκτιμά τη $\text{var}(\hat{\beta}_2)_{AR(1)}$ (Εξ. [12.2.8]), τη διακύμανσή της υπό αυτοσυσχέτιση (πρώτης τάξης), έστω και αν η τελευταία είναι αναποτελεσματική σε σύγκριση με τη $\text{var}(\hat{\beta}_2)^{GLS}$.

¹³ Όμως η άλγεβρα μητρών γίνεται σχεδόν αναγκαία για να αποφύγουμε ανιαρούς αλγεβρικούς μετασχηματισμούς.

¹⁴ Βλ. Kmenta, ό.π., σσ. 277–278.

- ④ Ως εκ τούτου, οι συνήθεις έλεγχοι σημαντικότητας t και F δεν ισχύουν πλέον, και εάν εφαρμοστούν, είναι πολύ πιθανό να δώσουν παραπλανητικά συμπεράσματα σχετικά με τη στατιστική σημαντικότητα των εκτιμημένων συντελεστών παλινδρόμησης.

Για να επιβεβαιώσουμε κάποιες από αυτές τις προτάσεις, ας επανέλθουμε στο διμεταβλητό υπόδειγμα. Γνωρίζουμε από το Κεφάλαιο 3 ότι, σύμφωνα με την κλασική υπόθεση

$$\hat{\sigma}^2 = \frac{\sum \hat{u}_i^2}{(n-2)}$$

παρέχει ένα αμερόληπτο εκτιμητή της σ^2 , δηλαδή, $E(\hat{\sigma}^2) = \sigma^2$. Εάν υπάρχει όμως αυτοσυσχέτιση, που δίνεται από το AR(1), μπορεί να αποδειχθεί ότι

$$E(\hat{\sigma}^2) = \frac{\sigma^2 \left\{ n - \left[\frac{2}{(1-\rho)} \right] - 2\rho r \right\}}{n-2} \quad (12.4.1)$$

όπου $r = \sum_{t=1}^{n-1} x_t x_{t-1} / \sum_{t=1}^n x_t^2$, που μπορεί να ερμηνευθεί ως ο συντελεστής συσχέτισης (του δείγματος) μεταξύ διαδοχικών τιμών της X .¹⁵ Αν οι ρ και r είναι και οι δύο θετικοί (όχι μία απίθανη υπόθεση για τις περισσότερες οικονομικές χρονοσειρές), γίνεται εμφανές από την Εξ. (12.4.1) ότι $E(\hat{\sigma}^2) < \sigma^2$ δηλαδή, ο συνήθης τύπος της διακύμανσης των καταλοίπων, κατά μέσο όρο, θα υποεκτιμήσει την πραγματική σ^2 . Με άλλα λόγια, $\hat{\sigma}^2$ θα είναι μεροληπτική προς τα κάτω. Είναι περιττό να αναφέρουμε ότι αυτή η μεροληψία στο $\hat{\sigma}^2$ θα μεταδοθεί στη $\text{var}(\hat{\beta}_2)$, διότι στην πράξη η τελευταία εκτιμάται από τον τύπο $\hat{\sigma}^2 / \sum x_t^2$.

Ακόμα και αν η σ^2 δεν υποεκτιμάται, η $\text{var}(\hat{\beta}_2)$ είναι ένας μεροληπτικός εκτιμητής της $\text{var}(\hat{\beta}_2)_{\text{AR}(1)}$, κάτι που διακρίνεται με ευκολία συγκρίνοντας την Εξ. (12.2.7) με την Εξ. (12.2.8),¹⁶ καθώς οι δύο τύποι δεν είναι ίδιοι. Μάλιστα, αν ο ρ είναι θετικός (το οποίο ισχύει για τις περισσότερες οικονομικές χρονοσειρές) και οι X συσχετίζονται θετικά (που ισχύει επίσης για τις περισσότερες οικονομικές χρονοσειρές), τότε είναι σαφές ότι

$$\text{var}(\hat{\beta}_2) < \text{var}(\hat{\beta}_2)_{\text{AR}(1)} \quad (12.4.2)$$

δηλαδή, η συνήθης διακύμανση της OLS του $\hat{\beta}_2$ υποεκτιμά τη διακύμανσή της υπό το AR(1) (βλ. Εξ. [12.2.9]). Ως εκ τούτου, αν χρησιμοποιήσουμε τη $\text{var}(\hat{\beta}_2)$, θα βελτιώσουμε την ακρίβεια (δηλαδή, θα υποεκτιμήσουμε το τυπικό σφάλμα) του εκτιμητή $\hat{\beta}_2$. Ως αποτέλεσμα, κατά τον υπολογισμό του δείκτη t ως $t = \hat{\beta}_2 / \text{sec}(\hat{\beta}_2)$ (υπό την υπόθεση ότι $\beta_2 = 0$), θα υπερεκτιμούμε την τιμή t και ως εκ τούτου, τη στατιστική σημαντικότητα του εκτιμημένου β_2 . Η κατάσταση ενδέχεται να επιδεινωθεί περαιτέρω, εάν η σ^2 έχει υποεκτιμηθεί, όπως αναφέρθηκε προηγουμένως.

Για να δείτε πώς η OLS είναι πιθανό να υποεκτιμά τη σ^2 και τη διακύμανση του $\hat{\beta}_2$, ας πραγματοποιήσουμε το ακόλουθο **πείραμα Monte Carlo**. Ας υποθέσουμε ότι στο διμεταβλητό υπόδειγμα «γνωρίζουμε» ότι οι πραγματικοί $\beta_1 = 1$ και $\beta_2 = 0,8$. Ως εκ τούτου, η στοχαστική PRF είναι

$$Y_t = 1 + 0,8X_t + u_t \quad (12.4.3)$$

Ως εκ τούτου,

$$E(Y_t | X_t) = 1 + 0,8 X_t \quad (12.4.4)$$

που δίνει την πραγματική γραμμή παλινδρόμησης του πληθυσμού. Ας υποθέσουμε ότι οι u_t προκύπτουν από το αυτοπαλινδρόμο σχήμα πρώτης τάξης ως εξής:

$$u_t = 0,7 u_{t-1} + \varepsilon_t \quad (12.4.5)$$

όπου ο όρος ε_t ικανοποιεί όλες τις υποθέσεις της OLS. Υποθέτουμε επίσης για λόγους ευκολίας ότι ο όρος ε_t ακολουθεί την κανονική κατανομή με μηδενική μέση τιμή και μοναδιαία (= 1) διακύμανση. Η Εξ. (12.4.5) δηλώνει ότι οι διαδοχικοί διαταρακτικοί όροι συσχετίζονται θετικά, με συντελεστή αυτοσυσχέτισης ίσο με +0,7, που αποτελεί ένα μάλλον υψηλό βαθμό εξάρτησης.

¹⁵ Βλ. S. M. Goldfeld and R. E. Quandt, *Nonlinear Methods in Econometrics*, North Holland Publishing Company, Amsterdam, 1972, σελ. 183. Παρεμπιπτόντως, επισημαίνεται ότι εάν τα σφάλματα εμφανίζουν θετική αυτοσυσχέτιση, η τιμή του R^2 τείνει να έχει αύξουσα μεροληψία, δηλαδή, τείνει να είναι μεγαλύτερος από το R^2 κατά την απουσία τέτοιας συσχέτισης.

¹⁶ Για μία τυπική απόδειξη, βλ. Kmenta, ό.π., σελ. 281.


ΠΙΝΑΚΑΣ 12.1 Ένα Υποθετικό Παράδειγμα των Θετικά Αυτοσυσχετιζόμενων Όρων Σφάλματος

	ε_t	$u_t = 0,7u_{t-1} + \varepsilon_t$
0	0	$u_0 = 5$ (assumed)
1	0,464	$u_1 = 0,7(5) + 0,464 = 3,964$
2	2,026	$u_2 = 0,7(3,964) + 2,026 = 4,8008$
3	2,455	$u_3 = 0,7(4,8010) + 2,455 = 5,8157$
4	-0,323	$u_4 = 0,7(5,8157) - 0,323 = 3,7480$
5	-0,068	$u_5 = 0,7(3,7480) - 0,068 = 2,5556$
6	0,296	$u_6 = 0,7(2,5556) + 0,296 = 2,0849$
7	-0,288	$u_7 = 0,7(2,0849) - 0,288 = 1,1714$
8	1,298	$u_8 = 0,7(1,1714) + 1,298 = 2,1180$
9	0,241	$u_9 = 0,7(2,1180) + 0,241 = 1,7236$
10	-0,957	$u_{10} = 0,7(1,7236) - 0,957 = 0,2495$

Σημείωση: Τα στοιχεία για το ε_t προέρχονται από το *A Million Random Digits and One Hundred Thousand Deviates*, Rand Corporation, Santa Monica, Calif., 1950.

Χρησιμοποιώντας τώρα ένα πίνακα τυχαίων κανονικών αριθμών με μηδενική μέση τιμή και μοναδιαία διακύμανση, δημιουργήσαμε 10 τυχαίους αριθμούς που παρατίθενται στον Πίνακα 12.1 και στη συνέχεια από τη σχέση (12.4.5) δημιουργήσαμε u_t . Για να ξεκινήσουμε, πρέπει να ορίσουμε την αρχική τιμή του u_t , για παράδειγμα, $u_0 = 5$.

Παρουσιάζοντας διαγραμματικά τα u_t που παρατίθενται στον Πίνακα 12.1, παίρνουμε το Διάγραμμα 12.5, το οποίο δείχνει ότι αρχικά κάθε διαδοχικός u_t είναι υψηλότερος από την προηγούμενη τιμή του και στη συνέχεια θα είναι γενικά μικρότερος από την προηγούμενη τιμή του παρουσιάζοντας, σε γενικές γραμμές, μία θετική αυτοσυσχέτιση.



ΔΙΑΓΡΑΜΜΑ 12.5 Συσχέτιση που προκύπτει από το σχήμα $u_t = 0,7u_{t-1} + \varepsilon_t$ (Πίνακας 12.1).

Έστω τώρα ότι οι τιμές της X είναι σταθερές (μη στοχαστικές) (1, 2, 3, ..., 10). Στη συνέχεια, λαμβάνοντας υπόψη αυτές τις X , μπορούμε να δημιουργήσουμε ένα δείγμα 10 τιμών της Y από την Εξ. (12.4.3) και τις τιμές του u_i που δίνονται στον Πίνακα 12.1. Οι λεπτομέρειες παρατίθενται στον Πίνακα 12.2.

ΠΙΝΑΚΑΣ 12.2 Δημιουργία Τιμών Y από το Δείγμα


X_i	u_i	$Y_i = 1,0 + 0,8X_i + u_i$
1	3,9640	$Y_1 = 1,0 + 0,8(1) + 3,9640 = 5,7640$
2	4,8010	$Y_2 = 1,0 + 0,8(2) + 4,8008 = 7,4008$
3	5,8157	$Y_3 = 1,0 + 0,8(3) + 5,8157 = 9,2157$
4	3,7480	$Y_4 = 1,0 + 0,8(4) + 3,7480 = 7,9480$
5	2,5556	$Y_5 = 1,0 + 0,8(5) + 2,5556 = 7,5556$
6	2,0849	$Y_6 = 1,0 + 0,8(6) + 2,0849 = 7,8849$
7	1,1714	$Y_7 = 1,0 + 0,8(7) + 1,1714 = 7,7714$
8	2,1180	$Y_8 = 1,0 + 0,8(8) + 2,1180 = 9,5180$
9	1,7236	$Y_9 = 1,0 + 0,8(9) + 1,7236 = 9,9236$
10	0,2495	$Y_{10} = 1,0 + 0,8(10) + 0,2495 = 9,2495$

Σημείωση: Τα στοιχεία για το u_i προέρχονται από τον Πίνακα 12.1.

Χρησιμοποιώντας τα στοιχεία του Πίνακα 12.2, αν παλινδρομήσουμε τη Y με τη X , θα αποκτήσουμε την ακόλουθη παλινδρόμηση (δείγματος):

$$\begin{aligned} \hat{Y}_i &= 6,5452 + 0,3051X_i \\ &\quad (0,6153) \quad (0,0992) \\ t &= (10,6366) \quad (3,0763) \quad r^2 = 0,5419 \quad \hat{\sigma}^2 = 0,8114 \end{aligned} \quad (12.4.6)$$

ενώ η πραγματική γραμμή παλινδρόμησης είναι όπως αυτή που δίνεται από την Εξ. (12.4.4). Και οι δύο γραμμές παλινδρόμησης δίνονται στο Διάγραμμα 12.6, το οποίο δείχνει σαφώς πόσο η εκτιμημένη γραμμή παλινδρόμησης διαστρεβλώνει την πραγματική γραμμή παλινδρόμησης· υποεκτιμά σοβαρά τον πραγματικό συντελεστή κλίσης αλλά υπερεκτιμά τον πραγματικό συντελεστή σταθεράς. (Σημειώστε όμως ότι οι εκτιμητές της OLS εξακολουθούν να είναι αμερόληπτοι).



ΔΙΑΓΡΑΜΜΑ 12.6 Πραγματική PRF και η εκτιμημένη γραμμή παλινδρόμησης για τα στοιχεία του Πίνακα 12.2.

Το Διάγραμμα 12.6 δείχνει, επίσης, γιατί η πραγματική διακύμανση του u_i είναι πιθανόν να υποεκτιμηθεί από τον εκτιμητή $\hat{\sigma}^2 = 0,8114$, ο οποίος υπολογίζεται από τα $\hat{u}_i$. Τα $\hat{u}_i$ είναι γενικά κοντά στην εκτιμημένη γραμμή (η οποία οφείλεται στη διαδικασία OLS), αλλά αποκλίνουν σημαντικά από την πραγματική PRF. Ως εκ τούτου, δεν δίνουν τη σωστή εικόνα του u_i . Για να αποκτήσουμε γνώση για την έκταση της υποεκτίμησης της πραγματικής σ^2 , ας υποθέσουμε ότι πραγματοποιούμε ένα άλλο πείραμα δειγματοληψίας. Διατηρώντας τα X_i και ε_i που παρατίθενται στους Πίνακες 12.1 και 12.2, ας υποθέσουμε ότι $\rho = 0$, δηλαδή, δεν υπάρχει αυτοσυσχέτιση. Το νέο δείγμα των τιμών Y που προκύπτει δίνεται στον Πίνακα 12.3.

ΠΙΝΑΚΑΣ 12.3 Δείγμα Τιμών Y με Μηδενική Σειριακή Συσχέτιση

X_t	$\varepsilon_t = u_t$	$Y_t = 1,0 + 0,8X_t + \varepsilon_t$
1	0,464	2,264
2	2,026	4,626
3	2,455	5,855
4	-0,323	3,877
5	-0,068	4,932
6	0,296	6,096
7	-0,288	6,312
8	1,298	8,698
9	0,241	8,441
10	-0,957	8,043

Σημείωση: Καθώς δεν υπάρχει αυτοσυσχέτιση, οι u_t και ε_t είναι πανομοιότυποι. Οι τιμές για το ε_t προέρχονται από τον Πίνακα 12.1.


Η παλινδρόμηση που βασίζεται στον Πίνακα 12.3 είναι η εξής:

$$\begin{aligned}\hat{Y}_t &= 2,5345 + 0,6145X_t \\ &\quad (0,6796) \quad (0,1087) \\ t &= (3,7910) \quad (5,6541) \\ r^2 &= 0,7997 \quad \hat{\sigma}^2 = 0,9752\end{aligned}\tag{12.4.7}$$

Αυτή η παλινδρόμηση είναι πολύ πιο κοντά στην «πραγματικότητα», επειδή οι τιμές της Y είναι τώρα ουσιαστικά τυχαίες. Σημειώστε ότι ο $\hat{\sigma}^2$ έχει αυξηθεί από 0,8114 ($\rho = 0,7$) σε 0,9752 ($\rho = 0$). Επίσης, παρατηρήστε ότι τα τυπικά σφάλματα των $\hat{\beta}_1$ και $\hat{\beta}_2$ έχουν αυξηθεί. Το αποτέλεσμα αυτό είναι σε συμφωνία με τα θεωρητικά αποτελέσματα που εξετάστηκαν προηγουμένως.

12.5 Σχέση μεταξύ Μισθών και Παραγωγικότητας στον Επιχειρηματικό Κλάδο των Η.Π.Α., 1960-2005

Έχοντας συζητήσει τις συνέπειες της αυτοσυσχέτισης, το προφανές ερώτημα είναι, Πώς μπορούμε να την ανιχνεύσουμε και πώς να τη διορθώσουμε; Προτού στραφούμε σε αυτά τα θέματα, είναι χρήσιμο να εξετάσουμε ένα παράδειγμα που στηρίζεται σε πραγματικά στοιχεία. Ο Πίνακας 12.4 παραθέτει στοιχεία για τους δείκτες της πραγματικής αμοιβής ανά ώρα Y (RCOMP) και της παραγωγής ανά ώρα X (PRODB) στον επιχειρηματικό κλάδο της οικονομίας των Η.Π.Α. για την περίοδο 1960-2005, με τη βάση των δεικτών να είναι το 1992 = 100. Παρουσιάζοντας αρχικά τα στοιχεία για τις Y και X διαγραμματικά, παίρνουμε το Διάγραμμα 12.7.



ΔΙΑΓΡΑΜΜΑ 12.7 Δείκτης της αμοιβής (Y) και δείκτης της παραγωγικότητας (X), Η.Π.Α., 1960-2005.

ΠΙΝΑΚΑΣ 12.4 Δείκτες της Πραγματικής Αμοιβής και της Παραγωγικότητας, των Η.Π.Α., 1960-2005 (Δείκτες, 1992=100' εποχικά διορθωμένα τριμηνιαία στοιχεία)

Έτος	Y	X	Έτος	Y	X
1960	60,8	48,9	1983	90,3	83,0
1961	62,5	50,6	1984	90,7	85,2
1962	64,6	52,9	1985	92,0	87,1
1963	66,1	55,0	1986	94,9	89,7
1964	67,7	56,8	1987	95,2	90,1
1965	69,1	58,8	1988	96,5	91,5
1966	71,7	61,2	1989	95,0	92,4
1967	73,5	62,5	1990	96,2	94,4
1968	76,2	64,7	1991	97,4	95,9
1969	77,3	65,0	1992	100,0	100,0
1970	78,8	66,3	1993	99,7	100,4
1971	80,2	69,0	1994	99,0	101,3
1972	82,6	71,2	1995	98,7	101,5
1973	84,3	73,4	1996	99,4	104,5
1974	83,3	72,3	1997	100,5	106,5
1975	84,1	74,8	1998	105,2	109,5
1976	86,4	77,1	1999	108,0	112,8
1977	87,6	78,5	2000	112,0	116,1
1978	89,1	79,3	2001	113,5	119,1
1979	89,3	79,3	2002	115,7	124,0
1980	89,1	79,2	2003	117,7	128,7
1981	89,3	80,8	2004	119,0	132,7
1982	90,4	80,1	2005	120,2	135,7

Σημειώσεις: Y = δείκτης της πραγματικής αμοιβής ανά ώρα, στον επιχειρηματικό κλάδο (1992 = 100). X = δείκτης της παραγωγής, στον επιχειρηματικό κλάδο (1992 = 100).

Πηγή: Economic Report of the President, 2007, Πίνακας B-49.

Δεδομένου ότι η σχέση μεταξύ πραγματικής αμοιβής και παραγωγικότητας της εργασίας αναμένεται να είναι θετική, δεν αποτελεί έκπληξη το γεγονός ότι οι δύο μεταβλητές σχετίζονται θετικά. Αυτό που προκαλεί έκπληξη είναι ότι η σχέση μεταξύ των δύο είναι σχεδόν γραμμική, αν και υπάρχει μία υποψία ότι σε υψηλότερες τιμές της παραγωγικότητας η σχέση μεταξύ των δύο μπορεί να είναι ελαφρώς μη γραμμική. Ως εκ τούτου, αποφασίσαμε να εκτιμήσουμε τόσο ένα γραμμικό, όσο και ένα λογαριθμικό-γραμμικό υπόδειγμα, με τα ακόλουθα αποτελέσματα:

$$\begin{aligned}\hat{Y}_t &= 32,7419 + 0,6704X_t \\ \text{se} &= (1,3940) \quad (0,0157) \\ t &= (23,4874) \quad (42,7813)\end{aligned}\tag{12.5.1}$$

$$r^2 = 0,9765 \quad d = 0,1739 \quad \hat{\sigma}^2 = 2,3845$$

όπου d είναι η στατιστική Durbin-Watson που θα συζητηθεί παρακάτω.

$$\begin{aligned}\ln \hat{Y}_t &= 1,6067 + 0,6522 \ln X_t \\ \text{se} &= (0,0547) \quad (0,0124) \\ t &= (29,3680) \quad (52,7996)\end{aligned}\tag{12.5.2}$$

$$r^2 = 0,9845 \quad d = 0,2176 \quad \hat{\sigma}^2 = 0,0221$$

Καθώς το παραπάνω υπόδειγμα είναι διπλο-λογαριθμικό, ο συντελεστής κλίσης αντιπροσωπεύει την ελαστικότητα. Στην προκειμένη περίπτωση, βλέπουμε ότι αν η παραγωγικότητα της εργασίας αυξηθεί κατά 1 τοις εκατό, η μέση αποζημίωση αυξάνεται κατά περίπου 0,65 τοις εκατό.

Ποιοτικά, και τα δύο υποδείγματα δίνουν παρόμοια αποτελέσματα. Και στις δύο περιπτώσεις, οι εκτιμημένοι συντελεστές είναι στατιστικά σημαντικοί, όπως φαίνεται από τις υψηλές τιμές- t . Στο γραμμικό υπόδειγμα, αν ο δείκτης της παραγωγικότητας αυξηθεί κατά μία μονάδα, κατά μέσο όρο, ο δείκτης της αμοιβής αυξάνεται κατά περίπου 0,67 μονάδες. Στο λογαριθμικό-γραμμικό υπόδειγμα, ο συντελεστής κλίσης που είναι η ελαστικότητα (γιατί;), βρίσκουμε ότι αν ο δείκτης της παραγωγικότητας αυξηθεί κατά 1 τοις εκατό, κατά μέσο όρο, ο δείκτης της πραγματικής αμοιβής αυξάνεται κατά περίπου 0,65 τοις εκατό.

Πόσο αξιόπιστα είναι τα αποτελέσματα που δίνονται στις Εξισώσεις (12.5.1) και (12.5.2) αν υπάρχει αυτοσυσχέτιση; Όπως αναφέρθηκε προηγουμένως, αν υπάρχει αυτοσυσχέτιση, τα εκτιμημένα τυπικά σφάλματα είναι μεροληπτικά, με αποτέλεσμα οι εκτιμημένοι λόγοι t να είναι αναξιόπιστοι. Θα πρέπει φυσικά να βρούμε εάν τα στοιχεία μας εμφανίζουν αυτοσυσχέτιση. Στην επόμενη ενότητα θα συζητήσουμε διάφορες μεθόδους για την ανίχνευση της αυτοσυσχέτισης. Θα παρουσιάσουμε αυτές τις μεθόδους με το λογαριθμικό-γραμμικό υπόδειγμα (12.5.2).


12.6 Ανίχνευση της Αυτοσυσχέτισης

I. Διαγραμματική Μέθοδος

Υπενθυμίζεται ότι η υπόθεση της μη αυτοσυσχέτισης του κλασικού υποδείγματος σχετίζεται με τους διαταρακτικούς όρους u_t του πληθυσμού, οι οποίοι δε μπορούν να παρατηρηθούν άμεσα. Αυτό που έχουμε, αντιθέτως, είναι οι προσεγγίσεις τους, τα κατάλοιπα $\hat{u}_t$, τα οποία μπορούν να προκύψουν από τη συνήθη διαδικασία της OLS. Παρά το γεγονός ότι τα $\hat{u}_t$ δεν είναι το ίδιο με τους u_t ,¹⁷ πολύ συχνά μία οπτική εξέταση των $\hat{u}_t$ μας δίνει κάποιες ενδείξεις για την πιθανή παρουσία αυτοσυσχέτισης στους u_t . Στην πραγματικότητα, μία οπτική εξέταση των $\hat{u}_t$ ή ($\hat{u}_t^2$) μπορεί να προσφέρει χρήσιμες πληροφορίες όχι μόνο για την αυτοσυσχέτιση, αλλά και για την ετεροσκεδαστικότητα (όπως είδαμε στο προηγούμενο κεφάλαιο), για την ανεπάρκεια του υποδείγματος, ή το σφάλμα εξειδίκευσης, όπως θα δούμε στο επόμενο κεφάλαιο. Όπως σημειώνει ένας συγγραφέας:

Πρέπει να επισημάνουμε τη σημασία της δημιουργίας και της ανάλυσης των διαγραμμάτων [των καταλοίπων] ως ένα τυπικό μέρος της στατιστικής ανάλυσης. Εκτός από το γεγονός ότι περιστασιακά παρέχει έναν εύκολο και κατανοητό τρόπο να παρουσιαστεί συνοπτικά ένα σύνθετο πρόβλημα, γίνεται δυνατή η ταυτόχρονη εξέταση των στοιχείων ως ένα σύνολο, ενώ ταυτόχρονα παρουσιάζεται με σαφήνεια η συμπεριφορά μεμονωμένων περιπτώσεων.¹⁸

Υπάρχουν διάφοροι τρόποι να εξετάσουμε τα κατάλοιπα. Μπορούμε να τα παρουσιάσουμε διαγραμματικά σε σχέση με το χρόνο, το **διάγραμμα χρονικής ακολουθίας** (time sequence plot), όπως έχουμε κάνει στο Διάγραμμα 12.8, το οποίο δείχνει τα κατάλοιπα που προέρχονται από τη λογαριθμική παλινδρόμηση μισθών-παραγωγικότητας (12.5.2). Οι τιμές αυτών των καταλοίπων ($S1$) δίνονται στον Πίνακα 12.5 μαζί με κάποια άλλα στοιχεία.



ΔΙΑΓΡΑΜΜΑ 12.8 Κατάλοιπα (μεγεθυμένα κατά 100 φορές) και τυποποιημένα κατάλοιπα από την παλινδρόμηση μισθών-παραγωγικότητας (λογαριθμική μορφή: υπόδειγμα 12.5.2).

¹⁷ Ακόμη και αν οι διαταρακτικοί όροι u_t είναι ομοσκεδαστικοί και ασυσχέτιστοι, οι εκτιμητές τους, τα κατάλοιπα, $\hat{u}_t$, είναι ετεροσκεδαστικά και αυτοσυσχέτιστα. Για το συγκεκριμένο, βλ. G. S. Maddala, *Introduction to Econometrics*, 2^η έκδοση, Macmillan, New York, 1992, σσ. 480–481. Ωστόσο, μπορεί να αποδειχθεί ότι όσο το δείγμα αυξάνεται επ' άπειρο, τα κατάλοιπα τείνουν να συγκλίνουν με τις πραγματικές τους τιμές, τους u_t . Για το συγκεκριμένο, βλ. E. Malinvaud, *Statistical Methods of Econometrics*, 2^η έκδοση, North-Holland Publishers, Amsterdam, 1970, σελ. 88.

¹⁸ Stanford Weisberg, *Applied Linear Regression*, John Wiley & Sons, New York, 1980, σελ. 120.

Εναλλακτικά, μπορούμε να παρουσιάσουμε διαγραμματικά τα **τυποποιημένα κατάλοιπα** (standardized residuals) σε σχέση με το χρόνο, που επίσης παρουσιάζονται στο Διάγραμμα 12.8 και στον Πίνακα 12.5. Τα τυποποιημένα κατάλοιπα (SDRES) είναι απλά τα κατάλοιπα ($\hat{u}_t$) διαιρεμένα με το τυπικό σφάλμα της παλινδρόμησης ($\sqrt{\hat{\sigma}^2}$), δηλαδή, είναι $(\hat{u}_t/\hat{\sigma})$. Παρατηρήστε ότι τα $\hat{u}_t$ και $\hat{\sigma}$ μετρώνται στις μονάδες που μετράται η παλινδρομούμενη μεταβλητή Y . Οι τιμές των τυποποιημένων καταλοίπων θα είναι συνεπώς καθαροί αριθμοί (απαλλαγμένοι από μονάδες μέτρησης) και μπορούν να συγκριθούν με τα τυποποιημένα κατάλοιπα άλλων παλινδρομήσεων. Επιπλέον, τα τυποποιημένα κατάλοιπα, όπως τα $\hat{u}_t$, έχουν μηδενικό μέσο (γιατί;) και περίπου μοναδιαία διακύμανση.¹⁹ Σε μεγάλα δείγματα τα $(\hat{u}_t/\hat{\sigma})$ ακολουθούν περίπου την κανονική κατανομή με μηδενική μέση τιμή και μοναδιαία διακύμανση. Για το παράδειγμά μας, $\hat{\sigma} = 2,6755$.

Εξετάζοντας το διάγραμμα χρονικής ακολουθίας που παρουσιάζεται στο Διάγραμμα 12.8, παρατηρούμε ότι τόσο τα $\hat{u}_t$ όσο και τα τυποποιημένα $\hat{u}_t$ παρουσιάζουν ένα πρότυπο που παρατηρείται στο Διάγραμμα 12.1δ, γεγονός που υποδηλώνει ότι ίσως τα u_t δεν είναι τυχαία. Για να το δούμε αυτό με διαφορετικό τρόπο, μπορούμε να παρουσιάσουμε διαγραμματικά τα $\hat{u}_t$ μαζί με τα $\hat{u}_{t-1}$, δηλαδή, να παρουσιάσουμε διαγραμματικά τα κατάλοιπα κατά τη χρονική στιγμή t σε σχέση με την τιμή τους στο χρόνο $(t-1)$, ένα είδος εμπειρικού ελέγχου του σχήματος AR(1). Αν τα κατάλοιπα είναι μη τυχαία, θα προκύψουν διαγράμματα παρόμοια με αυτά που φαίνονται στο Διάγραμμα 12.3. Το διάγραμμα για τη λογαριθμική παλινδρόμηση μισθών-παραγωγικότητας είναι όπως αυτό που παρουσιάζεται στο Διάγραμμα 12.9, ενώ τα στοιχεία δίνονται στον Πίνακα 12.5. Όπως αποκαλύπτει αυτό το διάγραμμα, τα περισσότερα από τα κατάλοιπα συσσωρεύονται στο δεύτερο (βορειοανατολικό) και τέταρτο (νοτιοδυτικό) τεταρτημόριο, γεγονός που υποδηλώνει μία ισχυρή θετική συσχέτιση στα κατάλοιπα.


Η διαγραμματική μέθοδος που μόλις εξετάσαμε, αν και ισχυρή και υποβλητική, είναι υποκειμενική ή ποιοτικού χαρακτήρα. Αλλά υπάρχουν πολλοί ποσοτικοί έλεγχοι που μπορεί να χρησιμοποιήσει κάποιος για να συμπληρώσει την καθαρά ποιοτική προσέγγιση. Παρακάτω εξετάζουμε κάποιους από αυτούς τους ελέγχους.

ΠΙΝΑΚΑΣ 12.5 Κατάλοιπα: Πραγματικά, Τυποποιημένα, και με Χρονική Υστέρηση

Παρατήρηση	S1	SDRES	S1(-1)	Παρατήρηση	S1	SDRES	S1(-1)
1960	-0,036068	-1,639433	NA	1983	0,014416	0,655291	0,038719
1961	-0,030780	-1,399078	-0,036068	1984	0,001774	0,080626	0,014416
1962	-0,026724	-1,214729	-0,030780	1985	0,001620	0,073640	0,001774
1963	-0,029160	-1,325472	-0,026724	1986	0,013471	0,612317	0,001620
1964	-0,026246	-1,193017	-0,029160	1987	0,013725	0,623875	0,013471
1965	-0,028348	-1,288551	-0,026246	1988	0,017232	0,783269	0,013725
1966	-0,017504	-0,795647	-0,028348	1989	-0,004818	-0,219005	0,017232
1967	-0,006419	-0,291762	-0,017504	1990	-0,006232	-0,283285	-0,004818
1968	0,007094	0,322459	-0,006419	1991	-0,004118	-0,187161	-0,006232
1969	0,018409	0,836791	0,007094	1992	-0,005078	-0,230822	-0,004118
1970	0,024713	1,123311	0,018409	1993	-0,010686	-0,485739	-0,005078
1971	0,016289	0,740413	0,024713	1994	-0,023553	-1,070573	-0,010686
1972	0,025305	1,150208	0,016289	1995	-0,027874	-1,266997	-0,023553
1973	0,025829	1,174049	0,025305	1996	-0,039805	-1,809304	-0,027874
1974	0,023744	1,079278	0,025829	1997	-0,041164	-1,871079	-0,039805
1975	0,011131	0,505948	0,023744	1998	-0,013576	-0,617112	-0,041164
1976	0,018359	0,834515	0,011131	1999	-0,006674	-0,303364	-0,013576
1977	0,020416	0,927990	0,018359	2000	0,010887	0,494846	-0,006674
1978	0,030781	1,399135	0,020416	2001	0,007551	0,343250	0,010887
1979	0,033023	1,501051	0,030781	2002	0,000453	0,020599	0,007551
1980	0,031604	1,436543	0,033023	2003	-0,006673	-0,303298	0,000453
1981	0,020801	0,945516	0,031604	2004	-0,015650	-0,711380	-0,006673
1982	0,038719	1,759960	0,020801	2005	-0,020198	-0,918070	-0,015650

Σημειώσεις: S1 = κατάλοιπα από την παλινδρόμηση μισθών-παραγωγικότητας (λογαριθμική μορφή). S1 (-1) = κατάλοιπα με μία χρονική υστέρηση. SDRES = τυποποιημένα κατάλοιπα = κατάλοιπα/τυπικό σφάλμα εκτίμησης.

¹⁹ Στην πραγματικότητα, είναι τα λεγόμενα **Studentized** κατάλοιπα αυτά που έχουν μοναδιαία διακύμανση. Όμως στην πράξη τα τυποποιημένα κατάλοιπα θα έχουν την ίδια εικόνα, οπότε δε μπορούμε να βασιστούμε σε αυτά. Για το συγκεκριμένο, βλ. Norman Draper and Harry Smith, *Applied Regression Analysis*, 3^η έκδοση, John Wiley & Sons, New York, 1998, σσ. 207–208.



ΔΙΑΓΡΑΜΜΑ 12.9 Τρέχοντα κατάλοιπα έναντι καταλοίπων με χρονική υστέρηση.

II. Έλεγχος Ροών

Αν εξετάσουμε προσεκτικά το Διάγραμμα 12.8, θα παρατηρήσουμε ένα ιδιαίτερο χαρακτηριστικό: Αρχικά, έχουμε πολλά κατάλοιπα που είναι αρνητικά, ενώ υπάρχει μία σειρά θετικών καταλοίπων και, στη συνέχεια υπάρχουν πολλά κατάλοιπα που είναι αρνητικά. Εάν τα κατάλοιπα αυτά ήταν καθαρά τυχαία, θα μπορούσε να υπάρξει ένα τέτοιο πρότυπο συμπεριφοράς; Διαισθητικά, φαίνεται απίθανο. Αυτή η διαισθηση μπορεί να ελεγχθεί από το λεγόμενο **έλεγχος ροών** (runs test), που είναι επίσης γνωστός ως **έλεγχος Geary**, και είναι ένας μη παραμετρικός έλεγχος.²⁰

Για να εξηγήσουμε τον έλεγχο ροών, ας σημειώσουμε απλώς τα πρόσημα (+ ή -) των καταλοίπων που προκύπτουν από την παλινδρόμηση μισθών-παραγωγικότητας, και τα οποία δίνονται στην πρώτη στήλη του Πίνακα 12.5.

$$(\text{-----})(\text{+++++++})(\text{-----})(\text{+++})(\text{---}) \quad (12.6.1)$$

Συνεπώς, υπάρχουν 8 αρνητικά κατάλοιπα, που ακολουθούνται από 21 θετικά κατάλοιπα, που ακολουθούνται από 11 αρνητικά κατάλοιπα, που ακολουθούνται από 3 θετικά κατάλοιπα, που ακολουθούνται από 3 αρνητικά κατάλοιπα, για ένα σύνολο 46 παρατηρήσεων.

Ορίζουμε τώρα μία **ροή** ως μία αδιάκοπη ακολουθία ενός συμβόλου ή ιδιότητας, όπως + ή -. Ορίζουμε περαιτέρω το **μήκος μίας ροής**, ως τον αριθμό των στοιχείων σε αυτό. Στην ακολουθία που παρουσιάζεται στην Εξ. (12.6.1), υπάρχουν 5 ροές: μία ροή από 8 αρνητικά πρόσημα (δηλαδή, μήκους 8), μία ροή από 21 θετικά πρόσημα (δηλαδή, μήκους 21), μία ροή από 11 αρνητικά πρόσημα (δηλαδή, μήκους 11), μία ροή από 3 θετικά πρόσημα (δηλαδή, μήκους 3), μία ροή από 3 αρνητικά πρόσημα (δηλαδή, μήκους 3). Για ένα καλύτερο οπτικό αποτέλεσμα, παρουσιάζουμε τις διάφορες ροές σε παρενθέσεις.

Εξετάζοντας πώς συμπεριφέρονται οι ροές σε μία αυστηρά τυχαία ακολουθία παρατηρήσεων, κάποιος μπορεί να αντλήσει έναν έλεγχο τυχαιότητας των ροών. Θέτουμε το ερώτημα: Είναι οι 5 ροές που παρατηρήθηκαν στο χαρακτηριστικό μας παράδειγμα, που αποτελείται από 46 παρατηρήσεις, πάρα πολλές ή πολύ λίγες σε σύγκριση με τον αριθμό των ροών που αναμένονται σε μία αυστηρά τυχαία ακολουθία 46 παρατηρήσεων; Αν υπάρχουν πάρα πολλές ροές, αυτό θα σήμαινε ότι στο παράδειγμά μας τα κατάλοιπα αλλάζουν συχνά πρόσημο, γεγονός που υποδεικνύει αρνητική σειριακή συσχέτιση (βλ. Διάγραμμα 12.3β). Παρομοίως, αν υπάρχουν πολύ λίγες ροές, μπορεί να υποδηλώνουν θετική αυτοσυσχέτιση, όπως στο Διάγραμμα 12.3α. *A priori*, στη συνέχεια, το Διάγραμμα 12.8 θα δείχνει θετική συσχέτιση στα κατάλοιπα.

²⁰ Σε μη παραμετρικούς ελέγχους δεν κάνουμε υποθέσεις σχετικά με την κατανομή (πιθανοτήτων) από την οποία προέρχονται οι παρατηρήσεις. Για τον έλεγχο Geary, βλ. R. C. Geary, "Relative Efficiency of Count Sign Changes for Assessing Residual Autoregression in Least Squares Regression," *Biometrika*, vol. 57, 1970, σσ. 123-127.

Έστω τώρα:

N = συνολικός αριθμός παρατηρήσεων = $N_1 + N_2$

N_1 = αριθμός + προσήμων (δηλ. + κατάλοιπα)

N_2 = αριθμός - προσήμων (δηλ. - κατάλοιπα)

R = αριθμός ροών

Στη συνέχεια, υπό τη μηδενική υπόθεση ότι τα διαδοχικά αποτελέσματα (εδώ, τα κατάλοιπα) είναι ανεξάρτητα, και υποθέτοντας ότι $N_1 > 10$ και $N_2 > 10$, ο αριθμός των ροών ακολουθεί (ασυμπτωτικά) την κανονική κατανομή με

$$\begin{aligned} \text{Μέσο:} \quad E(R) &= \frac{2N_1N_2}{N} + 1 \\ \text{Διακύμανση:} \quad \sigma_R^2 &= \frac{2N_1N_2(2N_1N_2 - N)}{(N)^2(N-1)} \end{aligned} \quad (12.6.2)$$

Σημείωση: $N = N_1 + N_2$.

Αν η μηδενική υπόθεση της τυχαιότητας είναι βιώσιμη, ακολουθώντας τις ιδιότητες της κανονικής κατανομής, θα πρέπει να περιμένουμε ότι:

$$\text{Prob} [E(R) - 1,96\sigma_R \leq R \leq E(R) + 1,96\sigma_R] = 0,95 \quad (12.6.3)$$

Δηλαδή, η πιθανότητα ότι το προηγούμενο διάστημα θα περιλαμβάνει το R είναι 95 τοις εκατό. Ως εκ τούτου έχουμε τον παρακάτω κανόνα:

Κανόνας απόφασης

Δεν απορρίπτουμε τη μηδενική υπόθεση της τυχαιότητας με 95% εμπιστοσύνη, αν ο R , ο αριθμός των ροών, βρίσκεται στο προηγούμενο διάστημα εμπιστοσύνης· απορρίπτουμε τη μηδενική υπόθεση, εάν ο εκτιμημένος R βρίσκεται εκτός αυτών των ορίων. (**Σημείωση:** Μπορείτε να επιλέξετε οποιοδήποτε διάστημα εμπιστοσύνης θέλετε.)

Επιστρέφοντας στο παράδειγμά μας, γνωρίζουμε ότι N_1 , ο αριθμός των θετικών προσήμων, είναι 24 και N_2 , ο αριθμός των αρνητικών προσήμων, είναι 22 και $R = 5$. Χρησιμοποιώντας τους τύπους που δίνονται στην Εξ. (12.6.2), έχουμε:

$$\begin{aligned} E(R) &= 24 \\ \sigma_R^2 &= 11 \\ \sigma_R &= 3,32 \end{aligned} \quad (12.6.4)$$

Συνεπώς, το διάστημα εμπιστοσύνης 95% στο παράδειγμά μας είναι:

$$[24 \pm 1,96 (3,32)] = (17,5, 30,5)$$

Προφανώς, αυτό το διάστημα δεν περιλαμβάνει το 5. Ως εκ τούτου, μπορούμε να *απορρίψουμε* την υπόθεση ότι τα κατάλοιπα στην παλινδρόμηση μισθών-παραγωγικότητας είναι τυχαία με 95% εμπιστοσύνη. Με άλλα λόγια, τα κατάλοιπα παρουσιάζουν αυτοσυσχέτιση. Ως ένας γενικός κανόνας, αν υπάρχει θετική αυτοσυσχέτιση, ο αριθμός των ροών θα είναι μικρός, ενώ αν υπάρχει αρνητική αυτοσυσχέτιση, ο αριθμός των ροών θα είναι μεγάλος. Φυσικά, από την Εξίσωση (12.6.2), μπορούμε να ανακαλύψουμε εάν έχουμε πάρα πολλές ή πολύ λίγες ροές.

Οι Swed και Eisenhart έχουν δημιουργήσει ειδικούς πίνακες που δίνουν τις κρίσιμες τιμές των ροών που αναμένονται σε μία τυχαία ακολουθία N παρατηρήσεων, εάν οι N_1 ή N_2 είναι μικρότερες από 20. Αυτοί οι πίνακες περιλαμβάνονται στο **Παράρτημα Δ**, Πίνακας Δ.6. Χρησιμοποιώντας αυτούς τους πίνακες, ο αναγνώστης μπορεί να επιβεβαιώσει ότι τα κατάλοιπα της παλινδρόμησης μισθών-παραγωγικότητας είναι πράγματι μη-τυχαία· στην πραγματικότητα συσχετίζονται θετικά.

III. Έλεγχος d Durbin-Watson²¹

Ο πιο γνωστός έλεγχος για την ανίχνευση της σειριακής συσχέτισης είναι αυτός που αναπτύχθηκε από τους στατιστικολόγους Durbin και Watson. Είναι ευρέως γνωστός ως η **στατιστική d Durbin Watson**, η οποία ορίζεται ως

$$d = \frac{\sum_{t=2}^{t=n} (\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{t=2}^{t=n} \hat{u}_t^2} \quad (12.6.5)$$

που είναι απλά ο λόγος του αθροίσματος των τετραγώνων των διαφορών σε διαδοχικά κατάλοιπα προς το RSS. Σημειώστε ότι στον αριθμητή της στατιστικής d , ο αριθμός των παρατηρήσεων είναι $n - 1$, επειδή μία παρατήρηση έχει χαθεί λόγω της λήψης διαδοχικών διαφορών.

Ένα μεγάλο πλεονέκτημα της στατιστικής d είναι ότι βασίζεται στα εκτιμημένα κατάλοιπα, τα οποία υπολογίζονται συνήθως στην ανάλυση παλινδρόμησης. Λόγω αυτού του πλεονεκτήματος, είναι πλέον κοινή πρακτική να παρατίθεται η στατιστική d των Durbin-Watson σε συνδυασμό με άλλους δείκτες, όπως ο R^2 , ο διορθωμένος R^2 , οι t και F . Αν και πλέον χρησιμοποιείται ευρέως, **είναι σημαντικό να επισημάνουμε τις υποθέσεις στις οποίες στηρίζεται η στατιστική d .**

- ❶ Το υπόδειγμα παλινδρόμησης περιλαμβάνει τον όρο της σταθεράς. Αν δεν υπάρχει, όπως στην περίπτωση της παλινδρόμησης χωρίς σταθερό όρο, είναι απαραίτητο να επανεκτιμηθεί η παλινδρόμηση, συμπεριλαμβάνοντας τον όρο της σταθεράς για να αποκτήσουμε το RSS.²²
- ❷ Οι ερμηνευτικές μεταβλητές, οι X , είναι μη-στοχαστικές, ή σταθερές σε επαναλαμβανόμενη δειγματοληψία.
- ❸ Οι διαταρακτικοί όροι u_t προκύπτουν από το αυτοπαλίνδρομο σχήμα πρώτης τάξης: $u_t = \rho u_{t-1} + \varepsilon_t$. Ως εκ τούτου, δε μπορεί να χρησιμοποιηθεί για την ανίχνευση αυτοπαλινδρομων σχημάτων ανώτερης τάξης.
- ❹ Ο όρος σφάλματος u_t θεωρείται ότι ακολουθεί την κανονική κατανομή.
- ❺ Το υπόδειγμα παλινδρόμησης δεν περιλαμβάνει την εξαρτημένη μεταβλητή με υστέρηση, ως μία από τις ερμηνευτικές μεταβλητές. Συνεπώς, ο έλεγχος δεν έχει εφαρμογή σε υποδείγματα της ακόλουθης μορφής:

$$Y_t = \beta_1 + \beta_2 X_{2t} + \beta_3 X_{3t} + \dots + \beta_k X_{kt} + \gamma Y_{t-1} + u_t \quad (12.6.6)$$

όπου Y_{t-1} είναι η μία χρονική υστέρηση της Y . Τα υποδείγματα αυτά είναι γνωστά ως αυτοπαλίνδρομα υποδείγματα, και θα τα μελετήσουμε στο Κεφάλαιο 17.

- ❻ Δε λείπουν παρατηρήσεις όσον αφορά τα στοιχεία. Συνεπώς, στην παλινδρόμηση μισθών-παραγωγικότητας για την περίοδο 1960-2005, αν, για παράδειγμα, οι παρατηρήσεις για τα έτη 1978 και 1982 έλειπαν για κάποιο λόγο, η στατιστική d δε θα λάμβανε υπόψη τις εν λόγω παρατηρήσεις.²³

Η ακριβής κατανομή ή δειγματοληψία πιθανότητας της στατιστικής d που δίνεται στην Εξ. (12.6.5) είναι δύσκολο να προκύψει, διότι, όπως έχουν δείξει οι Durbin και Watson, εξαρτάται κατά ένα περίπλοκο τρόπο από τις τιμές της X που υπάρχουν σε ένα δεδομένο δείγμα.²⁴ Αυτή η δυσκολία θα πρέπει να είναι κατανοητή επειδή η d υπολογίζεται από τα $\hat{u}_t$, τα οποία, φυσικά, εξαρτώνται από τις δοθείσες X . Ως εκ τούτου, σε αντίθεση με τους ελέγχους t , F , ή χ^2 , δεν υπάρχει καμία μοναδική κρίσιμη τιμή που θα οδηγήσει στην απόρριψη ή στην αποδοχή της μηδενικής υπόθεσης ότι δεν υπάρχει πρώτης τάξης αυτοσυσχέτιση στους διαταρακτικούς όρους u_t . Ωστόσο, οι Durbin και Watson μπόρεσαν με επιτυχία να ορίσουν ένα κατώτατο όριο d_L και ένα ανώτατο όριο d_U τέτοια ώστε, αν η υπολογιζόμενη d από την Εξ. (12.6.5) βρίσκεται έξω από αυτές τις κρίσιμες τιμές, να μπορεί να ληφθεί μία απόφαση σχετικά με την παρουσία θετικής ή αρνητικής σειριακής συσχέτισης. Επιπλέον, τα όρια αυτά εξαρτώνται μόνο από τον αριθμό των παρατηρήσεων n και ο αριθμός των ερμηνευτικών μεταβλητών δεν εξαρτάται από τις τιμές που λαμβά-

²¹ J. Durbin and G. S. Watson, "Testing for Serial Correlation in Least-Squares Regression," *Biometrika*, vol. 38, 1951, σσ. 159–171.

²² Ωστόσο, ο R. W. Farebrother έχει υπολογίσει τιμές d όταν απουσιάζει ο σταθερός όρος από το υπόδειγμα. Βλ. "The Durbin-Watson Test for Serial Correlation When There Is No Intercept in the Regression," *Econometrica*, vol. 48, 1980, σσ. 1553–1563.

²³ Για περισσότερες πληροφορίες, βλ. Gabor Korosi, Laszlo Matyas, and Istvan P. Szekey, *Practical Econometrics*, Avebury Press, England, 1992, σσ. 88–89.

²⁴ Διαβάστε τη συζήτηση για τον «ακριβή» έλεγχο Durbin-Watson που παρουσιάζεται παρακάτω στην Ενότητα.

νουν αυτές οι ερμηνευτικές μεταβλητές. Τα όρια αυτά, με το n να εκτείνεται από 6 έως 200 και για έως και 20 ερμηνευτικές μεταβλητές, έχουν καταγραφεί με τη μορφή πινάκων από τους Durbin και Watson και αναπαράγονται στο **Παράρτημα Δ**, Πίνακας Δ.5 (έως και 20 ερμηνευτικές μεταβλητές).

Η πραγματική διαδικασία του ελέγχου μπορεί να εξηγηθεί καλύτερα με τη βοήθεια του Διαγράμματος 12.10, το οποίο δείχνει ότι τα όρια της d είναι 0 και 4. Αυτά μπορούν να καθοριστούν ως εξής. Επεκτείνουμε την Εξ. (12.6.5) και παίρνουμε

$$d = \frac{\sum \hat{u}_t^2 + \sum \hat{u}_{t-1}^2 - 2 \sum \hat{u}_t \hat{u}_{t-1}}{\sum \hat{u}_t^2} \quad (12.6.7)$$

Καθώς τα $\sum \hat{u}_t^2$ και $\sum \hat{u}_{t-1}^2$ διαφέρουν κατά μία μόνο παρατήρηση, είναι περίπου ίσα. Ως εκ τούτου, ορίζοντας $\sum \hat{u}_{t-1}^2 \approx \sum \hat{u}_t^2$ η Εξ. (12.6.7) μπορεί να γραφεί ως

$$d \approx 2 \left(1 - \frac{\sum \hat{u}_t \hat{u}_{t-1}}{\sum \hat{u}_t^2} \right) \quad (12.6.8)$$

όπου $\approx$ σημαίνει περίπου. Έστω τώρα ότι

$$\hat{\rho} = \frac{\sum \hat{u}_t \hat{u}_{t-1}}{\sum \hat{u}_t^2} \quad (12.6.9)$$

ως το δειγματικό συντελεστή αυτοσυσχέτισης πρώτης τάξης, έναν εκτιμητή του όρου ρ . (Βλ. υποσημείωση 9). Χρησιμοποιώντας την Εξ. (12.6.9), μπορούμε να εκφράσουμε την Εξ. (12.6.8) ως

$$d \approx 2(1 - \hat{\rho}) \quad (12.6.10)$$

Καθώς όμως $-1 \leq \rho \leq 1$, η Εξ. (12.6.10) σημαίνει ότι

$$0 \leq d \leq 4 \quad (12.6.11)$$


Αυτά είναι τα όρια της d οποιαδήποτε εκτιμημένη τιμή d πρέπει να βρίσκεται εντός αυτών των ορίων.

Όπως προκύπτει από την Εξ. (12.6.10) αν $\hat{\rho} = 0$, $d = 2$ · δηλαδή, αν δεν υπάρχει σειριακή συσχέτιση (πρώτης τάξης), η d αναμένεται να είναι περίπου 2. Ως εκ τούτου, ως γενικός κανόνας, όταν η d είναι 2 σε μία εφαρμογή, κάποιος μπορεί να υποθέσει ότι δεν υπάρχει πρώτης τάξης αυτοσυσχέτιση, είτε θετική είτε αρνητική. Αν $\hat{\rho} = +1$, υποδεικνύοντας τέλεια θετική συσχέτιση στα κατάλοιπα, $d \approx 0$. Ως εκ τούτου, όσο πιο κοντά είναι η d στο 0, τόσο ισχυρότερες είναι οι αποδείξεις για την ύπαρξη θετικής σειριακής συσχέτισης. Η σχέση αυτή γίνεται εμφανής από την Εξ. (12.6.5), διότι αν υπάρχει θετική αυτοσυσχέτιση, τα $\hat{u}_t$ θα συσσωρεύονται μαζί, και οι διαφορές τους θα έχουν συνεπώς την τάση να είναι μικρές. Ως αποτέλεσμα, το άθροισμα των τετραγώνων στον αριθμητή θα είναι μικρότερο σε σύγκριση με το άθροισμα των τετραγώνων στον παρονομαστή, που παραμένει μία μοναδική τιμή για κάθε παλινδρόμηση.

Αν $\hat{\rho} = -1$, δηλαδή, υπάρχει τέλεια αρνητική συσχέτιση μεταξύ διαδοχικών καταλοίπων, $d \approx 4$. Ως εκ τούτου, όσο πιο κοντά είναι η d στο 4, τόσο ισχυρότερες είναι οι αποδείξεις για την ύπαρξη αρνητικής σειριακής συσχέτισης. Και πάλι, εξετάζοντας την Εξ. (12.6.5), αυτό είναι κατανοητό. Καθώς, εάν υπάρχει αρνητική αυτοσυσχέτιση, ένα θετικό $\hat{u}_t$ θα τείνει να ακολουθείται από ένα αρνητικό $\hat{u}_t$ και το αντίστροφο, έτσι ώστε η $|\hat{u}_t - \hat{u}_{t-1}|$ θα είναι συνήθως μεγαλύτερο από τη $|\hat{u}_t|$. Ως εκ τούτου, ο αριθμητής της d θα είναι συγκριτικά μεγαλύτερος από τον παρονομαστή.

Η μηχανική του ελέγχου Durbin-Watson είναι η ακόλουθη, κάνοντας την υπόθεση ότι ικανοποιούνται οι υποθέσεις στις οποίες βασίζεται ο έλεγχος:

- ❶ Εκτιμήστε την παλινδρόμηση OLS και βρείτε τα κατάλοιπα.
- ❷ Υπολογίστε τη στατιστική d από την Εξ. (12.6.5). (Τα περισσότερα οικονομετρικά προγράμματα το κάνουν ούτως ή άλλως.)
- ❸ Για το συγκεκριμένο μέγεθος δείγματος και με δεδομένο αριθμό ερμηνευτικών μεταβλητών, βρείτε τις κρίσιμες τιμές d_L και d_U .
- ❹ Ακολουθήστε τώρα τους κανόνες απόφασης που δίνονται στον Πίνακα 12.6. Για λόγους ευκολίας, οι εν λόγω κανόνες απόφασης παρατίθενται επίσης στο Διάγραμμα 12.10.



ΔΙΑΓΡΑΜΜΑ 12.10 Στατιστική d των Durbin-Watson.

ΠΙΝΑΚΑΣ 12.6 Έλεγχος d Durbin-Watson: Κανόνες απόφασης

Μηδενική Υπόθεση	Απόφαση	Εάν
Δεν υπάρχει θετική αυτοσυσχέτιση	Απορρίπτουμε	$0 < d < d_L$
Δεν υπάρχει θετική αυτοσυσχέτιση	Καμία απόφαση	$d_L \leq d \leq d_U$
Δεν υπάρχει αρνητική συσχέτιση	Απορρίπτουμε	$4 - d_L < d < 4$
Δεν υπάρχει αρνητική συσχέτιση	Καμία απόφαση	$4 - d_U \leq d \leq 4 - d_L$
Δεν υπάρχει αυτοσυσχέτιση, θετική ή αρνητική	Δεν απορρίπτουμε	$d_U < d < 4 - d_U$

Για να φανεί η μηχανική, ας επιστρέψουμε στην παλινδρόμηση μισθών-παραγωγικότητας. Από τα στοιχεία που παρατίθενται στον Πίνακα 12.5 η εκτιμημένη τιμή d μπορεί να αποδειχθεί ότι είναι 0,2175, γεγονός που υποδηλώνει ότι υπάρχει θετική αυτοσυσχέτιση στα κατάλοιπα. Από τους πίνακες Durbin Watson, διαπιστώνουμε ότι για 46 παρατηρήσεις και μία ερμηνευτική μεταβλητή, $d_L = 1,475$ και $d_U = 1,566$ στο επίπεδο του 5 τοις εκατό. Καθώς το υπολογισμένο d του 0,2175 βρίσκεται κάτω από το d_L , δε μπορούμε να απορρίψουμε την υπόθεση ότι υπάρχει θετική αυτοσυσχέτιση στα κατάλοιπα.

Αν και εξαιρετικά δημοφιλής, ο έλεγχος d έχει ένα μεγάλο μειονέκτημα το οποίο είναι ότι, αν εμπίπτει στην **αβέβαιη περιοχή**, δε μπορούμε να καταλήξουμε σε ασφαλές συμπέρασμα ότι υπάρχει ή δεν υπάρχει αυτοσυσχέτιση (πρώτης τάξης). Για να λυθεί αυτό το πρόβλημα, αρκετοί συγγραφείς έχουν προτείνει τροποποιήσεις του ελέγχου d οι οποίες, όμως, είναι αρκετά περίπλοκες και πέρα από το πεδίο εφαρμογής του παρόντος βιβλίου.²⁵ Σε πολλές περιπτώσεις, ωστόσο, έχει διαπιστωθεί ότι το ανώτατο όριο d_U είναι περίπου το πραγματικό όριο σημαντικότητας και συνεπώς, σε περίπτωση που το d βρίσκεται στην αβέβαιη περιοχή, κάποιος μπορεί να χρησιμοποιήσει τον ακόλουθο **τροποποιημένο έλεγχο d** (modified d test): Δοθέντος του επιπέδου σημαντικότητας α ,

1. $H_0: \rho = 0$ έναντι $H_1: \rho > 0$. Απορρίπτουμε τη H_0 στο επίπεδο α εάν $d < d_U$. Δηλαδή, υπάρχει στατιστικά σημαντική θετική αυτοσυσχέτιση.
2. $H_0: \rho = 0$ έναντι $H_1: \rho < 0$. Απορρίπτουμε τη H_0 στο επίπεδο α εάν η εκτιμημένη $(4 - d) < d_U$, δηλαδή, υπάρχει στατιστικά σημαντική ένδειξη αρνητικής αυτοσυσχέτισης.
3. $H_0: \rho = 0$ έναντι $H_1: \rho \neq 0$. Απορρίπτουμε τη H_0 στο επίπεδο 2α εάν $d < d_U$ ή $(4 - d) < d_U$, δηλαδή, υπάρχει στατιστικά σημαντική ένδειξη αυτοσυσχέτισης, θετική ή αρνητική.

Πρέπει να επισημάνουμε ότι η αβέβαιη περιοχή στενεύει όσο αυξάνεται το μέγεθος του δείγματος, το οποίο διακρίνεται με σαφήνεια από τους πίνακες Durbin-Watson. Για παράδειγμα, με 4 παλινδρομητές και 20 παρατηρήσεις, οι κατώτερες και ανώτερες τιμές d στο 5 τοις εκατό είναι 0,894 και 1,828, αντίστοιχα, αλλά αυτές οι τιμές είναι 1,515 και 1,739, αν το μέγεθος του δείγματος είναι 75.

Το πρόγραμμα SHAZAM, πραγματοποιεί έναν ακριβή έλεγχο d , δηλαδή, δίνει την τιμή p , την ακριβή πιθανότητα της υπολογιζόμενης τιμής d . Με τα σύγχρονα υπολογιστικά προγράμματα, δεν είναι πλέον δύσκολο να βρεθεί η τιμή- p της στατιστικής d . Χρησιμοποιώντας το SHAZAM (έκδοση 9) για την παλινδρόμηση μισθών-παραγωγικότητας, βρίσκουμε ότι η τιμή- p της στατιστικής d είναι 0,2176, δηλαδή είναι σχεδόν μηδενική, επιβεβαιώνοντας έτσι το προηγούμενο συμπέρασμά μας με βάση τους πίνακες Durbin-Watson.

²⁵ Για λεπτομέρειες, βλ. Thomas B. Fomby, R. Carter Hill, and Stanley R. Johnson, *Advanced Econometric Methods*, Springer Verlag, New York, 1984, σσ. 225–228.

Ο έλεγχος d των Durbin-Watson έχει γίνει τόσο αποδεκτός ώστε είναι πολλοί αυτοί που ξεχνούν συχνά τις υποθέσεις στις οποίες βασίζεται ο έλεγχος. Πιο συγκεκριμένα, οι υποθέσεις ότι, οι ερμηνευτικές μεταβλητές, ή παλινδρομητές, είναι μη-στοχαστικές, ο όρος σφάλματος ακολουθεί την κανονική κατανομή, τα υποδείγματα παλινδρόμησης δεν περιλαμβάνουν τη χρονική υστέρηση της παλινδρομούμενης μεταβλητής και λαμβάνεται υπόψη μόνο η σειριακή συσχέτιση πρώτης τάξης, είναι πολύ σημαντικές για την εφαρμογή του ελέγχου d . Θα πρέπει επίσης να προστεθεί ότι μία σημαντική στατιστική d μπορεί να μη δείχνει απαραίτητα αυτοσυσχέτιση. Αντίθετα, μπορεί να είναι μία ένδειξη της παράλειψης των σχετικών μεταβλητών από το υπόδειγμα.

Αν ένα υπόδειγμα παλινδρόμησης περιέχει υστέρηση της παλινδρομούμενης μεταβλητής, η τιμή d σε αυτές τις περιπτώσεις είναι συχνά κοντά στο 2, γεγονός που υποδηλώνει ότι δεν υπάρχει αυτοσυσχέτιση (πρώτης τάξης) σε τέτοια υποδείγματα. Επομένως, υπάρχει μία ενσωματωμένη μεροληψία έναντι της ανακάλυψης αυτοσυσχέτισης (πρώτης τάξης) σε τέτοια υποδείγματα. Αυτό δε σημαίνει ότι τα αυτοπαλινδρομα υποδείγματα δεν πάσχουν από πρόβλημα αυτοσυσχέτισης. Μάλιστα, ο Durbin έχει αναπτύξει το λεγόμενο **έλεγχο h** προκειμένου να ελέγχεται η αυτοσυσχέτιση σε τέτοια υποδείγματα. Όμως αυτός ο έλεγχος δεν είναι τόσο ισχυρός, από στατιστικής πλευράς, όσο είναι ο **έλεγχος Breusch-Godfrey** που θα συζητηθεί παρακάτω, με αποτέλεσμα να μην υπάρχει καμία ανάγκη να χρησιμοποιηθεί ο **έλεγχος h** . Ωστόσο, λόγω της ιστορικής σημασίας του, συζητείται στην Άσκηση 12.36.

Επίσης, εάν το όρος σφάλματος u_i δεν είναι NIID (normally and independently distributed), ο συνήθης έλεγχος d μπορεί να μην είναι αξιόπιστος.²⁶ Από αυτή την άποψη ο έλεγχος ροών που συζητήθηκε νωρίτερα έχει ένα πλεονέκτημα υπό την έννοια ότι δεν κάνει καμία υπόθεση κατανομής (πιθανότητας) σχετικά με τον όρο σφάλματος. Ωστόσο, εάν το δείγμα είναι μεγάλο (τεχνικά άπειρο), μπορούμε να χρησιμοποιήσουμε τη στατιστική d , καθώς μπορεί να αποδειχθεί ότι²⁷

$$\sqrt{n} \left(1 - \frac{1}{2} d \right) \approx N(0,1) \quad (12.6.12)$$

Δηλαδή, σε μεγάλα δείγματα η στατιστική d , όπως μετασχηματίζεται στην Εξ. (12.6.12) ακολουθεί την τυπική κανονική κατανομή. Παρεμπιπτόντως, με βάση τη σχέση μεταξύ των d και $\hat{\rho}$, ο εκτιμημένος συντελεστής αυτοσυσχέτισης πρώτης τάξης, που παρουσιάζεται στην Εξ. (12.6.10), προκύπτει ότι

$$\sqrt{n} \hat{\rho} \approx N(0,1) \quad (12.6.13)$$

δηλαδή, σε μεγάλα δείγματα, η τετραγωνική ρίζα του μεγέθους του δείγματος επί τον εκτιμημένο συντελεστή αυτοσυσχέτισης πρώτης τάξης ακολουθεί επίσης την τυπική κανονική κατανομή.

Ως παράδειγμα του ελέγχου, για το παράδειγμα μισθών-παραγωγικότητας, βρήκαμε ότι $d = 0,2176$ με $n = 46$. Ως εκ τούτου, από την Εξ. (12.6.12) βρίσκουμε ότι

$$\sqrt{46} \left(1 - \frac{0,2176}{2} \right) \approx 6,0447$$

Ασυμπτωτικά, εάν ίσχυε η μηδενική υπόθεση μηδενικής αυτοσυσχέτισης (πρώτης τάξης), η πιθανότητα να πάρουμε μία τιμή Z (δηλαδή, μία τυποποιημένη κανονική μεταβλητή) ίση με 6,0447 ή μεγαλύτερη είναι εξαιρετικά μικρή. Θυμηθείτε ότι για μία τυπική κανονική κατανομή, η (δίπλευρη) κρίσιμη στο 5 τοις εκατό τιμή Z είναι μόλις 1,96 και η κρίσιμη στο 5 τοις εκατό τιμή Z είναι περίπου 2,58. Παρόλο που το μέγεθος του δείγματός μας είναι μόλις 46, μπορεί, για πρακτικούς λόγους, να είναι αρκετά μεγάλο για να χρησιμοποιήσει τη συνηθισμένη προσέγγιση. Το συμπέρασμα παραμένει το ίδιο, δηλαδή, ότι τα κατάλοιπα από την παλινδρόμηση μισθών-παραγωγικότητας πάσχουν από αυτοσυσχέτιση.

Ωστόσο, το πιο σοβαρό πρόβλημα με τον έλεγχο d είναι η υπόθεση ότι οι παλινδρομητές είναι μη στοχαστικοί, δηλαδή, οι τιμές τους είναι σταθερές σε επαναλαμβανόμενη δειγματοληψία. Εάν αυτό δε συμβαίνει, τότε ο έλεγχος d δεν είναι έγκυρος ούτε σε πεπερασμένα, ή μικρά, δείγματα ούτε σε μεγάλα δείγματα.²⁸ Και επειδή αυτή η υπόθεση είναι συνήθως δύσκολο να ευσταθεί σε οικονομικά υποδείγμα-

²⁶ Για μία προχωρημένη ανάλυση, βλ. Ron C. Mittelhammer, George G. Judge, and Douglas J. Miller, *Econometric Foundations*, Cambridge University Press, New York, 2000, σελ. 550.

²⁷ Βλ. James Davidson, *Econometric Theory*, Blackwell Publishers, New York, 2000, σελ. 161.

²⁸ Ο.π., σελ. 161.

τα που περιλαμβάνουν στοιχεία χρονοσειρών, ένας συγγραφέας υποστηρίζει ότι η στατιστική Durbin-Watson δε μπορεί να είναι χρήσιμη στην οικονομετρία που αφορά στοιχεία χρονοσειρών.²⁹ Σύμφωνα με αυτή την άποψη, υπάρχουν διαθέσιμοι πιο χρήσιμοι έλεγχοι αυτοσυσχέτισης, όλοι όμως βασίζονται σε μεγάλα δείγματα. Συζητάμε έναν τέτοιο έλεγχο παρακάτω, τον έλεγχο **Breusch-Godfrey**.

IV. Ένας Γενικός Έλεγχος Αυτοσυσχέτισης: Ο Έλεγχος Breusch-Godfrey (BG)³⁰

Για να αποφύγουν ορισμένες από τις παγίδες του ελέγχου αυτοσυσχέτισης d των Durbin-Watson, οι στατιστικοί Breusch και Godfrey έχουν αναπτύξει έναν έλεγχο αυτοσυσχέτισης που είναι γενικός, με την έννοια ότι επιτρέπει

- ✦ μη στοχαστικούς παλινδρομητές, όπως οι υστερήσεις της παλινδρομούμενης μεταβλητής
- ✦ αυτοπαλίνδρομα σχήματα ανώτερης τάξης, όπως AR(1), AR(2) κ.λπ. και
- ✦ απλούς ή ανώτερης τάξης **κινητούς μέσους** των όρων σφάλματος λευκού θορύβου, όπως ο ε_t στην Εξίσωση (12.2.1).³¹

Χωρίς να υπεισέλθουμε σε μαθηματικές λεπτομέρειες, οι οποίες μπορούν να ληφθούν από τις βιβλιογραφικές αναφορές που παρατίθενται, ο έλεγχος **BG**, ο οποίος είναι επίσης γνωστός ως έλεγχος **LM**,³² έχει ως εξής: Χρησιμοποιούμε το διμεταβλητό υπόδειγμα παλινδρόμησης, για να παρουσιάσουμε τον έλεγχο, αν και μπορούν να προστεθούν πολλοί παλινδρομητές στο υπόδειγμα. Επίσης, μπορούν να προστεθούν στο υπόδειγμα χρονικές υστερήσεις της παλινδρομούμενης μεταβλητής. Έστω ότι:

$$Y_t = \beta_1 + \beta_2 X_t + u_t \quad (12.6.14)$$

Υποθέστε ότι ο όρος σφάλματος u_t ακολουθεί το αυτοπαλίνδρομο σχήμα p -τάξης, AR(p), ως εξής:

$$u_t = \rho_1 u_{t-1} + \rho_2 u_{t-2} + \dots + \rho_p u_{t-p} + \varepsilon_t \quad (12.6.15)$$

όπου ε_t είναι ένας όρος σφάλματος λευκού θορύβου, όπως συζητήθηκε προηγουμένως. Όπως θα αναγνωρίσετε, αυτή είναι απλά μία επέκταση του σχήματος AR(1).

Η μηδενική υπόθεση H_0 που θα ελεγχθεί είναι:

$$H_0: \rho_1 = \rho_2 = \dots = \rho_p = 0 \quad (12.6.16)$$

Δηλαδή, δεν υπάρχει σειριακή συσχέτιση οποιασδήποτε τάξης. Ο έλεγχος BG περιλαμβάνει τα ακόλουθα βήματα:

- ❶ Εκτίμηση της Εξ. (12.6.14) με την OLS και υπολογισμός των καταλοίπων, $\hat{u}_t$.
- ❷ Παλινδρομούμε τα $\hat{u}_t$ με την αρχική X_t (αν υπάρχουν περισσότερες από μία μεταβλητές X στο αρχικό υπόδειγμα, συμπεριλαμβάνονται και αυτές) και $\hat{u}_{t-1}, \hat{u}_{t-2}, \dots, \hat{u}_{t-p}$, όπου οι τελευταίες είναι οι χρονικές υστερήσεις των εκτιμημένων καταλοίπων του 1^{ου} βήματος. Συνεπώς, αν $p = 4$, θα εισαγάγουμε τέσσερις χρονικές υστερήσεις των τιμών των καταλοίπων ως επιπλέον παλινδρομητές στο υπόδειγμα. Επισημαίνεται ότι για να εκτιμηθεί αυτή η παλινδρόμηση θα έχουμε μόνο $(n - p)$ παρατηρήσεις (γιατί;). Με λίγα λόγια, εκτιμήστε την ακόλουθη παλινδρόμηση:

$$\hat{u}_t = \alpha_1 + \alpha_2 X_t + \hat{\rho}_1 \hat{u}_{t-1} + \hat{\rho}_2 \hat{u}_{t-2} + \dots + \hat{\rho}_p \hat{u}_{t-p} + \hat{\varepsilon}_t \quad (12.6.17)$$

και βρείτε το R^2 από αυτή τη (βοηθητική) παλινδρόμηση.³³

²⁹ Fumio Hayashi, *Econometrics*, Princeton University Press, Princeton, NJ, 2000, σελ. 45.

³⁰ Βλ., L. G. Godfrey, "Testing Against General Autoregressive and Moving Average Error Models When the Regressor Includes Lagged Dependent Variables," *Econometrica*, vol. 46, 1978, σσ. 1293–1302, και T. S. Breusch, "Testing for Autocorrelation in Dynamic Linear Models," *Australian Economic Papers*, vol. 17, 1978, σσ. 334–355.

³¹ Για παράδειγμα, στην παλινδρόμηση $Y_t = \beta_1 + \beta_2 X_t + u_t$, ο όρος σφάλματος μπορεί να παρουσιαστεί ως $u_t = \varepsilon_t + \lambda_1 \varepsilon_{t-1} + \lambda_2 \varepsilon_{t-2}$, που αντιπροσωπεύει ένα κινητό μέσο τριών περιόδων του όρου σφάλματος λευκού θορύβου ε_t .

³² Ο έλεγχος βασίζεται στην **αρχή του πολλαπλασιαστή του Lagrange** στην οποία αναφερθήκαμε συνοπτικά στο Κεφάλαιο 8.

³³ Ο λόγος που συμπεριλαμβάνεται στο υπόδειγμα ο αρχικός παλινδρομητής X είναι για να λάβουμε υπόψη μας το γεγονός ότι ο X μπορεί να μην είναι αυστηρά μη στοχαστικός. Εάν όμως είναι αυστηρά μη στοχαστικός, μπορεί να απαλειφθεί από το υπόδειγμα. Επί του συγκεκριμένου, βλ. Jeffrey M. Wooldridge, *Introductory Econometrics: A Modern Approach*, South-Western Publishing Co., 2003, σελ. 386.

- ❸ Εάν το μέγεθος του δείγματος είναι μεγάλο (τεχνικά, άπειρο), οι Breusch και Godfrey έχουν δείξει ότι

$$(n - p)R^2 \sim \chi_p^2 \quad (12.6.18)$$

Δηλαδή, ασυμπτωτικά, $n - p$ επί την τιμή του R^2 που προκύπτει από τη βοηθητική παλινδρόμηση (12.6.17) ακολουθεί τη χ^2 κατανομή με p βαθμούς ελευθερίας. Εάν σε μία εφαρμογή, το $(n - p)R^2$ υπερβαίνει την κρίσιμη χ^2 τιμή στο επιλεγμένο επίπεδο σημαντικότητας, απορρίπτουμε τη μηδενική υπόθεση, στην οποία περίπτωση τουλάχιστον ένας ρ στην Εξίσωση (12.6.15) είναι στατιστικά σημαντικά διαφορετικός από το μηδέν.

Μπορούμε να επισημάνουμε τα ακόλουθα *πρακτικά ζητήματα* σχετικά με τον έλεγχο BG:

- ❶ Οι παλινδρομητές που περιλαμβάνονται στο υπόδειγμα παλινδρόμησης μπορεί να περιέχουν υστερήσεις της παλινδρομούμενης μεταβλητής Y , δηλαδή οι, Y_{t-1} , Y_{t-2} , κλπ., μπορούν να συμπεριληφθούν στο υπόδειγμα ως ερμηνευτικές μεταβλητές. Αντιπαραβάλλετε αυτό το υπόδειγμα με τον περιορισμό του ελέγχου Durbin-Watson σύμφωνα με τον οποίο δε μπορεί να υπάρξει υστέρηση της παλινδρομούμενης μεταβλητής μεταξύ των παλινδρομητών.
- ❷ Όπως προαναφέρθηκε, ο έλεγχος BG εφαρμόζεται ακόμα και αν οι διαταρακτικοί όροι ακολουθούν ένα σχήμα κινητών μέσων p -τάξης (MA), δηλαδή, τα u_t προκύπτουν ως εξής:

$$u_t = \varepsilon_t + \lambda_1 \varepsilon_{t-1} + \lambda_2 \varepsilon_{t-2} + \dots + \lambda_p \varepsilon_{t-p} \quad (12.6.19)$$

όπου ε_t είναι ένας όρος σφάλματος λευκού θορύβου, δηλαδή, ο όρος σφάλματος που ικανοποιεί όλες τις κλασικές υποθέσεις. Στα κεφάλαια στα οποία θα αναφερθούμε στις χρονοσειρές, θα εξετάσουμε με μεγάλη λεπτομέρεια την αυτοπαλινδρομη διαδικασία p -τάξης και τη διαδικασία κινητών μέσων.

- ❸ Εάν στην Εξίσωση (12.6.15) $p = 1$, που σημαίνει αυτοπαλινδρόμηση πρώτης τάξης, τότε ο έλεγχος BG είναι γνωστός ως **έλεγχος m του Durbin**.
- ❹ Ένα μειονέκτημα του ελέγχου BG είναι ότι η τιμή του p , το εύρος των υστερήσεων, δε μπορεί να καθοριστεί εκ των προτέρων. Είναι αναπόφευκτοι ορισμένοι πειραματισμοί με την τιμή p . Ορισμένες φορές κάποιος μπορεί να χρησιμοποιήσει τα λεγόμενα **κριτήρια πληροφορίας Akaike και Schwarz** προκειμένου να επιλέξει το εύρος των χρονικών υστερήσεων. Θα συζητήσουμε αυτά τα κριτήρια στο Κεφάλαιο 13 και αργότερα στα κεφάλαια για τις χρονοσειρές.
- ❺ Λαμβάνοντας υπόψη τις τιμές της (των) μεταβλητής (-ών) X και τις χρονικές υστερήσεις των τιμών του u , ο έλεγχος υποθέτει ότι η διακύμανση του u στην Εξ. (12.6.15) είναι ομοσκεδαστική.

Παρουσίαση του Ελέγχου BG: Η Σχέση Μισθών-Παραγωγικότητας

Για να παρουσιάσουμε τον έλεγχο, θα τον εφαρμόσουμε στο ενδεικτικό μας παράδειγμα. Χρησιμοποιώντας ένα σχήμα AR(6), καταλήξαμε στα αποτελέσματα που παρουσιάζονται στην Άσκηση 12.25. Από τα αποτελέσματα της παλινδρόμησης που δίνονται εκεί, μπορεί να διαπιστωθεί ότι $(n - p) = 40$ και $R^2 = 0,7498$. Ως εκ τούτου, πολλαπλασιάζοντας αυτά τα δύο, αποκτούμε μία τιμή χ^2 ίση με 29,992. Για 6 βαθμούς ελευθερίας (γιατί;), η πιθανότητα λήψης μίας τιμής χ^2 ίσης με 29,992 ή μεγαλύτερης είναι εξαιρετικά μικρή· ο πίνακας χ^2 στο Παράρτημα Δ.4 δείχνει ότι η πιθανότητα λήψης μίας τιμής χ^2 ίσης ή μεγαλύτερης του 18,5476 είναι μόνο 0,005. Ως εκ τούτου, για τους ίδιους βαθμούς ελευθερίας, η πιθανότητα απόκτησης μίας τιμής χ^2 περίπου ίσης με 30 πρέπει να είναι εξαιρετικά μικρή. Στην πραγματικότητα, η πραγματική τιμή p είναι σχεδόν μηδενική.

Ως εκ τούτου, το συμπέρασμα είναι ότι, για το παράδειγμά μας, τουλάχιστον μία από τις έξι αυτοσυσχετίσεις πρέπει να είναι μη μηδενική. Δοκιμάζοντας διάφορα μεγέθη υστερήσεων από 1 έως 6, διαπιστώνουμε ότι μόνο ο συντελεστής AR(1) είναι σημαντικός, γεγονός που υποδηλώνει ότι δεν υπάρχει ανάγκη να εξεταστούν περισσότερες από μία χρονικές υστερήσεις. Στην ουσία ο έλεγχος BG σε αυτή την περίπτωση αποδεικνύεται ότι είναι ο **έλεγχος m του Durbin**.

Γιατί Τόσοι Πολλοί Έλεγχοι Αυτοσυσχέτισης;

Η απάντηση στο ερώτημα αυτό είναι ότι «...δεν υπάρχει ακόμη κάποιος έλεγχος ο οποίος να έχει κριθεί απερίφραστα ότι είναι ο καλύτερος [δηλαδή, ισχυρότερος από στατιστικής άποψης], και έτσι ο αναλυτής βρίσκεται ακόμα στη διόλου αξιοζήλευτη θέση να εξετάζει πολυάριθμους ελέγχους για την ανίχνευση της παρουσίας ή της δομής, ή και των δύο, της αυτοσυσχέτισης.»³⁴ Φυσικά, μπορεί να διατυπωθεί ένα παρόμοιο επιχείρημα σχετικά με τους διάφορους ελέγχους ετεροσκεδαστικότητας που συζητήθηκαν στο προηγούμενο κεφάλαιο.

12.7 Τι Πρέπει να Κάνετε Όταν Βρείτε Αυτοσυσχέτιση: Διορθωτικά Μέτρα

Πως προχωρούμε εάν μετά την εφαρμογή ενός ή περισσοτέρων από τους διαγνωστικούς ελέγχους αυτοσυσχέτισης που συζητήθηκαν στην προηγούμενη ενότητα, διαπιστώσουμε ότι υπάρχει αυτοσυσχέτιση; Έχουμε τέσσερις επιλογές:

- 1 Προσπαθούμε να βρούμε αν η αυτοσυσχέτιση είναι **καθαρή αυτοσυσχέτιση** (pure autocorrelation) και όχι το αποτέλεσμα της λάθος εξειδίκευσης του υποδείγματος. Όπως συζητήσαμε στην Ενότητα 12.1, ορισμένες φορές παρατηρούμε πρότυπα στα κατάλοιπα, επειδή το υπόδειγμα είναι λανθασμένα εξειδικευμένο –δηλαδή, έχουν απαλειφθεί ορισμένες σημαντικές μεταβλητές– ή επειδή η συναρτησιακή μορφή του είναι εσφαλμένη.
- 2 Αν είναι καθαρή αυτοσυσχέτιση, κάποιος μπορεί να χρησιμοποιήσει τον κατάλληλο μετασχηματισμό του αρχικού υποδείγματος, ούτως ώστε το μετασχηματισμένο υπόδειγμα να μην έχει το πρόβλημα της (καθαρής) αυτοσυσχέτισης. Όπως και στην περίπτωση της ετεροσκεδαστικότητας, θα πρέπει να χρησιμοποιήσετε κάποια γενικευμένη μέθοδο ελαχίστων τετραγώνων (GLS).
- 3 Σε μεγάλα δείγματα, μπορούμε να χρησιμοποιήσουμε τη **μέθοδο Newey-West** για να αποκτήσουμε τα τυπικά σφάλματα των εκτιμητών της OLS τα οποία είναι διορθωμένα για αυτοσυσχέτιση. Αυτή η μέθοδος είναι στην πραγματικότητα μία επέκταση της μεθόδου των ετεροσκεδαστικά-συνεπών τυπικών σφαλμάτων White, που συζητήσαμε στο προηγούμενο κεφάλαιο.
- 4 Σε ορισμένες περιπτώσεις μπορούμε να συνεχίσουμε να χρησιμοποιούμε τη μέθοδο OLS.

Λόγω της σπουδαιότητας αυτών των θεμάτων, έχουμε αφιερώσει ένα κεφάλαιο στο καθένα.


12.8 Σφάλμα Εξειδίκευσης στο Υπόδειγμα έναντι Καθαρής Αυτοσυσχέτισης

Ας επιστρέψουμε στην παλινδρόμηση μισθών-παραγωγικότητας που δίνεται στην Εξ. (12.5.2). Εκεί είδαμε ότι η τιμή d ήταν 0,2176 και με βάση τον έλεγχο d των Durbin-Watson καταλήξαμε στο συμπέρασμα ότι υπήρχε θετική συσχέτιση στον όρο σφάλματος. Θα μπορούσε να έχει προκύψει αυτή η συσχέτιση επειδή το υπόδειγμα μας δεν ήταν σωστά εξειδικευμένο; Δεδομένου ότι τα στοιχεία στα οποία στηρίζεται η παλινδρόμηση (12.5.1) είναι στοιχεία χρονοσειρών, είναι αρκετά πιθανό τόσο οι μισθοί όσο και η παραγωγικότητα να παρουσιάζουν τάσεις. Αν αυτό συμβαίνει, τότε θα πρέπει να συμπεριλάβουμε τη μεταβλητή του χρόνου ή της τάσης, t , στο υπόδειγμα για να δούμε τη σχέση μεταξύ μισθών και παραγωγικότητας καθαρή από τις τάσεις στις δύο μεταβλητές.

Για τον έλεγχο αυτό, συμπεριλάβαμε τη μεταβλητή τάσης στην Εξ. (12.5.2) και λάβαμε τα ακόλουθα αποτελέσματα

$$\begin{aligned} \hat{Y}_t &= 0,1209 + 1,0283X_t - 0,0075t \\ \text{se} &= (0,3070) \quad (0,0776) \quad (0,0015) \\ t &= (0,3939) \quad (13,2594) \quad (-4,8903) \\ R^2 &= 0,9900 \quad d = 0,4497 \end{aligned} \tag{12.8.1}$$

³⁴ Ron C. Mittelhammer et al., ό.π., σελ. 547. Υπενθυμίζεται ότι η **ισχύς ενός στατιστικού ελέγχου** είναι 1 μείον την πιθανότητα να διαπράξουμε σφάλμα Τύπου II, δηλαδή, 1 μείον την πιθανότητα αποδοχής μίας ψευδούς υπόθεσης. Η μέγιστη δύναμη ενός ελέγχου είναι 1 και η ελάχιστη είναι 0. Όσο πιο κοντά είναι η ισχύς ενός ελέγχου στο μηδέν, τόσο χειρότερος είναι αυτός ο έλεγχος, και όσο πιο κοντά είναι στο 1, τόσο πιο ισχυρός είναι αυτός. Αυτό που διατυπώνουν αυτοί οι συγγραφείς είναι ουσιαστικά ότι δεν υπάρχει ένας μοναδικός, ισχυρός έλεγχος αυτοσυσχέτισης.



ΕΚΔΟΣΕΙΣ ΤΖΙΟΛΑ

