

NORBERT VANHOVE

ΤΑ ΟΙΚΟΝΟΜΙΚΑ ΤΩΝ ΤΟΥΡΙΣΤΙΚΩΝ ΠΡΟΟΡΙΣΜΩΝ

Θεωρία και πρακτική

ΕΠΙΣΤΗΜΟΝΙΚΗ ΕΠΙΜΕΛΕΙΑ

Γιώργος Μ. Αγιομυργιανάκης

Αγγελική Ν. Μενεγάκη

ΜΕΤΑΦΡΑΣΗ

Ανδρέας Σοκοδήμος



GUTENBERG

NORBERT VANHOVE

ΤΑ ΟΙΚΟΝΟΜΙΚΑ ΤΩΝ ΤΟΥΡΙΣΤΙΚΩΝ ΠΡΟΟΡΙΣΜΩΝ

Θεωρία και πρακτική

ΕΠΙΣΤΗΜΟΝΙΚΗ ΕΠΙΜΕΛΕΙΑ

Γιώργος Μ. Αγιομυργιανάκης

Αγγελική Ν. Μενεγάκη

ΜΕΤΑΦΡΑΣΗ

Ανδρέας Σοκοδήμος



ΕΚΔΟΣΕΙΣ GUTENBERG

Norbert Vanhove

ΤΑ ΟΙΚΟΝΟΜΙΚΑ
ΤΩΝ ΤΟΥΡΙΣΤΙΚΩΝ ΠΡΟΟΡΙΣΜΩΝ

Θεωρία και πρακτική

Επιστημονική επιμέλεια: Γ.Μ. Αγιομυργιανάκης – Α.Ν. Μενεγάκη
Μετάφραση: Ανδρέας Σοκοδήμος

718 σσ. (17 × 24 εκ.)

Αριθμός έκδοσης: 3180

Κωδικός καταλόγου: 9550627

ISBN 978-960-01-2020-2

Norbert Vanhove

THE ECONOMICS OF TOURISM DESTINATIONS, 3rd ed.

© 2018 Norbert Vanhove

All rights reserved. Authorized translation from the English language edition
published by Routledge, a member of the Taylor & Francis Group.



© Copyright 2019 Gutenberg

ΔΙΟΡΘΩΣΕΙΣ: Κ. Παντελίδου

ΣΕΛΙΔΟΠΟΙΗΣΗ: Γ. Καρδαμίτσης

ΜΟΝΤΑΖ - ΦΙΛΟΜΟΠΟΙΗΣΗ: Β. & Κ. Χριστοδούλου

ΜΑΚΕΤΑ ΕΞΩΦΥΛΛΟΥ: Χρ. Παρασκευοπούλου



ΒΙΒΛΙΟΠΩΛΕΙΟ GUTENBERG

ΔΙΔΟΤΟΥ 37, 106 80 ΑΘΗΝΑ

Τηλ.: 210 36.42.003 – Fax: 210 36.42.030

ΥΠΟΚΑΤΑΣΤΗΜΑ ΘΕΣΣΑΛΟΝΙΚΗΣ

ΙΑΣΩΝΙΔΟΥ 13 - 546 35

Τηλ.-Fax: 2310 271147

www.dardanosnet.gr -- e-mail: info@dardanosnet.gr

e-shop: www.dardanosnet.gr

Απαγορεύεται η αναδημοσίευση και γενικά η ολική, μερική ή περιληπτική αναπαραγωγή και μετάδοση ή εστω και μιας σελίδας του παρόντος βιβλίου, κατά παράφραση ή διασκευή με οποιονδήποτε τρόπο (μηχανικό, ηλεκτρονικό, φωτοτυπικό κ.λπ. – Ν. 2121/93, άρθρο 51). Η απαγόρευση αυτή ισχύει και για τις δημόσιες υπηρεσίες, βιβλιοθήκες, οργανισμούς κ.λπ. (άρθρο 18). Οι παραβάτες διώκονται (άρθρο 13) και τους επιβάλλονται κατάσχεση, αστικές και ποινικές κυρώσεις σύμφωνα με το νόμο (άρθρα 64-66).

Στοιχεία ποσοτικών μεθόδων

(για το βιβλίο του Vanhove)

Αγγελική Ν. Μενεγάκη • Γιώργος Μ. Αγιομυργιανάκης

Εισαγωγή

ΤΟ ΠΑΡΟΝ ΚΕΦΑΛΑΙΟ έχει στόχο να βοηθήσει τους αναγνώστες του βιβλίου *Τα οικονομικά των τουριστικών προορισμών: Θεωρία και πρακτική* (*The Economics of Tourism Destinations: Theory and Practice*), του Norbert Vanhove, να κατανοήσουν καλύτερα και ευκολότερα τις οικονομετρικές έννοιες και τις εφαρμογές που χρησιμοποιούνται σε αυτό. Ταυτόχρονα μπορεί να αποτελέσει και ένα γενικότερο βοήθημα για αναγνώστες σχετικών βιβλίων, οι οποίοι ενδέχεται να μη διαθέτουν το απαραίτητο υπόβαθρο στη Στατιστική και την Οικονομετρία, με αποτέλεσμα να έχουν κενά γνώσης σε αυτό που μόλις διάβασαν. Επομένως, αυτό το κεφάλαιο μπορεί να διαβαστεί και σε συνάρτηση με το περιεχόμενο του βιβλίου του Norbert Vanhove, αλλά και ως ανεξάρτητο κεφάλαιο από οποιονδήποτε φοιτητή επιθυμεί να βρει συγκεντρωμένες, σε μερικές μόνο σελίδες, βασικές και συμπυκνωμένες γνώσεις Στατιστικής και Οικονομετρίας. Αυτές οι γνώσεις είναι χρήσιμες και στο πλαίσιο άλλων μαθημάτων (όχι μόνο της Τουριστικής Οικονομικής) ή μπορεί να χρησιμεύσουν και ως υλικό που κάποιος θα διαβάσει μια οποιαδήποτε χρονική στιγμή, για τις ανάγκες οποιουδήποτε μαθήματος, με σκοπό να φρεσκάρει τις ήδη υπάρχουσες γνώσεις του στα συγκεκριμένα θέματα.

Το παρόν κεφάλαιο χωρίζεται σε τέσσερις υποενότητες: στην πρώτη παρουσιάζονται τα βασικά εργαλεία περιγραφικής Στατιστικής, στη δεύτερη ο έλεγχος υποθέσεων και τα βασικά εργαλεία επαγωγικού λογισμού, στην τρίτη ενότητα αναπτύσσεται η απλή και πολλαπλή παλινδρόμηση, ενώ στην τέταρτη και τελευταία ενότητα αναλύονται στοιχεία χρονολογικών σειρών και δεδομένων πάνελ. Οι δύο πρώτες ενότητες εντάσσονται στο πεδίο της Στατιστικής, ενώ οι δύο τελευταίες στο πεδίο της Οικονομετρίας. Όλες οι ενότητες έχουν γραφτεί σε απλή γλώσσα για να είναι προσιτές και σε αναγνώστες με λίγες προϋπάρχουσες γνώσεις.

Η διαφορά της Οικονομετρίας από τη Στατιστική

Η Οικονομετρία είναι τα μαθηματικά εργαλεία που χρειάζονται οι οικονομολόγοι για να αναλύουν δεδομένα, να ποσοτικοποιούν συσχετίσεις μεταξύ οικονομικών μεγεθών και κοινωνικών μεταβλητών, καθώς και να προβλέπουν την εξέλιξη μιας μεταβλητής. Η ανάλυση αιτιότητας και η ανάλυση χρονολογικών σειρών ειδικότερα είναι πεδία της Οικονομετρίας, των οποίων οι βάσεις βρίσκονται στη Στατιστική, αλλά αναπτύχθηκαν περισσότερο εντός αυτού του επιστημονικού πεδίου που ονομάζουμε Οικονομετρία. Η παραδοσιακή Οικονομετρία περιλαμβάνει τα ακόλουθα βήματα:

1. Δηλώνει το μαθηματικό υπόδειγμα της θεωρίας που επιθυμεί να εξετάσει.
2. Κατασκευάζει το οικονομετρικό υπόδειγμα μέσα από το οποίο προσεγγίζει αυτή τη θεωρία.
3. Εκτιμά τις παραμέτρους του οικονομετρικού υποδείγματος με τα δεδομένα που έχει επιλέξει.
4. Κάνει έλεγχο υποθέσεων για το συνολικό υπόδειγμα και για τις επιμέρους παραμέτρους του.
5. Χρησιμοποιεί το οικονομετρικό υπόδειγμα για να κάνει προβλέψεις οι οποίες θα είναι χρήσιμες για άσκηση πολιτικής ή για έλεγχο και επιβεβαίωση της επιστημονικής θεωρίας που εξετάζεται, μέσα από την οποία προάγεται και εξελίσσεται η επιστημονική γνώση.

ΜΕΡΟΣ Α'

ΒΑΣΙΚΑ ΕΡΓΑΛΕΙΑ ΠΕΡΙΓΡΑΦΙΚΗΣ ΣΤΑΤΙΣΤΙΚΗΣ

Η Στατιστική διακρίνεται σε *περιγραφική* (descriptive) και *επαγωγική* (inductive). Η περιγραφική Στατιστική «περιγράφει» τα δεδομένα που έχουν συλλεχθεί προς μελέτη ως προς τα χαρακτηριστικά τους, ενώ η επαγωγική Στατιστική ασχολείται με την εξαγωγή συμπερασμάτων που αντλούνται από ένα δείγμα (sample) και αφορούν τον συνολικό πληθυσμό (population) που μελετάται. Το δείγμα αποτελεί υποσύνολο του πληθυσμού και στο πλαίσιο των περισσότερων ερευνών είμαστε αναγκασμένοι να εργαστούμε πάνω σε κάποιο δείγμα, αφού είναι αδύνατον να συμπεριλάβουμε όλο τον πληθυσμό λόγω του μεγέθους του ή/και της αδυναμίας συγκέντρωσης δεδομένων για το σύνολο του πληθυσμού.

Ποσοτικά και ποιοτικά δεδομένα

Τα στατιστικά δεδομένα διακρίνονται σε *ποσοτικά* (quantitative) και *ποιοτικά* (qualitative). Ποσοτικά είναι τα δεδομένα τα οποία αντιπροσωπεύονται με αριθμούς και κάνουν χρήση αντικειμενικών κλιμάκων μέτρησης. Για παράδειγμα, το μήκος συνηθίζουμε να το μετράμε σε μέτρα και εκατοστά ή σε γιάρδες και ίντσες, τα οποία εκφράζονται μέσω κάποιου αριθμού· το βάρος το μετράμε σε κιλά ή ουγκιές, τα οποία και αυτά εκφράζονται μέσω κάποιου αριθμού· την ηλικία την υπολογίζουμε με έτη, τις ημέρες ηλιοφάνειας με αριθμό· ο αριθμός τουριστικών αφίξεων και διανυκτερεύσεων είναι ποσοτικές μετρήσεις του εισερχόμενου τουρισμού σε ένα γεωγραφικό διαμέρισμα ή σε μια χώρα. Όλα αυτά είναι αριθμητικά στοιχεία ή αλλιώς ποσοτικά στοιχεία και εκφράζονται με συνεχείς μεταβλητές.

Υπάρχουν όμως και δεδομένα τα οποία είναι ποιοτικά και διατυπώνονται μέσω κάποιων πιο υποκειμενικών, λεκτικών κλιμάκων. Για παράδειγμα, στην ερώτηση «Πόσο ικανοποιημένος είσαι από τις διακοπές σου στην Ελλάδα;», ο ερωτώμενος πρέπει να επιλέξει μεταξύ των ακόλουθων απαντήσεων: Καθόλου, Πολύ λίγο, Λίγο, Πολύ, Πάρα πολύ, Πλήρως. Αυτές οι απαντήσεις είναι ποιοτικού χαρακτήρα (ιεραρχικές μεταβλητές) και τα δεδομένα που τις περιγράφουν λέγονται ποιοτικά.

Υπάρχουν επίσης και μεταβλητές οι οποίες περιγράφονται μέσω διαστημάτων, όπως για παράδειγμα όταν κάνουμε την ερώτηση «Σε ποια ηλικιακή ομάδα ανήκετε;», στην οποία χρησιμοποιείται η συγκεκριμένη λεκτική διατύπωση για να μη φέρουμε σε δύσκολη θέση κάποιον που δεν θέλει να αποκαλύψει ακριβώς την ηλικία του (π.χ. είμαι 45 χρονών)· έτσι, ο ερωτώμενος νιώθει πιο άνετα να απαντήσει ότι ανήκει στην ηλικιακή ομάδα μεταξύ 40-50 ετών. Αυτές οι μεταβλητές είναι ένα παράδειγμα ποιοτικών (qualitative) ή αλλιώς διακριτών (discrete) μεταβλητών.

Τυχαία δειγματοληψία

Το σύνολο των μετρήσεων που αφορούν μια μεταβλητή ονομάζεται στη Στατιστική *πληθυσμός*. Για παράδειγμα, αν η μεταβλητή μας είναι πόσο ξοδεύουν οι τουρίστες κατά τη διάρκεια των διακοπών τους στο Ηράκλειο Κρήτης, κατά τους μήνες Ιούνιο έως Σεπτέμβριο του 2018, τότε ο πληθυσμός είναι οι μετρήσεις δαπανών που είχαν *όλοι* οι τουρίστες οι οποίοι επισκέφτηκαν το Ηράκλειο Κρήτης εκείνη την περίοδο. Η έννοια του πληθυσμού στη Στατιστική δεν σημαίνει απαραίτητα ένα πλήθος ανθρώπων, αλλά εν γένει περιπτώσεων και μετρήσεων. Επειδή είναι αδύνατον να εντοπιστούν όλα τα μέλη του πληθυσμού, αλλά και ταυτόχρονα υπάρχουν χρονικοί και οικονομικοί περιορισμοί που μας εμποδίζουν να κάνουμε κάτι τέτοιο, στη Στατιστική και την Οικονομετρία επιλέγουμε να δουλεύουμε με τυχαία δείγματα του πληθυσμού. Η *τυχαία δειγματοληψία* (random sampling) αναφέρεται σε

τεχνική κατά την οποία κάθε δείγμα έχει την ίδια πιθανότητα να επιλεγεί μέσα από τον πληθυσμό.

Και φυσικά όταν ένα δείγμα έχει φτιαχτεί με τη μέθοδο της τυχαίας δειγματοληψίας, αυτό σημαίνει ότι είναι μία ακριβής απεικόνιση του πληθυσμού. Αν δεν ισχύει αυτό, τότε έχουμε *σφάλμα δειγματοληψίας* (sampling error). Ένα παράδειγμα τυχαιότητας δείγματος έχουμε κατά την επιλογή των αριθμών σε μια κληρωτίδα ή στην εμφάνιση ενός αριθμού σε ένα ζάρι. Η κανονική κατανομή για την οποία θα αναφερθούμε αναλυτικότερα στην επόμενη ενότητα αποτελεί μια πρώτη περιγραφή τυχαίων μεταβλητών πραγματικών τιμών (τυχαίων φαινομένων), οι οποίες τείνουν να συγκεντρώνονται γύρω από τη μέση τιμή του πληθυσμού.¹

Τα τρία χαρακτηριστικά στοιχεία που μας ενδιαφέρουν όταν μελετάμε κάποια δεδομένα είναι η *κεντρική τάση και θέση* (central tendency and location), η *διακύμανση* (variation) και το *σχήμα της κατανομής* τους (shape). Αυτά τα χαρακτηριστικά περιγράφονται από συγκεκριμένα στατιστικά μεγέθη.

Μέτρα κεντρικής τάσης ή θέσης (Measures of Central Tendency or Location)

Τα συνήθη περιγραφικά στατιστικά μέτρα των δειγμάτων, καθώς και τα στατιστικά εργαλεία και οι έννοιες που χρησιμοποιούνται σε απλές έρευνες παρουσιάζονται ακολούθως.

ι) Η κατανομή συχνότητας

Αν τοποθετήσουμε τις παρατηρήσεις ενός δείγματος σε αύξουσα σειρά π.χ., $x_1 < x_2 < \dots < x_n$, τότε κατανομή ονομάζουμε το πλήθος των παρατηρήσεων που παίρνουν τιμή, $x_1, x_2, \dots, x_n$. Επομένως, έστω ότι η ακόλουθη σειρά τιμών αντιπροσωπεύει την ημερήσια δαπάνη δέκα τουριστών στα Χανιά, τον μήνα Αύγουστο του 2019, σε ευρώ: 50, 50, 58, 63, 63, 63, 68, 70, 70, 71. Τότε, η συχνότητα της δαπάνης των 50€ είναι 2 (δηλαδή, αυτή η τιμή τουριστικής δαπάνης εμφανίζεται 2 φορές στο δείγμα), η συχνότητα της δαπάνης 58€ είναι 1 (δηλαδή εμφανίζεται 1 φορά στο δείγμα), η συχνότητα της δαπάνης 63€ είναι 3 (δηλαδή εμφανίζεται 3 φορές στο δείγμα) κ.ο.κ.


Αξίζει να σημειώσουμε σε αυτό το σημείο ότι κάποιες φορές χρησιμοποιείται και η έννοια της *σχετικής συχνότητας* (relevant frequency) έναντι της *απόλυτης συχνότητας* (absolute frequency), η οποία διαιρείται με το πλήθος του δείγματος. Επο-

1. Η κανονική κατανομή μαζί με το Κεντρικό Οριακό Θεώρημα (Central Limit Theorem - CLT) αποτελούν τη βάση της επαγωγικής Στατιστικής. Σύμφωνα με το Κεντρικό Οριακό Θεώρημα, όσο μεγαλώνει το δείγμα μιας μεταβλητής, τότε η κατανομή αυτής της μεταβλητής τείνει προς την κανονική κατανομή (αυτή με το σχήμα της καμπάνας). Στο πλαίσιο αυτού του κεφαλαίου δεν θα αναφερθούμε περισσότερο στο Κεντρικό Οριακό Θεώρημα.

μένως, αναφορικά με το ανωτέρω παράδειγμα, η σχετική συχνότητα της δαπάνης των 50€ των τουριστών είναι $2/10$, η σχετική συχνότητα της δαπάνης 58€ των τουριστών είναι $1/10$ κ.ο.κ. Η πινακοποίηση αυτών των δεδομένων (στον Πίνακα 13.1) ονομάζεται *κατανομή συχνότητας* (frequency distribution) και η τοποθέτησή τους πάνω σε ένα διάγραμμα ονομάζεται *διάγραμμα συχνότητας* (βλέπε Σχήμα 13.1) ή *ιστόγραμμα* (histogram). Η κατανομή συχνότητας είναι ένα πολύ χρήσιμο εργαλείο, διότι μας δίνει σε έναν πίνακα το πόσες φορές εμφανίζεται η κάθε τιμή του δείγματος, δηλαδή μας δίνει μια άμεση εποπτική εικόνα του δείγματος.


Πίνακας 13.1 Παράδειγμα πίνακα συχνότητας

Τουριστική δαπάνη σε €	Απόλυτη συχνότητα	Σχετική συχνότητα
50	2	$2/10$
58	1	$1/10$
63	3	$3/10$
68	1	$1/10$
70	2	$2/10$
71	1	$1/10$



Σχήμα 13.1 Διάγραμμα στηλών για την κατανομή της τουριστικής δαπάνης

Όμως, πιο συχνά χρησιμοποιούμε στα εφαρμοσμένα οικονομικά τον όρο *αθροιστική κατανομή* (cumulative frequency of distribution). Με αυτό το στατιστικό μπορούμε να υπολογίσουμε για κάθε τουριστική δαπάνη του δείγματος πόσοι τουρίστες βρίσκονται κάτω από μια δεδομένη τιμή δαπάνης. Επομένως, δαπάνη μικρότερη των 63€ έχουν 3 τουρίστες, δηλαδή έχουμε 2 τουρίστες με δαπάνη που ισούται με 50€ και έναν τουρίστα με δαπάνη 58€. Διαπιστώνουμε στο Σχήμα 13.2 ότι η αθροιστική κατανομή έχει διαρκώς μια αύξουσα πορεία, διότι σε κάθε σημείο της περιλαμβάνει το άθροισμα των συχνοτήτων όλων των προηγούμενων κατηγοριών.



Σχήμα 13.2 Διάγραμμα αθροιστικής κατανομής για την κατανομή της τουριστικής δαπάνης

Σημείωση: σε κάποιες παραλλαγές στο Σχήμα 13.2 μπορεί να υπάρχει και γραμμή η οποία ενώνει τις κλάσεις (κατηγορίες) της κατανομής.

ii) Μέσος όρος ή μέση τιμή

Είναι ο μέσος όρος (mean, average) των τιμών του δείγματος. Υπολογίζεται ως το άθροισμα όλων των τιμών διαιρεμένων διά το πλήθος τους. Δηλαδή ισχύει η σχέση 13.1:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (13.1)$$

όπου x η δαπάνη των τουριστών και i ο τουρίστας.

Εφαρμογή

Στο προαναφερθέν παράδειγμα με την τουριστική δαπάνη, η μέση τιμή είναι ίση με:

$$\frac{50 + 50 + 58 + 63 + 63 + 63 + 68 + 70 + 70 + 71}{10} = \frac{626}{10} = 62,6\text{€}$$

Σταθμικός μέσος

Αν σε ένα δείγμα χρειάζεται να δώσουμε μεγαλύτερη βαρύτητα σε ορισμένες τιμές, τότε χρησιμοποιούμε τον *σταθμικό μέσο* (weighted mean), ο οποίος εφαρμόζει συγκεκριμένες σταθμίσεις - βάρη (weights) ή αλλιώς συντελεστές βαρύτητας στις τιμές, και στη συνέχεια εφαρμόζει τον τύπο της μέσης τιμής. Οι σταθμίσεις είναι συνήθως υποκειμενικές. Ο τύπος του σταθμικού μέσου αποτυπώνεται στη σχέση 13.2:

$$\bar{x} = \frac{\sum_{i=1}^k (w_i x_i)}{\sum_{i=1}^k (w_i)} \quad (13.2)$$

όπου w είναι η στάθμιση. Συνεπώς, ο απλός μέσος όρος είναι υποπερίπτωση του σταθμικού μέσου, όπου τα βάρη είναι ίσα μεταξύ τους.

Εφαρμογή

Έστω για παράδειγμα ότι οι τουριστικές αρχές των Χανίων δίνουν μεγάλη έμφαση στους Κινέζους τουρίστες, των οποίων ο αριθμός είναι πολύ μικρός στα Χανιά. Έτσι, θέλουν να δώσουν μεγαλύτερη (π.χ. διπλή) στάθμιση στην τουριστική δαπάνη που προέρχεται από Κινέζους. Έστω ότι οι τρεις πρώτες δαπάνες προέρχονται από Κινέζους τουρίστες, δηλαδή οι δαπάνες 50, 50 και 58 (*σημείωση*: τα νούμερα αυτά επιλέχθηκαν τυχαία). Ο σταθμικός μέσος όρος υπολογίζεται ως εξής:

$$\frac{(2) \times (50) + (2) \times (50) + (2) \times (58) + (1) \times (63) + (1) \times (63) + (1) \times (63) + (1) \times (68) + (1) \times (70) + (1) \times (70) + (1) \times (71)}{13} = \frac{787}{13} = 60,53$$

Δίνοντας μεγαλύτερη βαρύτητα στη δαπάνη των Κινέζων τουριστών (πολλαπλασιάζοντας τις τρεις πρώτες δαπάνες με το 2), έχουμε ως αποτέλεσμα ο σταθμικός μέσος όρος να είναι μικρότερος από τον απλό μέσο όρο.

iii) Κεντρική τιμή ή επικρατούσα τιμή

Κεντρική ή επικρατούσα τιμή (Mode, M_0) είναι η συχνότερη τιμή που εμφανίζεται στο δείγμα. Αν οι συχνότερες τιμές που εμφανίζονται σε ένα δείγμα είναι δύο, τότε λέμε ότι το δείγμα είναι bimodal (με δύο κεντρικές τιμές).

Εφαρμογή

Στο προηγούμενο παράδειγμα με τη δαπάνη των τουριστών στα Χανιά, η κεντρική τιμή είναι ίση με: $M_0 = 63$ ευρώ.

iv) Διάμεσος

Έστω ότι οι τιμές του δείγματος ταξινομούνται από τη μικρότερη στη μεγαλύτερη. Η διάμεσος (median, δ) πρόκειται για την τιμή που βρίσκεται στη μέση του ιεραρχημένου αυτού πλήθους τιμών και χωρίζει τις τιμές του δείγματος σε δύο ίσα σύνολα. Η γνώση αυτού του μέτρου είναι πιο χρήσιμη όταν υπάρχουν ακραίες τιμές (extreme values ή outliers) στο δείγμα. Η θέση της διαμέσου υπολογίζεται με χρήση του τύπου $\frac{n+1}{2}$, όπου n = το μέγεθος του δείγματος.

Εφαρμογή

Στο παράδειγμα με την τουριστική δαπάνη το οποίο αποτελείται από 10 παρατηρήσεις, η διάμεσος είναι ο μέσος της 5ης και της 6ης παρατήρησης, δηλαδή $63 + 63 / 2 = 63$. Αν το δείγμα είχε 9 παρατηρήσεις, η διάμεσος θα ήταν η 5η παρατήρηση, δηλαδή πάλι το 63.

Επομένως, αν το μέγεθος του δείγματος είναι μονός αριθμός, η διάμεσος αντιπροσωπεύεται από τη σειρά του αριθμού που δίνεται από τον τύπο $\frac{n+1}{2}$. Αν όμως το μέγεθος του δείγματος είναι ζυγός αριθμός, η διάμεσος αντιπροσωπεύεται από τον μέσο όρο των δύο τιμών που βρίσκονται στη μέση της σειράς των αριθμών.

Παρατήρηση

Παρατηρούμε ότι στο συγκεκριμένο παράδειγμα ισχύει ότι ο μέσος όρος $\bar{x} = 62,6 < \text{Διάμεσος} = \delta = 63$. Σχόλιο: Ο $\bar{x}$ επηρεάζεται από υψηλές ακραίες τιμές του δείγματος (μεγάλες ή μικρές).

Μέτρα διασποράς ή θέσης

(Measures of Variation, Dispersion, Location)

v) Εύρος

Περιγράφει το εύρος (range) των τιμών ενός δείγματος μεταξύ της μικρότερης και της μεγαλύτερης τιμής. Υπολογίζεται με αφαίρεση της μικρότερης από τη μεγαλύτερη τιμή.


Εφαρμογή

Στο παράδειγμα με την τουριστική δαπάνη το οποίο αποτελείται από 10 παρατηρήσεις, το εύρος είναι η διαφορά της μικρότερης από τη μεγαλύτερη δαπάνη, δηλαδή: $\text{Εύρος} = 71 - 50 = 21$.

vi) Τεταρτημόρια κ.ά.

Λιγότερο συχνά, χρησιμοποιούνται ως στατιστικά διασποράς ή θέσης τα *τεταρτημόρια* (quartiles), τα οποία μπορεί εύκολα και αμέσως να φανταστεί κάποιος ότι είναι *τέσσερα* στον αριθμό και συμβολίζονται ως Q_1 , Q_2 , Q_3 . Το Q_4 δεν το γράφουμε διότι συμπίπτει με ολόκληρο το δείγμα. Τα τεταρτημόρια χωρίζουν το δείγμα σε *τέσσερα* ακριβώς ίσα κομμάτια ως εξής (βλέπε Σχήμα 13.3):

- Q_1 : το πρώτο τεταρτημόριο είναι εκείνη η τιμή του δείγματος, αριστερά της οποίας βρίσκεται το 25% του συνολικού αριθμού των τιμών. Συχνά, πρέπει να υπολογιστεί κατά προσέγγιση ως μία διάμεσος του πρώτου μισού των ιεραρχημένων παρατηρήσεων. Στο παράδειγμά μας $Q_1 = 58$.
- Q_2 : το δεύτερο τεταρτημόριο συμπίπτει με τη διάμεσο που αναφέραμε προηγουμένως, δηλαδή είναι μία τιμή αριστερά της οποίας βρίσκεται το 50% του συνολικού αριθμού των δεδομένων και δεξιά της το υπόλοιπο 50% των δεδομένων. Δηλαδή το Q_2 ισούται με τη συνολική διάμεσο. Στο παράδειγμά μας $Q_2 = 63$.
- Q_3 : το τρίτο τεταρτημόριο είναι μια τιμή, αριστερά της οποίας βρίσκεται το 75% των παρατηρήσεων. Συχνά, πρέπει να υπολογιστεί κατά προσέγγιση ως μία διάμεσος του δεύτερου μισού των ιεραρχημένων παρατηρήσεων. Στο παράδειγμά μας $Q_3 = 70$.



Σχήμα 13.3 Επεξηγηματική απεικόνιση τεταρτημορίων

Για περισσότερη ευκολία στον υπολογισμό τους, η θέση του πρώτου τεταρτημορίου βρίσκεται υπολογισμένη ως $(N+1)/4$ και η θέση του τρίτου τεταρτημορίου ως $3(N+1)/4$. Η θέση του δεύτερου τεταρτημορίου, το οποίο συμπίπτει με τη διάμεσο, ισούται με $(N+1)/2$.

Τα τεταρτημόρια διευκολύνουν στον υπολογισμό δύο ακόμη μέτρων τα οποία είναι ανθεκτικά στην ύπαρξη ακραίων τιμών (outliers). Αυτά τα μέτρα είναι το

midrange (ο μέσος όρος της ελάχιστης και μέγιστης τιμής) και το midhinge (ο μέσος όρος 1ου και 3ου τεταρτημορίου, αντίστοιχα), αλλά αυτά χρησιμοποιούνται πιο σπάνια. Ακολουθούν οι μαθηματικές μορφές τους στις σχέσεις 13.3 και 13.4:

$$Midrange = \frac{x_{\text{μικρότερο}} + x_{\text{μεγαλύτερο}}}{2} \quad (13.3)$$

$$Midhinge = \frac{Q_1 + Q_3}{2} \quad (13.4)$$

Σημειώνουμε ότι πέραν των τεταρτημορίων τα οποία χωρίζουν το δείγμα σε τέσσερα κομμάτια, μπορούμε να χωρίσουμε το δείγμα σε οποιαδήποτε άλλη υποδιαίρεση (quantiles). Αν το δείγμα χωριστεί σε 5 τμήματα (μέσω τεσσάρων ορίων - διαχωριστικών σημείων), το κάθε πέμπτο περιλαμβάνει το 20% των παρατηρήσεων· αν το δείγμα χωριστεί σε 10 τμήματα (μέσω εννέα ορίων - διαχωριστικών σημείων), το κάθε δέκατο περιλαμβάνει το 10% των παρατηρήσεων κ.τ.λ. Μπορούμε να κρατήσουμε στο μυαλό μας τον παρακάτω γενικό τύπο υπολογισμού των οποιωνδήποτε υποδιαιρέσεων, π.χ. πεντημορίων δείγματος.

$Q \cdot N / (\text{πλήθος μικρότερων δειγμάτων στα οποία χωρίζουν το συνολικό δείγμα})$, όπου Q είναι η ιεράρχηση π.χ. του πεντημορίου, 1ο, 2ο, 3ο, 4ο κ.λπ., N το μέγεθος του δείγματος και το πλήθος των μικρότερων δειγμάτων στα οποία χωρίζεται ένα δείγμα (βάσει πεντημορίων ισούται με 5). Παρακάτω ακολουθεί εφαρμογή για εμπέδωση.

Εφαρμογή

Έστω οι ιεραρχημένες τιμές της τουριστικής δαπάνης των 10 τουριστών του προηγούμενου παραδείγματος: 50, 50, 58, 63, 63, 63, 68, 70, 70, 71. Ας δοκιμάσουμε να βρούμε τα πεντημόρια και τα δεκατημόρια.

Πεντημόρια (quintiles): πρόκειται για τέσσερις τιμές που χωρίζουν το δείγμα σε 5 ίσα τμήματα. Το κάθε πεντημόριο περιέχει το 20% των τιμών του δείγματος.

Q_1 : $N/5 = 10/5 = 2$ (2η τιμή), δηλ. $Q_1 = 50$, που σημαίνει ότι το 20% των τουριστών ξοδεύει μέχρι 50€.

Q_2 : $2N/5 = (2 \cdot 10)/5 = 20/5 = 4$ (4η τιμή), δηλ. $Q_2 = 63$, που σημαίνει ότι το 40% των τουριστών ξοδεύει μέχρι 63€.

Q_3 : $3N/5 = (3 \cdot 10)/5 = 30/5 = 6$ (6η τιμή), δηλ. $Q_3 = 63$, που σημαίνει ότι το 60% των τουριστών ξοδεύει μέχρι 63€.

Q_4 : $4N/5 = (4 \cdot 10)/5 = 40/5 = 8$ (8η τιμή), δηλ. $Q_4 = 70$, που σημαίνει ότι το 80% των τουριστών ξοδεύει μέχρι 70€.

Δεκατημόρια (deciles): πρόκειται για εννέα τιμές που χωρίζουν το δείγμα σε 10 ίσα τμήματα. Το κάθε δεκατημόριο περιέχει το 10% των τιμών του δείγματος. Από τον αγγλικό όρο deciles μπορούμε να χρησιμοποιήσουμε και το σύμβολο D_1 εναλλακτικά του Q_1 .

Q_1 : $N/10=10/10=1$ (1η τιμή), δηλ. $Q_1=50$, που σημαίνει ότι το 10% των τουριστών ξοδεύει μέχρι 50€.

Q_2 : $2N/10= (2*10)/10=20/10=2$ (2η τιμή), δηλ. $Q_2=50$, που σημαίνει ότι το 20% των τουριστών ξοδεύει μέχρι 50€.

Q_3 : $3N/10= (3*10)/10=30/10=3$ (3η τιμή), δηλ. $Q_3=58$, που σημαίνει ότι το 30% των τουριστών ξοδεύει μέχρι 58€.

Q_4 : $4N/10= (4*10)/10=40/10=4$ (4η τιμή), δηλ. $Q_4=63$, που σημαίνει ότι το 40% των τουριστών ξοδεύει μέχρι 63€.

Q_5 : $5N/10= (5*10)/10=50/10=5$ (5η τιμή), δηλ. $Q_5=63$, που σημαίνει ότι το 50% των τουριστών ξοδεύει μέχρι 63€.

Q_6 : $6N/10= (6*10)/10=60/10=6$ (6η τιμή), δηλ. $Q_6=63$, που σημαίνει ότι το 60% των τουριστών ξοδεύει μέχρι 63€.

Q_7 : $7N/10= (7*10)/10=70/10=7$ (7η τιμή), δηλ. $Q_7=68$, που σημαίνει ότι το 70% των τουριστών ξοδεύει μέχρι 68€.

Q_8 : $8N/10= (8*10)/10=80/10=8$ (8η τιμή), δηλ. $Q_8=70$, που σημαίνει ότι το 80% των τουριστών ξοδεύει μέχρι 70€.

Q_9 : $9N/10= (9*10)/10=90/10=9$ (9η τιμή), δηλ. $Q_9=70$, που σημαίνει ότι το 90% των τουριστών ξοδεύει μέχρι 70€.

vii) Διακύμανση ή διασπορά

Η μέτρηση της διακύμανσης ή διασποράς (variance, dispersion) υπολογίζει την απόκλιση (απόσταση) κάθε τιμής από τον μέσο όρο και την υψώνει στο τετράγωνο. Στη συνέχεια αθροίζονται τα τετράγωνα των αποκλίσεων και υπολογίζεται η διακύμανση. Η διακύμανση μετρά πόσο μακριά βρίσκονται οι τιμές ενός δείγματος από τη μέση τιμή του δείγματος. Συμβολίζεται με σ^2 ή $\text{Var}(x)$ από τον αγγλικό όρο variance, ενώ σε κάποια βιβλία μπορεί να το συναντήσουμε και ως $\text{dis}(x)$. Είναι η σχέση 13.5:

$$\sigma^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n - 1} = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1} \quad (13.5)$$

Όπου $\bar{x}$ ο αριθμητικός μέσος, n το μέγεθος δείγματος, $x_1, x_2, \dots, x_n$ οι τιμές που παίρνει η μεταβλητή x .

Σημείωση: διαιρώντας με $n - 1$ υπολογίζουμε τη δειγματική διακύμανση, ενώ διαιρώντας με n υπολογίζουμε την πληθυσμιακή.

Εφαρμογή

Ας παραμείνουμε στο προαναφερθέν παράδειγμα με την τουριστική δαπάνη, η οποία αποτελείται από 10 παρατηρήσεις με μέση τιμή τα 62,6€. Παίρνουμε κάθε τιμή του δείγματος και από αυτήν αφαιρούμε τον μέσο. Στη συνέχεια υψώνουμε τη διαφορά στο τετράγωνο και τέλος αθροίζουμε όλα τα τετράγωνα. Οι πράξεις φαίνονται αναλυτικά στον Πίνακα 13.2.

Πίνακας 13.2 Αναλυτικός υπολογισμός διακύμανσης

Τουριστική δαπάνη σε €	Διαφορά κάθε τιμής x από τον μέσο όρο $\bar{x} = 62,6$ δηλαδή $x - \bar{x}$	Ύψωση της διαφοράς $x - \bar{x}$ στο τετράγωνο, δηλαδή $(x - \bar{x})^2$
50	$50 - 62,6 = -12,6$	$(-12,6)^2 = 158,76$
50	$50 - 62,6 = -12,6$	$(-12,6)^2 = 158,76$
58	$58 - 62,6 = -4,6$	$(-4,6)^2 = 21,16$
63	$63 - 62,6 = 0,4$	$(0,4)^2 = 0,16$
63	$63 - 62,6 = 0,4$	$(0,4)^2 = 0,16$
63	$63 - 62,6 = 0,4$	$(0,4)^2 = 0,16$
68	$68 - 62,6 = 5,4$	$(5,4)^2 = 29,16$
70	$70 - 62,6 = 7,4$	$(7,4)^2 = 54,76$
70	$70 - 62,6 = 7,4$	$(7,4)^2 = 54,76$
71	$71 - 62,6 = 8,4$	$(8,4)^2 = 70,56$
	Διακύμανση=	548,40

viii) Τυπική απόκλιση

Τυπική απόκλιση (standard deviation) είναι η τετραγωνική ρίζα της διακύμανσης. Συμβολίζεται με $S = \sqrt{\sigma^2}$ και ορίζεται ως:

$$S = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}} \quad (13.6)$$

Εφαρμογή

Στο ανωτέρω παράδειγμα της τουριστικής δαπάνης, προκύπτει ότι

$$S = \sqrt{548,40} = 23,41$$

ix) Συντελεστής μεταβλητότητας

Συντελεστής μεταβλητότητας (Coefficient of Variation - CV) είναι ο λόγος της τυπικής απόκλισης προς τη μέση τιμή, δηλαδή $CV = \frac{s}{\bar{x}}$. Ο συντελεστής μεταβλητότητας ποσοτικοποιεί πολύ καλύτερα αυτό που διαισθητικά αντιλαμβανόμαστε ως διακύμανση και μεταβλητότητα. Συχνά το συναντάμε και σε ποσοστιαία έκφραση, δηλαδή με τη μορφή:

$$CV = \frac{s}{\bar{x}} * 100\% \quad (13.7)$$

Όταν ο συντελεστής μεταβλητότητας δεν ξεπερνά το 10%, δεχόμαστε ότι πρόκειται για ένα δείγμα ομοιογενές. Ο συντελεστής μεταβλητότητας πρόκειται για ένα περιγραφικό μέτρο σχετικής μεταβλητότητας (relative variation). Αυτό το μέτρο είναι χρήσιμο για τη σύγκριση δύο ή περισσότερων δειγμάτων.

Εφαρμογή

Στο προαναφερθέν παράδειγμα της τουριστικής δαπάνης η οποία αποτελείται από 10 παρατηρήσεις με μέση τιμή το 62,6 και τυπική απόκλιση ίση με $s=23,41$, ο συντελεστής μεταβλητότητας ισούται με $CV=23,41/62,6=37\%$. Αυτό δείχνει ότι η τουριστική δαπάνη δεν παρουσιάζει ομοιογένεια.

x) Ροπές

Η μέση τιμή και η διασπορά ορίζονται ως *ροπή* (moment) πρώτης και δεύτερης τάξης, αντίστοιχα. Ως ροπή πρώτης τάξης ορίζουμε την $E(X^n)$ και ως ροπή n -στής τάξης (από τον μέσο) ορίζουμε τη σχέση 13.8:

$$\mu_n = E[(x - \mu_x)^n] \text{ για κάθε τάξη } n \quad (13.8)$$

Εφαρμογή

Στο προαναφερθέν παράδειγμα με την τουριστική δαπάνη 50, 58, 63, 63, 63, 68, 70, 70, 71, η οποία αποτελείται από 10 παρατηρήσεις με μέση τιμή το 62,6:

Η πρώτη ροπή ισούται με τον μέσο όρο, όπως φαίνεται στη σχέση 13.9.

$$E(x^1) = \bar{x} \quad (13.9)$$

Η δεύτερη ροπή $E(x^2)$ ισούται με τη σχέση 13.10.

$$\frac{\Sigma x^2}{N} = \frac{50^2 + 50^2 + 58^2 + 63^2 + 63^2 + 63^2 + 68^2 + 70^2 + 70^2 + 71^2}{10} = \frac{39736}{10} = 3973,6 \quad (13.10)$$

Η τρίτη ροπή $E(x^3)$ ισούται με τη σχέση 13.11.

$$\begin{aligned} \frac{\Sigma x^3}{N} &= \frac{50^3 + 50^3 + 58^3 + 63^3 + 63^3 + 63^3 + 68^3 + 70^3 + 70^3 + 71^3}{10} = \frac{2553596}{10} = \\ &= 255359,6 \text{ κ.τ.λ.} \end{aligned} \quad (13.11)$$

Η πρώτη ροπή από τον μέσο $E[(x - \mu)^1]$ δίνεται από τη 13.12 με:

$$\begin{aligned} \frac{\Sigma(x - \bar{x})}{N} &= \frac{(50 - 62,6) + (50 - 62,6) + (58 - 62,6) + (63 - 62,6) + (63 - 62,6) + \\ &+ (63 - 62,6) + (68 - 62,6) + (70 - 62,6) + (70 - 62,6) + (71 - 62,6)}{10} = \\ &= \frac{0}{10} = 0 \end{aligned} \quad (13.12)$$

Η δεύτερη ροπή από τον μέσο $E[(x - \mu)^2]$ ισούται με τη 13.13:


$$\begin{aligned} \frac{\Sigma(x - \bar{x})^2}{N} &= \frac{(50 - 62,6)^2 + (50 - 62,6)^2 + (58 - 62,6)^2 + (63 - 62,6)^2 + (63 - 62,6)^2 + \\ &+ (63 - 62,6)^2 + (68 - 62,6)^2 + (70 - 62,6)^2 + (70 - 62,6)^2 + (71 - 62,6)^2}{10} = \\ &= \frac{548,4}{10} = 54,84 \text{ κ.τ.λ.} \end{aligned} \quad (13.13)$$

Μέτρα ασυμμετρίας (Measures of skewness)

xi) Λοξότητα και κύρτωση

Μια κατανομή στοιχείων δείγματος λέγεται κανονική όταν έχει σχήμα καμπάνας. Η κανονική κατανομή είναι συμμετρική και με σημείο αναφοράς αυτήν συγκρίνουμε άλλες κατανομές ως προς τη *λοξότητα* (skewness) και την *κύρτωση* (curtosis) τους.

Η λοξότητα (ουρά είτε προς τα αριστερά ή προς τα δεξιά), καθώς και η κύρτωση (η συγκέντρωση της μάζας της κατανομής) περιγράφουν την όψη μιας κατανομής όταν χαρακτηρίζεται από α-συμμετρία. Δηλαδή, δίνουν τον βαθμό αυτής της έλλειψης συμμετρίας.



Σχήμα 13.4 Παράδειγμα κανονικής κατανομής (Μέρος Α'),
θετικής λοξότητας (Μέρος Β') και αρνητικής λοξότητας (Μέρος Γ')


Θετική λοξότητα: σημαίνει ότι η κατανομή παρουσιάζει μεγαλύτερη ουρά στα δεξιά και ότι η κύρια μάζα της κατανομής συγκεντρώνεται στα αριστερά (δεξιό-κυρτη κατανομή). Σε αυτή την περίπτωση ο μέσος όρος είναι μεγαλύτερος από τη διάμεσο.

Αρνητική λοξότητα: σημαίνει ότι η κατανομή έχει την ουρά της στα αριστερά και ότι η κύρια μάζα της κατανομής συγκεντρώνεται στα δεξιά (αριστερό-κυρτη κατανομή). Σε αυτή την περίπτωση ο μέσος όρος είναι μικρότερος από τη διάμεσο.

Η κύρτωση έχει την έννοια της καμπυλότητας και της σχετικής συγκέντρωσης τιμών στις ουρές της κατανομής. Πρόκειται για ένα περιγραφικό μέτρο που ασχολείται με τη μάζα που υπάρχει στις ουρές της κατανομής και την κορύφωση της κατανομής (Σχήμα 13.4). Η κύρτωση είναι αποτέλεσμα ακραίων τιμών (outliers).

Ουσιαστικά, η κύρτωση περιγράφει το πόσο μυτερή είναι η κατανομή σε σχέση με την κανονική κατανομή. Στο Σχήμα 13.5 βλέπουμε πέντε παραδείγματα κυρτότητας κατανομής. Όσο πιο μυτερή είναι η κατανομή, λέγεται λεπτόκυρτη (ή με θε-


τική κύρτωση) και όσο πιο πλατιά είναι, λέγεται πλατύκυρτη (ή με αρνητική κύρτωση). Μια ενδιάμεση περίπτωση καμπύλης που δεν είναι ούτε πολύ μυτερή, ούτε πολύ πλατιά, λέγεται μεσόκυρτη. Υπάρχουν διάφορα στατιστικά με τα οποία υπολογίζουμε επακριβώς την ασυμμετρία (λοξότητα και κύρτωση) μιας καμπύλης κατανομής, αλλά στο πλαίσιο αυτού του κεφαλαίου δεν θα τα αναφέρουμε.



Σχήμα 13.5 Παραδείγματα κύρτωσης
(λεπτόκυρτες, μεσόκυρτες και πλατύκυρτες κατανομές)

Εφαρμογή

Στο παράδειγμα της τουριστικής δαπάνης, η κατανομή φαίνεται στην καμπύλη του Σχήματος 13.6. Πώς θα σχολιάζατε τη συμμετρία (ή ασυμμετρία) της;



Σχήμα 13.6 Η κατανομή της τουριστικής δαπάνης του παραδείγματος

Παρατηρούμε ότι πρόκειται για πλατύκυρτη κατανομή με ανεπαίσθητη αρνητική λοξότητα. Ο μέσος όρος (62,6) είναι μικρότερος της διαμέσου (63).

Τα κριτήρια AIC και BIC

Τα στατιστικά AIC και BIC τοποθετούνται στην πρώτη ενότητα του κεφαλαίου, αλλά μπορούν να γίνουν περισσότερο κατανοητά μετά την ανάγνωση της τρίτης ενότητας. Ωστόσο, θεωρούμε ότι η θέση τους βρίσκεται στην παρούσα ενότητα και γι' αυτό είναι χρήσιμο ο αναγνώστης να παραλείψει αυτό το τμήμα στην πρώτη ανάγνωση και να επιστρέψει ξανά αργότερα, όταν θα έχει διαβάσει το τρίτο μέρος του κεφαλαίου.

Τα κριτήρια AIC (Akaike Information Criterion) και το BIC² (Bayes - Schwartz Information Criterion) χρησιμοποιούνται ως στατιστικά καλής προσαρμογής ενός οικονομετρικού μοντέλου και μας βοηθούν να επιλέξουμε το καταλληλότερο οικονομετρικό μοντέλο από ένα σύνολο εκτιμηθέντων (εκείνο με το μικρότερο AIC ή/και BIC). Οι μαθηματικοί τύποι των κριτηρίων AIC και BIC δίνονται αντίστοιχα από τις σχέσεις³ 13.14 και 13.15:

$$\ln AIC = \ln \left(\frac{RSS}{n} \right) + \frac{2}{n} k \quad (13.14)$$

$$\ln BIC = \ln \left(\frac{RSS}{n} \right) + \frac{k}{n} \ln(n) \quad (13.15)$$

Όπου RSS (Residual Sum of Squares) άθροισμα τετραγώνων καταλοίπων παλινδρόμησης, n ο αριθμός του δείγματος, k ο αριθμός των παραμέτρων. Όμως αυτά θα γίνουν πλήρως κατανοητά μετά την ανάγνωση του τρίτου μέρους. Ακολουθεί ο Πίνακας 13.3 με τους τύπους τους οποίους περιλαμβάνει το πρώτο μέρος του παρόντος κεφαλαίου.

2. Σε κάποια βιβλία αναφέρεται και ως SIC.

3. Ο λογάριθμος χρησιμοποιείται για λόγους μαθηματικής ευκολίας, επειδή ο αρχικός τύπος είναι

$AIC = e^{2k/n} \frac{RSS}{n}$. Ανάλογα ισχύουν και για τον BIC.

Πίνακας 13.3 Τυπολόγιο περιγραφικής Στατιστικής Μέρους Α΄

Τεχνικός όρος στατιστικού μέτρου	Μαθηματικός τύπος στατιστικού μέτρου
Μέσος όρος ή μέση τιμή (Mean, Average)	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
Σταθμικός μέσος (weighted mean)	$\bar{x} = \frac{\sum_{i=1}^k (w_i x_i)}{\sum_{i=1}^k (w_i)}$
Κεντρική τιμή (mode)	Η συχνότερη τιμή στο δείγμα
Διάμεσος (median)	$\frac{n + 1}{2}$
Εύρος (range)	Μεγαλύτερη - Μικρότερη τιμή
1ο, 2ο, 3ο τεταρτημόριο (1st, 2nd, 3rd quartiles)	$(n+1)/4, (n+1)/2, 3*(n+1)/4$
Διακύμανση ή διασπορά (variance, dispersion)	$\sigma^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n - 1} = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$
Τυπική απόκλιση (standard deviation)	$S = \sqrt{\sigma^2}$
Συντελεστής μεταβλητότητας (Coefficient of Variation)	$CV = \frac{\bar{S}}{\bar{X}} * 100\%$
Ροπές (Moments)	$E(x^n), \mu_n = E[(x - \mu_x)^n]$
Ασυμμετρία: Λοξότητα (Skewness)	Με οπτική παρατήρηση ⁴
Ασυμμετρία: Κύρτωση (Curtosis)	Με οπτική παρατήρηση
AIC, Akaike Information Criterion	$AIC = \ln \left(\frac{RSS}{n - k} \right) + \frac{2}{n} k$
BIC, Bayes (Schwartz) Information Criterion	$BIC = \ln \left(\frac{RSS}{n - k} \right) + \frac{k}{n} \ln(n)$

4. Ο τύπος παραλείπεται λόγω πολυπλοκότητας. Το ίδιο ισχύει και για την κύρτωση.

ΜΕΡΟΣ Β'

ΔΙΑΣΤΗΜΑΤΑ ΕΜΠΙΣΤΟΣΥΝΗΣ ΚΑΙ ΕΛΕΓΧΟΙ ΥΠΟΘΕΣΕΩΝ

Το δεύτερο μέρος του παρόντος κεφαλαίου ασχολείται με στοιχεία επαγωγικής Στατιστικής. Η επαγωγική Στατιστική μας δίνει τα εργαλεία ώστε από τις πληροφορίες του δείγματος να οδηγηθούμε σε κάποιο συμπέρασμα για τον πληθυσμό. Πριν όμως παρουσιάσουμε τη διαδικασία της εκτίμησης, είναι χρήσιμο να γνωρίσουμε κάποιες έννοιες που θα μας εισαγάγουν σταδιακά στο κεντρικό αντικείμενο αυτής της υποενότητας. Έτσι ξεκινάμε με την έννοια των βαθμών ελευθερίας και της κανονικής κατανομής.

Τι είναι οι βαθμοί ελευθερίας;

Οι *βαθμοί ελευθερίας* (degrees of freedom) δίνονται από τον αριθμό των παρατηρήσεων των μεταβλητών που υπάρχουν σε ένα μοντέλο. Δηλώνουν τις τιμές που είναι ελεύθερες (τυχαίες) στις μεταβλητές οι οποίες χρησιμοποιούνται στο οικονομικό μοντέλο. Έτσι οι βαθμοί ελευθερίας σε ένα μοντέλο είναι τόσοι όσο το πλήθος του δείγματος, δηλαδή n . Όμως, επειδή υπάρχει η δέσμευση της μέσης τιμής, χάνεται ένας βαθμός ελευθερίας και έτσι λέμε ότι το δείγμα έχει $n-1$ βαθμούς ελευθερίας.

Η κανονική κατανομή

Η σημασία της κανονικής κατανομής και των παραλλαγών της είναι μεγάλη, διότι πολλά συνεχή φαινόμενα ακολουθούν την κανονική κατανομή. Τη χρησιμοποιούμε για να προσεγγίσουμε φαινόμενα που χαρακτηρίζονται από διακριτή επιλογή και αποτελεί τη βάση της στατιστικής επαγωγής εξαιτίας της σχέσης της με το κεντρικό οριακό θεώρημα. Ορίζεται όπως στη σχέση 13.16:


$$f(X) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(1/2)[(X-\mu)/\sigma]^2} \quad (13.16)$$

Όπου e η μαθηματική σταθερά που ισούται με 2,71828, π η μαθηματική σταθερά που ισούται με 3,14159, μ ο μέσος του πληθυσμού, σ η τυπική απόκλιση του πληθυσμού, x οποιαδήποτε τιμή μιας συνεχούς τυχαίας μεταβλητής.

Σημείωση: κάθε φορά που ορίζουμε ένα καινούργιο μ και σ , μια νέα κανονική κατανομή δημιουργείται. Το εμβαδόν μεταξύ της καμπύλης που περιγράφεται από την παραπάνω συνάρτηση και του άξονα των x ισούται με 1. Επίσης, η περιοχή μεταξύ δύο τιμών του x , έστω α και β , με $\alpha < \beta$, εκφράζει την πιθανότητα το x να βρίσκεται μεταξύ α και β και αυτή η πιθανότητα γράφεται όπως στη σχέση 13.17:

$$\Pr\{\alpha < X < \beta\} \quad (13.17)$$

Για περισσότερη ευκολία, το x το εκφράζουμε σε σχέση με τον μέσο και τη διακύμανσή του κι έτσι δημιουργείται η τυποποιημένη μεταβλητή $z = (x - \mu) / \sigma$, και λέμε τότε ότι η μεταβλητή x ακολουθεί την τυποποιημένη κανονική κατανομή με $\mu = 0$ και $\sigma = 1$.



Σχήμα 13.7 Η τυποποιημένη κανονική κατανομή

Οι πιο σημαντικές ιδιότητες της τυποποιημένης κανονικής κατανομής που συνήθως χρησιμοποιείται αντί της κανονικής κατανομής, είναι:

1. Έχει καμπανοειδή και συμμετρική μορφή (βλ. Σχήμα 13.7).
2. Τα μέτρα κεντρικής τάσης (μέσος, διάμεσος, επικρατούσα τιμή) που τη χαρακτηρίζουν είναι όλα ίσα.
3. Η περιοχή που βρίσκεται μεταξύ -1σ και $+1\sigma$ ισούται με 68,27% της περιοχής κάτω από την «καμπάνα», η περιοχή μεταξύ -2σ και $+2\sigma$ ισούται με 95,45% της περιοχής κάτω από την «καμπάνα», η περιοχή μεταξύ -3σ και $+3\sigma$ ισούται με 99,73% της περιοχής κάτω από την «καμπάνα» (Σχήμα 13.7).

4. Ο συντελεστής κύρτωσης ισούται με 3 και ο συντελεστής λοξότητας ισούται με μηδέν.

Επειδή τα ανωτέρω είναι θεωρητικές ιδιότητες, στην πράξη τα φαινόμενα δεν ακολουθούν κατά γράμμα την κανονική κατανομή, αλλά την προσεγγίζουν. Επομένως, οι ανωτέρω ιδιότητες πληρούνται σε έναν βαθμό αλλά όχι πλήρως.

Χρησιμοποιώντας τον πίνακα τυποποιημένης κανονικής κατανομής

Η περιοχή κάτω από την καμπύλη της κανονικής κατανομής ισούται με τη μονάδα, διότι αντιπροσωπεύει όλο τον πληθυσμό του υπό μελέτη θέματος. Ο πίνακας κανονικής κατανομής δίνει τις πιθανότητες (ή περιοχές) υπό την καμπύλη κανονικής κατανομής, υπολογισμένες από τον μέσο $\mu=0$ μέχρι την τιμή του εκάστοτε X . Κατά ανάλογο τρόπο, στην περίπτωση της τυποποιημένης κανονικής κατανομής αυτή η περιοχή αντιστοιχεί στις πιθανότητες (ή περιοχές) με μέσο $\mu=0$ μέχρι τη μεταβλητή Z (βλ. Σχήμα 13.7). Συγκεκριμένα το $\pm 1\sigma$ αντιστοιχεί σε $Z=\pm 1$, το $\pm 2\sigma$ αντιστοιχεί σε $Z=\pm 2$, το $\pm 3\sigma$ αντιστοιχεί σε $Z=\pm 3$ κ.τ.λ.

Ο Πίνακας 13.4 περιλαμβάνει μόνο θετικές τιμές, αφού για έναν συμμετρικό πίνακα μέσου μ , η περιοχή από τον μέσο μέχρι το $+Z$, είναι ίση με την περιοχή από τον μέσο μέχρι $-Z$. Προκειμένου να μπορέσουμε να καταλάβουμε πώς διαβάζεται και πώς χρησιμοποιείται ένας τέτοιος πίνακας, διατρέχουμε τη στήλη με τίτλο Z μέχρι να βρούμε την τιμή που μας ενδιαφέρει, έστω $Z=1$. Αυτή η τιμή στον πίνακα γράφεται με δεκαδικό ψηφίο το μηδέν, δηλαδή $Z=1,0$. Μετά διαβάζουμε προς τα δεξιά της στήλης Z , για να συμπληρώσουμε τον αριθμό Z με τα υπόλοιπα δεκαδικά ψηφία, αν έχει. Αν $Z=1,00$ δεν υπάρχουν άλλα δεκαδικά ψηφία και σταματούμε στην πρώτη στήλη δεξιά της στήλης Z , δηλαδή στη στήλη με τίτλο, 00. Το συγκεκριμένο κελί του πίνακα δίνει τον αριθμό 0,3413. Αυτό ερμηνεύεται ως εξής: υπάρχει 34,13% πιθανότητα το γεγονός που εξετάζουμε να παίρνει τιμές που οριοθετούνται μεταξύ του μέσου και της απόστασης μιας τυπικής διακύμανσης δεξιά από τον μέσο.

Πίνακας 13.4 Πίνακας τυποποιημένης κανονικής κατανομής

Z	,00	,01	,02	,03	,04	,05	,06	,07	,08	,09
0,0	0,0000	0,0040	0,0080	0,0120	0,0160	0,0199	0,0239	0,0279	0,0319	0,0359
0,1	0,0398	0,0438	0,0478	0,0517	0,0557	0,0596	0,0636	0,0675	0,0714	0,0753
0,2	0,0793	0,0832	0,0871	0,0910	0,0948	0,0987	0,1026	0,1064	0,1103	0,1141
0,3	0,1179	0,1217	0,1255	0,1293	0,1331	0,1368	0,1406	0,1443	0,1480	0,1517
0,4	0,1554	0,1591	0,1628	0,1664	0,1700	0,1736	0,1772	0,1808	0,1844	0,1879
0,5	0,1915	0,1950	0,1985	0,2019	0,2054	0,2088	0,2123	0,2157	0,2190	0,2224
0,6	0,2257	0,2291	0,2324	0,2357	0,2389	0,2422	0,2454	0,2486	0,2518	0,2549
0,7	0,2580	0,2612	0,2642	0,2673	0,2704	0,2734	0,2764	0,2794	0,2823	0,2852
0,8	0,2881	0,2910	0,2939	0,2967	0,2995	0,3023	0,3051	0,3078	0,3106	0,3133
0,9	0,3159	0,3186	0,3212	0,3238	0,3264	0,3289	0,3315	0,3340	0,3365	0,3389
1,0	0,3413	0,3438	0,3461	0,3485	0,3508	0,3531	0,3554	0,3577	0,3599	0,3621
1,1	0,3643	0,3665	0,3686	0,3708	0,3729	0,3749	0,3770	0,3790	0,3810	0,3830
1,2	0,3849	0,3869	0,3888	0,3907	0,3925	0,3944	0,3962	0,3980	0,3997	0,4015
1,3	0,4032	0,4049	0,4066	0,4082	0,4099	0,4115	0,4131	0,4147	0,4162	0,4177
1,4	0,4192	0,4207	0,4222	0,4236	0,4251	0,4265	0,4279	0,4292	0,4306	0,4319
1,5	0,4332	0,4345	0,4357	0,4370	0,4382	0,4394	0,4406	0,4418	0,4429	0,4441
1,6	0,4452	0,4463	0,4474	0,4484	0,4495	0,4505	0,4515	0,4525	0,4535	0,4545
1,7	0,4554	0,4564	0,4573	0,4582	0,4591	0,4599	0,4608	0,4616	0,4625	0,4633
1,8	0,4641	0,4649	0,4656	0,4664	0,4671	0,4678	0,4686	0,4693	0,4699	0,4706
1,9	0,4713	0,4719	0,4726	0,4732	0,4738	0,4744	0,4750	0,4756	0,4761	0,4767
2,0	0,4772	0,4778	0,4783	0,4788	0,4793	0,4798	0,4803	0,4808	0,4812	0,4817
2,1	0,4821	0,4826	0,4830	0,4834	0,4838	0,4842	0,4846	0,4850	0,4854	0,4857
2,2	0,4861	0,4864	0,4868	0,4871	0,4875	0,4878	0,4881	0,4884	0,4887	0,4890
2,3	0,4893	0,4896	0,4898	0,4901	0,4904	0,4906	0,4909	0,4911	0,4913	0,4916
2,4	0,4918	0,4920	0,4922	0,4925	0,4927	0,4929	0,4931	0,4932	0,4934	0,4936
2,5	0,4938	0,4940	0,4941	0,4943	0,4945	0,4946	0,4948	0,4949	0,4951	0,4952
2,6	0,4953	0,4955	0,4956	0,4957	0,4959	0,4960	0,4961	0,4962	0,4963	0,4964
2,7	0,4965	0,4966	0,4967	0,4968	0,4969	0,4970	0,4971	0,4972	0,4973	0,4974
2,8	0,4974	0,4975	0,4976	0,4977	0,4977	0,4978	0,4979	0,4979	0,4980	0,4981
2,9	0,4981	0,4982	0,4982	0,4983	0,4984	0,4984	0,4985	0,4985	0,4986	0,4986
3,0	0,49865	0,49869	0,49874	0,49878	0,49882	0,49886	0,49889	0,49893	0,49897	0,49900

Z	,00	,01	,02	,03	,04	,05	,06	,07	,08	,09
3,1	0,49903	0,49906	0,49910	0,49913	0,49916	0,49918	0,49921	0,49924	0,49926	0,49929
3,2	0,49931	0,49934	0,49936	0,49938	0,49940	0,49942	0,49944	0,49946	0,49948	0,49950
3,3	0,49952	0,49953	0,49955	0,49957	0,49958	0,49960	0,49961	0,49962	0,49964	0,49965
3,4	0,49966	0,49968	0,49969	0,49970	0,49971	0,49972	0,49973	0,49974	0,49975	0,49976
3,5	0,49977	0,49978	0,49978	0,49979	0,49980	0,49981	0,49981	0,49982	0,49983	0,49983
3,6	0,49984	0,49985	0,49985	0,49986	0,49986	0,49987	0,49987	0,49988	0,49988	0,49989
3,7	0,49989	0,49990	0,49990	0,49990	0,49991	0,49991	0,49992	0,49992	0,49992	0,49992
3,8	0,49993	0,49993	0,49993	0,49994	0,49994	0,49994	0,49994	0,49995	0,49995	0,49995
3,9	0,49995	0,49995	0,49996	0,49996	0,49996	0,49996	0,49996	0,49996	0,49997	0,49997

Πηγή: Υπάρχει σε όλα τα βιβλία Στατιστικής και Οικονομετρίας

Η θεωρία της τυχαίας δειγματοληψίας

Η θεωρία δειγματοληψίας είναι σημαντική διότι μας αποκαλύπτει τη σχέση μεταξύ πληθυσμού και δείγματος κι έτσι μπορούμε, γνωρίζοντας παραμέτρους του δείγματος (π.χ. τον μέσο ή τη διακύμανση κ.τ.λ.), να εκτιμήσουμε και παραμέτρους του πληθυσμού. Επίσης, η θεωρία δειγματοληψίας συμβάλλει στο να αποφασίσουμε σχετικά με το αν η διαφορά μεταξύ δύο δειγμάτων είναι στατιστικά σημαντική ή είναι τυχαία.

Η κατανομή του μέσου και η εκτίμηση διαστήματος εμπιστοσύνης του

Έστω ότι έχουμε έναν πληθυσμό μεγέθους N , τον οποίο συμβολίζουμε ως N_p . Επιπλέον υποθέτουμε ότι από αυτόν τον πληθυσμό αντλούμε όλα τα πιθανά δείγματα μεγέθους N , με $N_p > N$. Η άντληση όλων αυτών των πιθανών δειγμάτων, όπου το καθένα έχει έναν διαφορετικό μέσο, θα δημιουργήσει μια κατανομή του μέσου η οποία θα έχει έναν μέσο όρο $\mu_{\bar{x}}$ και μια διακύμανση $\sigma_{\bar{x}}$, ενώ οι αντίστοιχοι παράμετροι για ολόκληρο τον πληθυσμό θα είναι μ και σ . Τότε, μεταξύ του μέσου και της διακύμανσης του δείγματος και του πληθυσμού αντίστοιχα, ισχύει η σχέση 13.18:

$$\mu_{\bar{x}} = \mu \text{ και } \sigma_{\bar{x}} = \frac{\sigma}{\sqrt{N}} \quad (13.18)$$

Όταν το δείγμα είναι αρκετά μεγάλο η κατανομή του μέσου προσεγγίζει την κανονική κατανομή. Όσο μεγαλύτερο γίνεται το δείγμα, τόσο πιο ακριβής είναι αυτή η προσέγγιση. Αν επομένως μια κατανομή ενός στατιστικού S είναι κανονική και έχει μέσο μ_s και διακύμανση σ_s , τότε το στατιστικό S βρίσκεται εντός των κάτωθι διαστημάτων:

$(\mu_s - \sigma_s, \mu_s + \sigma_s)$ στο 68,2% των περιπτώσεων

$(\mu_s - 2\sigma_s, \mu_s + 2\sigma_s)$ στο 95,4% των περιπτώσεων

$(\mu_s - 3\sigma_s, \mu_s + 3\sigma_s)$ στο 99,7% των περιπτώσεων

Εναλλακτικά μπορούμε να θεωρήσουμε ότι τον μέσο μ_s βρίσκουμε στα κάτωθι διαστήματα:

$(S - \sigma_s, S + \sigma_s)$ στο 68,2% των περιπτώσεων

$(S - 2\sigma_s, S + 2\sigma_s)$ στο 95,4% των περιπτώσεων

$(S - 3\sigma_s, S + 3\sigma_s)$ στο 99,7% των περιπτώσεων

Τα άκρα αυτών των διαστημάτων προσδιορίζουν το διάστημα εμπιστοσύνης (confidence interval).

Το διάστημα εμπιστοσύνης του μέσου ενός πληθυσμού δίνεται από την 13.19:

$$\bar{x} \pm z_c \frac{\sigma}{\sqrt{N}} \quad (13.19)$$

Όπου $\bar{x}$ είναι ο μέσος, σ η διακύμανση, N το μέγεθος του δείγματος και z_c είναι η κριτική τιμή του z από τον πίνακα της τυποποιημένης κατανομής. Τα διαστήματα 95% και 99% αντιστοιχούν στους συντελεστές 1,96 και 2,58 του τυποποιημένου πίνακα κανονικής κατανομής (Πίνακας 13.4). Το διάστημα 95% αντιστοιχεί σε περιοχή εμβαδού $0,95/2=0,475$ επειδή η κατανομή είναι συμμετρική (και η συνολική περιοχή κάτω από αυτήν ισούται με 1). Το κελί του Πίνακα 13.4 με τιμή ίση με 0,475 αντιστοιχεί σε $z=1,96$. Το διάστημα 99% αντιστοιχεί σε $0,99/2=0,495$, δηλαδή $z=2,58$.

Εφαρμογή

Έστω ότι η δαπάνη των 10 τουριστών στα Χανιά είναι αντιπροσωπευτική όλων των τουριστών εκείνη την περίοδο. Βρείτε τον μέσο του πληθυσμού της τουριστικής δαπάνης.

Λύση

Κάνοντας αντικατάσταση στα μεγέθη που γνωρίζουμε, το διάστημα εμπιστοσύνης 95% δίδεται από τη σχέση 13.20:

$$\bar{x} \pm z_c \frac{\sigma}{\sqrt{N}} = 62,6 \pm 1,96 \frac{23,42}{\sqrt{10}} = 62,60 \pm 14,50 \quad (13.20)$$

Άρα υπάρχει 95% πιθανότητα (ή εμπιστοσύνη) η μέση τουριστική δαπάνη να κυμαίνεται από 48,08 μέχρι 77,12€. Εναλλακτικά μπορούμε να πούμε ότι η πιθανότητα να βρίσκεται ο μέσος της τουριστικής δαπάνης μεταξύ 48,08 και 77,12 € είναι 95%, το οποίο γράφεται ως $\Pr \{48,08 < \mu < 77,12\} = 0,95$.

Το διάστημα εμπιστοσύνης 99% δίδεται από τη 13.21:

$$\bar{x} \pm z_c \frac{\sigma}{\sqrt{N}} = 62,6 \pm 2,58 \frac{23,42}{\sqrt{10}} = 62,60 \pm 19,10 \quad (13.21)$$

Άρα υπάρχει 99% πιθανότητα (ή εμπιστοσύνη) η μέση τουριστική δαπάνη να κυμαίνεται από 43,50 μέχρι 81,70€. Εναλλακτικά μπορούμε να πούμε ότι η πιθανότητα να βρίσκεται ο μέσος της τουριστικής δαπάνης μεταξύ 43,50 και 81,70 ευρώ είναι 99%, το οποίο γράφεται ως $\Pr \{43,50 < \mu < 81,70\} = 0,99$.

Βασισμένοι στο δείγμα, ελέγχουμε υποθέσεις και παίρνουμε αποφάσεις για τον πληθυσμό. Κατά τη διαδικασία αυτή μπορεί να διαπράξουμε σφάλμα. Παρακάτω ακολουθούν οι δύο τύποι σφάλματος που μπορεί να κάνουμε σε μια τέτοια περίπτωση.

Έλεγχος υποθέσεων και σφάλματα τύπου I και τύπου II

Για να ελέγξουμε μια υπόθεση, ορίζουμε πρώτα τη μηδενική υπόθεση η οποία συμβολίζεται με H_0 και κατόπιν την εναλλακτική υπόθεση που τη συμβολίζουμε με H_1 . Επιλέγουμε το στατιστικό με το οποίο θα κάνουμε τον έλεγχο, καθώς και ποια κατανομή ακολουθεί το στατιστικό μας. Μετά ορίζουμε το επίπεδο σημαντικότητας α και χρησιμοποιούμε τον πίνακα κατανομής πιθανότητας του συγκεκριμένου στατιστικού για να κατασκευάσουμε ένα διάστημα εμπιστοσύνης. Αν η τιμή του μεγέθους που εξετάζουμε βρίσκεται εντός του ανωτέρω διαστήματος εμπιστοσύνης, τότε δεν απορρίπτουμε τη μηδενική υπόθεση.


Κατά τον έλεγχο υποθέσεων, μπορεί ο ερευνητής να κάνει κάποιο σφάλμα. Αν απορρίψουμε τη μηδενική υπόθεση, ενώ είναι αληθής, τότε κάνουμε σφάλμα τύπου I. Αν πάλι δεν απορρίψουμε τη μηδενική υπόθεση, ενώ αυτή είναι ψευδής, τότε έχουμε διαπράξει σφάλμα τύπου II (Πίνακας 13.5).

Πίνακας 13.5 Σφάλματα ελέγχων

Τι ισχύει;		
Απόφαση	H_0 είναι αληθής	H_0 είναι ψευδής
Απορρίπτω	Σφάλμα τύπου I (α)	Όχι σφάλμα ($1-\beta$)
Δεν απορρίπτω	Όχι σφάλμα ($1-\alpha$)	Σφάλμα τύπου II (β)

Το επίπεδο σημαντικότητας

Αποτελεί τη μέγιστη πιθανότητα που είμαστε διατεθειμένοι να ρισκάρουμε ένα σφάλμα τύπου I. Το συμβολίζουμε με α . Τα πιο συνήθη επίπεδα σημαντικότητας είναι το 5% και το 1%. Όμως στην πραγματικότητα, μπορούμε να θέσουμε οποιοδήποτε επίπεδο σημαντικότητας επιθυμούμε. Ένα επίπεδο σημαντικότητας 5% σημαίνει ότι υπάρχει 5% πιθανότητα να απορρίψω υπόθεση η οποία έπρεπε να γίνει αποδεκτή. Δηλαδή, υπάρχει 95% εμπιστοσύνη ότι έχουμε πάρει τη σωστή απόφαση. Η πιθανότητα διάπραξης σφάλματος τύπου II δηλώνεται ως β . Η διαφορά ($1-\beta$) ονομάζεται *δύναμη του ελέγχου* (power of the test). Η δύναμη του ελέγχου είναι η πιθανότητα να απορρίψουμε τη μηδενική υπόθεση όταν αυτή είναι λάθος και άρα πρέπει να απορριφθεί.



Σχήμα 13.8 Κριτικές περιοχές και έλεγχος υποθέσεων

Το Σχήμα 13.8 είναι το ίδιο με το Σχήμα 13.7. Το επαναλαμβάνουμε στο σημείο αυτό προκειμένου να εξηγήσουμε έννοιες του ελέγχου υποθέσεων. Όταν το διάστημα εμπιστοσύνης είναι 95,4%, τότε η κριτική περιοχή, δηλαδή το επίπεδο σημαντικότητας, είναι το εμβαδόν της καμπύλης που ξεκινά από το μείον άπειρο μέχρι το σημείο -2σ και από το σημείο $+2\sigma$ μέχρι συν άπειρο, σύνολο εμβαδού $100\%-95,4\%=4,6\%$ και αποτελεί την περιοχή απόρριψης της απόφασης. Η περιοχή που αποτελείται από το πράσινο και το κίτρινο χρώμα είναι η περιοχή μη απόρριψης της μηδενικής υπόθεσης. Γενικά ισχύει ότι: ή δεν απορρίπτουμε (αλλά δεν λέμε ότι δεχόμαστε) ή απορρίπτουμε τη μηδενική.

Δίπλευροι και μονόπλευροι έλεγχοι

Από το Σχήμα 13.8, αντιλαμβανόμαστε ότι η περιοχή απόρριψης, δηλαδή το επίπεδο σημαντικότητας, είναι τα δύο άκρα (δηλαδή η περιοχή στις δύο ουρές) της κατανομής και σε κάθε άκρο αντιστοιχεί το μισό α , ή $\alpha/2$. Αυτός ο έλεγχος λέγεται δι-κατάληκτος. Υπάρχει όμως περίπτωση να κάνουμε έναν μονόπλευρο έλεγχο αν η περιοχή απόρριψης βρίσκεται σε μία μόνο πλευρά της κατανομής, η οποία αποτελεί και ολόκληρο το α .

Πίνακας 13.6 Παράδειγμα κριτικών τιμών για μονόπλευρο και δίπλευρο έλεγχο

Επίπεδο σημαντικότητας α	0,10	0,05	0,01
Κριτικές τιμές z για μονόπλευρο έλεγχο	-1,28 ή 1,28	-1,645 ή 1,645	-2,33 ή 2,33
Κριτικές τιμές z για δίπλευρο έλεγχο	-1,645 και 1,645	-1,96 και 1,96	-2,58 και 2,58

Όταν έχουμε μονόπλευρο έλεγχο, κάνουμε τους υπολογισμούς στη μισή κατανομή, άρα αφαιρούμε το επίπεδο σημαντικότητας από το 50% (ολόκληρη η κατανομή είναι 100%). Για παράδειγμα όταν $\alpha=10\%$, ισχύει ότι $0,5-0,1=0,4$. Αναζητούμε την τιμή 0,4 στους Πίνακες 13.4 και 13.6 και αυτό ισούται με 1,28 ή -1,28 αναλόγως σε ποιο μισό της κατανομής εφαρμόζεται η απόφαση (το δεξιό ή το αριστερό). Αντίστοιχα, όταν έχουμε δίπλευρο έλεγχο, αφαιρούμε από το 100% το $\alpha=10\%$, δηλαδή έχουμε 90% εμπιστοσύνη το οποίο αντιστοιχεί σε 45% από κάθε πλευρά. Αναζητώντας το κελί 0,45 στους Πίνακες 13.4 και 13.6, μας δίνει $z=-1,645$ και 1,645. Αντίστοιχα μπορούμε να βρούμε τις κριτικές τιμές z για επίπεδο εμπιστοσύνης 5% ή/και 1%. Μπορείτε να τα υπολογίσετε μόνοι σας για εξάσκηση.

Εφαρμογή

Έστω ότι θέλουμε στο παράδειγμα της τουριστικής δαπάνης να ελέγξουμε την υπόθεση ότι η μέση τουριστική δαπάνη είναι μεγαλύτερη από 60€.

Λύση

Εφόσον διαπιστώνουμε ότι μας απασχολεί ένα ερώτημα που έχει μια συγκεκριμένη κατεύθυνση, όπως την περίπτωση ο μέσος της τουριστικής δαπάνης να είναι μεγαλύτερος από 60€, διατυπώνουμε τις υποθέσεις του προβλήματος όπως η σχέση 13.22:

$$\begin{aligned} H_0: \mu &\leq 60 \\ H_1: \mu &> 60 \end{aligned} \quad (13.22)$$

Η περιοχή απόρριψης περιλαμβάνεται στο άνω (δεξί άκρο) της κατανομής του μέσου, αφού θα απορρίψουμε τη μηδενική υπόθεση μόνο αν ο μέσος του δείγματος είναι στατιστικά μεγαλύτερος από 60€. Επομένως θα χρησιμοποιήσουμε μονόπλευρο έλεγχο. Αν επιλέξουμε επίπεδο σημαντικότητας $\alpha=0,05$, θα βρούμε την κριτική τιμή Z . Από τον Πίνακα 13.6, αφαιρούμε από το 0,5 (περιοχή μισής κατανομής) το επίπεδο σημαντικότητας και βρίσκουμε $0,5-0,05=0,45$.⁵ Αυτή η τιμή αντιστοιχεί σε $Z=1,65$. Υπολογίζουμε το στατιστικό Z όπως στη 13.23:

$$Z = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{N}}} = \frac{62,6 - 60}{\frac{23,42}{\sqrt{10}}} = \frac{2,6}{\frac{23,42}{3,16}} = \frac{2,6}{7,41} = 0,35 < 1,645 \quad (13.23)$$

Όπου $N=10$, $\bar{x} = 62,6$ και $\sigma=23,42$. Αφού το στατιστικό Z που εκτιμήσαμε είναι μικρότερο από το σχετικό στατιστικό του Πίνακα 13.6, δεν μπορούμε να απορρίψουμε τη μηδενική υπόθεση. Παρότι εμείς στο δείγμα έχουμε υπολογίσει τον μέσο ίσο με 62,6€, το αποτέλεσμα αυτού του ελέγχου ίσως να οφείλεται σε σφάλμα δειγματοληψίας ή εμπίπτει στο σφάλμα τύπου I.

5. Επειδή η τιμή 0,45 δεν υπάρχει στον πίνακα, μπορούμε να χρησιμοποιήσουμε τον μέσο όρο των τιμών των δύο διαδοχικών κελιών στα οποία περιέχεται. Δηλαδή, τα κελιά 0,4495 και 0,4505.

Δειγματοληψία και έλεγχος αποφάσεων σε μικρά δείγματα

Όταν τα δείγματα που χρησιμοποιούμε δεν είναι αρκετά μεγάλα, τότε η κανονική κατανομή δεν είναι η σωστή προσέγγιση στη στατιστική επαγωγή. Στην περίπτωση αυτή χρησιμοποιούμε τις κατανομές Student's t ή την κατανομή F . Στη συνέχεια αναφερόμαστε εν συντομία στην κατανομή Student's t , αλλά εξαιτίας της περιορισμένης έκτασης του κεφαλαίου δεν θα αναφερθούμε σε άλλες κατανομές. Σε περίπτωση που κάποιος αναγνώστης ενδιαφέρεται γι' αυτές, μπορεί να επεκτείνει τη μέλητή του σε κάποιο άλλο βιβλίο εισαγωγικής Στατιστικής.

Η κατανομή Student's t

Σύμφωνα με την κατανομή αυτή, αν μια τυχαία μεταβλητή x κατανέμεται κανονικά, τότε το στατιστικό $\frac{\bar{x} - \mu}{\frac{S}{\sqrt{n}}}$ ακολουθεί την κατανομή t με $n-1$ βαθμούς ελευθερίας.

Βλέπουμε ότι στον παρονομαστή εισέρχεται ο εκτιμητής του σ , δηλαδή το S (standard deviation), και αυτό συμβαίνει επειδή το σ δεν είναι γνωστό, αφού είναι παράμετρος του πληθυσμού. Η κατανομή t μοιάζει πολύ με την κανονική, δηλαδή έχει καμπανοειδή και συμμετρική μορφή.

Καθώς το πλήθος των βαθμών ελευθερίας αυξάνεται, η κατανομή t προσεγγίζει σταδιακά την κανονική κατανομή. Οι κριτικές τιμές του t βρίσκονται σε ειδικό πίνακα (Πίνακας 13.7). Κάθε στήλη του εν λόγω πίνακα δείχνει την περιοχή στη δεξιά ουρά της κατανομής t (upper tail). Η κάθε γραμμή αντιπροσωπεύει συγκεκριμένη τιμή t . Για παράδειγμα, αν επιθυμούμε διάστημα εμπιστοσύνης 95% με 31 βαθμούς ελευθερίας, αυτό δείχνει ότι θα υπήρχε περιοχή 0,025 σε κάθε ουρά της κατανομής. Αυτό προκύπτει από τον λόγο $\frac{1 - 0,95}{2} = 0,025$. Κοιτάζοντας τη στήλη του

πίνακα t με δεξιά ουρά 0,025 και 31 βαθμούς ελευθερίας, καταλήγει σε τιμή 2,0395. Εφόσον πρόκειται για συμμετρική κατανομή, και η τιμή της αριστερής ουράς θα είναι -2,0332. Το αποτέλεσμα αυτό ερμηνεύεται ως εξής: η πιθανότητα το t να ξεπερνά το +2,0332 είναι 25%.

Πίνακας 13.7 Απόσπασμα κριτικών τιμών στον πίνακα της κατανομής t , με ένα παράδειγμα

Περιοχή δεξιάς ουράς						
Βαθμοί ελευθερίας	0,25	0,10	0,05	0,025	0,01	0,005
1	1,000	3,077	6,313	12,706	31,820	63,657
2	0,816	1,885	2,920	4,302	6,964	9,924
3	0,764	1,637	2,353	3,182	4,540	5,840
...						
31	0,682	1,309	1,695	2,039	2,452	2,744

Πηγή: Ο πίνακας υπάρχει σε κάθε βιβλίο Στατιστικής και Οικονομετρίας

Η δήλωση του διαστήματος εμπιστοσύνης

Το διάστημα εμπιστοσύνης $(1-\alpha)*100\%$ του μέσου μ , με σ άγνωστο, εκφράζεται ως εξής:

$$\bar{X} - t_{n-1} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{n-1} \frac{S}{\sqrt{n}} \quad (13.24)$$

όπου t_{n-1} είναι η κριτική τιμή της κατανομής t με $n-1$ βαθμούς ελευθερίας για μια περιοχή ίση με $\alpha/2$ της δεξιάς ουράς.

Παραμετρική έναντι μη παραμετρικής προσέγγισης

Όταν δεν είμαστε σίγουροι για την κατανομή την οποία ακολουθεί ένα δείγμα ή διαπιστώνουμε ότι δεν προσεγγίζει καμία από τις γνωστές κατανομές, μπορούμε να ακολουθήσουμε τη *μη-παραμετρική* (non-parametric) προσέγγιση στην ανάλυσή μας. Αντίθετα, όταν γνωρίζουμε ότι τα δεδομένα που διέπουν ένα πρόβλημα ακολουθούν μια γνωστή κατανομή, τότε είναι χρησιμότερο να ακολουθούμε *παραμετρική* (parametric) ανάλυση.

Μη παραμετρικοί έλεγχοι

Οι μη παραμετρικοί έλεγχοι είναι πολύ χρήσιμοι όταν ο πληθυσμός αφορά μη αριθμητικά δεδομένα. Από τους πιο γνωστούς ελέγχους που χρησιμοποιούνται είναι ο έλεγχος Mann - Whitney, ο έλεγχος Kruskal - Wallis και ο έλεγχος συσχέτισης του Spearman.

i) Ο έλεγχος Mann - Whitney

Όταν πρέπει να συγκρίνουμε δύο δείγματα τιμών και επιδιώκουμε να διαπιστώσουμε αν η διαφορά μεταξύ των δειγμάτων είναι στατιστικά σημαντική, τότε ενώνουμε τα δύο δείγματα σε μια σειρά, με τις τιμές από τη μικρότερη στη μεγαλύτερη και τις τοποθετούμε δίπλα σε μια ιεράρχηση (rank) από το 1 ως το n . Αν υπάρχουν δύο ίδιες τιμές στα δείγματα, τότε τους αποδίδουμε rank ίσο με τον μέσο όρο των 2 ranks που θα καταλάμβαναν. Στη συνέχεια βρίσκουμε τα αθροίσματα των ranks που αντιστοιχούν σε κάθε δείγμα. Το ένα ονομάζεται R_1 και το άλλο R_2 , ενώ N_1 και N_2 είναι τα μεγέθη των δειγμάτων. Για να ελέγξουμε αν τα ranks είναι στατιστικά διαφορετικά χρησιμοποιούμε το στατιστικό U , που μπορεί να διατυπωθεί για το δείγμα 1 και το δείγμα 2 αντίστοιχα στις σχέσεις 13.25 και 13.26:

$$U = N_1 N_2 + \frac{N_1(N_1 + 1)}{2} - R_1 \quad (13.25)$$

$$U = N_1 N_2 + \frac{N_2(N_2 + 1)}{2} - R_2 \quad (13.26)$$

Το U έχει κανονική κατανομή με μέσο μ_U και διασπορά σ_U^2 . Αν τα N_1 και N_2 είναι και τα δύο τουλάχιστον ίσα με 8, τότε η κατανομή του U είναι πολύ κοντά στην κανονική. Ουσιαστικά το πρακτικό νόημα του στατιστικού U στην πρώτη σχέση μάς δείχνει πόσες φορές οι τιμές του δείγματος 1 προηγούνται των τιμών του δείγματος 2, επειδή είναι μικρότερες και μην ξεχνάμε ότι έχουν τοποθετηθεί με αύξουσα σειρά από την μικρότερη τιμή προς τη μεγαλύτερη.

ii) Ο έλεγχος Kruskal - Wallis

Ο έλεγχος Kruskal - Wallis είναι μία γενίκευση του ελέγχου Mann - Whitney για k αριθμό δειγμάτων, ενώ ο έλεγχος Mann - Whitney αφορά τη σύγκριση μόνο 2 δειγμάτων. Έστω λοιπόν ότι έχουμε k δείγματα, $N_1, N_2, \dots, N_k$ με N το συνολικό άθροισμά τους και τα αθροίσματα των ranks τους είναι $R_1, R_2, \dots, R_k$. Τότε ο έλεγχος Kruskal - Wallis πραγματοποιείται με το στατιστικό H στη 13.27:

$$H = \frac{12}{N(N+1)} \sum_{j=1}^k \frac{R_j^2}{N_j} - 3(N+1) \quad (13.27)$$

το οποίο ακολουθεί την κατανομή χ^2 με $k-1$ βαθμούς ελευθερίας, με την προϋπόθεση ότι τα δείγματα έχουν τουλάχιστον μέγεθος πέντε παρατηρήσεων.

iii) Ο έλεγχος συσχέτισης του Spearman

Έστω ότι έχουμε δύο μεταβλητές X και Y . Όταν οι τιμές τους δεν είναι αριθμητικές, χρησιμοποιούμε μη παραμετρικούς ελέγχους συσχέτισης. Τα δεδομένα X και Y ιεραρχούνται από το 1 ως το N , ανάλογα με το μέγεθος ή τη σημασία. Ο συντελεστής συσχέτισης του Spearman δίνεται από τη 13.28:

$$r_s = 1 - \frac{6\sum D^2}{N(N^2 - 1)} \quad (13.28)$$

Όπου D είναι οι διαφορές ανάμεσα στα ranks που αντιστοιχούν στον X και Y , και N ο αριθμός των ζευγών (X, Y) στις παρατηρήσεις. Όταν η συσχέτιση κατά Spearman ισούται με $+1$ ή -1 είναι πλήρης συσχέτιση (θετική ή αρνητική, αντίστοιχα).

ΜΕΡΟΣ Γ'


ΑΠΛΗ ΠΑΛΙΝΔΡΟΜΗΣΗ - ΠΟΛΛΑΠΛΗ ΠΑΛΙΝΔΡΟΜΗΣΗ

Μέχρι αυτό το σημείο στο παρόν κεφάλαιο έχουμε δει εν τάχει διάφορα εργαλεία στατιστικής περιγραφής και επαγωγής. Από εδώ και μετά θα δούμε πώς ανακαλύπτουμε, επιβεβαιώνουμε και μεταχειριζόμαστε τις σχέσεις που υπάρχουν μεταξύ κάποιων μεταβλητών με σκοπό στη συνέχεια τις προβλέψεις για την εξαρτημένη μεταβλητή η οποία εξαρτάται από μια σειρά από ανεξάρτητες μεταβλητές. Για να το πετύχουμε αυτό, θα περιγράψουμε δύο τεχνικές, την απλή και την πολλαπλή παλινδρόμηση (simple and multiple regression) και τη συσχέτιση (correlation).

Η ανάλυση απλής παλινδρόμησης χρησιμοποιεί μια ανεξάρτητη μεταβλητή x για να προβλέψει την εξέλιξη της εξαρτημένης μεταβλητής y , ενώ η πολλαπλή παλινδρόμηση χρησιμοποιεί περισσότερες από μία ανεξάρτητες μεταβλητές x , δηλαδή $x_1, x_2, \dots, x_n$, για να κάνει πρόβλεψη για την εξαρτημένη μεταβλητή y .

Πριν την έναρξη της ανάλυσης παλινδρόμησης, είναι χρήσιμη μια οπτική επισκόπηση των μεταβλητών x και y σε ένα διάγραμμα διασποράς (scatter diagram). Αυτή η οπτική επισκόπηση προϋποθέτει τον ερευνητή για τη μορφή της σχέσης, αλλά και αποκαλύπτει τυχόν απομακρυσμένες τιμές (outliers), οι οποίες μπορούν, κατά περίπτωση, να αφαιρεθούν (trimming) από το δείγμα ώστε να μην επηρεάζονται τα

αποτελέσματα ή να αντικατασταθούν (winsorizing). Ωστόσο, η συσχέτιση δεν συνεπάγεται πάντα αιτιότητα (causation). Το Σχήμα 13.9 μας δείχνει δύο μορφές συσχέτισης που μπορούμε να εντοπίσουμε ανάμεσα στις μεταβλητές x και y .



Μέρος Α. Παράδειγμα θετικής συσχέτισης x και y

Μέρος Β. Παράδειγμα αρνητικής συσχέτισης x και y

Σχήμα 13.9 Παράδειγμα συσχέτισης μεταξύ των μεταβλητών x και y

Ενδέχεται να μην παρατηρείται καμία σαφής σχέση μεταξύ των δύο μεταβλητών, όπως φαίνεται στο Σχήμα 13.10.



Σχήμα 13.10 Παράδειγμα μη συσχέτισης μεταξύ των μεταβλητών x και y

Υπάρχουν πολλές μαθηματικές μορφές που μπορεί να λάβει η σχέση του x με το y . Η πιο απλή μορφή σχέσης ανάμεσα στην εξαρτημένη και την ανεξάρτητη μεταβλητή είναι η γραμμική, η οποία ακολουθεί τη μαθηματική μορφή της σχέσης 13.29 (για έναν πληθυσμό):

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \quad (13.29)$$

ε_i είναι ο τυχαίος όρος (random error) του y για την παρατήρηση i .

Το β_1 (slope) είναι η κλίση της ευθείας και αντιπροσωπεύει την προσδοκώμενη μεταβολή στη y για τη μοναδιαία μεταβολή στη x ή τη μέση μεταβολή της y όταν η x μεταβάλλεται κατά 1. Το β_0 (intercept) αντιπροσωπεύει τη μέση τιμή του y όταν το x ισούται με μηδέν.


Η μέθοδος των ελαχίστων τετραγώνων

Επειδή δεν είναι εύκολο να δουλέψουμε τη σχέση μεταξύ x και y σε όλο τον πληθυσμό της, επιλέγουμε να επεξεργαστούμε τη σχέση σε ένα τυχαίο δείγμα της. Έτσι, αυτό που αναζητούμε εμφανίζεται στη 13.30:

$$\hat{y}_i = b_0 + b_1 x_i \quad (13.30)$$

$\hat{y}_i$ είναι η προβλεφθείσα τιμή (predicted value) του y για την παρατήρηση i .

Ο υπολογισμός των συντελεστών b_0 και b_1 ⁶ μας δίνει τη γραμμή που αντιπροσωπεύει τη σχέση των x και y , και στη συνέχεια μπορούμε να ελέγξουμε πόσο κοντά ή πόσο μακριά βρίσκεται αυτή η ευθεία από τα δεδομένα του πληθυσμού (βλ. Σχήμα 13.11).



Σχήμα 13.11 Η γραμμή παλινδρόμησης

Η εκτίμηση των τιμών b_0 και b_1 που ελαχιστοποιεί την απόσταση της ευθείας από τα σημεία (Σχήμα 13.11) λέγεται *μέθοδος ελαχίστων τετραγώνων* (Least Squares Method - LSE). Με αυτή τη μέθοδο παίρνουμε τις λύσεις στις σχέσεις 13.31 και 13.32:

6. Όταν αναφερόμαστε στον πληθυσμό, οι συντελεστές αναφέρονται ως β_1 και β_2 .

$$b_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} \quad (13.31)$$

$$b_0 = \bar{y} - b_1 \bar{x} \quad (13.32)$$

Η εύρεση αυτών των λύσεων γίνεται πολύ εύκολα από κάποιο οικονομετρικό πρόγραμμα. Στο πλαίσιο του παρόντος κεφαλαίου, θα δείξουμε πώς γίνεται η παλινδρόμηση βήμα βήμα στο Excel.

Εφαρμογή

Έστω τα ακόλουθα δεδομένα των πωλήσεων και πελατών 20 εστιατορίων της Κρήτης κατά τον μήνα Αύγουστο 2019.

Πίνακας 13.8 Δεδομένα πωλήσεων και αριθμού πελατών 20 εστιατορίων της Κρήτης κατά τον μήνα Αύγουστο 2019

Εστιατόριο	Αριθμός πελατών = X	Εβδομαδιαίες πωλήσεις (σε 000€) = Y
1	907	11,20
2	926	11,05
3	506	6,84
4	741	9,21
5	789	9,42
6	889	10,08
7	874	9,45
8	510	6,73
9	529	7,24
10	420	6,12
11	679	7,63
12	872	9,43
13	924	9,46
14	607	7,64
15	452	6,92
16	729	8,95
17	794	9,33
18	844	10,23
19	1.010	11,77
20	621	7,41

Λύση

Για να βρούμε τη σχέση αριθμού πελατών και πωλήσεων, εισάγουμε τα στοιχεία του Πίνακα 13.8 στο Excel και στη συνέχεια επιλέγουμε τη ρουτίνα (από το μενού) με τίτλο «Ανάλυση δεδομένων». Από εκεί διαλέγουμε την εφαρμογή με τίτλο «Παλινδρόμηση». Η ρουτίνα μάς ζητά να προσδιορίσουμε ποια είναι η εξαρτημένη μεταβλητή y και ποια είναι η ανεξάρτητη μεταβλητή x . Τα αποτελέσματα φαίνονται στον Πίνακα 13.9.

Ποια είναι τα πιο σημαντικά στοιχεία που κρατάμε από τον Πίνακα 13.9; Αρχικά ελέγχουμε την εκτιμηθείσα σχέση η οποία βρίσκεται στο κάτω μέρος του πίνακα. Η τεταγμένη επί της αρχής είναι το b_0 και ο συντελεστής πωλήσεων είναι το b_1 . Στη στήλη με τίτλο «Συντελεστές», βλέπουμε ότι το $b_0 = 2,423044$ και το $b_1 = 0,008729$, δηλαδή η σχέση που εκτιμήθηκε δίνεται από τη 13.33:

$$\hat{y} = 2,42 + 0,009 x \quad (13.33)$$

Ελέγχουμε αν η σχέση που εκτιμήσαμε έχει οικονομική λογική ή αν είναι σύμφωνη με την οικονομική θεωρία, αν τα πρόσημα και τα μεγέθη των συντελεστών είναι αναμενόμενα κ.τ.λ. Στην προκειμένη περίπτωση η κλίση της καμπύλης είναι 0,009. Αυτό σημαίνει ότι για κάθε επιπλέον μονάδα του x , δηλαδή για κάθε επιπλέον πελάτη, οι πωλήσεις αυξάνονται κατά 0,009 χιλιάδες €. Η σταθερά 2,42 αντιπροσωπεύει τη μέση τιμή των πωλήσεων όταν οι πελάτες είναι μηδέν. Επειδή είναι μάλλον αδύνατον να υπάρχουν πωλήσεις χωρίς πελάτες, αυτή η ποσότητα θα μπορούσε να αντιπροσωπεύει άλλους παράγοντες που επηρεάζουν τις εβδομαδιαίες πωλήσεις (δηλαδή την εξαρτημένη μεταβλητή στο οικονομετρικό μας μοντέλο) και που δεν τους έχουμε (εσφαλμένα) συμπεριλάβει στο μοντέλο μας.

Ένα άλλο σημείο που πρέπει να ελέγξουμε στην εκτιμηθείσα σχέση είναι αφενός η στατιστική σημαντικότητα των επιμέρους συντελεστών, αλλά και η στατιστική σημαντικότητα της συνολικής σχέσης. Όταν το στατιστικό t είναι μεγαλύτερο του 2, ο συντελεστής είναι σημαντικός. Η τιμή του p είναι μικρότερη του 0,05 και σε αυτή την περίπτωση οι συντελεστές είναι σημαντικοί. Το Excel παράγει και τα δύο αυτά στατιστικά (t και p). Διαφορετικά, αν ένας συντελεστής δεν είναι σημαντικός, δεν μπορούμε να βασιστούμε σε αυτόν για προβλέψεις. Στον Πίνακα 13.9 παρατηρούμε ότι και ο συντελεστής του x και η σταθερά είναι στατιστικά σημαντικοί. Επίσης, από τη σημαντικότητα του στατιστικού F , διαπιστώνουμε ότι και η συνολική σχέση είναι στατιστικά σημαντική. Αυτό το αποτέλεσμα, σε συνδυασμό με το υψηλό $R^2=0,91$, μας πληροφορούν ότι το μοντέλο είναι καλό και ότι το 91% της μεταβλητότητας του y ερμηνεύεται από τη μεταβλητότητα του x , δηλαδή από αυτό το μοντέλο.

Εφόσον λοιπόν πρόκειται για ένα καλό μοντέλο, με την έννοια ότι ερμηνεύει καλά τα δεδομένα («fits the data» στην αγγλική ορολογία), μπορούμε να το χρησιμοποιήσουμε για προβλέψεις εντός του δείγματος, δηλαδή για τιμές του x που θα

Πίνακας 13.9 Αποτελέσματα παλινδρόμησης στο Excel

Στατιστικά παλινδρόμησης								
Πολλαπλό R	0,954913							
R Τετράγωνο	0,911859							
Προσαρμοσμένο R Τετράγωνο	0,906963							
Τυπικό σφάλμα	0,501495							
Μέγεθος δείγματος	20							
ΑΝΑΛΥΣΗ ΔΙΑΚΥΜΑΝΣΗΣ								
	Βαθμοί ελευθερίας	SS	MS	F	Σημαντικότητα F			
Παλινδρόμηση	1	46,83354	46,83354	186,2188	6,21E-11			
Υπόλοιπο	18	4,526954	0,251497					
Σύνολο	19	51,3605						
	Συντελεστές	Τυπικό σφάλμα	t	τιμή-P	Κατώτερο 95%	Υψηλότερο 95%	Κατατεριο 95,0%	Υψηλότερο 95,0%
Τεταγμένη επί την αρχή	2,423044	0,480965	5,037885	8,55E-05	1,412575	3,433514	1,412575	3,433514
Αριθμός πελάτων	0,008729	0,00064	13,6462	6,21E-11	0,007385	0,010073	0,007385	0,010073

βρίσκονται εντός του εύρους του δείγματος. Έτσι, για παράδειγμα, μπορούμε να κάνουμε μια πρόβλεψη για $x=600$. Αν οι πελάτες είναι 600, τότε αντικαθιστούμε την τιμή 600 στη θέση του x της εξίσωσης που εκτιμήσαμε και έχουμε τη σχέση 13.34:

$$\hat{y} = 2,42 + 0,009 * (600) = 7,82 \quad (13.34)$$

Δηλαδή με 600 πελάτες οι εβδομαδιαίες πωλήσεις είναι 7,82 χιλ€.

Όταν τελικά εκτιμήσουμε τη σχέση $\hat{y}_i = b_0 + b_1 x_i$, τη χρησιμοποιούμε για προβλέψεις (predictions). Για να κάνουμε τις προβλέψεις, χρησιμοποιούμε τιμές του x , πάντα εντός του εύρους του δείγματος. Προσοχή: αν οι προβλέψεις γίνονται εκτός του εύρους του δείγματος, χρειάζεται ειδική τροποποίηση για το τυπικό σφάλμα με την οποία δεν θα ασχοληθούμε στο πλαίσιο αυτού του κεφαλαίου.

Ο συντελεστής προσδιορισμού

Για να κατανοήσουμε πόσο το x επηρεάζει το y , χρησιμοποιούμε διάφορα μέτρα μεταβλητότητας τα οποία αντανakλούν στην ποιότητα της παλινδρόμησης και την ακρίβεια των εκτιμηθέντων παραμέτρων. Το συνολικό άθροισμα τετραγώνων (Total Sum of Squares - TSS) αποτελεί ένα μέτρο υπολογισμού της διαφοροποίησης του y_i από την εκτίμησή του, δηλαδή το $\hat{y}_i$. Το συνολικό άθροισμα τετραγώνων διακρίνεται σε άθροισμα τετραγώνων παλινδρόμησης (Regression Sum of Squares - RSE), που αντιστοιχεί στην ερμηνευμένη διαφοροποίηση, και στο άθροισμα τετραγώνων του σφάλματος (Error Sum of Squares - ESS), που αντιστοιχεί στη μη ερμηνευμένη διαφοροποίηση, δηλαδή εκείνη τη διαφοροποίηση του y η οποία δεν ερμηνεύεται από την παλινδρόμηση (για πολλούς λόγους). Επομένως ισχύει:

Το συνολικό άθροισμα τετραγώνων ισούται με το άθροισμα τετραγώνων παλινδρόμησης συν το άθροισμα τετραγώνων του σφάλματος, όπως φαίνεται στη σχέση 13.35:

$$TSS = RSE + ESS \quad (13.35)$$

Η προηγούμενη παράγραφος ήταν απαραίτητη ως εισαγωγή για να μπορέσουμε να κατανοήσουμε την έννοια του *συντελεστή προσδιορισμού* (coefficient of determination), ο οποίος ισούται με το άθροισμα τετραγώνων παλινδρόμησης διαιρεμένο με το συνολικό άθροισμα τετραγώνων, όπως δηλώνει η 13.36:

$$r^2 = 1 - \frac{\text{άθροισμα τετραγώνων παλινδρόμησης}}{\text{συνολικό άθροισμα τετραγώνων TSS}} = 1 - \frac{RSS}{TSS} \quad (13.36)$$

Επομένως, ο συντελεστής προσδιορισμού μετρά τον βαθμό στον οποίο η ερμηνευτική μεταβλητή x ερμηνεύει το y . Ο συντελεστής προσδιορισμού λαμβάνει τιμές από το 0 μέχρι το 1. Αν, για παράδειγμα, ο συντελεστής προσδιορισμού σε μια παλινδρόμηση είναι 90%, αυτό σημαίνει ότι η μεταβλητότητα του x ερμηνεύει κατά 90% τη μεταβλητότητα του y . Ενώ κατά 10% το y ερμηνεύεται από κάποια άλλη μεταβλητή (ή άλλες μεταβλητές) η οποία δεν έχει συμπεριληφθεί στη σχέση. Στην περίπτωση της πολλαπλής παλινδρόμησης, αντί του συντελεστή προσδιορισμού r^2 , χρησιμοποιούμε τον προσαρμοσμένο συντελεστή προσδιορισμού $\text{adjusted } r^2$, ο οποίος ορίζεται στη 13.37:

$$r_{\text{adj}}^2 = 1 - \left[(1 - r^2) \frac{n - 1}{n - 2} \right] \quad (13.37)$$

Συσχέτιση

Η ανάλυση *συσχέτισης* (correlation) χρησιμοποιείται για να μετρήσει τη δύναμη της σχέσης που υπάρχει μεταξύ δύο μεταβλητών. Για τη μέτρηση αυτής της δύναμης της σχέσης χρησιμοποιούμε τον συντελεστή συσχέτισης r , ο οποίος κυμαίνεται σε ένα εύρος από -1 (τέλεια αρνητική συσχέτιση) έως $+1$ (τέλεια θετική συσχέτιση). Ο συντελεστής συσχέτισης δίνεται από τη 13.38:

$$r = \sqrt{r^2} \quad (13.38)$$

Σε περίπτωση που δεν μας ενδιαφέρει η παλινδρόμηση (για την κατεύθυνση της σχέσης) αλλά μόνο η ύπαρξη συσχέτισης (association), τότε μπορεί να υπολογιστεί ο συντελεστής συσχέτισης όπως στη 13.39:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n x_i^2 - n\bar{x}^2} \sqrt{\sum_{i=1}^n y_i^2 - n\bar{y}^2}} \quad (13.39)$$

Στο παράδειγμα των πωλήσεων των 20 εστιατορίων της Κρήτης, πριν προχωρήσουμε στην ανάλυση παλινδρόμησης, μπορούμε να κάνουμε έναν έλεγχο συσχέτισης για να διαπιστώσουμε αν υπάρχει σχέση μεταξύ των πωλήσεων και των πελατών (Πίνακας 13.10).

Πίνακας 13.10 Πίνακας συσχέτισης

	Στήλη 1 = Αριθμός πελατών	Στήλη 2 = Πωλήσεις
Στήλη 1 = Αριθμός πελατών	1	
Στήλη 2 = Πωλήσεις	0,954913	1

Ο πίνακας συσχέτισης προκύπτει από την ίδια ρουτίνα της «Ανάλυσης δεδομένων», επιλέγοντας στη συνέχεια τη «Συσχέτιση». Διαπιστώνουμε επομένως ότι υπάρχει υψηλή συσχέτιση μεταξύ πωλήσεων και πελατών, ίση με 0,95.

Υποθέσεις παλινδρόμησης

Για να εφαρμοστεί η μέθοδος της παλινδρόμησης και να εκτιμηθούν σωστά οι παράμετροι του οικονομετρικού μοντέλου, πρέπει να ισχύουν οι ακόλουθες υποθέσεις:


1. Κανονικότητα (normality): απαιτεί οι τιμές του y να κατανέμονται κανονικά σε κάθε τιμή του x . Ακόμα όμως και αν η κατανομή του y δεν είναι ακριβώς κανονική, τα αποτελέσματα δεν επηρεάζονται πολύ. Αν το δείγμα είναι μεγάλο, τότε προσεγγίζει την κανονική κατανομή.
2. Ομοσκεδαστικότητα (homoskedasticity): απαιτεί η διαφοροποίηση γύρω από τη γραμμή της παλινδρόμησης να είναι σταθερή για όλες τις τιμές του x . Δηλαδή το y δείχνει την ίδια μεταβλητότητα τόσο στις χαμηλές όσο και στις υψηλές τιμές του y . Αν παραβιάζεται αυτή η υπόθεση, πρέπει να χρησιμοποιήσουμε μετασχηματισμούς των στοιχείων ή τη μέθοδο των σταθμισμένων ελαχίστων τετραγώνων (Weighted Least Squares Method).
3. Ανεξαρτησία σφάλματος (independence of errors): απαιτεί το σφάλμα να είναι ανεξάρτητο για κάθε τιμή του x . Αυτή η παραβίαση συμβαίνει κυρίως σε χρονολογικές σειρές ή δεδομένα τύπου πάνελ, όπου τα κατάλοιπα της μιας περιόδου συσχετίζονται με αυτά της προηγούμενης περιόδου.
4. Γραμμικότητα (linearity): απαιτεί η σχέση ανάμεσα στις μεταβλητές να είναι γραμμική και να έχουμε σωστή εξειδίκευση του υποδείγματος.
5. Να υπάρχει μεταβλητότητα στις τιμές των μεταβλητών X .
6. Τα ζεύγη (Y, X) να είναι iid, δηλαδή independent and identically distributed.⁷

7. Ανεξάρτητα και πανομοιότυπα κατανεμημένα.

Τα κατάλοιπα

Για να αξιολογήσουμε την καταλληλότητα της παλινδρόμησης που έχουμε «τρέξει», είναι απαραίτητη μια ενδελεχής ανάλυση των *καταλοίπων* (residuals). Αυτή θα μας πληροφορήσει σχετικά με το αν έχουν παραβιαστεί οι παραπάνω υποθέσεις. Αλλά ας δώσουμε πρώτα έναν ορισμό του καταλοίπου: ως κατάλοιπο e_i ονομάζουμε τη διαφορά ανάμεσα στο y_i και το $\hat{y}_i$ για κάθε x_i . Δηλαδή το κατάλοιπο ορίζεται ως η σχέση 13.40:


$$e_i = y_i - \hat{y}_i \quad (13.40)$$



Σχήμα 13.12 Η γραμμή παλινδρόμησης και τα κατάλοιπά της

Στο Σχήμα 13.12, η κάθετη απόσταση (στον άξονα των x) της γραμμής παλινδρόμησης από τις κουκκίδες (που αποτελούν τα y_i) ορίζει τα κατάλοιπα της παλινδρόμησης.

Τα κατάλοιπα μπορούν να ελεγχθούν οπτικά, δηλαδή να τα τοποθετήσουμε σε ένα διάγραμμα όπου στον οριζόντιο άξονα θα βρίσκεται το x_i και στον κάθετο το e_i . Αν το μοντέλο που έχουμε εκτιμήσει με τη μέθοδο της παλινδρόμησης είναι καλό, τότε δεν θα πρέπει να ανιχνεύουμε κάποιο σχήμα (pattern) σε αυτό το γράφημα, δηλαδή τα κατάλοιπα πρέπει να κατανέμονται τυχαία (randomly). Στο παράδειγμα των πωλήσεων των εστιατορίων, το γράφημα καταλοίπων δίνεται από το Σχήμα 13.13.




Σχήμα 13.13 Τα κατάλοιπα της παλινδρόμησης της σχέσης πωλήσεων εστιατορίων και πελατών

Στις αναλύσεις καταλοίπων συνηθίζεται να χρησιμοποιούμε όχι τα απλά κατάλοιπα αλλά τα τυποποιημένα κατάλοιπα (standardized residuals), όπου κάθε κατάλοιπο διαιρείται με το τυπικό σφάλμα του (standard error). Ένα άλλο είδος καταλοίπων που επίσης χρησιμοποιούμε στις αναλύσεις μας είναι τα κατάλοιπα κατά Student (studentized residuals), δηλαδή τυποποιημένα κατάλοιπα προσαρμοσμένα με την απόσταση του μέσου, όπως η σχέση 13.41:

$$h_i = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (13.41)$$

Η ομοσκεδαστικότητα γίνεται αντιληπτή με το μάτι, όταν παρατηρήσουμε ότι δεν υπάρχει διαφοροποίηση των καταλοίπων σε μεγάλες ή μικρές τιμές του x_i . Αντιθέτως, αν, όσο μεγαλώνει το x_i , μεγαλώνει και το κατάλοιπο, τότε έχουμε ετεροσκε-

δαστικότητα (heteroskedasticity), η οποία αποτελεί πρόβλημα που πρέπει να λυθεί και να «ξενατρεύουμε» την παλινδρόμηση. Δείτε το Σχήμα 13.14, όπου στον κάθετο άξονα βρίσκονται τα κατάλοιπα και στον οριζόντιο η ανεξάρτητη μεταβλητή x . Καθώς αυξάνεται το x , αυξάνονται και τα κατάλοιπα αντί να είναι σταθερά. Δημιουργείται ένα σχήμα σαν βεντάλια (fanning effect).



Σχήμα 13.14 Διάγραμμα διασποράς καταλοίπων
όταν υπάρχει ετεροσκεδαστικότητα
(Σημείωση: στον κάθετο άξονα τα κατάλοιπα, στον οριζόντιο το x)

Ένας συνήθης τρόπος γρήγορης επίλυσης του προβλήματος της ετεροσκεδαστικότητας είναι ο μετασχηματισμός των x και y στις λογαριθμικές τιμές τους, δηλαδή αντί να «τρέξουμε» την παλινδρόμηση μεταξύ x και y , την «τρέχουμε» μεταξύ των $\log x$ και $\log y$. Αυτός ο μετασχηματισμός των μεταβλητών μας επιτρέπει να εκλάβουμε τους εκτιμηθέντες συντελεστές b_0 και b_1 ως ελαστικότητες, ωστόσο, όταν υπάρχουν αρνητικές παρατηρήσεις, χρειάζονται ειδικοί χειρισμοί.

Επίσης, η κανονικότητα των καταλοίπων μπορεί να ελεγχθεί «με το μάτι», αν παρατηρήσουμε την κατανομή των καταλοίπων κατά Student και κατά πόσο αυτή ακολουθεί την καμπανοειδή μορφή.

Όσον αφορά την ανεξαρτησία σφάλματος, συχνά, όταν έχουμε δεδομένα τα οποία έχουν συλλεχθεί σε διαδοχικές χρονικές στιγμές, τα θετικά κατάλοιπα τείνουν να ακολουθούνται από θετικά κατάλοιπα (ακολουθίες θετικών καταλοίπων) και τα

αρνητικά κατάλοιπα τείνουν να ακολουθούνται από αρνητικά κατάλοιπα (ακολουθίες αρνητικών καταλοίπων). Τέτοια σχήματα καταλοίπων λέμε ότι χαρακτηρίζονται από αυτοσυσχέτιση (autocorrelation). Η αυτοσυσχέτιση αποτελεί σοβαρό πρόβλημα το οποίο θέτει σε αμφιβολία τα αποτελέσματα της παλινδρόμησης.

Για να ανιχνεύσουμε το πρόβλημα της αυτοσυσχέτισης, χρησιμοποιούμε το στατιστικό Durbin - Watson (DW) (για 1ου βαθμού αυτοσυσχέτιση). Αυτό το στατιστικό d μετρά τη συσχέτιση κάθε καταλοίπου μιας περιόδου με το κατάλοιπο της προηγούμενης περιόδου. Ορίζεται όπως η σχέση 13.42:

$$d = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2} \quad (13.42)$$

Η τιμή του D μας δίνει τις κάτωθι ενδεικτικές πληροφορίες για την ύπαρξη αυτοσυσχέτισης:

Όταν $d \approx 0$, τότε υπάρχει θετική αυτοσυσχέτιση.

Όταν $d \approx 2$, τότε δεν υπάρχει αυτοσυσχέτιση.

Όταν $d > 2$, τότε υπάρχει αρνητική αυτοσυσχέτιση. Το d ορίζεται στο διάστημα $[0, 4]$.

Η απόφαση για τη σοβαρότητα του προβλήματος της αυτοσυσχέτισης σε μια παλινδρόμηση εξαρτάται από τον αριθμό των παρατηρήσεων στις οποίες βασίστηκε η παλινδρόμηση και τον αριθμό των ανεξάρτητων μεταβλητών x_i . Παρακάτω ακολουθεί ένα μικρό απόσπασμα πίνακα του στατιστικού DW ή d . Όπως διαπιστώνουμε, για κάθε συνδυασμό επιπέδου σημαντικότητας α , μεγέθους δείγματος n και αριθμού ανεξάρτητων μεταβλητών p αντιστοιχούν δύο τιμές του πίνακα DW. Η πρώτη τιμή d_L αντιπροσωπεύει τη χαμηλότερη κριτική τιμή, όταν δεν υπάρχει αυτοσυσχέτιση στα κατάλοιπα. Αν η τιμή του στατιστικού είναι μικρότερη από d_L , καταλήγουμε στο συμπέρασμα ότι υπάρχει αυτοσυσχέτιση. Σε αυτή την περίπτωση η μέθοδος των ελαχίστων τετραγώνων δεν είναι η κατάλληλη για να προβούμε σε εκτίμηση κάποιου μοντέλου. Η δεύτερη τιμή που δίνει ο πίνακας είναι η d_U , η οποία αντιπροσωπεύει την άνω κριτική τιμή του DW, πάνω από την οποία μπορούμε να συμπεράνουμε ότι δεν υπάρχει αυτοσυσχέτιση (Πίνακας 13.11). Αν η τιμή DW βρίσκεται μεταξύ d_L και d_U , δεν μπορούμε να αποφασίσουμε ξεκάθαρα για τον ύπαρξη ή δεν υπάρχει αυτοσυσχέτιση και χρειάζονται επιπλέον χειρισμοί.

Πίνακας 13.11 Απόσπασμα πίνακα DW για επίπεδο σημαντικότητας 5%

	p=1		p=2		p=3		p=4	
n	d _L	d _U	d _L	d _U	d _L	d _U	d _L	d _U
15	1,08	1,36	0,95	1,54	0,82	1,75	0,69	1,97
...								
18	1,16	1,39	1,05	1,53	0,93	1,69	0,82	1,87
19	1,18	1,40	1,08	1,53	0,97	1,68	0,86	1,85
...								
100	1,65	1,69	1,63	1,72	1,61	1,74	1,59	1,76

Πηγή: Υπάρχει σε όλα τα βιβλία Στατιστικής ή Οικονομετρίας

Εφαρμογή

Στα δεδομένα πωλήσεων και πελατών των 20 εστιατορίων της Κρήτης,⁸ υπολογίστε το στατιστικό DW και αποφασίστε αν υπάρχει πρόβλημα αυτοσυσχέτισης καταλοίπων.

Λύση

Από το μενού της «Ανάλυσης δεδομένων» επιλέξτε τη ρουτίνα με τίτλο «Παλινδρόμηση» και αφού εισαγάγετε τις μεταβλητές x και y, τικάρετε την επιλογή «Υπόλοιπα». Αυτή η επιλογή θα σας δώσει τα κατάλοιπα. Πάρτε τα κατάλοιπα σε ένα χωριστό φύλλο και υπολογίστε τη διαφορά της κάθε τιμής καταλοίπου από την προηγούμενη τιμή του, και αυτή τη διαφορά υψώστε την στο τετράγωνο. Στη συνέχεια παίρνετε το άθροισμα αυτής της καινούργιας στήλης που φτιάξατε και αποτελεί τον αριθμητή του στατιστικού DW. Ακολούθως φτιάχνετε μια άλλη στήλη η οποία αποτελείται από τα τετράγωνα της στήλης των καταλοίπων. Παίρνετε και από αυτή τη στήλη το άθροισμα, και τώρα έχετε φτιάξει και τον παρονομαστή του στατιστικού DW. Στη στήλη C φαίνονται οι εξισώσεις του Excel που μπορείτε να χρησιμοποιήσετε για γρήγορο υπολογισμό (Πίνακας 13.12).

8. Συνήθως στα cross sectional δεδομένα η αυτοσυσχέτιση δεν αποτελεί πρόβλημα. Για να κά-
νουμε το παράδειγμα πιο ρεαλιστικό για την περίπτωση της αυτοσυσχέτισης, θα προσθέσουμε τη διά-
σταση ότι ανήκουν στον ίδιο ιδιοκτήτη και επομένως η καλή φήμη του ενός εστιατορίου εύλογα επη-
ραάζει και την πελατεία του άλλου εστιατορίου.

Πίνακας 13.12 Παράδειγμα υπολογισμού στατιστικού DW στο Excel

	A	B	C	D
	Κατάλοιπα			
1	0,859445883	(Άθροισμα διαφορών καταλοίπου από προηγούμενη τιμή του) ²	=SUMXMY2(A2:A21;A1:A20)	4,5845
2	0,543588457	Άθροισμα τετραγώνων καταλοίπων	=SUMSQ(A1:A21)	4,5269
3	-8,95107E-05	Στατιστικό DW	=C1/C2	1,012
4	0,318516019			
5	0,109507787			
6	-0,10342603			
7	-0,602485958			
8	-0,145006863			
9	0,199135711			
10	0,030633572			
11	-0,720265014			
12	-0,605027281			
13	-1,028952866			
14	-0,081752666			
15	0,551294751			
16	0,163268077			
17	-0,024138904			
18	0,439394187			
19	0,530324051			
20	-0,4339634			
21	0,859445883			

Βρίσκουμε τις άνω και κάτω τιμές του στατιστικού DW από τον Πίνακα 13.11 για $p=1$ (μια ανεξάρτητη μεταβλητή) και $n=21$. Λόγω του στατιστικού που υπολογίσαμε στον Πίνακα 13.12, δηλαδή $1,012 < d_L$, μπορούμε να πούμε ότι υπάρχει αυτοσυσχέτιση σε αυτό το μοντέλο. Ένας τρόπος για να ξεπεραστεί το πρόβλημα είναι να προσθέσουμε και άλλες ανεξάρτητες μεταβλητές στο μοντέλο, οι οποίες σίγουρα επηρεάζουν το Y και τις έχουμε παραλείψει.

Πολλαπλή παλινδρόμηση

Προηγουμένως αντιμετωπίσαμε την περίπτωση μια ερμηνευτική μεταβλητή x να χρησιμοποιείται για την πρόβλεψη του y . Στην πραγματικότητα όμως μπορούν πολλές μεταβλητές x να χρησιμοποιηθούν για την ερμηνεία και την πρόβλεψη του y . Αυτό είναι το πλαίσιο της πολλαπλής παλινδρόμησης που θα εξετάσουμε στη συνέχεια, και συνοψίζεται στην εξίσωση της μορφής στη σχέση 13.43 (για p ερμηνευτικές μεταβλητές):

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \dots + \beta_p x_{pi} + \varepsilon_i \quad (13.43)$$

Το β_0 είναι η σταθερά, β_1 είναι η κλίση του y (κρατώντας τις άλλες μεταβλητές σταθερές), το β_2 είναι η κλίση του y (κρατώντας τις άλλες μεταβλητές σταθερές), το β_p είναι η κλίση του y (κρατώντας τις άλλες μεταβλητές σταθερές) και το ε_i είναι ο διαταρακτικός όρος (το σφάλμα). Με τρόπο ανάλογο με αυτόν που αναφέραμε στην απλή παλινδρόμηση, οι συντελεστές β_i αναφέρονται στον πληθυσμό, ενώ οι συντελεστές b_i αναφέρονται στο δείγμα.

Ο συντελεστής πολλαπλού προσδιορισμού

Ο *συντελεστής πολλαπλού προσδιορισμού* (coefficient of multiple determination) αντιπροσωπεύει την αναλογία του y , η οποία ερμηνεύεται από τις ερμηνευτικές μεταβλητές x . Έστω ότι έχουμε δύο ερμηνευτικές μεταβλητές: ο συντελεστής πολλαπλού προσδιορισμού ($r_{y,12}^2$) δίδεται από το σύνολο των τετραγώνων της παλινδρόμησης (Sum of Squares of Regression - SSR)⁹ διαιρεμένο με το συνολικό σύνολο τετραγώνων (Total Sum of Squares - SST), δηλαδή όπως η 13.44:

9. Το αποτέλεσμα του Excel παράγει αυτές τις τιμές στο πεδίο «Ανάλυση διακύμανσης» στα κελιά με τίτλους «Παλινδρόμηση» και «Σύνολο», αντίστοιχα.

$$r_{y.12}^2 = 1 - \frac{SSR}{SST} \quad (13.44)$$

Έτσι, αν για παράδειγμα, ο συντελεστής πολλαπλού προσδιορισμού είναι 95%, αυτό σημαίνει ότι το 95% της μεταβλητότητας του y οφείλεται στη μεταβλητότητα των ερμηνευτικών μεταβλητών x_1 και x_2 . Κάποιοι ερευνητές προτείνουν τη χρήση του προσαρμοσμένου συντελεστή πολλαπλού προσδιορισμού (Adjusted r^2) στην περίπτωση της πολλαπλής παλινδρόμησης. Ο προσαρμοσμένος συντελεστής αντανakλά και τον αριθμό των ερμηνευτικών μεταβλητών του μοντέλου και το μέγεθος του δείγματος, και γράφεται όπως η 13.45:

$$r_{adj}^2 = 1 - \left[(1 - r_{y.12...p}^2) \frac{n-1}{n-p-1} \right] \quad (13.45)$$

Όπου p είναι ο αριθμός των ερμηνευτικών μεταβλητών σε μια παλινδρόμηση (σημείωση: δεν συμπεριλαμβάνεται η σταθερά στο p). Για λόγους οικονομίας χώρου, δεν θα δείξουμε ξεχωριστό παράδειγμα στο Excel για την περίπτωση της πολλαπλής παλινδρόμησης.

Μοντέλα με μεταβλητές dummy (ψευδομεταβλητές)

Υπάρχουν περιπτώσεις που χρειάζεται να χρησιμοποιήσουμε ποιοτικές και όχι ποσοτικές μεταβλητές για να περιγράψουμε ένα φαινόμενο. Η χρήση των dummy variables (ψευδομεταβλητών) μας επιτρέπει να εισαγάγουμε σε ένα μοντέλο αυτές τις μεταβλητές. Αν η ποιοτική μεταβλητή έχει μόνο δύο επίπεδα - δύο κατηγορίες, τότε χρειάζεται να χρησιμοποιήσουμε μόνο μία dummy μεταβλητή [αν χρησιμοποιούσαμε δύο μεταβλητές, θα είχαμε το πρόβλημα της γνωστής στη βιβλιογραφία «παγίδας των μεταβλητών dummy» (dummy variable trap)]. Αυτή η dummy μεταβλητή x_d ορίζεται ως εξής:

$x_d = 0$, αν η παρατήρηση βρίσκεται στην κατηγορία 1

$x_d = 1$, αν η παρατήρηση βρίσκεται στην κατηγορία 2

Έτσι, για παράδειγμα, θα μπορούσαμε σε μια ξεχωριστή στήλη, να προσθέσουμε μια ψευδομεταβλητή στα δεδομένα των πωλήσεων των εστιατορίων. Αυτή η μεταβλητή θα περιέγραφε τα εστιατόρια που βρίσκονται σε αστικά κέντρα. Άρα, για κάθε εστιατόριο από τα 20 του δείγματος, θα βάζαμε τη μονάδα αν το εστιατόριο βρισκόταν σε αστικό κέντρο. Διαφορετικά, αν δηλαδή βρισκόταν στην εξοχή, σε παραλία ή σε χωριό κ.τ.λ., θα βάζαμε την τιμή μηδέν.

Η χρήση των όρων αλληλεπίδρασης

Μερικές φορές η σχέση ανάμεσα στο y και σε μία από τις ερμηνευτικές μεταβλητές, έστω τη x_1 , αλλάζει για διαφορετικές τιμές του x_2 (αν έχουμε μοντέλο με δύο ερμηνευτικές μεταβλητές). Σε αυτές τις περιπτώσεις μπορούμε να συμπεριλάβουμε έναν όρο αλληλεπίδρασης (interaction term) ως το γινόμενο $x_1 x_2$. Με δύο ερμηνευτικές μεταβλητές, ένα τέτοιο μοντέλο γράφεται όπως η 13.46:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{1i} x_{2i} + \varepsilon_i \quad (13.46)$$

Η πολυσυγγραμμικότητα

Η *πολυσυγγραμμικότητα* (multicollinearity) αναφέρεται σε μια προβληματική κατάσταση του εκτιμηθέντος μοντέλου, κατά την οποία μία ή περισσότερες από τις ερμηνευτικές μεταβλητές παρουσιάζουν υψηλή συσχέτιση με μια άλλη ερμηνευτική μεταβλητή. Σε ένα τέτοιο περιβάλλον, οι συγγραμμικές μεταβλητές δεν παρέχουν καινούργια πληροφόρηση και είναι δύσκολο να ξεχωρίσουμε την πραγματική επίδραση της κάθε μιας στην εξαρτημένη μεταβλητή. Ένα χαρακτηριστικό σύμπτωμα των συντελεστών σε μια τέτοια παλινδρόμηση είναι ότι η συσχέτιση των μεταβλητών αλλάζει πολύ όταν εισέρχονται νέες μεταβλητές στο μοντέλο. Ένας τρόπος για να μετρηθεί η πολυσυγγραμμικότητα είναι η μέτρηση του παράγοντα πληθωρισμού της διακύμανσης (Variance Inflation Factor - VIF) για κάθε μεταβλητή. Αυτός υπολογίζεται με την κάτωθι σχέση 13.47:

$$VIF_j = \frac{1}{1 - r_{x,12}^2} \quad (13.47)$$

Όπου $r_{x,12}^2$ είναι ο συντελεστής πολλαπλού προσδιορισμού της μεταβλητής x_j με όλα τα άλλα x (στη συγκεκριμένη περίπτωση του x_1 με το x_2). Αν κάποιες ερμηνευτικές μεταβλητές είναι ασυσχέτιστες, τότε το VIF_j είναι ίσο με τη μονάδα. Αν αντίθετα υπάρχει υψηλή συσχέτιση, το VIF_j μπορεί να ξεπεράσει την τιμή 10. Πάντως, κάποιιοι ερευνητές (Snee, 1973) θεωρούν ότι ακόμα και αν το VIF_j είναι γύρω στο 5, υπάρχει υψηλή πολυσυγγραμμικότητα και πρέπει να χρησιμοποιηθούν άλλοι μέθοδοι εκτίμησης πέραν των ελαχίστων τετραγώνων ή να παραλειφθεί η μεταβλητή που προκαλεί το πρόβλημα της πολυσυγγραμμικότητας.

Σε αυτό το σημείο ολοκληρώσαμε τη σύντομη αναφορά μας στην απλή και πολλαπλή παλινδρόμηση, και θα συνεχίσουμε στην τελευταία ενότητα μια εξίσου σύντομη αναφορά στα βασικά στοιχεία της ανάλυσης χρονολογικών σειρών και της ειδικής περίπτωσης των δεδομένων τύπου πάνελ (panel data).

Το παρόν βιβλίο παρέχει την πιο επικαιροποιημένη γνώση πάνω στη θεωρία των Οικονομικών του Τουρισμού, εμπλουτισμένη με τη διεθνή εμπειρία και εφαρμογές. Είναι βιβλίο μεσαίας δυσκολίας, το οποίο μπορεί να χρησιμοποιηθεί σε όλα τα έτη προπτυχιακών φοιτητών που σπουδάζουν τον τουρισμό αλλά και μεταπτυχιακούς φοιτητές, ακόμα κι αν προέρχονται από αντικείμενα σπουδών ξένα προς τα οικονομικά. Ταυτόχρονα, είναι εξαιρετικό εργαλείο για επαγγελματίες του τουρισμού, οι οποίοι επιθυμούν να εμπλουτίσουν τις γνώσεις τους αλλά και να δουν επιστημονικά τεκμηριωμένες, πρακτικές και γνώσεις που οι ίδιοι απέκτησαν εμπειρικά μέσα από τη μακροχρόνια τριβή τους με τον τουρισμό. Το κυριότερο όμως όφελος για τους αναγνώστες είναι να εξοικειωθούν με τη διεθνή εμπειρία που προσφέρει το βιβλίο, δεδομένου ότι το τουριστικό προϊόν είναι από τη φύση του παγκοσμιοποιημένο. Για να διευκολυνθούν οι αναγνώστες που μπορεί να μη διαθέτουν το απαραίτητο γνωστικό υπόβαθρο στις Αρχές της Οικονομικής Θεωρίας καθώς και στη Στατιστική - Οικονομετρία, οι επιστημονικοί επιμελητές έγραψαν δύο επιπλέον κεφάλαια με αντίστοιχη θεματολογία τα οποία διευκολύνουν την απρόσκοπτη ανάγνωση και κατανόηση του βιβλίου.



ΕΚΔΟΣΕΙΣ GUTENBERG

ISBN 978-960-01-2020-2



9 789600 120202

KK 9550627