




Ποσοτικές Μέθοδοι στην Διοίκηση Τουρισμού (ΔΙΤ 10)

ΟΣΣ3

Περιγραφή διακριτών τυχαίων μεταβλητών

Μια **διακριτή τυχαία μεταβλητή** X περιγράφεται από μια **συνάρτηση μάζας πιθανότητας** (probability mass function, PMF), $f(x)$, που δίνει την πιθανότητα η τυχαία μεταβλητή να λάβει μια συγκεκριμένη αριθμητική τιμή x , δηλαδή

$$f(x) = \Pr(X = x)$$

Περιγραφή διακριτών τυχαίων μεταβλητών

Παράδειγμα

Παράδειγμα: Εάν στη ρίψη ενός ζαριού έρθει 6, τότε κερδίζετε €10, εάν έρθει 1, 3, 5, τότε χάνετε €5. Η συνάρτηση μάζας πιθανότητας θα είναι:

$$f(x) = \begin{cases} 1/6 & \text{εάν } x = 10 \\ 3/6 & \text{εάν } x = -5 \\ 2/6 & \text{εάν } x = 0 \end{cases}$$

Προσοχή στη διάκριση μεταξύ X (η τ.μ.) και της τιμής x που μπορεί να λάβει η X .

Αθροιστική συνάρτηση διακριτής κατανομής

Από την **PMF**, $f(x)$, της τυχαίας μεταβλητής X , μπορεί να οριστεί η **αθροιστική συνάρτηση κατανομής** (cumulative distribution function, CDF) $F(x)$, της X .

Οι τιμές της **CDF** αντιστοιχούν στην πιθανότητα η X να λάβει τιμές που δεν ξεπερνούν μια αριθμητική τιμή:

$$F(x) = \Pr(X \leq x)$$

Αθροιστική συνάρτηση διακριτής κατανομής

Για διακριτές τυχαίες μεταβλητές:

$$F(x) = \sum_{t \leq x} f(t)$$

Μέσω της **CDF** μπορεί να υπολογιστεί η πιθανότητα να συμβούν διάφορα ενδεχόμενα που αφορούν την τυχαία μεταβλητή, όπως:

$$\Pr(X > x) = 1 - F(x), \quad \Pr(x_1 \leq X \leq x_2) = F(x_2) - F(x_1)$$

Αθροιστική συνάρτηση διακριτής κατανομής

Παράδειγμα

Παράδειγμα: Εάν στη ρίψη ενός ζαριού έρθει 6, τότε κερδίζετε €10, εάν έρθει 1, 3, 5, τότε χάνετε €5. Η συνάρτηση μάζας πιθανότητας θα είναι:

$$f(x) = \begin{cases} 1/6 & \text{εάν } x = 10 \\ 3/6 & \text{εάν } x = -5 \\ 2/6 & \text{εάν } x = 0 \end{cases}$$

$$F(-5) = \frac{3}{6}, \quad x \in \{-5, 0, 10\} \Rightarrow F(0) = \frac{3}{6} + \frac{2}{6} = \frac{5}{6}, \quad F(10) = \frac{6}{6} = 1$$

Διωνυμική κατανομή

Διακριτή κατανομή που περιγράφει την πιθανότητα x «επιτυχιών» σε n διαδοχικές δοκιμές.

Κάθε δοκιμή έχει μόνο δύο αποτελέσματα: «αποτυχία» ή «επιτυχία»

Το αποτέλεσμα μίας δοκιμής είναι ανεξάρτητο από τις προηγούμενες.

Η πιθανότητα «επιτυχίας» σε κάθε δοκιμή είναι p και η πιθανότητα «αποτυχίας» $q = 1 - p$

$$\Pr(X = x) = \frac{n!}{x! (n - x)!} p^x q^{n-x}$$

Διωνυμική κατανομή

Αναμενόμενος αριθμός «επιτυχιών»: $\mu = np$

Διακύμανση: $\sigma^2 = npq$

Συνάρτηση **Excel**

=binom.dist(x; n; p; true/false)

(true για αθροιστική κατανομή, false για συνάρτηση μάζας πιθανότητας)

Διωνυμική κατανομή

Παράδειγμα

Ένας ασφαλιστής συνεργάζεται με κάποια αντιπροσωπεία αυτοκινήτων. Ο ασφαλιστής έχει **ασφαλίσει 15 αυτοκίνητα** της αντιπροσωπείας τα οποία έχουν το ίδιο έτος κατασκευής και προέρχονται από την ίδια κατασκευάστρια εταιρεία.

Από παλιότερα δεδομένα που έχει συλλέξει η εταιρεία, έχει εκτιμηθεί ότι κάθε αυτοκίνητο με αυτά τα χαρακτηριστικά **έχει πιθανότητα 5%** να παρουσιάσει βλάβη σε ένα έτος.

α. Ποια η πιθανότητα σε ένα έτος:

- να παρουσιάσουν βλάβη **2** αυτοκίνητα;
- να μην παρουσιάσει βλάβη **κανένα** από τα 15 αυτοκίνητα;
- να παρουσιάσουν βλάβη **τουλάχιστον 2** αυτοκίνητα;

Διωνυμική κατανομή

Παράδειγμα

Απάντηση:

α. Ποια η πιθανότητα σε ένα έτος

- να παρουσιάσουν βλάβη **2** αυτοκίνητα;

$$\Pr(X = 2) = \frac{15!}{2! (15 - 2)!} 0,05^2 0,95^{15-2} = \mathbf{0,135}$$

- να μην παρουσιάσει βλάβη **κανένα** από τα 15 αυτοκίνητα;

$$\Pr(X = 0) = \frac{15!}{0! (15 - 0)!} 0,05^0 0,95^{15} = \mathbf{0,463}$$

- να παρουσιάσουν βλάβη **τουλάχιστον** 2 αυτοκίνητα;

$$\Pr(X \geq 2) = 1 - [\Pr(X = 0) + \Pr(X = 1)] = \mathbf{0,171}$$

Διωνυμική κατανομή

Παράδειγμα

β. Αν κάθε αυτοκίνητο που παρουσιάζει βλάβη μέσα στο έτος **λαμβάνει αποζημίωση 500 ευρώ**, ποιο είναι το συνολικό ποσό που αναμένεται να πληρώσει η ασφαλιστική εταιρεία;

$$Y = 500X,$$
$$\mu_Y = 500\mu_X = 500(15)(0,05) = 375\text{€}$$

γ. Ποια είναι η τυπική απόκλιση για τη συνολική αποζημίωση που θα πληρώσει η εταιρεία;

$$\sigma_Y^2 = 500^2\sigma_X^2 = 500^2(15)(0,05)(0,95) = 178125$$
$$\sigma_Y = 422,05$$

Κατανομή Poisson

Τυχαία ενδεχόμενα **εμφανίζονται κατά διαστήματα χρόνου ή χώρου** ως εξής

- Σε κάθε διάστημα το ενδεχόμενο συμβαίνει ή δεν συμβαίνει.
- Η εμφάνιση του ενδεχομένου σε ένα διάστημα είναι ανεξάρτητη από τα προηγούμενα.
- Η πιθανότητα εμφάνισης του ενδεχομένου είναι σταθερή στα διαστήματα.

Κατανομή Poisson

Η **κατανομή Poisson** περιγράφει τον αριθμό των συμβάντων, δεδομένου του μέσου αριθμού λ των συμβάντων σε ένα προκαθορισμό διάστημα:

$$\Pr(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}$$

Μέση τιμή και διακύμανση: $\mu = \sigma^2 = \lambda$

Συνάρτηση **Excel**

=poisson.dist(x; λ; true/false)

(true για αθροιστική κατανομή, false για συνάρτηση μάζας πιθανότητας)

Κατανομή Poisson

Παράδειγμα

Μια βιοτεχνία λειτουργεί 8 ώρες/ημέρα και δέχεται 24 παραγγελίες / ημέρα. Αν ο αριθμός των παραγγελιών ακολουθεί την κατανομή Poisson:

1. Ποια είναι η πιθανότητα να υπάρξουν **4** παραγγελίες την επόμενη ώρα;
2. Ποια είναι η πιθανότητα να υπάρξουν **το πολύ 2** παραγγελίες την επόμενη ώρα;
3. Ποιος είναι **ο αναμενόμενος αριθμός παραγγελιών** σε διάστημα **2 ωρών**;
4. Ποια είναι η πιθανότητα να υπάρξουν **τουλάχιστον 3** παραγγελίες σε 2 ώρες;

Κατανομή Poisson

Παράδειγμα

Απάντηση:

1. Ποια είναι η πιθανότητα να υπάρξουν **4** παραγγελίες την επόμενη ώρα;

$$\Pr(X = 4) = \frac{e^{-3} 3^4}{4!} = 0,168$$

2. Ποια είναι η πιθανότητα να υπάρξουν **το πολύ 2** παραγγελίες την επόμενη ώρα;

$$\Pr(X \leq 2) = \Pr(X = 0) + \Pr(X = 1) + \Pr(X = 2) = 0,4232$$

3. Ποιος είναι **ο αναμενόμενος αριθμός παραγγελιών** σε διάστημα **2 ωρών**;

$$2\lambda = 6 \text{ παραγγελίες ανά 2 ώρες}$$

Κατανομή Poisson

Παράδειγμα

Απάντηση:

4. Ποια είναι η πιθανότητα να υπάρξουν **τουλάχιστον 3** παραγγελίες σε 2 ώρες;

$$\Pr(X \geq 3) = 1 - [\Pr(X = 0) + \Pr(X = 1) + \Pr(X = 2)] = \mathbf{0,9380}$$

$$\Pr(X = 0) = \frac{e^{-6}6^0}{0!} = \mathbf{0,0025}$$

$$\Pr(X = 1) = \frac{e^{-6}6^1}{1!} = \mathbf{0,0149}$$

$$\Pr(X = 2) = \frac{e^{-6}6^2}{2!} = \mathbf{0,0446}$$

Περιεχόμενα παρουσίασης

1. Απλή Γραμμική Παλινδρόμηση
2. Πολλαπλή Γραμμική Παλινδρόμηση


Γραμμική Συσχέτιση Μεταβλητών

- Η τεχνική της παλινδρόμησης αναφέρεται στη στατιστική τεχνική της μοντελοποίησης της σχέσης μεταξύ μεταβλητών.
- Στην απλή γραμμική παλινδρόμηση, μοντελοποιούμε τη σχέση μεταξύ δυο μεταβλητών.
- Η μια μεταβλητή, που συμβολίζεται με Y , ονομάζεται **εξαρτημένη μεταβλητή** και η δεύτερη, που συμβολίζεται με X , ονομάζεται **ανεξάρτητη μεταβλητή**.
- Το μοντέλο που χρησιμοποιούμε είναι μια **σχέση ευθείας γραμμής** μεταξύ των X και Y .
- Το διάγραμμα των ζευγών (X, Y) ονομάζεται **διάγραμμα σκεδασμού**.

Γραμμική Συσχέτιση Μεταβλητών

Στο διάγραμμα σκεδασμού (ή διασποράς) σχεδιάζονται ζεύγη παρατηρήσεων. Παρατηρούμε ότι:

- ✓ Μεγαλύτερες (μικρότερες) τιμές στον άξονα Y **τείνουν** να σχετίζονται με μεγαλύτερες (μικρότερες) τιμές στον άξονα των X .









Γραμμική Συσχέτιση Μεταβλητών

Στο διάγραμμα σκεδασμού (ή διασποράς) σχεδιάζονται ζεύγη παρατηρήσεων. Παρατηρούμε ότι:

- ✓ Τα σημεία **τείνουν** να κατανέμονται γύρω από μια ευθεία γραμμή με θετική κλίση.
- ✓ Τα ζεύγη των σημείων δεν βρίσκονται ακριβώς πάνω σε μια ευθεία γραμμή.
- ✓ Το διάγραμμα σκεδασμού φανερώνει μια περισσότερο ή λιγότερο ισχυρή **τάση** και όχι μια αυστηρή **γραμμική σχέση**.
- ✓ Η γραμμή αντιπροσωπεύει τη φύση της σχέσης **κατά μέσο όρο**.

Γραμμική Συσχέτιση Μεταβλητών









Γραμμική Συσχέτιση Μεταβλητών

Η **συσχέτιση** μεταξύ δυο τυχαίων μεταβλητών, X και Y , είναι ένα μέτρο του **βαθμού γραμμικής σχέσης** μεταξύ των δυο μεταβλητών.

Η πληθυσμιακή συσχέτιση συμβολίζεται με ρ και παίρνει τιμές από το **-1 έως το 1** .

$\rho = -1$	σημαίνει ότι υπάρχει μια τέλεια αρνητική γραμμική σχέση
$-1 < \rho < 0$	σημαίνει ότι υπάρχει μια αρνητική γραμμική σχέση
$\rho = 0$	σημαίνει ότι δεν υπάρχει γραμμική σχέση
$0 < \rho < 1$	σημαίνει ότι υπάρχει μια θετική γραμμική σχέση
$\rho = 1$	σημαίνει ότι υπάρχει μια τέλεια θετική γραμμική σχέση

Γραμμική Συσχέτιση Μεταβλητών



Μοντέλο απλής γραμμικής παλινδρόμησης

Το γεγονός ότι η σχέση μεταξύ των Y και X δεν είναι ακριβής παραπέμπει στη χρήση ενός **στατιστικού μοντέλου** για την ανάλυση αυτής της σχέσης.

Το στατιστικό μοντέλο διαχωρίζει το **συστηματικό μέρος** της σχέσης από το **τυχαίο μέρος**.

Δεδομένα



**Στατιστικό
μοντέλο**



**Συστηματικό
μέρος**
+
**Τυχαία
σφάλματα**

Στην **ANOVA**, το συστηματικό μέρος είναι το **SSTR** (εξηγούμενη μεταβλητότητα) και το τυχαίο μέρος είναι το **SSE** (ανεξήγητη μεταβλητότητα).

Στην **παλινδρόμηση**, το συστηματικό μέρος είναι η **συνολική γραμμική σχέση** και το τυχαίο μέρος είναι η μεταβλητότητα γύρω από την γραμμή.

Μοντέλο απλής γραμμικής παλινδρόμησης

Το μοντέλο **απλής γραμμικής παλινδρόμησης** για τον πληθυσμό είναι:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Τυχαίο μέρος

Μη τυχαίο ή
συστηματικό μέρος

όπου

- Y είναι η **εξαρτημένη μεταβλητή**, η μεταβλητή την οποία θέλουμε να εξηγήσουμε ή να προβλέψουμε.
- X είναι η **ανεξάρτητη μεταβλητή**, που επίσης ονομάζεται και μεταβλητή πρόβλεψης.

Μοντέλο απλής γραμμικής παλινδρόμησης

Το μοντέλο **απλής γραμμικής παλινδρόμησης** για τον πληθυσμό είναι:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Τυχαίο μέρος


Μη τυχαίο ή
συστηματικό μέρος

όπου

- ε είναι ο **όρος των σφαλμάτων**, ο μόνος τυχαίος παράγοντας στο μοντέλο και συνεπώς η μόνη πηγή τυχαιότητας της Y .
- Το β_0 είναι ο **σταθερός όρος** του συστηματικού μέρους της γραμμικής παλινδρόμησης.
- Το β_1 είναι η **κλίση** της γραμμικής παλινδρόμησης.

Μοντέλο απλής γραμμικής παλινδρόμησης

- Η **σχέση** που συνδέει τα X και Y είναι **γραμμική**.
- Οι τιμές της ανεξάρτητης μεταβλητής X υποθέτουμε ότι είναι σταθερές (όχι τυχαίες). Η μόνη **τυχειότητα** που υπάρχει είναι στις τιμές της Y που προέρχεται από τον όρο σφάλματος ε_i .
- Τα σφάλματα ε_i είναι **κανονικά κατανεμημένα** με μέσο 0 και διακύμανση σ^2 . Τα σφάλματα είναι ασυσχέτιστα σε διαδοχικές παρατηρήσεις. Δηλαδή $X \sim N(0, \sigma^2)$.



Μοντέλο απλής γραμμικής παλινδρόμησης

- Η εκτίμηση του απλού γραμμικού μοντέλου συνεπάγεται την εύρεση εκτιμώμενων ή προβλεπόμενων τιμών του σταθερού όρου και της κλίσης για την γραμμή της παλινδρόμησης.
- Η **εκτιμώμενη εξίσωση παλινδρόμησης** είναι:

$$Y = b_0 + b_1 X + e$$

όπου το b_0 είναι η εκτίμηση του σταθερού όρου β_0 της πληθυσμιακής γραμμικής παλινδρόμησης, το b_1 εκτιμά την κλίση β_1 της πληθυσμιακής γραμμικής παλινδρόμησης και το e δηλώνει τα παρατηρούμενα σφάλματα, δηλαδή τα υπόλοιπα από την προσαρμογή της γραμμής $b_0 + b_1 X$ στο σύνολο των n δεδομένων.





Μοντέλο απλής γραμμικής παλινδρόμησης

- Η γραμμή παλινδρόμησης είναι:


$$\hat{Y} = b_0 + b_1 X + e$$

όπου όπου το $\hat{Y}$ είναι η τιμή της Y που βρίσκεται στην προσαρμοσμένη γραμμή παλινδρόμησης για ένα δοθέν X .

Μοντέλο απλής γραμμικής παλινδρόμησης






Μοντέλο απλής γραμμικής παλινδρόμησης



Έλεγχος Υπόθεσης

$$H_0: \beta_1 = 0$$
$$H_1: \beta_1 \neq 0$$



Ο **έλεγχος υπόθεσης** για την ύπαρξη γραμμικής σχέσης μεταξύ των X και Y είναι:

$$H_0: \beta_1 = 0$$
$$H_1: \beta_1 \neq 0$$

Έλεγχος Υπόθεσης

Παράδειγμα

Ένα υπουργείο καταγράφει τις λειτουργικές δαπάνες Y σε κάθε κτίριο που στεγάζονται υπηρεσίες του (σε χιλιάδες ευρώ) και τα τετραγωνικά μέτρα X του κτιρίου (σε εκατοντάδες). Τα δεδομένα είναι τα ακόλουθα:


Y	15	11	18	13	10	8	12	9	14	16
X	4.5	3.3	5.2	4.6	3.9	3.2	4.1	3.3	4.3	4.8

1. Υπολογίστε την εκτιμώμενη γραμμή παλινδρόμησης. Ερμηνεύστε τον συντελεστή β_1 της εξίσωσης παλινδρόμησης.
2. Ελέγξτε αν η παλινδρόμηση είναι στατιστικά σημαντική σε $\alpha = 1\%$.

Μοντέλο απλής γραμμικής παλινδρόμησης

Παράδειγμα

Επιλέγουμε **Insert > Chart > Scatter**



Έλεγχος Υπόθεσης

Παράδειγμα

- Αφού ανοίξουμε το **Excel** εισάγουμε τις τιμές σε δυο στήλες με ονομασίες Y και X αντίστοιχα.
- Στη συνέχεια επιλέγεται η διαδοχή εντολών

Data > Data Analysis > Regression > OK

- Στο παράθυρο που ανοίγει στο πεδίο **Input Y Range** επιλέγουμε τα κελιά που αντιστοιχούν στη στήλη X (B2:B12), στο πεδίο **Input X Range** επιλέγουμε τα κελιά που αντιστοιχούν στη στήλη Y (C2:C12), επιλέγουμε το **Labels**, το **Confidence Level 95%** και **OK**.
- Τα αποτελέσματα τα παραθέτουμε στις επόμενες δυο διαφάνειες.

Έλεγχος Υπόθεσης

Παράδειγμα

SUMMARY OUTPUT					
<i>Regression Statistics</i>					
Multiple R	0,934740103				
R Square	0,873739061				
Adjusted R Square	0,857956444				
Standard Error	1,20760666				
Observations	10				
ANOVA					
	<i>df</i>	<i>SS</i>	<i>MS</i>	<i>F</i>	<i>Significance F</i>
Regression	1	80,73348924	80,73348924	55,36085	7,33062E-05
Residual	8	11,66651076	1,458313845		
Total	9	92,4			

Έλεγχος Υπόθεσης

Παράδειγμα

	<i>Coefficients</i>	<i>Standard Error</i>	<i>t Stat</i>	<i>P-value</i>
Intercept	-5,302151543	2,436162385	-2,176436011	0,061202
X	4,345182413	0,583991668	7,440486996	7,33E-05

<i>Lower 95%</i>	<i>Upper 95%</i>	<i>Lower 95,0%</i>	<i>Upper 95,0%</i>
-10,91995208	0,315648991	-10,91995208	0,315648991
2,998495211	5,691869615	2,998495211	5,691869615

Έλεγχος Υπόθεσης

Παράδειγμα

Από τα αποτελέσματα διαπιστώνουμε ότι η ευθεία της παλινδρόμησης είναι:

$$\hat{Y} = -5.30 + 4.35X$$

Η ερμηνεία της κλίσης της ευθείας της παλινδρόμησης είναι:

Αν τα τετραγωνικά μέτρα X του κτιρίου **αυξηθούν** μια μονάδα (100 τετραγωνικά μέτρα) οι λειτουργικές δαπάνες Y θα **αυξηθούν** 4.35 χιλιάδες ευρώ (4350 ευρώ) κατά μέσο όρο.

Έλεγχος Υπόθεσης

Παράδειγμα

Για να ελέγξουμε αν η παλινδρόμηση είναι στατιστικά σημαντική θα **εξετάσουμε την τιμή p** για τον έλεγχο:

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

- Η p τιμή για αυτόν τον έλεγχο υπάρχει στην γραμμή αποτελεσμάτων για το X .
- Διαπιστώνουμε ότι $p = 0.000 < 0.01 = \alpha$ συνεπώς απορρίπτουμε την μηδενική υπόθεση.
- Είμαστε 99% βέβαιοι ότι η παλινδρόμηση είναι στατιστικά σημαντική.

Συμπερασματολογία για το μοντέλο


Ο συντελεστής προσδιορισμού, r^2 , είναι ένα περιγραφικό μέτρο της ισχύος της εξίσωσης της παλινδρόμησης, ένα μέτρο του πόσο καλά προσαρμόζεται η γραμμή παλινδρόμησης στα δεδομένα.

Σημείωση:

Αν $\rho < 0, b_1 < 0$

Αν $\rho = 0, b_1 = 0$

Αν $\rho > 0, b_1 > 0$






$$SST = SSE + SSR$$

$$r^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

Ποσοστό ολικής μεταβλητότητας που εξηγείται από την παλινδρόμηση.

Συμπερασματολογία για το μοντέλο

Παράδειγμα





$$r^2 = \frac{SSR}{SST} = \frac{80.733}{92.4} = 0.874$$

Συμπερασματολογία για το μοντέλο

Πηγή Μεταβλητότητας	Άθροισμα Τετραγώνων	Βαθμοί Ελευθερίας	Μέσα Τετράγωνα	F
Παλινδρόμηση	SSR	(1)	MSR	MSR MSE
Σφάλμα	SSE	(n-2)	MSE	
Σύνολο	SST	(n-1)	MST	


Μοντέλο απλής γραμμικής παλινδρόμησης

Για να ελέγξουμε αν ισχύουν οι υποθέσεις κανονικότητα και ομοσκεδαστικότητα επιλέγουμε στο αρχικό παράθυρο τα residual plots και Normal Probability Plots.




Μοντέλο απλής γραμμικής παλινδρόμησης

Από τα διαγράμματα παρατηρούμε ότι στο διάγραμμα καταλοίπων δεν φαίνεται να υπάρχει κάποιο μοτίβο συνεπώς δεν απορρίπτεται η υπόθεση της ομοσκεδαστικότητας.



Μοντέλο απλής γραμμικής παλινδρόμησης

Στο διάγραμμα κανονικότητας τα σημεία είναι πολύ κοντά σε μια ευθεία και συμπεραίνουμε ότι δεν έχουμε ενδείξεις ότι δεν ικανοποιείται η κανονικότητα.



Συσχέτιση παλινδρόμηση

Παράδειγμα

Τα ακόλουθα δεδομένα είναι τιμές χρυσού (Y) και χαλκού (X) για μια περίοδο 10 ετών.

Y	76	62	70	59	52	53	53	56	57	56
X	80	68	73	63	65	68	65	63	65	66

- Υπάρχει γραμμική συσχέτιση μεταξύ των τιμών των δυο μετάλλων;
- Μπορεί να υποστηριχθεί ότι υπάρχει στατιστικά σημαντική γραμμική παλινδρόμηση των τιμών του χρυσού (Y) με τον χαλκό (X) σε $\alpha=1\%$;

Συσχέτιση παλινδρόμηση

Παράδειγμα

- Αφού ανοίξουμε το Excel εισάγουμε τις τιμές σε δυο στήλες με ονομασίες Y και X αντίστοιχα.
- Στη συνέχεια επιλέγεται η διαδοχή εντολών

Data > Data Analysis > Correlation > OK

- Στο παράθυρο που ανοίγει στο πεδίο **Input Range** σημειώνουμε E2:F12, επιλέγουμε το **Labels in First Row** και OK. Τα αποτελέσματα είναι:

	Χρυσός	Χαλκός
Χρυσός	1	
Χαλκός	0,875369	1

Συσχέτιση παλινδρόμηση

Παράδειγμα

Από τα αποτελέσματα διαπιστώνουμε ότι υπάρχει ισχυρή γραμμική συσχέτιση των δυο μεταβλητών αφού είναι $r = 0.875$.

Στη συνέχεια:

- Επιλέγεται η διαδοχή εντολών

Data > Data Analysis > Regression > OK

- Στο παράθυρο που ανοίγει στο πεδίο **Input Y Range** σημειώνουμε E2:E12, στο πεδίο **Input X Range** σημειώνουμε F2:F12, επιλέγουμε το **Labels**, το **Confidence Level 95%** και **OK**. Τα αποτελέσματα τα παραθέτουμε στις επόμενες δυο διαφάνειες.

Συσχέτιση παλινδρόμηση

Παράδειγμα

SUMMARY OUTPUT					
<i>Regression Statistics</i>					
Multiple R	0,87536932				
R Square	0,766271446				
Adjusted R Square	0,737055377				
Standard Error	4,046317484				
Observations	10				
ANOVA					
	<i>df</i>	<i>SS</i>	<i>MS</i>	<i>F</i>	<i>Significance F</i>
Regression	1	429,4185185	429,4185	26,22774	0,000905735
Residual	8	130,9814815	16,37269		
Total	9	560,4			

Συσχέτιση παλινδρόμηση

Παράδειγμα

	<i>Coefficients</i>	<i>Standard Error</i>	<i>t Stat</i>	<i>P-value</i>
Intercept	-29,48148148	17,40235461	-1,69411	0,128695
Χαλκός	1,314814815	0,256734457	5,121302	0,000906

<i>Lower 95%</i>	<i>Upper 95%</i>	<i>Lower 95,0%</i>	<i>Upper 95,0%</i>
-69,61138317	10,6484202	-69,61138317	10,6484202
0,722784096	1,906845534	0,722784096	1,906845534

Συσχέτιση παλινδρόμηση

Παράδειγμα

Από τα αποτελέσματα διαπιστώνουμε ότι η ευθεία της παλινδρόμησης είναι:

$$\hat{Y} = -29.48 + 1.31X$$

Για να ελέγξουμε αν η παλινδρόμηση έχει καλή προσαρμογή (είναι στατιστικά σημαντική) θα εξετάσουμε την τιμή p για τον έλεγχο:

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

Η p τιμή για αυτόν τον έλεγχο υπάρχει στην γραμμή αποτελεσμάτων για το X .

Διαπιστώνουμε ότι $p = 0.001 < 0.01 = \alpha$

συνεπώς **απορρίπτουμε** την μηδενική υπόθεση.

Είμαστε 99% βέβαιοι ότι η παλινδρόμηση είναι **στατιστικά σημαντική**.

Συσχέτιση παλινδρόμηση

Παράδειγμα

Από τα αποτελέσματα διαπιστώνουμε ότι υπάρχει ισχυρή γραμμική συσχέτιση των δυο μεταβλητών αφού είναι $r = 0.875$.


Στη συνέχεια:

- Επιλέγεται η διαδοχή εντολών


Data > Data Analysis > Regression > OK

- Στο παράθυρο που ανοίγει στο πεδίο **Input Y Range** σημειώνουμε E2:E12, στο πεδίο **Input X Range** σημειώνουμε F2:F12, επιλέγουμε το **Labels**, το **Confidence Level 95%** και **OK**. Τα αποτελέσματα τα παραθέτουμε στις επόμενες δυο διαφάνειες.

Μοντέλο Πολλαπλής Γραμμικής Παλινδρόμησης



Δυο οποιαδήποτε σημεία (Α και Β), ή ο σταθερός όρος και η κλίση (β_0 και β_1), ορίζουν μια γραμμή σε επιφάνεια δυο διαστάσεων.




Τρία οποιαδήποτε σημεία (Α, Β και Γ), ή ο σταθερός όρος και οι συντελεστές των x_1 και x_2 (β_0 , β_1 , και β_2), ορίζουν ένα επίπεδο σε μια επιφάνεια τριών διαστάσεων.

Μοντέλο Πολλαπλής Γραμμικής Παλινδρόμησης

Το **μοντέλο παλινδρόμησης του πληθυσμού** μιας εξαρτημένης μεταβλητής Y , σε ένα σύνολο k ανεξάρτητων μεταβλητών, $X_1, X_2, \dots, X_k$ δίνεται από τη σχέση:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$


όπου β_0 είναι ο σταθερός όρος επιπέδου της παλινδρόμησης και κάθε β_i , $i = 1, 2, \dots, k$ είναι η κλίση του επιπέδου της παλινδρόμησης ως προς το X_i .




Υποθέσεις μοντέλου παλινδρόμησης:

1. $\varepsilon \sim N(0, \sigma^2)$, ανεξάρτητα από τα άλλα σφάλματα.
2. Οι μεταβλητές X_i είναι ασυσχέτιστες με τον όρο των σφαλμάτων.

Μοντέλο Πολλαπλής Γραμμικής Παλινδρόμησης



Στην **απλή γραμμική παλινδρόμηση**, οι εκτιμητές ελαχιστοποιούν το άθροισμα των τετραγώνων των σφαλμάτων από την εκτιμώμενη **γραμμή παλινδρόμησης**.



Στην **πολλαπλή γραμμική παλινδρόμηση**, οι εκτιμητές ελαχιστοποιούν το άθροισμα των τετραγώνων από το εκτιμώμενο **επίπεδο παλινδρόμησης**.

Μοντέλο Πολλαπλής Γραμμικής Παλινδρόμησης

Η εκτιμώμενη σχέση παλινδρόμησης είναι:

$$\hat{Y} = b_0 + b_1X_1 + b_2X_2 + \cdots + b_kX_k$$

όπου $\hat{Y}$ είναι η προβλεπόμενη τιμή της Y , η τιμή που βρίσκεται πάνω στην εκτιμώμενη επιφάνεια της παλινδρόμησης.

Οι όροι b_i , για $i = 0, 1, \dots, k$ είναι οι εκτιμητές των πληθυσμιακών παραμέτρων της παλινδρόμησης β_i .

Οι πραγματικές, παρατηρούμενες τιμές της Y είναι οι προβλεπόμενες τιμές στις οποίες προσθέτουμε ένα σφάλμα:

$$y_j = b_0 + b_1x_{1j} + b_2x_{2j} + \cdots + b_kx_{kj} + e, \quad j = 1, \dots, n.$$

Μοντέλο Πολλαπλής Γραμμικής Παλινδρόμησης

Παράδειγμα

Προκειμένου να προβλεφθεί η τιμή πώλησης σπιτιών σε μια περιοχή επιλέγεται τυχαίο δείγμα 10 σπιτιών που πωλήθηκαν ένα συγκεκριμένο μήνα.

Καταγράφεται η τιμή πώλησης (Y) σε εκατομμύρια ευρώ, το μέγεθος του σπιτιού σε εκατοντάδες τετραγωνικά μέτρα (X_1) και το ετήσιο ποσό φόρου (ΕΝΦΙΑ) σε χιλιάδες ευρώ (X_2).

Τα ποσά δίνονται στον ακόλουθο πίνακα:

Y : 0.65, 1.11, 0.92, 0.85, 0.63, 0.75, 0.84, 0.91, 1.01, 0.54

X_1 : 2.2, 3.8, 3.2, 3, 2.6, 2.7, 2.9, 3, 3.9, 1.9

X_2 : 14.7, 21.5, 16.4, 14.9, 12.1, 11.8, 12.6, 13, 17.3, 10.4

Μοντέλο Πολλαπλής Γραμμικής Παλινδρόμησης

Παράδειγμα

- Υπολογίστε την εκτιμώμενη σχέση παλινδρόμησης.
- Ελέγξτε αν είναι στατιστικά σημαντική η παλινδρόμηση σε $\alpha = 1\%$.

Μοντέλο Πολλαπλής Γραμμικής Παλινδρόμησης

Παράδειγμα

- Αφού ανοίξουμε το Excel εισάγουμε τις τιμές σε τρεις στήλες με ονομασίες Y, X1 και X2 αντίστοιχα.
- Στη συνέχεια επιλέγεται η διαδοχή εντολών

Data > Data Analysis > Regression > OK.

- Στο παράθυρο που ανοίγει στο πεδίο **Input Y Range** σημειώνουμε B2:B12, στο πεδίο **Input X Range** σημειώνουμε C2:D12, επιλέγουμε το **Labels**, το **Confidence Level 95%** και **OK**.
- Τα αποτελέσματα τα παραθέτουμε στις επόμενες δυο διαφάνειες.

Μοντέλο Πολλαπλής Γραμμικής Παλινδρόμησης

Παράδειγμα

SUMMARY OUTPUT					
<i>Regression Statistics</i>					
Multiple R	0,959786614				
R Square	0,921190344				
Adjusted R Square	0,898673299				
Standard Error	0,056931678				
Observations	10				
ANOVA					
	<i>df</i>	<i>SS</i>	<i>MS</i>	<i>F</i>	<i>Significance F</i>
Regression	2	0,265201488	0,132600744	40,91080159	0,000137413
Residual	7	0,022688512	0,003241216		
Total	9	0,28789			

Μοντέλο Πολλαπλής Γραμμικής Παλινδρόμησης

Παράδειγμα

	<i>Coefficients</i>	<i>Standard Error</i>	<i>t Stat</i>	<i>P-value</i>
Intercept	0,004705503	0,092838772	0,05068468	0,960992749
X1	0,233016165	0,050574883	4,607349555	0,002462677
X2	0,009390967	0,009688139	0,969326199	0,364674122

<i>Lower 95%</i>	<i>Upper 95%</i>	<i>Lower 95,0%</i>	<i>Upper 95,0%</i>
-0,214823309	0,224234316	-0,214823309	0,224234316
0,11342557	0,352606761	0,11342557	0,352606761
-0,013517842	0,032299776	-0,013517842	0,032299776

Μοντέλο Πολλαπλής Γραμμικής Παλινδρόμησης


Παράδειγμα

Από τα αποτελέσματα διαπιστώνουμε ότι η σχέση παλινδρόμησης είναι:

$$\hat{Y} = 0.0047 + 0.233X_1 + 0.00939X_2$$

Έλεγχος Υπόθεσης

Παράδειγμα



Συνολική Απόκλιση = Απόκλιση παλινδρόμησης + Απόκλιση σφάλματος
 $SST = SSR + SSE$

Έλεγχος Υπόθεσης

Παράδειγμα

Ο στατιστικός έλεγχος για την ύπαρξη γραμμικής σχέσης μεταξύ της και ορισμένων ή όλων των ανεξάρτητων μεταβλητών $X_1, X_2, \dots, X_k$ έχει τις υποθέσεις:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$$

H_1 : Δεν είναι όλα τα β_i ($i = 1, 2, \dots, k$) ίσα με το 0

Πηγή Μεταβλητότητας	Άθροισμα Τετραγώνων	Βαθμοί Ελευθερίας	Μέσα Τετράγωνα	F
Παλινδρόμηση	SSR	k	$MSR = \frac{SSR}{k}$	$F = \frac{MSR}{MSE}$
Σφάλμα	SSE	$n - (k + 1)$	$MSE = \frac{SSE}{n - (k + 1)}$	
Σύνολο	SST	$n - 1$	$MST = \frac{SST}{n - 1}$	

Έλεγχος Υπόθεσης

Παράδειγμα

Για να ελέγξουμε αν η παλινδρόμηση είναι στατιστικά σημαντική θα εξετάσουμε την τιμή p για τον έλεγχο:


$$H_0: \beta_1 = \beta_2 = 0$$

$$H_1: \{ \text{Δεν ισχύει η } H_0 \}$$

Διαπιστώνουμε ότι $p = 0.000 < 0.01 = \alpha$ συνεπώς **απορρίπτουμε** την μηδενική υπόθεση και καταλήγουμε ότι **η παλινδρόμηση είναι στατιστικά σημαντική.**

Συμπερασματολογία για το μοντέλο

Παράδειγμα



Ο πολλαπλός συντελεστής προσδιορισμού R^2 μετρά το ποσοστό της μεταβλητότητας της εξαρτημένης μεταβλητής που εξηγείται από τον συνδυασμό των ανεξάρτητων μεταβλητών στο μοντέλο πολλαπλής παλινδρόμησης

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

Συμπερασματολογία για το μοντέλο

Παράδειγμα

Το R^2 έχει ένα σοβαρό μειονέκτημα: το R^2 **αυξάνεται όταν προστίθενται επιπλέον επεξηγηματικές μεταβλητές σε μια εξίσωση.**

Αυτό μπορεί να οδηγήσει σε εκφυλιστικές τακτικές όπου προσθέτονται μεταβλητές σε μια εξίσωση, μερικές από τις οποίες δεν έχουν εννοιολογική σχέση με την εξαρτημένη μεταβλητή, απλώς για να αυξηθεί η τιμή του R^2 .

Για να μην προσθέτουμε επιπλέον μεταβλητές που δεν είναι χρήσιμες, χρησιμοποιούμε το προσαρμοσμένο R^2 που δεν έχει το μειονέκτημα του R^2 .

Συμπερασματολογία για το μοντέλο

Παράδειγμα


Το **προσαρμοσμένο R^2** είναι ένα μέτρο που χρησιμοποιείται πρωτίστως για την παρακολούθηση του κατά πόσο οι επιπλέον επεξηγηματικές μεταβλητές πρέπει να συμπεριλαμβάνονται στην εξίσωση.

Αν και δεν έχει άμεση ερμηνεία ως **ποσοστό μεταβλητότητας που εξηγείται**, μπορεί να μειωθεί όταν προστίθενται περιττές επεξηγηματικές μεταβλητές σε μια εξίσωση.

Αν προσθέσετε μεταβλητές και το **προσαρμοσμένο R^2** μειωθεί, οι επιπλέον μεταβλητές πιθανώς θα πρέπει να παραλειφθούν.

Συμπερασματολογία για το μοντέλο

Παράδειγμα



Ο προσαρμοσμένος πολλαπλός συντελεστής προσδιορισμού, δίνεται από τον τύπο:

$$\bar{R}^2 = 1 - \frac{\frac{SSE}{n - (k + 1)}}{\frac{SST}{n - 1}}$$

R square = 92.1%

Adjusted R square = 89.9%

Συμπερασματολογία για το μοντέλο

Έλεγχοι υπόθεσης για τις παραμέτρους ξεχωριστά:

$$(1) \quad H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

$$(2) \quad H_0: \beta_2 = 0$$

$$H_1: \beta_2 \neq 0$$

$$\vdots$$

$$(1) \quad H_0: \beta_k = 0$$

$$H_1: \beta_k \neq 0$$

Προσοχή: Ο κάθε έλεγχος εξετάζει αν είναι στατιστικά σημαντική η προσθήκη της παραμέτρου στο πρότυπο που περιλαμβάνει όλες τις υπόλοιπες

Συμπερασματολογία για το μοντέλο

Παράδειγμα


Για να ελέγξουμε αν είναι στατιστικά σημαντική η προσθήκη της μεταβλητής X_1 στο πρότυπο που περιλαμβάνει ήδη την X_2 και τον σταθερό όρο έχουμε τις υποθέσεις:

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

Από τα αποτελέσματα διαπιστώνουμε ότι $p = 0.002 < 0.01 = \alpha$
συνεπώς απορρίπτουμε την H_0

δηλαδή είναι στατιστικά σημαντική η προσθήκη της μεταβλητής X_1 στο πρότυπο που περιλαμβάνει ήδη την X_2 και τον σταθερό όρο.



Ποσοτικές Μέθοδοι στην Διοίκηση Τουρισμού (ΔΙΤ 10)

ΤΕΛΟΣ ΠΑΡΟΥΣΙΑΣΗΣ